
Modelos De Difusión Probabilística Condicionada Para La Reconstrucción De Imágenes Galácticas



The logo consists of the lowercase letters "unir" in a bold, black, sans-serif font. The letter "i" has a vertical bar extending upwards from its dot.

UNIVERSIDAD
INTERNACIONAL
DE LA RIOJA

Trabajo de Fin de Máster

Ander Dorado Bolé

Universidad Internacional de la Rioja

Septiembre 2024

Modelos De Difusión Probabilística Condicionada Para La Reconstrucción De Imágenes Galácticas

Máster Universitario en Inteligencia Artificial

Universidad Internacional de la Rioja

Septiembre 2024

Copyright © Ander Dorado Bolé

*A mi familia,
mi viriditas*

One man's noise is another man's signal

Agradecimientos

Este trabajo no hubiera sido posible sin la colaboración de Jenaro Sánchez Monzón, responsable de la creación del Dataset, durante el desarrollo de su tesis, sobre el cual se basa esta investigación. Por ello, quiero agradecer profundamente su contribución, que ha sido esencial para el desarrollo de este proyecto.

Como dijo Isaac Newton: “*Si he logrado ver más lejos, ha sido porque he subido a hombros de gigantes.*” En este sentido, agradezco especialmente a Roberto Baena y Alejandro Cervantes por su disponibilidad, paciencia y consejos, más que necesarios para completar este trabajo a tiempo y con éxito.

Resumen

La astronomía depende en gran medida de las imágenes obtenidas a través de telescopios. Las imágenes de altos tiempos de exposición, determinantes para observar objetos débiles y distantes con mayor definición, son costosas de obtener y, por lo tanto, menos abundantes. Y las imágenes con bajos tiempos de exposición suelen requerir de técnicas para quitar el ruido durante la fase de post-procesado y así poder extraer el máximo de la información disponible en cada imagen.

Las técnicas de Deep Learning, como UNet, han mejorado el procesamiento de imágenes astronómicas, pero muestran limitaciones perservando la diversidad y complejidad de estructuras astronómicas, tendiendo a suavizar excesivamente los detalles. Esto compromete el realismo y la extracción de datos de las imágenes generadas. Aunque los modelos de difusión probabilística (DDPM) se han aplicado en radioastronomía, existe una brecha en su uso para la reconstrucción de imágenes astronómicas obtenidas mediante instrumentos ópticos.

Este estudio compara el rendimiento de modelos *DDPM* y *Residual Attention UNet* en la reconstrucción de imágenes galácticas de bajo SNR. Los resultados revelan la superioridad de los modelos de difusión, según una nueva métrica propuesta. Se observó una correlación positiva entre pasos de difusión y rendimiento, requiriendo *DDPM* más datos que *UNet*. Se identificaron limitaciones en métricas existentes para evaluar similitud en imágenes ruidosas. Como respuesta a esto, se propone el *Mean Square Error* de la transformada de *Fourier* como métrica complementaria y un método para cuantificar la incertidumbre en las predicciones.

Los resultados indican que los modelos de difusión son eficaces en la reconstrucción de imágenes astronómicas, generando resultados más realistas y densos en información que los basados en *UNet*. La naturaleza estocástica de los DDPM permite obtener estadísticos más relevantes en comparación con modelos deterministas. Estas capacidades podrían influir significativamente en las predicciones astronómicas futuras.

Abstract

Astronomy heavily relies on images obtained through telescopes. High exposure time images, crucial for observing faint and distant objects with greater definition, are costly to obtain and therefore less abundant. Images with low exposure times often require noise reduction techniques during the post-processing phase to extract the maximum information available in each image.

Deep Learning techniques, such as UNet, have improved the processing of astronomical images, but show limitations in preserving the diversity and complexity of astronomical structures, tending to excessively smooth details. This compromises the realism and data extraction from generated images. Although probabilistic diffusion models (DDPM) have been applied in radio astronomy, there is a gap in their use for reconstructing astronomical images obtained through optical instruments.

This study compares the performance of *DDPM* and *Residual Attention UNet* models in reconstructing low SNR galactic images. Results reveal the superiority of diffusion models, according to a newly proposed metric. A positive correlation was observed between diffusion steps and performance, with *DDPM* requiring more data than *UNet*. Limitations were identified in existing metrics for evaluating similarity in noisy images. In response, the *Mean Square Error* of the *Fourier* transform is proposed as a complementary metric, along with a method to quantify uncertainty in predictions.

The results indicate that diffusion models are effective in reconstructing astronomical images, generating more realistic and information-dense results than those based on UNet. The stochastic nature of DDPM allows for obtaining more relevant statistics compared to deterministic models. These capabilities could significantly influence future astronomical predictions.

Índice

Agradecimientos	IX
Resumen	XI
Abstract	XIII
1. Introducción	1
1.1. Contexto y Motivación	1
1.2. Problema de Investigación	2
1.3. Contribuciones del Estudio	2
2. Marco Teórico	5
2.1. Redes Neuronales Convolucionales (CNNs)	5
2.1.1. Introducción	5
2.1.2. Estructura y Funcionamiento de las CNNs	6
2.1.3. Entrenamiento de las CNNs	7
2.2. Redes UNet	7
2.2.1. Introducción	7
2.2.2. <i>Residual Attention UNet</i>	9
2.3. Modelos de Difusión	10
2.3.1. Introducción	10
2.3.2. Encoder (<i>forward process</i>)	12
2.3.3. Programadores de Ruido (<i>Noise Schedulers</i>)	12
2.3.4. Difusión Condicionada	15
2.3.5. Implementación	15
2.3.6. Mejorando la Velocidad de Generación	16
2.4. Métricas clásicas para Evaluar la Reconstrucción de Imágenes Astronómicas	18
2.4.1. Mean Absolute Error (MAE)	18
2.4.2. Mean Squared Error (MSE)	18
2.4.3. Structural Similarity Index (SSIM)	19
2.4.4. Peak Signal-to-Noise Ratio (PSNR)	19

2.5. Estadísticos Relevantes para Medir la Similitud	19
2.5.1. Entropía	19
2.5.2. Contornos Galácticos	20
3. Estado del Arte	23
3.1. Modelos de Difusión	23
3.1.1. Innovaciones en Arquitecturas y Entrenamiento	23
3.1.2. Image Denoising mediante Guiado	24
3.2. Reconstrucción de Imágenes Astronómicas	24
3.2.1. Métodos Basados en Deep Learning	25
3.2.2. Modelos de Difusión en Astronomía	25
3.3. Métricas Cuantitativas Especializadas para Modelos de Difusión	26
3.3.1. Inception Score (IS)	26
3.3.2. Fréchet Inception Distance (FID)	27
3.4. Limitaciones de las métricas actuales	27
3.5. Conclusiones del estado del arte	27
4. Objetivos	29
5. Metodología	31
5.1. Especificaciones Técnicas	31
5.2. Dataset	32
5.2.1. Descripción	32
5.2.2. Preprocesamiento	34
5.3. Exploración de métricas	39
5.3.1. Elementos de prueba	39
5.3.2. Niveles de ruido	41
5.3.3. Métricas evaluadas	41
5.3.4. Procedimiento experimental	42
5.4. Configuración Experimental	43
5.4.1. Impacto del Número de Diffusion Steps	46
5.4.2. Impacto de la cantidad de datos	46
5.4.3. Impacto del número de parámetros de la red	47
5.4.4. Impacto de la Agregación	47
6. Resultados	49
6.1. Exploración de Métricas	49
6.2. Experimentación de Modelos	51
6.2.1. Impacto del Número de Pasos de Difusión	52
6.2.2. Impacto del Porcentaje de Datos	54
6.2.3. Impacto del Número de Parámetros de la Red	56
6.2.4. Impacto de los Métodos de Agregación	58

6.2.5. Evaluación de la Incertidumbre	60
6.2.6. Análisis cualitativo	62
7. Conclusiones	71
7.1. Resumen de Resultados	71
7.2. Limitaciones del Estudio	72
7.3. Posibles Ampliaciones y Trabajos Futuros	72
7.4. Conclusiones Finales	73
Bibliografía	75
Apéndice A: Disponibilidad de Datos y Código	79
Apéndice B: Figuras Suplementarias	81
7.5. Grid de comparación de similitud de métricas	81
7.6. Muestras en escala logarítmica	88
7.7. Muestras en escala raíz cuadrada	98
7.8. Muestras en escala lineal	108
Apéndice C: Tablas Suplementarias	119
7.9. Impacto del Número de Diffusion Steps	119
7.10. Impacto del Porcentaje de Datos	120
7.11. Impacto del número de parámetros	122
7.12. Agregación	123
7.12.1. Impacto del número de pasos de difusión	123
7.12.2. Impacto del porcentaje de datos	129
7.12.3. Impacto del número de parámetros de la red	135

Índice de figuras

2.1. Flujo de datos en una red neuronal convolucional (CNN). El modelo obtiene una probabilidad sobre 10 posibles resultados, dado un dígito escrito a mano.	5
2.2. Arquitectura de la UNet básica. La figura muestra el camino de contracción (encoder) y el camino de expansión (decoder), junto con las conexiones de salto (skip connections) entre ellos.	8
2.3. Diagrama básico de la arquitectura de una red UNet con mecanismos de atención	9
2.4. Secuencia de elementos dentro de un bloque de atención dentro de una red UNet	10
2.5. Diagrama básico de una conexión residual	10
2.6. Visualización del proceso de difusión en modelos de difusión. De izquierda a derecha, se muestra la transformación gradual de una imagen de entrada X a través de estados latentes intermedios (Z_0, Z_1, Z_2, \dots) hasta llegar a ruido puro Z_T . La flecha azul superior representa el proceso de codificación (<i>forward</i>), que añade ruido progresivamente. La flecha negra inferior ilustra el flujo de decodificación (<i>reverse</i>) aprendido, que elimina el ruido para regenerar la imagen. Este último proceso se utiliza para generar nuevas imágenes partiendo de ruido puro.	11
2.7. Forward process. a) Se considera datos unidimensionales x con $T = 100$ variables latentes z_1, \dots, z_{100} y $\beta = 0,03$ en todos los pasos. Se inician tres valores de x (gris, cian y naranja) (fila superior). Estos se propagan a través de z_1, \dots, z_{100} . En cada paso, la variable se actualiza atenuando su valor por $\sqrt{1 - \beta}$ y añadiendo ruido con media cero y varianza β . En consecuencia, los tres ejemplos se propagan ruidosamente a través de las variables con una tendencia hacia cero. b) Las probabilidades condicionales $q(z_1 x)$ y $q(z_t z_{t-1})$ son distribuciones normales con una media centrada a 0 y una varianza fija β_t	13

2.8. Muestras latentes de los esquemas cosine (arriba) y linear (abajo) respectivamente. El esquema linear utiliza $\beta_{\text{start}} = 0,0001$ y $\beta_{\text{end}} = 0,02$	13
2.9. UNet utilizado en modelos de difusión para imágenes. La red predice el ruido añadido a la imagen, utilizando un codificador y un decodificador con conexiones residuales y atención global periódica. Una sola red se emplea para todos los pasos de tiempo, con un <i>embedding</i> temporal sinusoidal que se pasa a través de una red neuronal y se añade a cada etapa del UNet. Fuente de la imagen: Prince (2023)	17
2.10. Visualización del <i>embedding</i> temporal sinusoidal	18
5.1. Panel de control de Weights & Biases mostrando el seguimiento de múltiples métricas durante el entrenamiento de los modelos	32
5.2. Imágenes del Hyper Suprime-Cam (HSC) y tabla resumen de las observaciones.	33
5.3. Histograma de frecuencias de los valores PSNR de las muestras, mostrando la división en el umbral de $\text{PSNR} = 30$	36
5.4. Muestra de datos en escala lineal - WIDE	37
5.5. Muestra de datos en escala lineal - DUD	37
5.6. Muestra de datos en escala raíz cuadrada - WIDE	38
5.7. Muestra de datos en escala raíz cuadrada - DUD	38
5.8. Muestra de datos en escala logarítmica - WIDE	38
5.9. Muestra de datos en escala logarítmica - DUD	39
5.10. Muestras para el caso de ruido puro con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2	40
5.11. Muestras para el caso cuadrado con ruido de fondo con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2	40
5.12. Muestras para el caso cuadrado con ruido en toda la imagen con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2	40
5.13. Muestras para el caso triangulo con ruido de fondo con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2	40
5.14. Muestras para el caso triangulo con ruido en toda la imagen con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2	41
5.15. Muestras para el caso galaxia elíptica con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2	41
5.16. Muestras para el caso galaxia circular con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2	41

5.17. Diagrama de la arquitectura <i>Residual Attention UNet</i> utilizado como <i>UNet</i> base	44
5.18. Representación esquemática de un paso en el proceso de entrenamiento de un modelo de difusión guiado. x_0 es la imagen esperada (objetivo), z es la imagen ruidosa utilizada para el guiado. Para el paso de tiempo t , ϵ representa el ruido de entrada y x_t es la imagen calculada para el paso t generada según la ecuación mostrada. La <i>Residual Attention UNet</i> , condicionada con z , procesa x_t para estimar el ruido $\hat{\epsilon}$. El modelo se entrena minimizando el <i>loss</i> entre ϵ y $\hat{\epsilon}$ en cada paso. Este proceso se repite para cada uno de los pasos de difusión definidos.	45
5.19. Proceso de inferencia del modelo de difusión guiado. Se inicia con ruido aleatorio ϵ como imagen de entrada. En cada paso, la <i>Residual Attention UNet</i> estima el ruido presente $\hat{\epsilon}$ en la imagen, condicionada por la imagen de referencia z . La imagen resultante de cada paso se utiliza como entrada para el siguiente, concatenándola con z . Este proceso se repite durante el número predefinido de pasos de difusión, reduciendo gradualmente el ruido hasta obtener la imagen final reconstruida.	45
6.1. Matrices de similitud para diversas métricas aplicadas a la simulación de una galaxia elíptica	50
6.2. Evolución del <i>SSIM</i> durante el entrenamiento para la escala de datos logarítmica con el conjunto de datos completo. Se muestran las curvas de entrenamiento y validación para los modelos <i>UNet</i> y <i>DDPM</i> , ambos con una arquitectura de 2M de parámetros. La línea rosa continua representa el <i>SSIM</i> del conjunto de entrenamiento y la discontinua del mismo color el de validación. De manera similar, la línea morada continua representa el modelo <i>DDPM</i> en el subconjunto de entrenamiento y la discontinua los resultados del subconjunto de validación.	51
6.3. Evolución de las métricas en función del número de muestras agregadas en escala lineal. Se observa una mejora en la mayoría de las métricas, incluyendo <i>PSNR</i> y <i>SSIM</i> , a medida que aumenta el número de muestras. La métrica <i>FFT MSE</i> muestra una mejora en esta escala.	59
6.4. Evolución de las métricas en función del número de muestras agregadas en escala logarítmica. Se observa una mejora en la mayoría de las métricas con el aumento de muestras agregadas. La métrica <i>FFT MSE</i> muestra un empeoramiento.	59

6.5. Evolución de las métricas en función del número de muestras agregadas en escala de raíz cuadrada. Se observan patrones similares a los de la escala logarítmica, con una mejora en la mayoría de las métricas, pero un empeoramiento en la <i>FFT MSE</i>	60
6.6. Representación del <i>Input</i> , el <i>True</i> , la predicción <i>DDPM</i> y las probabilidades con un umbral de 1	60
6.7. Representación del <i>Input</i> , el <i>True</i> , la predicción <i>DDPM</i> y las probabilidades con un umbral de 0.75	61
6.8. Representación del <i>Input</i> , el <i>True</i> , la predicción <i>DDPM</i> y las probabilidades con un umbral de 0.5	61
6.9. Representación del <i>Input</i> , el <i>True</i> , la predicción <i>DDPM</i> y las probabilidades con un umbral bajo de 0.1	61
6.10. Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	62
6.11. Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	63
6.12. Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	63
6.13. Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	64
6.14. Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	64
6.15. Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	65
6.16. Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	65
6.17. Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	66
6.18. Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	66
6.19. Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	67

6.20. Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	67
6.21. Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	68
7.1. Visualizaciones de las matrices de similitud de varias métricas para ruido puro	81
7.2. Visualizaciones de las matrices de similitud de varias métricas para cuadrado con ruido de fondo	82
7.3. Visualizaciones de las matrices de similitud de varias métricas para cuadrado con ruido en toda la imagen	83
7.4. Visualizaciones de las matrices de similitud de varias métricas para triangulo con ruido de fondo	84
7.5. Visualizaciones de las matrices de similitud de varias métricas para triangulo con ruido en toda la imagen	85
7.6. Visualizaciones de las matrices de similitud de varias métricas para simulación de una galaxia elíptica	86
7.7. Visualizaciones de las matrices de similitud de varias métricas para simulación de una galaxia circular	87
7.8. Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	88
7.9. Muestra 2: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	88
7.10. Muestra 3: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	89
7.11. Muestra 4: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	89
7.12. Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	90
7.13. Muestra 6: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	90
7.14. Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	91

7.15. Muestra 8: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	91
7.16. Muestra 9: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	92
7.17. Muestra 10: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	92
7.18. Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	93
7.19. Muestra 12: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	93
7.20. Muestra 13: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	94
7.21. Muestra 14: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	94
7.22. Muestra 15: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	95
7.23. Muestra 16: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	95
7.24. Muestra 17: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	96
7.25. Muestra 18: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	96
7.26. Muestra 19: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	97
7.27. Muestra 20: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.	97
7.28. Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	98

7.29. Muestra 2: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	98
7.30. Muestra 3: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	99
7.31. Muestra 4: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	99
7.32. Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	100
7.33. Muestra 6: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	100
7.34. Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	101
7.35. Muestra 8: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	101
7.36. Muestra 9: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	102
7.37. Muestra 10: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	102
7.38. Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	103
7.39. Muestra 12: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	103
7.40. Muestra 13: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	104
7.41. Muestra 14: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	104
7.42. Muestra 15: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	105

7.43. Muestra 16: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	105
7.44. Muestra 17: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	106
7.45. Muestra 18: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	106
7.46. Muestra 19: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	107
7.47. Muestra 20: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.	107
7.48. Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	108
7.49. Muestra 2: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	108
7.50. Muestra 3: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	109
7.51. Muestra 4: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	109
7.52. Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	110
7.53. Muestra 6: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	110
7.54. Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	111
7.55. Muestra 8: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	111
7.56. Muestra 9: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.	112

- 7.57. Muestra 10: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 112
- 7.58. Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 113
- 7.59. Muestra 12: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 113
- 7.60. Muestra 13: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 114
- 7.61. Muestra 14: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 114
- 7.62. Muestra 15: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 115
- 7.63. Muestra 16: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 115
- 7.64. Muestra 17: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 116
- 7.65. Muestra 18: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 116
- 7.66. Muestra 19: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 117
- 7.67. Muestra 20: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal . . . 117

Índice de Tablas

6.1.	Comparación de métricas para diferentes pasos de difusión. Escala de datos: Log Scale. Conjunto de datos: Clean 30.	52
6.2.	Comparación de métricas para diferentes pasos de difusión. Escala de datos: Log Scale. Conjunto de datos: Full.	52
6.3.	Comparación de métricas para diferentes pasos de difusión. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.	52
6.4.	Comparación de métricas para diferentes pasos de difusión. Escala de datos: Sqrt Scale. Conjunto de datos: Full.	53
6.5.	Comparación de métricas para diferentes pasos de difusión. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.	53
6.6.	Comparación de métricas para diferentes pasos de difusión. Escala de datos: Linear Scale. Conjunto de datos: Full.	53
6.7.	Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Log Scale. Conjunto de datos: Clean 30.	54
6.8.	Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Log Scale. Conjunto de datos: Full.	54
6.9.	Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.	55
6.10.	Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Sqrt Scale. Conjunto de datos: Full.	55
6.11.	Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.	55
6.12.	Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Linear Scale. Conjunto de datos: Full.	56
6.13.	Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Clean 30.	57
6.14.	Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Full.	57

6.15. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.	57
6.16. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Full.	57
6.17. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.	57
6.18. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Linear Scale. Conjunto de datos: Full.	57
 7.1. Comparación de métricas para diferentes pasos de difusión. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.	119
7.2. Comparación de métricas para diferentes pasos de difusión. Escala de datos: Linear Scale. Conjunto de datos: Full.	119
7.3. Comparación de métricas para diferentes pasos de difusión. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.	119
7.4. Comparación de métricas para diferentes pasos de difusión. Escala de datos: Sqrt Scale. Conjunto de datos: Full.	119
7.5. Comparación de métricas para diferentes pasos de difusión. Escala de datos: Log Scale. Conjunto de datos: Clean 30.	120
7.6. Comparación de métricas para diferentes pasos de difusión. Escala de datos: Log Scale. Conjunto de datos: Full.	120
7.7. Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Log Scale. Conjunto de datos: Clean 30.	120
7.8. Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Log Scale. Conjunto de datos: Full.	120
7.9. Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.	120
7.10. Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Sqrt Scale. Conjunto de datos: Full.	121
7.11. Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.	121
7.12. Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Linear Scale. Conjunto de datos: Full.	121
7.13. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Clean 30.	122

7.14. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Full.	122
7.15. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.	122
7.16. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Full.	122
7.17. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.	122
7.18. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Linear Scale. Conjunto de datos: Full.	123
7.19. Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.	123
7.20. Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Linear Scale. Conjunto de datos: Full.	124
7.21. Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.	125
7.22. Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Sqrt Scale. Conjunto de datos: Full.	126
7.23. Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Log Scale. Conjunto de datos: Clean 30.	127
7.24. Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Log Scale. Conjunto de datos: Full.	128
7.25. Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Log Scale. Conjunto de datos: Clean 30.	129
7.26. Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Log Scale. Conjunto de datos: Full.	130
7.27. Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.	131
7.28. Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Sqrt Scale. Conjunto de datos: Full.	132

7.29. Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.	133
7.30. Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Linear Scale. Conjunto de datos: Full.	134
7.31. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Clean 30.	135
7.32. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Full.	136
7.33. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.	136
7.34. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Full.	137
7.35. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.	137
7.36. Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Linear Scale. Conjunto de datos: Full.	138

Capítulo 1

Introducción

1.1. Contexto y Motivación

La astronomía, como ciencia observacional, depende de la calidad de los datos obtenidos mediante telescopios y otros instrumentos. Las imágenes astronómicas son fundamentales para comprender el universo, desde la formación y evolución de galaxias hasta la detección de exoplanetas y el estudio de la materia oscura. Sin embargo, estas imágenes se ven afectadas por factores que degradan su calidad, como el ruido instrumental, las limitaciones atmosféricas y los largos tiempos de exposición necesarios para captar objetos tenues.

Los grandes *surveys* astronómicos actuales generan volúmenes de datos diversos en calidad y características. En este contexto, el desarrollo de métodos para analizar imágenes de variada resolución se ha convertido en un área de interés para la comunidad científica. Estas técnicas permiten ampliar el rango de datos utilizables en investigación, incluyendo aquellos que anteriormente podrían haberse considerado de calidad insuficiente para ciertos análisis.

En este contexto, las técnicas de procesamiento de imágenes, particularmente aquellas basadas en aprendizaje profundo, están emergiendo como herramientas prometedoras para el análisis de datos astronómicos. Los modelos generativos de difusión, que han mostrado resultados notables en la reconstrucción de imágenes en diversos campos, podrían tener aplicaciones significativas en astronomía. Su implementación sugiere la posibilidad de extraer información relevante de datos que, bajo criterios tradicionales, se considerarían de calidad insuficiente para un análisis científico riguroso.

1.2. Problema de Investigación

Esta investigación se centra en la reconstrucción de imágenes galácticas con bajo *SNR*¹ para obtener equivalentes de alto *SNR*, utilizando redes generativas de difusión. Este trabajo implica varios aspectos interrelacionados:

- **Adaptación de modelos de difusión:** Aunque estos modelos han mostrado resultados prometedores en otros campos, su aplicación en imágenes astronómicas aún no se ha explorado en profundidad. Es necesario ajustar estos modelos para que puedan procesar las características propias de las imágenes galácticas, como sus estructuras multiescala y patrones de ruido particulares.
- **Evaluación de la calidad de reconstrucción:** Las métricas actuales para medir la similitud entre imágenes, como el PSNR y el SSIM, a menudo no capturan adecuadamente los aspectos más finos para el análisis astronómico en muestras donde existe ruido. Es necesario desarrollar y validar nuevas métricas que sean más relevantes para este dominio específico.
- **Preservación de información científica:** En la reconstrucción de imágenes astronómicas, es fundamental no solo mejorar la calidad visual, sino también mantener la información científicamente relevante presente en la imagen original.
- **Generalización a diversas imágenes astronómicas:** El modelo propuesto debe ser capaz de procesar eficazmente distintos tipos de imágenes galácticas.

1.3. Contribuciones del Estudio

Este estudio aporta varias contribuciones al campo del procesamiento de imágenes astronómicas y la aplicación de técnicas de aprendizaje profundo en astronomía:

- Se presenta una aplicación de modelos generativos de difusión para la reconstrucción de imágenes galácticas de bajo SNR. Este enfoque explora el potencial de estas técnicas en el contexto astronómico.
- Se proponen y evalúan métricas alternativas, como el MSE de la FFT², diseñadas para evaluar la calidad de imágenes astronómicas reconstruidas. Estas métricas buscan solucionar algunas de las limitaciones de las medidas tradicionales en el contexto del análisis astronómico.

¹Signal To Noise Ratio

²Fast Fourier Transform

- Se realiza una comparación entre los modelos *DDPM* y los modelos de *Residual Attention UNet*. Este análisis examina las capacidades de cada modelo en la reconstrucción de imágenes astronómicas.
- Se analizan la influencia de diversos parámetros en los modelos de difusión y en la arquitectura *Residual Attention UNet*. Para los modelos de difusión, se estudian factores como el número de pasos de difusión, mientras que para ambos modelos se examina el impacto del volumen de datos de entrenamiento y el tamaño de la red. Estos resultados se orientan a la optimización de futuros modelos.
- Se exploran métodos para estimar la incertidumbre a nivel de píxel, proporcionando herramientas adicionales para el análisis astronómico.
- Se analiza el rendimiento de los modelos de difusión mediante técnicas de agregación.
- Se establece una base para futuras investigaciones sobre la aplicación de modelos generativos en astronomía, identificando áreas para explotación adicional.

Estas contribuciones avanzan el estado del arte en el procesamiento de imágenes astronómicas y abren nuevas vías para extraer información científica de datos de baja calidad, con implicaciones para la realización y análisis de observaciones astronómicas.

Capítulo 2

Marco Teórico

2.1. Redes Neuronales Convolucionales (CNNs)

2.1.1. Introducción

Los datos de imágenes se representan tradicionalmente como una cuadrícula bidimensional de píxeles, ya sean imágenes monocromáticas o a color. Cada píxel corresponde a uno o múltiples valores numéricos, respectivamente. Anteriormente, este tipo de datos se procesaba “aplanando” las imágenes en vectores unidimensionales, ignorando la estructura espacial entre los píxeles. Este enfoque, aunque insatisfactorio, era necesario para alimentar los vectores resultantes a través de un Fully Connected Multilayer Perceptron.

Sin embargo, las Redes Neuronales Convolucionales (CNNs) introducidas por LeCun et al. (1989) emergieron como una solución más eficiente y efectiva para el procesamiento y análisis de imágenes. Estas redes aprovechan nuestro conocimiento previo de que los píxeles cercanos suelen estar relacionados entre sí, permitiendo construir modelos que aprenden eficazmente de los datos de imagen mientras preservan su estructura espacial.

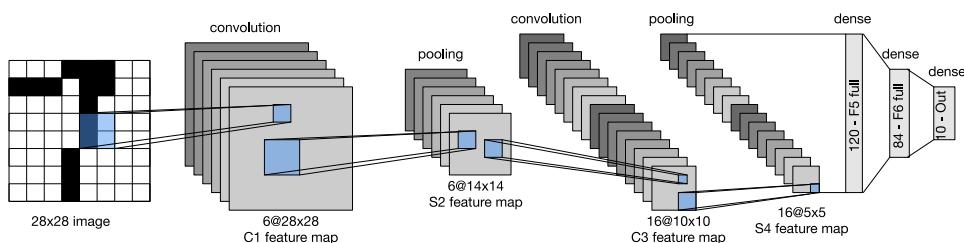


Figura 2.1: Flujo de datos en una red neuronal convolucional (CNN). El modelo obtiene una probabilidad sobre 10 posibles resultados, dado un dígito escrito a mano.

2.1.2. Estructura y Funcionamiento de las CNNs

El componente principal de las CNNs son las capas convolucionales. Estas capas aplican una operación de convolución sobre los mapas de características de entrada utilizando filtros específicos, produciendo mapas de características de salida. Esta operación se puede expresar matemáticamente como:

$$O_{i,j} = (I * F)_{i,j} = \sum_m \sum_n I_{i-m, j-n} F_{m,n}$$

Donde I representa la entrada de la capa, F el filtro convolucional, y O la salida resultante. Cada filtro contiene parámetros entrenables (pesos) que se ajustan durante el entrenamiento de la red para captar distintas características de los datos.

El tamaño de la salida depende de tres factores principales: el tamaño del filtro, el paso (*stride*) y el relleno (*padding*). El paso determina cuánto se desplaza el filtro sobre el mapa de entrada entre convoluciones, mientras que el relleno añade márgenes de ceros alrededor de la imagen para controlar el tamaño de la salida.

Tras la capa convolucional, generalmente se aplica una función de activación no lineal. Esta función introduce no linealidades en el modelo, permitiendo que la red aprenda representaciones más complejas Goodfellow et al. (2016).

Para reducir el tamaño espacial (anchura y altura) de las capas, se emplea comúnmente una capa de agrupamiento (*pooling*). Esta capa no solo reduce la dimensionalidad, sino que también disminuye la cantidad de cálculos necesarios. El *pooling* Boureau et al. (2010); Wu and Gu (2015); Scherer et al. (2010) se aplica a cada mapa de características de manera independiente, utilizando operaciones como el máximo o el promedio. Por ejemplo, en el *max-pooling*, se selecciona el valor máximo de un parche de imagen que se solapa con el filtro. Luego, el filtro se desplaza según el paso predefinido y el proceso se repite Boureau et al. (2010); Scherer et al. (2010).

Otro tipo de capa importante en las CNNs es la capa de sobremuestreo (*up-sampling*), que incrementa el tamaño espacial de la entrada (Dumoulin and Visin, 2018). Este proceso puede realizarse mediante técnicas como la interpolación por vecino más cercano, la interpolación bilineal, o la convolución transpuesta. La interpolación utiliza datos conocidos para estimar valores desconocidos. Por ejemplo, la interpolación por vecino más cercano simplemente duplica el valor del píxel más cercano en el píxel desconocido.

La convolución transpuesta, por otro lado, utiliza la matriz del kernel transpuesta y desenrollada multiplicada por la entrada vectorizada Zeiler et al. (2011). Es importante notar que la convolución transpuesta puede generar artefactos de tablero de ajedrez si no se eligen adecuadamente el tamaño del filtro y el paso (Odena et al., 2016).

2.1.3. Entrenamiento de las CNNs

El entrenamiento de una red neuronal convolucional (CNN) requiere la definición de elementos clave: la función de pérdida, el optimizador y el conjunto de datos de entrenamiento. En el aprendizaje supervisado, los conjuntos de datos se componen de pares entrada-salida, como imágenes de galaxias con bajo *Signal-to-Noise Ratio* (SNR) y sus versiones correspondientes de alto SNR.

El entrenamiento se inicia con la asignación de valores pequeños aleatorios a los pesos de la red. Se busca ajustar estos pesos para minimizar una función de pérdida calculada sobre el conjunto de entrenamiento, como el *Mean Absolute Error* (MAE) descrito en 2.4.1. Esta función depende de todos los pesos de la red.

Para hallar los pesos que minimizan la función de pérdida, se emplean algoritmos de optimización. Estos siguen el principio del descenso de gradiente, representado de forma general como:

$$w_{t+1} = w_t - \eta \nabla_w L(w_t)$$

donde w_t son los pesos en el tiempo t , η es la tasa de aprendizaje, y L es la función de pérdida. El gradiente se calcula para cada peso y se propaga hacia atrás en la red.

Durante el entrenamiento, la red desarrolla representaciones jerárquicas de las características de las imágenes de entrada. Las capas iniciales captan características básicas, mientras que las capas profundas desarrollan representaciones más elaboradas. En la reconstrucción de imágenes astronómicas, la red se adapta para transformar imágenes de bajo SNR en imágenes de alto SNR, comparables a las imágenes objetivo del conjunto de entrenamiento.

2.2. Redes UNet

2.2.1. Introducción

La arquitectura UNet es una red neuronal convolucional diseñada para tareas de segmentación de imágenes¹, introducida inicialmente para la segmentación biomédica. La UNet original, propuesta por Ronneberger et al. (2015), presenta una estructura simétrica en forma de *U*, compuesta por dos caminos: el *encoder* (camino de contracción) y el *decoder* (camino de expansión).

El *encoder* está compuesto por varias etapas de capas convolucionales. Cada etapa incluye operaciones de convolución seguidas de funciones de

¹La segmentación de imágenes es un proceso que divide una imagen en regiones o segmentos distintos, cada uno correspondiendo a diferentes objetos o partes de la imagen.

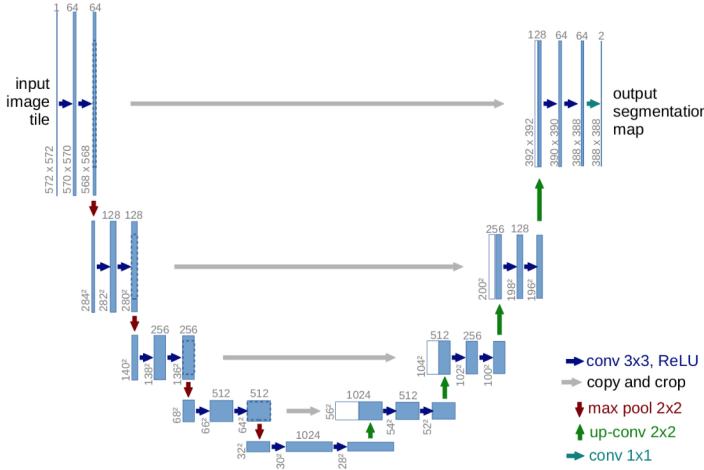


Figura 2.2: Arquitectura de la UNet básica. La figura muestra el camino de contracción (encoder) y el camino de expansión (decoder), junto con las conexiones de salto (skip connections) entre ellos.

activación ReLU y una operación de *max-pooling*. Este proceso reduce gradualmente la resolución espacial de las características mientras aumenta su profundidad. En la UNet básica, cada etapa del *encoder* duplica el número de canales de características, permitiendo a la red capturar representaciones más complejas a medida que se avanza en profundidad. Este diseño facilita la extracción de características jerárquicas, desde patrones simples en las primeras capas hasta estructuras más complejas en las capas posteriores.

El *decoder* es simétrico al *encoder* y se compone de capas deconvolucionales que aumentan la resolución espacial mientras reducen la profundidad de las características. Cada etapa del *decoder* incluye una operación de *upsampling* seguida de una convolución de 3x3, que reduce el número de canales a la mitad. Las características obtenidas se concatenan con las características correspondientes del *encoder* (*skip connections*), lo que preserva la información espacial de las etapas previas. Esta estrategia de concatenación es necesaria para mantener los detalles espaciales necesarios para una segmentación precisa. Finalmente, una capa convolucional de 1x1 se utiliza para mapear cada vector de características a la clase deseada, produciendo la segmentación final.

Aunque inicialmente se desarrolló para segmentación² de imágenes biomédicas, la arquitectura UNet se ha adaptado y utilizado en diversas tareas de *image-to-image*. Estas tareas incluyen la eliminación de ruido en imágenes, donde la UNet ayuda a limpiar imágenes ruidosas preservando los

²La segmentación de imágenes es un proceso que divide una imagen en regiones o segmentos distintos, cada uno correspondiendo a diferentes objetos o partes de la imagen.

detalles relevantes, y la reconstrucción de imágenes, en la que se rellenan partes faltantes de una imagen de manera coherente con el contexto circundante. Además, la UNet se ha aplicado en la *super-resolución* de imágenes, mejorando la calidad de las imágenes de baja resolución, y en la detección y clasificación de objetos en imágenes satelitales y médicas. Estas aplicaciones demuestran la versatilidad y eficacia de la arquitectura UNet en múltiples dominios del procesamiento de imágenes.

2.2.2. *Residual Attention UNet*

Durante los últimos años, se han desarrollado muchas variaciones de la arquitectura para mejorar su rendimiento en diferentes tareas. Una de las variaciones más destacadas es la *Residual Attention UNet* creada por Ni et al. (2019), que integra mecanismos de atención y conexiones residuales.

En la *Residual Attention UNet*, los bloques de atención se incorporan en las conexiones de salto (*skip connections*) entre el *encoder* y el *decoder*. Estos bloques de atención generan mapas de atención que ponderan las características espaciales según su relevancia para la tarea deseada. Esto se logra mediante la utilización de capas convolucionales y funciones de activación *sigmoid* para producir mapas de atención, que luego se multiplican *element-wise* con las características del *encoder* antes de la concatenación con las características del *decoder*.

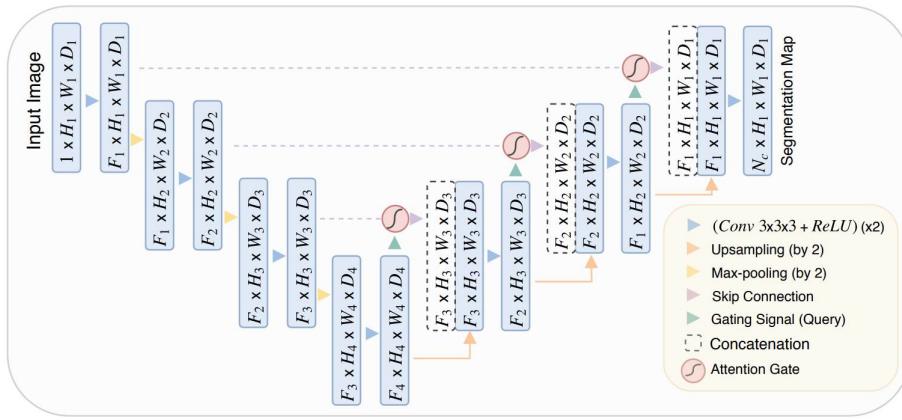


Figura 2.3: Diagrama de básico de la arquitectura de una red UNet con mecanismos de atención

Un bloque de atención típico utiliza la fórmula:

$$\text{Attention}(x, g) = \sigma(W_f([x; g])),$$

donde x son las características del *encoder*, g son las características del *decoder*, $[x; g]$ denota la concatenación de x y g , W_f son los pesos aprendidos

y σ es la función de activación *sigmoid*. Este mecanismo permite que la red se centre en las regiones de la imagen más relevantes para la segmentación.

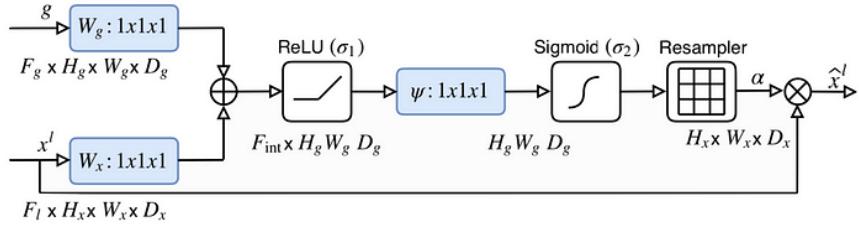


Figura 2.4: Secuencia de elementos dentro de un bloque de atención dentro de una red UNet

Además de los mecanismos de atención, las conexiones residuales (*residual connections*) se utilizan para mitigar el problema de la degradación del gradiente en redes profundas. Las conexiones residuales permiten que los gradientes fluyan directamente a través de la red durante el entrenamiento, lo que facilita la optimización y mejora la convergencia. En la *Residual Attention UNet*, estas conexiones se implementan para preservar la información de características a través de diferentes capas de la red, asegurando que los detalles importantes no se pierdan durante el proceso de aprendizaje.

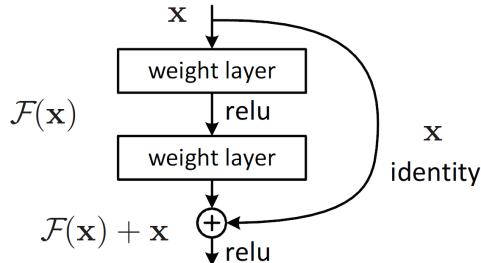


Figura 2.5: Diagrama básico de una conexión residual

2.3. Modelos de Difusión

2.3.1. Introducción

Los modelos de difusión representan una clase importante de modelos generativos en aprendizaje profundo, fundamentados en principios de procesos estocásticos y teoría de la probabilidad. Estos modelos se basan en la idea de transformar gradualmente una distribución de datos compleja en una distribución simple, y luego aprender a revertir este proceso. Formalmente, un modelo de difusión se define por dos componentes principales: un proceso de difusión hacia adelante (codificador) y un proceso de difusión

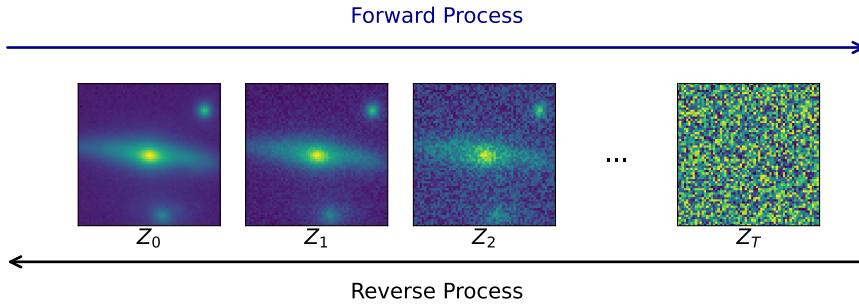


Figura 2.6: Visualización del proceso de difusión en modelos de difusión. De izquierda a derecha, se muestra la transformación gradual de una imagen de entrada X a través de estados latentes intermedios (Z_0, Z_1, Z_2, \dots) hasta llegar a ruido puro Z_T . La flecha azul superior representa el proceso de codificación (*forward*), que añade ruido progresivamente. La flecha negra inferior ilustra el flujo de decodificación (*reverse*) aprendido, que elimina el ruido para regenerar la imagen. Este último proceso se utiliza para generar nuevas imágenes partiendo de ruido puro.

inversa (decodificador). El proceso de difusión hacia adelante se define como una cadena de Markov que gradualmente añade ruido gaussiano a los datos. Sea x_0 una muestra de datos inicial, el proceso se describe como:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t\mathbf{I})$$

donde β_t es un parámetro que controla la cantidad de ruido añadido en cada paso t , y N denota una distribución normal. El proceso inverso busca reconstruir los datos originales a partir del ruido. Se modela como:

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

donde μ_θ y Σ_θ son funciones parametrizadas por una red neuronal con parámetros θ . El objetivo del entrenamiento es maximizar la verosimilitud de los datos observados bajo este modelo. Esto se logra minimizando una cota inferior de la log-verosimilitud negativa, conocida como ELBO (*Evidence Lower Bound*). En la práctica, esta optimización se realiza utilizando técnicas de estimación de gradiente estocástico, donde el gradiente del ELBO se aproxima mediante muestreo.

Una característica distintiva y de gran importancia en los modelos de difusión es su capacidad para generar muestras de alta calidad. El proceso de generación implica muestrear de la distribución de ruido final y luego aplicar iterativamente el proceso de difusión inversa:

$$\begin{aligned} z_T &\sim \mathcal{N}(0, \mathbf{I}) \\ x_{t-1} &\sim p_\theta(x_{t-1}|x_t) \quad \text{para } t = T, \dots, 1 \end{aligned}$$

2.3.2. Encoder (*forward process*)

El proceso de difusión hacia adelante, también conocido como el *forward process* o *encoder*, transforma una muestra de datos x a través de una serie de variables latentes intermedias z_1, z_2, \dots, z_T . Este proceso se define mediante una cadena de Markov que añade ruido gaussiano de manera progresiva en cada paso. Formalmente, se describe mediante las siguientes ecuaciones:

$$\begin{aligned} z_1 &= \sqrt{1 - \beta_1} \cdot x + \sqrt{\beta_1} \cdot \epsilon_1 \\ z_t &= \sqrt{1 - \beta_t} \cdot z_{t-1} + \sqrt{\beta_t} \cdot \epsilon_t \quad \forall t \in \{2, \dots, T\} \end{aligned}$$

donde ϵ_t es ruido extraído de una distribución normal estándar y $\beta_t \in [0, 1]$ son hiperparámetros que determinan la rapidez con la que se añade el ruido, conocidos como la “*noise schedulers*”. Este proceso atenúa los datos y añade ruido en cada paso, moviendo gradualmente las variables latentes hacia una distribución normal estándar.

Las distribuciones condicionales correspondientes se expresan como:

$$\begin{aligned} q(z_1|x) &= \mathcal{N}(z_1; \sqrt{1 - \beta_1}x, \beta_1 \mathbf{I}) \\ q(z_t|z_{t-1}) &= \mathcal{N}(z_t; \sqrt{1 - \beta_t}z_{t-1}, \beta_t \mathbf{I}) \quad \forall t \in \{2, \dots, T\} \end{aligned}$$

Este proceso se ilustra en la Figura 2.6, donde se muestra la propagación de datos unidimensionales x a través de 100 variables latentes z_1, \dots, z_{100} con $\beta = 0,03$ en todos los pasos. Cada paso actualiza la variable latente atenuando su valor actual y añadiendo ruido, con una tendencia hacia cero (Figura 2.7).

El *forward process* es básico en este proceso ya que, con suficientes pasos T , se eliminan todos los rastros de los datos originales, resultando en una distribución normal estándar $q(z_T|x) = \mathcal{N}(z_T; 0, \mathbf{I})$. La distribución conjunta de todas las variables latentes dado el dato de entrada x se puede expresar como:

$$q(z_{1:T}|x) = q(z_1|x) \prod_{t=2}^T q(z_t|z_{t-1})$$

Este enfoque permite modelar el complejo proceso de agregar ruido de manera controlada y es fundamental para el entrenamiento eficaz de modelos de difusión, facilitando la generación de datos de alta calidad mediante el proceso inverso aprendido.

2.3.3. Programadores de Ruido (*Noise Schedulers*)

En los modelos de difusión, los *schedulers* de ruido son fundamentales para determinar cómo se introduce el ruido gaussiano en cada paso del proceso de difusión hacia adelante. La elección del *scheduler* de ruido influye

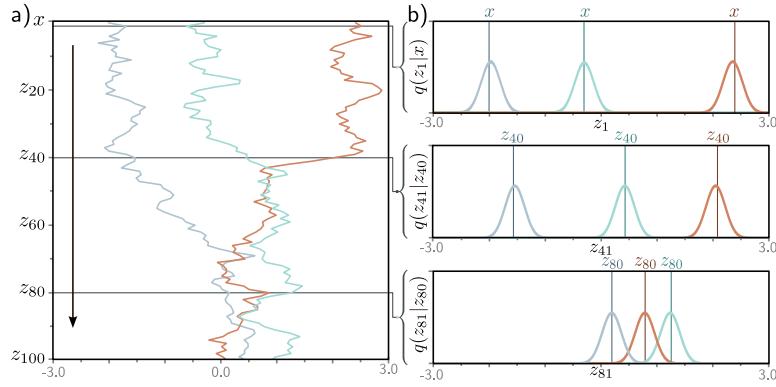


Figura 2.7: Forward process. a) Se considera datos unidimensionales x con $T = 100$ variables latentes z_1, \dots, z_{100} y $\beta = 0,03$ en todos los pasos. Se inician tres valores de x (gris, cian y naranja) (fila superior). Estos se propagan a través de z_1, \dots, z_{100} . En cada paso, la variable se actualiza atenuando su valor por $\sqrt{1 - \beta}$ y añadiendo ruido con media cero y varianza β . En consecuencia, los tres ejemplos se propagan ruidosamente a través de las variables con una tendencia hacia cero. b) Las probabilidades condicionales $q(z_1|x)$ y $q(z_t|z_{t-1})$ son distribuciones normales con una media centrada a 0 y una varianza fija β_t .

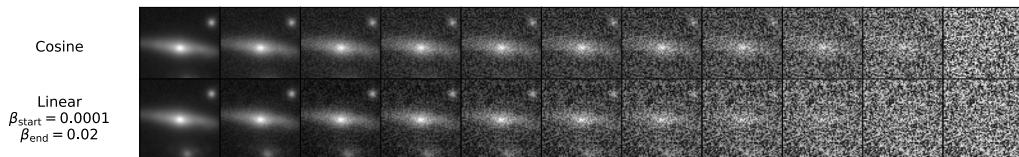


Figura 2.8: Muestras latentes de los esquemas cosine (arriba) y linear (abajo) respectivamente. El esquema linear utiliza $\beta_{\text{start}} = 0,0001$ y $\beta_{\text{end}} = 0,02$.

directamente en el rendimiento y la calidad de las muestras generadas. A continuación, se describen las estrategias más comunes de programación del ruido: el *scheduler* lineal y el *scheduler* cosenoidal.

2.3.3.1. *Scheduler* Lineal

El *scheduler* lineal es uno de los métodos más simples y utilizados para la programación del ruido en modelos de difusión. En este enfoque, la varianza del ruido aumenta linealmente con el tiempo, lo cual se expresa matemáticamente como:

$$\sigma_t^2 = \sigma_{\min}^2 + \left(\frac{t}{T} \right) (\sigma_{\max}^2 - \sigma_{\min}^2)$$

donde σ_{\min}^2 y σ_{\max}^2 son las varianzas mínima y máxima del ruido, respectivamente, y t representa el paso de tiempo actual en el proceso de difusión. Esta fórmula asegura que el ruido añadido aumenta de manera uniforme desde un valor mínimo al inicio hasta un valor máximo al final del proceso.

El *scheduler* lineal es fácil de implementar y proporciona una base sólida para muchos problemas de modelado generativo. Sin embargo, puede no ser óptimo en casos donde la distribución objetivo presenta características complejas que requieren una programación de ruido alternativa.

2.3.3.2. *Scheduler* Cosenoidal

El *scheduler* cosenoidal, introducido por Nichol and Dhariwal (2021), es una alternativa que modula el ruido según una función coseno. La varianza del ruido en cada paso de tiempo se define como:

$$\sigma_t^2 = \sigma_{\min}^2 + 0.5 \left(1 - \cos \left(\frac{t}{T} \pi \right) \right) (\sigma_{\max}^2 - \sigma_{\min}^2)$$

En este esquema, la varianza del ruido sigue una curva cosenoidal, comenzando con un crecimiento lento, acelerando en la mitad del proceso y desacelerando nuevamente hacia el final. Esta técnica tiene la ventaja de distribuir el ruido de manera más suave al principio y al final del proceso de difusión, mejorando la captura de las características de la distribución objetivo en esos intervalos.

2.3.3.3. Comparación entre *Scheduler* Lineal y *Scheduler* Cosenoidal

Ambos presentan ventajas y limitaciones específicas. El *scheduler* lineal, por su simplicidad, puede ser adecuado para problemas donde las características de la distribución objetivo son relativamente uniformes a lo largo del

proceso de difusión. En cambio, el *scheduler* cosenoidal puede ofrecer mejoras significativas en la calidad de las muestras generadas, especialmente en problemas con distribuciones objetivo más complejas.

2.3.4. Difusión Condicionada

La difusión condicionada es una técnica utilizada en modelos de difusión para modelar y mejorar el proceso de generación de datos. Estos modelos se aplican en tareas como la síntesis de imágenes y señales. El objetivo es aprender una transformación gradual y reversible entre una distribución compleja de datos y una distribución más simple, como una gaussiana estándar. Para lograrlo, se busca capturar cómo los datos cambian de un paso temporal t a otro $t - 1$ en el proceso de difusión.

Un desafío principal es calcular la distribución condicional $q(z_{t-1}|z_t)$, que describe la evolución de los datos en cada paso del proceso. Como la distribución marginal $q(z_{t-1})$ es desconocida, no es posible obtener directamente $q(z_{t-1}|z_t)$. Sin embargo, cuando se tiene acceso a la variable original x (por ejemplo, la imagen o señal original), es posible calcular $q(z_{t-1}|x)$. Esto permite estimar la distribución condicional $q(z_{t-1}|z_t, x)$ usando la información que proporciona x .

El cálculo de esta distribución sigue la regla de Bayes. Dado que el proceso de difusión es Markoviano, donde z_t solo depende de z_{t-1} , se puede simplificar esta expresión. Finalmente, utilizando propiedades de distribuciones gaussianas, la distribución $q(z_{t-1}|z_t, x)$ se puede escribir como una combinación de dos gaussianas.

2.3.5. Implementación

La implementación de los modelos de difusión incluye algoritmos tanto para el entrenamiento del modelo como para la generación de muestras. El algoritmo de entrenamiento es simple de implementar y permite aumentar el conjunto de datos de manera natural reutilizando cada punto de datos original tantas veces como sea necesario en cada paso de tiempo con diferentes instancias de ruido ϵ . Por otro lado, el algoritmo de muestreo tiene la desventaja de requerir un procesamiento secuencial de muchas redes neuronales $g_t[z_t, \phi_t]$, lo cual es un proceso que consume tiempo.

2.3.5.1. Entrenamiento del Modelo

El algoritmo de entrenamiento del modelo de difusión se detalla a continuación:

Algorithm 1 Entrenamiento del modelo de difusión

Input: Datos de entrenamiento x
Output: Parámetros del modelo ϕ_t

```

1: repeat
2:   for cada índice de ejemplo de entrenamiento  $i$  en el batch  $B$  do
3:      $t \sim \text{Uniform}[1, \dots, T]$   $\triangleright$  Muestrear un paso de tiempo aleatorio
4:      $\epsilon \sim \text{Norm}[0, I]$   $\triangleright$  Muestrear ruido
5:      $\ell_i = \|g_t(\sqrt{\alpha_t}x_i + \sqrt{1 - \alpha_t}\epsilon, \phi_t) - \epsilon\|^2$   $\triangleright$  Calcular pérdida individual
6:   end for
7:   Acumular pérdidas para el batch y realizar un paso de gradiente
8: until convergencia

```

Este algoritmo de entrenamiento aprovecha la capacidad de reparametrización del modelo, permitiendo que cada punto de datos se utilice múltiples veces con diferentes instancias de ruido, mejorando así la robustez y generalización del modelo entrenado.

2.3.5.2. Inferencia

El algoritmo de inferencia se detalla a continuación:

Algorithm 2 Inferencia

Input: Modelo $g_t[\cdot, \phi_t]$

Output: Muestra x

```

1:  $z_T \sim \text{Norm}[0, I]$   $\triangleright$  Muestrear la última variable latente
2: for  $t = T, T - 1, \dots, 2$  do
3:    $\hat{z}_{t-1} = \frac{1}{\sqrt{1-\beta_t}}z_t - \frac{\sqrt{\beta_t}}{\sqrt{1-\alpha_t}\sqrt{1-\beta_t}}g_t[z_t, \phi_t]$   $\triangleright$  Predecir la variable latente anterior
4:    $\epsilon \sim \text{Norm}[0, I]$   $\triangleright$  Generar un nuevo vector de ruido
5:    $z_{t-1} = \hat{z}_{t-1} + \sigma_t\epsilon$   $\triangleright$  Agregar ruido a la variable latente anterior
6: end for
7:  $x = \frac{1}{\sqrt{1-\beta_1}}z_1 - \frac{\sqrt{\beta_1}}{\sqrt{1-\alpha_1}\sqrt{1-\beta_1}}g_1[z_1, \phi_1]$   $\triangleright$  Generar muestra a partir de  $z_1$  sin ruido

```

Este proceso de inferencia requiere la ejecución secuencial de múltiples redes neuronales para predecir las variables latentes anteriores y añadir el ruido correspondiente en cada paso.

2.3.6. Mejorando la Velocidad de Generación

La función de pérdida utilizada en los modelos de difusión, $\ell(\theta)$, requiere que el núcleo de difusión tenga la forma $q(z_t|x) = \text{Norm}[\sqrt{\alpha_t}x, \sqrt{1 - \alpha_t}]$.

$I]$. Esta misma función de pérdida será válida para cualquier proceso de avance que mantenga esta relación, lo que implica que existe una familia de procesos compatibles optimizados por la misma función de pérdida, pero con diferentes reglas tanto para el proceso de avance como para el uso del ruido estimado $g[z_t, \phi_t]$ para predecir z_{t-1} a partir de z_t en el proceso inverso.

Para mejorar la velocidad de generación, Ho et al. (2020) desarrolló modelos de muestreo acelerado donde el proceso de avance se define solo en una subsecuencia de pasos de tiempo. Esto permite un proceso inverso que omite ciertos pasos de tiempo, haciendo el muestreo mucho más eficiente; muestras de buena calidad pueden ser creadas con solo 50 pasos de tiempo. Aunque esto es mucho más rápido que antes, aún es más lento en comparación con otros modelos generativos.

2.3.6.1. UNet en Modelos de Difusión

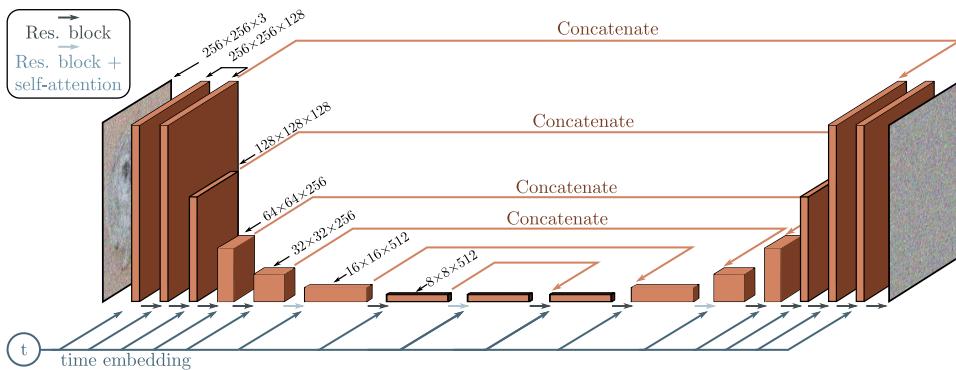


Figura 2.9: UNet utilizado en modelos de difusión para imágenes. La red predice el ruido añadido a la imagen, utilizando un codificador y un decodificador con conexiones residuales y atención global periódica. Una sola red se emplea para todos los pasos de tiempo, con un *embedding* temporal sinusoidal que se pasa a través de una red neuronal y se añade a cada etapa del UNet. Fuente de la imagen: Prince (2023)

Las UNet es una arquitectura comúnmente utilizada en modelos de difusión para imágenes (algunos de los conceptos más relevantes se explicaron en 2.2). El objetivo de la red es predecir el ruido que se ha añadido a la imagen. Las representaciones del codificador se concatenan con sus correspondientes en el decodificador, y las conexiones entre representaciones adyacentes consisten en bloques residuales y atención global periódica, donde cada posición espacial interactúa con todas las demás posiciones espaciales. Una única red se usa para todos los pasos de tiempo, incorporando un embedding temporal sinusoidal que se añade a los canales en cada posición espacial en cada etapa del UNet (Figura 2.9).

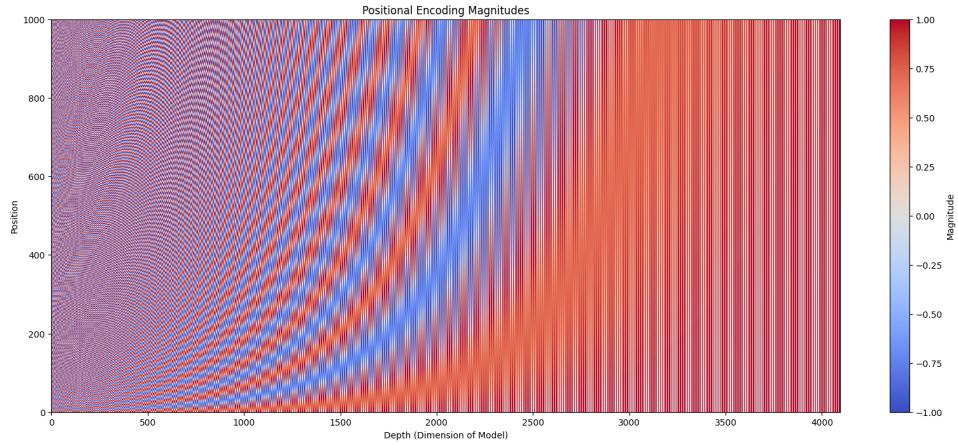


Figura 2.10: Visualización del *embedding* temporal sinusoidal

2.4. Métricas clásicas para Evaluar la Reconstrucción de Imágenes Astronómicas

Para evaluar el rendimiento de los modelos de reconstrucción de imágenes galácticas, se emplearon varias métricas que permiten cuantificar la similitud y la calidad de las imágenes reconstruidas. A continuación, se describen las métricas de evaluación utilizadas: *Mean Absolute Error* (MAE), *Mean Squared Error* (MSE), *Peak Signal-to-Noise Ratio* (PSNR) y *Structural Similarity Index* (SSIM).

2.4.1. Mean Absolute Error (MAE)

El Error Absoluto Medio (MAE) cuantifica la diferencia promedio absoluta entre los píxeles de la imagen original y la reconstruida. Un MAE menor indica mayor similitud entre las imágenes. Se calcula mediante la fórmula:

$$MAE = \frac{1}{n} \sum_{i=1}^n |x_i - y_i|$$

donde x_i y y_i son los valores de los píxeles en las posiciones correspondientes de las imágenes original y reconstruida, respectivamente, y n es el número total de píxeles.

2.4.2. Mean Squared Error (MSE)

El Error Cuadrático Medio (MSE) calcula el promedio de los cuadrados de las diferencias entre los píxeles de la imagen original y la reconstruida. El MSE tiende a dar más peso a errores grandes que el MAE. Su fórmula es:

$$MSE = \frac{1}{n} \sum_{i=1}^n (x_i - y_i)^2$$

donde x_i y y_i son los valores de los píxeles en las posiciones correspondientes de las imágenes original y reconstruida, respectivamente, y n es el número total de píxeles.

2.4.3. Structural Similarity Index (SSIM)

El Índice de Similitud Estructural (SSIM), propuesto por Wang et al. (2004), es una métrica utilizada para evaluar la similitud entre dos imágenes intentando emular la percepción visual del ser humano. En lugar de considerar solo las diferencias en la intensidad de los píxeles, SSIM también tiene en cuenta cambios en la luminancia, el contraste y la estructura. Esta métrica proporciona un valor entre -1 y 1, donde 1 indica una similitud perfecta. La fórmula para calcular SSIM es:

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

donde μ_x y μ_y son las medias de x e y , σ_x^2 y σ_y^2 son las varianzas, σ_{xy} es la covarianza entre x e y , y C_1 y C_2 son constantes para evitar divisiones por cero.

2.4.4. Peak Signal-to-Noise Ratio (PSNR)

El Ratio Señal-Ruido de Pico (PSNR) mide la calidad de la imagen reconstruida en relación con la original. Esta métrica se expresa en decibelios (dB) y se calcula a partir del Error Cuadrático Medio (MSE). La fórmula del PSNR es:

$$PSNR(I, J) = 10 \log_{10} \left(\frac{\max(I)^2}{MSE(I, J)} \right)$$

donde $\max(I)$ es el valor máximo posible de los píxeles en la imagen original I , y $MSE(I, J)$ es el Error Cuadrático Medio entre las imágenes I y J .

2.5. Estadísticos Relevantes para Medir la Similitud

2.5.1. Entropía

La entropía, concepto introducido por Shannon (1948), es una medida que cuantifica la cantidad de información o incertidumbre presente en una

imagen. En el contexto del procesamiento de imágenes, donde los valores de los píxeles pueden tener un rango amplio, la entropía se calcula frecuentemente utilizando una discretización en bins de tamaño N Kapur et al. (1985). La fórmula general para la entropía en este caso es:

$$H = - \sum_{i=1}^M p(i) \log_2 p(i)$$

donde:

- M representa el número total de bins utilizados para discretizar los valores de los píxeles.
- $p(i)$ indica la probabilidad de que un píxel se encuentre en el bin i .

La selección del número de bins M y su tamaño N depende de las características de las imágenes y los objetivos del análisis. Métodos comunes para determinar el número óptimo de bins incluyen la regla de Sturges y la regla de Freedman-Diaconis.

La entropía refleja la distribución de intensidades en la imagen. Un valor de entropía mayor indica una distribución más uniforme de los valores de los píxeles entre los bins, lo que suele asociarse con imágenes de mayor complejidad o contenido informativo. En contraste, una entropía menor sugiere una distribución menos uniforme, que puede indicar la presencia de estructuras más definidas o un rango dinámico más acotado en la imagen.

En el contexto de la reconstrucción de imágenes, comparar la entropía entre la imagen original y la reconstruida puede revelar cómo el proceso de reconstrucción afecta la distribución de información. Una reconstrucción de alta calidad debería, en principio, mantener la entropía de la imagen original, preservando así su contenido informativo.

Cabe destacar que la elección del número y tamaño de los bins puede influir significativamente en el valor calculado de la entropía. Por lo tanto, es importante mantener esta elección constante al comparar diferentes imágenes o métodos de reconstrucción.

2.5.2. Contornos Galácticos

Los contornos galácticos son líneas que conectan puntos de igual intensidad en una imagen de una galaxia. Estos contornos facilitan la visualización de la estructura galáctica y pueden emplearse como métrica para comparar la morfología entre imágenes originales y reconstruidas. La detección de contornos se realiza mediante algoritmos como el operador Sobel Kanopoulos et al. (1988) o el detector de bordes Canny Canny (1986). La similitud entre los contornos de dos imágenes puede cuantificarse utilizando métricas como la distancia de Hausdorff Huttenlocher et al. (1993) o el índice de Jaccard Jaccard (1912).

2.5.2.1. Kullback-Leibler (KL) Divergence

La Divergencia Kullback-Leibler (KL) Kullback and Leibler (1951) es una métrica de la teoría de la información para medir la diferencia entre dos distribuciones de probabilidad. En el contexto de la evaluación de imágenes, la KL Divergence se utiliza para cuantificar cuán bien la distribución de un conjunto de imágenes se ajusta a la distribución de otro conjunto. Para distribuciones discretas, se define como:

$$D_{KL}(P \parallel Q) = \sum_{x \in \mathcal{X}} P(x) \log \left(\frac{P(x)}{Q(x)} \right)$$

Y para distribuciones continuas:

$$D_{KL}(P \parallel Q) = \int_{-\infty}^{\infty} p(x) \log \left(\frac{p(x)}{q(x)} \right) dx$$

donde P y Q son las distribuciones de probabilidad que se comparan. Una menor divergencia KL indica que las distribuciones están más cercanas entre sí en términos probabilísticos. Aunque no siempre se usa como una métrica única debido a su naturaleza unidireccional y a veces no simétrica, la divergencia KL es muy útil para evaluar la similitud entre distribuciones.

Capítulo 3

Estado del Arte

3.1. Modelos de Difusión

3.1.1. Innovaciones en Arquitecturas y Entrenamiento

Los modelos de difusión Ho et al. (2020) han experimentado avances en arquitecturas y métodos de entrenamiento, lo que ha mejorado la calidad y eficiencia en la generación de imágenes. Estas innovaciones han expandido su aplicabilidad en diversos campos.

Las arquitecturas recientes incorporan mecanismos de atención como *self-attention* y *cross-attention* Vaswani et al. (2023), que capturan dependencias a largo plazo y mejoran la coherencia global de las imágenes generadas. La integración de *transformers* con redes neuronales convolucionales ha resultado en modelos que generan imágenes de alta resolución.

Las arquitecturas híbridas, que combinan elementos de diferentes modelos generativos, han ganado relevancia. Por ejemplo, la fusión de *GANs* (*Generative Adversarial Networks*) Vaswani et al. (2023) con modelos de difusión aprovecha características de ambos enfoques, afectando la generación de detalles y la preservación de la estructura global de las imágenes.

Técnicas de normalización como la normalización de grupo Wu and He (2018) y la normalización espectral han influido en la estabilidad del entrenamiento y en la generación de imágenes de alta resolución. Estas técnicas permiten a los modelos procesar las variaciones en los datos de entrada.

En el entrenamiento, se han aplicado técnicas de aprendizaje por refuerzo para optimizar hiperparámetros y funciones de pérdida, lo que ha modificado la automatización y eficiencia del proceso.

La integración de métodos de aprendizaje auto-supervisado ha influido en cómo los modelos aprenden representaciones, lo que afecta la generación de detalles y estructuras complejas. Además, la implementación de algoritmos de optimización como optimizadores adaptativos y técnicas de ajuste de hiperparámetros basadas en algoritmos genéticos ha modificado la con-

vergencia y eficiencia del entrenamiento.

3.1.2. Image Denoising mediante Guiado

El *image denoising* mediante guiado de modelos de difusión Dhariwal and Nichol (2021) es un método que emplea modelos de difusión para reducir el ruido en imágenes. Esta técnica utiliza imágenes de referencia o guías que aportan información adicional al proceso de eliminación de ruido Choi et al. (2021).

Los modelos de difusión guiados utilizan un proceso iterativo en el que la imagen ruidosa se refina gradualmente usando la información de la guía Saharia et al. (2022). Este enfoque permite preservar detalles y mantener la estructura de la imagen, incluso con niveles de ruido significativos. Las guías pueden ser imágenes de alta calidad obtenidas por varios métodos o creadas sintéticamente.

Un caso de aplicación involucra el uso de guías generadas por redes neuronales entrenadas con datos de alta calidad Song et al. (2022). Estas redes crean imágenes de referencia que el modelo de difusión usa para mejorar las imágenes ruidosas. Esta metodología se ha implementado en varios campos, como la mejora de imágenes médicas Khader et al. (2023) y astronómicas Drozdova et al. (2024), donde la reducción precisa del ruido es necesaria para el análisis de datos.

En el ámbito de la edición y síntesis de imágenes, se han desarrollado técnicas que emplean ecuaciones diferenciales estocásticas para dirigir el proceso de *denoising* Meng et al. (2022). Este método facilita ediciones locales en las imágenes mientras preserva la coherencia global, proporcionando una forma flexible de manipular imágenes mediante modelos de difusión guiados.

En cuanto a la restauración de imágenes, se han creado arquitecturas como la propuesta por Zamir et al. (2022) que superan las limitaciones de los métodos convencionales. Estos modelos captan interacciones de píxeles a larga distancia manteniendo su aplicabilidad a imágenes de alta resolución, mostrando resultados efectivos en diversas tareas de restauración, como la eliminación de lluvia, la corrección de desenfoque y la reducción de ruido en imágenes sintéticas y reales.

3.2. Reconstrucción de Imágenes Astronómicas

La reconstrucción de imágenes astronómicas es un campo de estudio en la astrofísica contemporánea que busca mejorar la calidad e interpretación de los datos observacionales. Este proceso aborda retos como el ruido instrumental, las perturbaciones atmosféricas y las limitaciones de los sistemas ópticos. En años recientes, el avance de las técnicas computacionales ha permitido extraer información más precisa y detallada de las observaciones

astronómicas. Esta sección examina los métodos actuales en la reconstrucción de imágenes astronómicas, con énfasis en los enfoques basados en *deep learning* y los modelos de difusión.

3.2.1. Métodos Basados en Deep Learning

Las técnicas de *deep learning* han emergido como herramientas para la reconstrucción de imágenes astronómicas, con las redes neuronales convolucionales (CNNs) O’Shea and Nash (2015) y las arquitecturas UNet Ronneberger et al. (2015) destacando en este campo. Estos métodos procesan datos astronómicos complejos y ruidosos, abordando limitaciones de enfoques previos.

Las CNNs 2.1 han mostrado eficacia en la eliminación de ruido y segmentación de datos radioastronómicos. Gheller and Vazza (2021) aplicaron *autoencoders* convolucionales para reducir ruido y artefactos en imágenes de radiotelescopios, preservando características de fuentes de radio difusas en condiciones de baja relación señal-ruido (SNR). Su estudio también comparó *autoencoders* con métodos como el filtrado gaussiano y las transformadas rápidas de Fourier (FFT) para identificar y extraer fuentes difusas en entornos de bajo SNR.

Las arquitecturas UNet 2.2 han ganado relevancia en astronomía por su capacidad de segmentación y reconstrucción de imágenes. Vojtekova et al. (2020) utilizaron una UNet para reconstruir imágenes astronómicas a partir de datos ruidosos, evaluando su impacto en la calidad de la imagen y la detección de fuentes astronómicas. La estructura simétrica de codificación-decodificación de la UNet permitió captar características tanto globales como locales de la imagen.

En una aplicación específica, Sweere et al. (2022) implementaron UNets para reconstruir imágenes del archivo de ciencia de XMM-Newton, analizando su efecto en la resolución espacial y el ruido en observaciones de rayos X. Su trabajo examinó cómo las UNets alteran la relación señal-ruido y resaltan características, validando los resultados con datos del telescopio Chandra.

Las investigaciones actuales exploran la eficiencia de estos modelos, su capacidad de generalización a diversos tipos de datos astronómicos, y enfoques que integren *deep learning* con técnicas de procesamiento de señales tradicionales. El avance en capacidad computacional y disponibilidad de datos sugiere que estos métodos podrían influir en futuros descubrimientos astronómicos.

3.2.2. Modelos de Difusión en Astronomía

Los modelos de difusión representan un avance en la reconstrucción de imágenes astronómicas. Estos modelos abordan retos en el procesamiento de datos astronómicos complejos.

Wang et al. (2023) presentan el modelo VIC-DDPM. Este utiliza datos de visibilidad del dominio espectral e imágenes *sucias*¹ del dominio espacial para generar imágenes limpias. VIC-DDPM combina ambos dominios para mejorar detalles y reducir ruido. Pruebas en observaciones sintéticas y reales demuestran reducción de artefactos y recuperación de fuentes débiles.

Drozdova et al. (2023) implementan modelos de difusión condicionales para reconstruir modelos del cielo. Este método localiza fuentes y estima flujos con incertidumbres. Supera a técnicas como CLEAN Högbom (1974) y PyBDSF Mohan and Rafferty (2015) en extracción de fuentes débiles y preservación de detalles estructurales.

Xue et al. (2023) aplican modelos de difusión a la deconvolución probabilística de imágenes de galaxias. Este enfoque infiere distribuciones posteriores de imágenes deconvolucionadas, considerando la función de dispersión de punto (PSF)². La técnica genera más diversidad de deconvoluciones que los autoencoders variacionales condicionales (CVAEs) propuesta por Sohn et al. (2015). Datos sintéticos indican mayor efectividad de los modelos de difusión en la generación de muestras para deconvolución.

La aplicación de modelos de difusión en astronomía enfrenta desafíos: requiere grandes conjuntos de datos y recursos computacionales significativos. La integración con datos observacionales reales, que incluyen variaciones y ruido no modelados, necesita enfoques adaptables.

3.3. Métricas Cuantitativas Especializadas para Modelos de Difusión

3.3.1. Inception Score (IS)

El Inception Score (IS), introducido por Salimans et al. (2016), evalúa la probabilidad condicional de las etiquetas de imágenes generadas utilizando el modelo Inception V3. Esta métrica mide la calidad y diversidad de las imágenes generadas. Un IS alto indica variedad en las imágenes y semejanza de cada imagen a una clase distinta de imágenes reales. Barratt and Sharma (2018) analizaron el IS, identificando limitaciones como su dependencia en la cobertura del conjunto de datos y su insensibilidad a ciertas cualidades visuales. El IS continúa siendo una métrica común en la evaluación de modelos generativos.

¹Las imágenes “*sucias*” en radioastronomía son imágenes iniciales obtenidas de datos de visibilidad mediante transformadas de Fourier inversas, conteniendo fuentes astronómicas, artefactos y ruido debido a datos incompletos de radiotelescopios.

²La PSF describe la respuesta de un sistema óptico a una fuente puntual, necesaria para corregir imágenes borrosas por limitaciones instrumentales o atmosféricas.

3.3.2. Fréchet Inception Distance (FID)

La Fréchet Inception Distance (FID), propuesta por Heusel et al. (2018), mide la distancia entre las distribuciones de características de imágenes reales y generadas. Estas características se extraen de la capa Pool-3 del modelo Inception V3 Szegedy et al. (2015). La FID considera la media y covarianza de las distribuciones, así como la estructura global de los datos, ofreciendo una medida de similitud entre imágenes generadas y reales. Heusel et al. (2018) demostraron que la FID detecta discrepancias en las distribuciones de características que otras métricas podrían no identificar.

3.4. Limitaciones de las métricas actuales

Las métricas *FID* e *IS* para evaluar la calidad de imágenes generadas se basan en modelos entrenados en *datasets* específicos. Estas métricas pueden no adaptarse adecuadamente a tareas especializadas como la astronomía. Los modelos subyacentes están generalmente entrenados con imágenes *RGB*, limitando su aplicabilidad a imágenes con diferente número de capas, comunes en astronomía.

El *SSIM* y el *PSNR* también presentan limitaciones. El *SSIM* mide la distorsión estructural, mientras que el *PSNR* es sensible a diferencias *pixel a pixel*. Ambas métricas pueden ser afectadas por técnicas como el desenfoque o la adición de ruido, y no siempre correlacionan con la percepción visual humana en tareas como *super-resolución* o eliminación de ruido.

El *PSNR*, aunque simple de calcular y ampliamente utilizado, a menudo muestra una correlación débil con la calidad visual percibida, especialmente en casos donde los detalles estructurales son críticos. El *SSIM* puede no capturar adecuadamente diferencias en brillo, contraste, tonalidad y saturación.

Para los modelos de difusión, capaces de replicar distribuciones específicas de ruido y estructuras, estas métricas pueden no reflejar precisamente la calidad de las imágenes generadas. Actualmente, no existe una métrica única que evalúe de manera definitiva la calidad de las imágenes generadas por modelos de difusión, evidenciando la necesidad de desarrollar nuevas métricas para estas aplicaciones específicas.

3.5. Conclusiones del estado del arte

La reconstrucción de imágenes astronómicas ha progresado con modelos de difusión y técnicas de *deep learning*. Los modelos de difusión han demostrado mejoras en generación y reconstrucción de imágenes, superando métodos tradicionales en diversos escenarios. Su capacidad para modelar la distribución de probabilidad de los datos a nivel de píxel los hace aplicables en astronomía, donde la cuantificación de la incertidumbre es necesaria para

el análisis de datos.

La implementación de modelos como VIC-DDPM en astronomía Wang et al. (2023) ha aumentado la calidad de imagen, reducido artefactos y mejorado la detección de fuentes débiles. Esto impacta el análisis de datos de radiotelescopios y la deconvolución de imágenes de galaxias. Las técnicas de *deep learning*, como *CNNs* y *UNet*, han mostrado eficacia en el procesamiento de datos astronómicos.

Los desafíos incluyen la necesidad de grandes conjuntos de datos para entrenamiento y recursos computacionales significativos. La adaptación de estos modelos a la diversidad de datos astronómicos continúa siendo un área de desarrollo.

La evaluación de calidad de imágenes generadas presenta retos. Las métricas actuales (*FID*, *IS*, *SSIM*, *PSNR*) tienen limitaciones en el contexto de imágenes astronómicas y modelos de difusión. El avance en la investigación de métricas específicas para estas aplicaciones es necesario.

Las investigaciones futuras se centrarán en mejorar la eficiencia computacional y extender estos métodos a más tipos de datos astronómicos, incluyendo imágenes ópticas de alta resolución y datos multidimensionales. También se busca desarrollar enfoques para integrar estos modelos con datos observacionales reales.

Capítulo 4

Objetivos

El objetivo general de este trabajo es investigar y aplicar redes generativas de difusión para la reconstrucción de imágenes galácticas de bajo *Signal to Noise Ratio* (SNR) en equivalentes de alto SNR. Este enfoque busca optimizar el retorno científico de los datos astronómicos con peor calidad. Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

- Revisar el estado del arte en técnicas de *denoising* de imágenes, con énfasis en las aplicaciones de redes generativas de difusión en astronomía.
- Seleccionar y preparar un conjunto de datos para el entrenamiento y validación de la red generativa, utilizando imágenes del telescopio Subaru. Este proceso incluirá el preprocesamiento y, cuando sea necesario, la ampliación de datos para mejorar el entrenamiento del modelo.
- Diseñar y desarrollar una red generativa de difusión adaptada a las características del ruido en imágenes astronómicas. Este objetivo abarca la configuración de la arquitectura de la red y la selección de parámetros.
- Analizar y proponer métricas alternativas para evaluar la similitud entre imágenes astronómicas con ruido. Se explorarán métricas específicas del dominio astronómico y se comparará su desempeño con algunas métricas actuales.
- Evaluar la eficacia de la red generativa de difusión en la mejora de la calidad de las imágenes ruidosas. Esto incluirá el uso de métricas como el PSNR y la SSIM, así como las nuevas métricas propuestas para imágenes astronómicas.
- Analizar el impacto de la mejora de las imágenes en la interpretación

y el análisis científico, comparando los resultados obtenidos antes y después del proceso de *denoising*.

- Documentar el desarrollo y los resultados del proyecto, incluyendo un análisis comparativo de las métricas utilizadas. Preparar el código fuente y los modelos entrenados para su disponibilidad como recursos de código abierto.

Capítulo 5

Metodología

5.1. Especificaciones Técnicas

La implementación y el entrenamiento de los modelos se llevaron a cabo utilizando una infraestructura de computación distribuida. Se empleó una combinación de recursos de computación en la nube y *hardware* local, que incluye:

- Múltiples GPUs NVIDIA A100 accesibles a través de Google Colab
- Múltiples GPUs NVIDIA L40 proporcionadas por otras plataformas cloud
- Una GPU NVIDIA 2070 Max-Q para desarrollo y pruebas locales

Todos estos recursos de hardware fueron aprovechados mediante la utilización de CUDA, la plataforma de computación paralela de NVIDIA, lo que permitió una aceleración significativa en el entrenamiento de los modelos de aprendizaje profundo. El entrenamiento total de todos los modelos requirió aproximadamente 600 horas de *GPUs*.

El desarrollo de los modelos se realizó utilizando el framework PyTorch Lightning, que proporciona una capa de abstracción sobre PyTorch para facilitar la implementación de modelos complejos y su entrenamiento distribuido. Además, se utilizó PyTorch Lightning Metrics para el cálculo eficiente de métricas de evaluación durante el entrenamiento y la validación.

Para la gestión y seguimiento de los experimentos, se utilizó Weights & Biases (wandb), una plataforma de experimentación de *machine learning*. Esta herramienta permitió el registro, visualización y comparación de los resultados de múltiples experimentos de manera eficiente.

La Figura 5.1 muestra una captura de pantalla del panel de control de Weights & Biases, ilustrando cómo se visualizan y comparan las métricas de rendimiento de diferentes experimentos a lo largo del tiempo de entrenamiento.

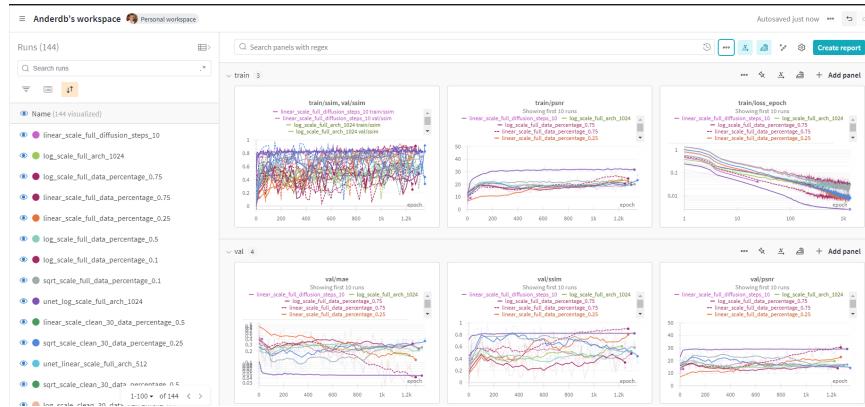


Figura 5.1: Panel de control de Weights & Biases mostrando el seguimiento de múltiples métricas durante el entrenamiento de los modelos

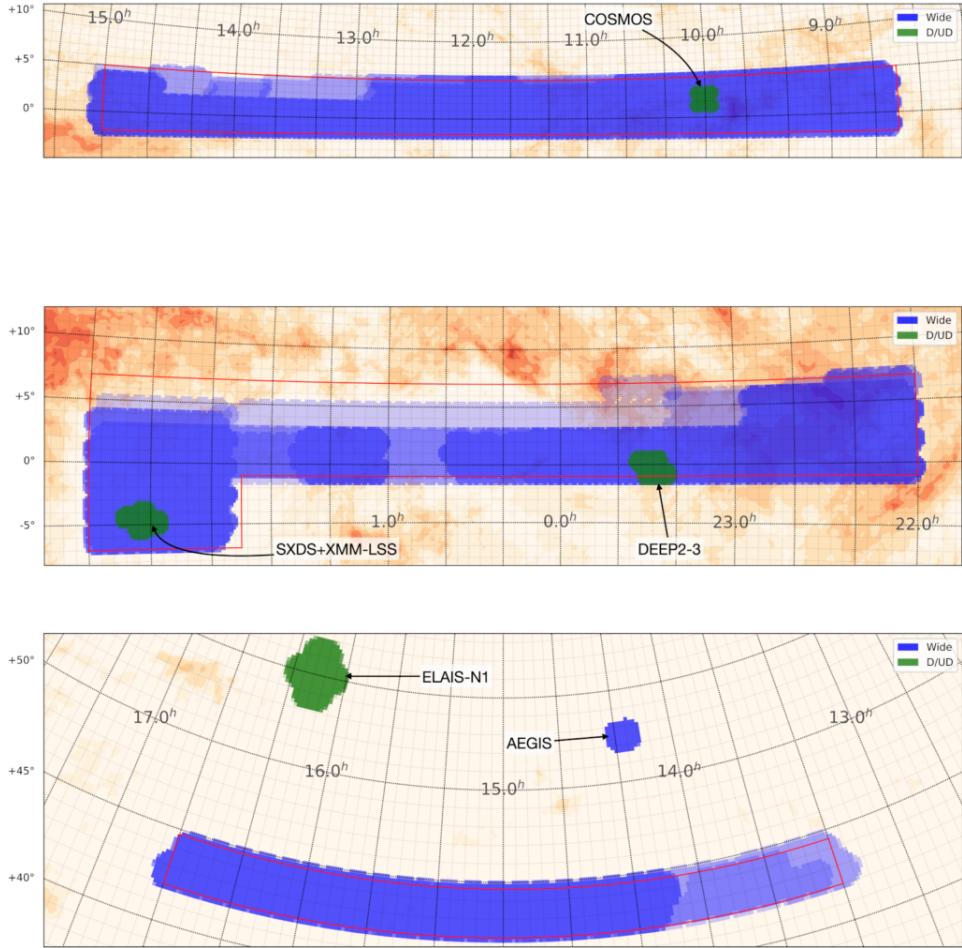
5.2. Dataset

5.2.1. Descripción

Para este estudio, se utilizaron imágenes astronómicas del programa Hyper Suprime-Cam Subaru Strategic Program (HSC-SSP), específicamente de la versión pública de datos PDR3 Aihara et al. (2022). Este programa ofrece un catálogo extenso de imágenes de galaxias obtenidas con múltiples bandas y diferentes tiempos de exposición, cubriendo más de 600 grados cuadrados del cielo.

El conjunto de datos HSC-SSP PDR3 se divide en varias capas de profundidad: la capa *Wide* y las capas *Deep+UltraDeep*. En la figura 5.2, las áreas de la capa *Wide* (mostradas en azul en la documentación del HSC-SSP) se caracterizan por tiempos de exposición más cortos, oscilando entre 10 y 20 minutos, resultando en imágenes con menor relación señal-ruido (*SNR*). Esta capa cubre un área extensa de aproximadamente 1300 grados cuadrados. Por otro lado, las áreas *Deep+UltraDeep* (mostradas en verde) tienen tiempos de exposición entre 7 y 10 veces mayores, produciendo imágenes con mayor *SNR*, pero cubriendo un área más reducida de solo 36 grados cuadrados. Las regiones de azul más oscuro dentro de la capa *Wide* indican áreas cubiertas con hasta cinco filtros, proporcionando datos en múltiples bandas.

Para el entrenamiento del modelo, se seleccionaron regiones específicas que contienen galaxias, obteniendo un total de 880 pares de imágenes. Cada par consiste en una imagen de la capa *Wide* (utilizada como imagen de entrada ruidosa) y su correspondiente imagen de la capa *Deep+UltraDeep* (utilizada como imagen objetivo a generar por el modelo). Esto resulta en un total de 1760 muestras monocanales de 64x64 píxeles.



Wide	<i>g</i>	<i>r</i>	<i>i</i>	<i>z</i>	<i>y</i>	<i>NB387</i>	<i>NB816</i>	<i>NB921</i>	<i>NB1010</i>
exposure (min)	10^{+2}_{-2}	10^{+2}_{-2}	20^{+3}_{-6}	20^{+3}_{-10}	20^{+3}_{-10}				
seeing (arcsec)	$0.79^{+0.09}_{-0.08}$	$0.75^{+0.13}_{-0.09}$	$0.61^{+0.05}_{-0.05}$	$0.68^{+0.08}_{-0.06}$	$0.68^{+0.10}_{-0.08}$				
depth (mag)	$26.5^{+0.2}_{-0.2}$	$26.5^{+0.2}_{-0.2}$	$26.2^{+0.2}_{-0.3}$	$25.2^{+0.2}_{-0.3}$	$24.4^{+0.2}_{-0.3}$				
saturation (mag)	$17.4^{+0.6}_{-0.4}$	$18.1^{+0.5}_{-0.5}$	$18.3^{+0.5}_{-0.3}$	$17.5^{+0.5}_{-0.4}$	$17.0^{+0.5}_{-0.7}$				
area (deg ²)	1332	1298	1264	1299	1209				
Deep+UltraDeep	<i>g</i>	<i>r</i>	<i>i</i>	<i>z</i>	<i>y</i>	<i>NB387</i>	<i>NB816</i>	<i>NB921</i>	<i>NB1010</i>
exposure (min)	70^{+21}_{-21}	66^{+17}_{-17}	98^{+46}_{-32}	177^{+130}_{-46}	93^{+23}_{-23}	68^{+13}_{-13}	120^{+30}_{-15}	168^{+14}_{-28}	705^{+45}_{-345}
seeing (arcsec)	$0.83^{+0.05}_{-0.12}$	$0.77^{+0.04}_{-0.04}$	$0.66^{+0.07}_{-0.06}$	$0.78^{+0.02}_{-0.03}$	$0.70^{+0.04}_{-0.05}$	$0.82^{+0.07}_{-0.08}$	$0.70^{+0.07}_{-0.08}$	$0.67^{+0.04}_{-0.04}$	$0.77^{+0.02}_{-0.02}$
depth (mag)	$27.4^{+0.2}_{-0.2}$	$27.1^{+0.1}_{-0.1}$	$26.9^{+0.3}_{-0.3}$	$26.3^{+0.1}_{-0.3}$	$25.3^{+0.2}_{-0.2}$	$25.0^{+0.2}_{-0.2}$	$26.0^{+0.2}_{-0.2}$	$25.9^{+0.2}_{-0.2}$	$24.2^{+0.2}_{-0.5}$
saturation (mag)	$18.0^{+0.4}_{-0.5}$	$18.2^{+0.4}_{-0.4}$	$18.6^{+0.3}_{-0.4}$	$17.7^{+0.3}_{-0.3}$	$17.4^{+0.3}_{-0.3}$	$14.8^{+0.4}_{-0.3}$	$16.8^{+0.4}_{-0.4}$	$16.9^{+0.4}_{-0.3}$	$14.8^{+0.2}_{-0.2}$
area (deg ²)	36	36	36	37	36	30	33	33	5

Figura 5.2: Imágenes del Hyper Suprime-Cam (HSC) y tabla resumen de las observaciones.

5.2.2. Preprocesamiento

El estudio utilizó datos en formato Flexible Image Transport System (FITS), el estándar en astronomía para el almacenamiento de imágenes y datos científicos. Los archivos FITS contienen información cuantitativa sobre la intensidad lumínica captada por los detectores de los telescopios. A diferencia de los formatos de imagen convencionales, que típicamente limitan los valores de píxel a un rango de 0 a 255, los archivos FITS permiten un rango dinámico significativamente mayor, para preservar la precisión de las observaciones astronómicas.

El preprocesamiento de las imágenes se llevó a cabo mediante los siguientes pasos específicos:

1. **Escalado de los datos:** Debido a la baja luminosidad de las galaxias, se aplican diferentes escalas a los datos para mejorar la visualización de sus características. Se generaron las siguientes versiones de los datos:

- **Escala Lineal:** Las imágenes se mantienen en su escala original, preservando la relación directa entre los valores de píxel y la intensidad lumínica detectada. Esta escala permite análisis cuantitativos precisos al mantener la integridad de los datos originales. No obstante, puede reducir la visibilidad de estructuras de baja luminosidad en galaxias distantes o tenues.

$$y = x$$

Donde x representa el valor original del píxel y y el valor resultante.

- **Escala Logarítmica:** Se aplica una transformación logarítmica a las imágenes para resaltar las características de baja intensidad. Esta escala comprime el rango dinámico de los datos, permitiendo visualizar simultáneamente áreas brillantes y oscuras. Facilita la observación de la estructura interna de galaxias y la detección de objetos tenues que podrían ser menos visibles en la escala lineal.

$$y = \frac{\log(ax + 1)}{\log(a)}$$

Donde a es un factor de escala ajustable que determina el grado de compresión del rango dinámico. Un valor común de a es 1000, aunque puede ajustarse según las características específicas de las imágenes y los objetivos del estudio.

- **Escala Raíz Cuadrada:** Esta transformación proporciona un punto medio entre la escala lineal y la logarítmica. Reduce el rango dinámico de las imágenes de manera menos pronunciada

que la escala logarítmica, lo que permite resaltar estructuras de luminosidad intermedia. Es efectiva para visualizar detalles en regiones de brillo moderado, como los brazos espirales de galaxias o regiones de formación estelar, manteniendo una representación equilibrada de las áreas más brillantes.

$$y = \sqrt{x}$$

Esta transformación es adecuada para datos con un rango dinámico moderado, ofreciendo una mejora en la visualización sin la compresión extensiva de la escala logarítmica.

2. **Normalización:** El proceso de normalización se aplicó a los datos FITS para adaptarlos específicamente a los requerimientos del modelo de Difusión Denoising Probabilistic Model (DDPM). Cada píxel se normalizó al rango [-1, 1] mediante la fórmula $p_{normalizado} = 2 * (p/I_{max}) - 1$, donde p es el valor original del píxel e I_{max} es el valor máximo de intensidad en la imagen. Esta normalización es esencial para los modelos DDPM, que operan óptimamente en este rango. El procedimiento preserva las relaciones relativas entre las intensidades de los píxeles, manteniendo la integridad de la información astronómica. Además de mejorar la estabilidad numérica durante el entrenamiento, esta normalización facilita la convergencia del algoritmo de optimización y permite una representación uniforme de las características de baja y alta intensidad. En el contexto de los modelos DDPM, esta normalización es particularmente importante para el proceso de adición y eliminación de ruido gaussiano durante las etapas de difusión y generación.
3. **División de Datos:** El conjunto de datos se dividió aleatoriamente en tres subconjuntos: 80 % para entrenamiento, 10 % para validación y 10 % para prueba. Esta división permite evaluar el rendimiento del modelo y prevenir el sobreajuste. El conjunto de entrenamiento se utilizó para ajustar los parámetros del modelo. El conjunto de validación se empleó para evaluar el progreso durante el entrenamiento y guiar la selección de hiperparámetros. El conjunto de prueba, aislado durante el desarrollo, se reservó para la evaluación final del modelo. Todos los modelos entrenados con el conjunto completo de datos utilizaron los mismos archivos para cada fase, al igual que los modelos entrenados con el subconjunto de datos limpios, llamados “Clean 30”.
4. **Generación de Versiones Clean 30:** El Análisis Exploratorio de Datos (EDA) reveló dos distribuciones distintas en el PSNR (Peak Signal-to-Noise Ratio) entre las capas Deep+UltraDeep (DUD) y Wide, como muestra la Figura 5.3. Se estableció un umbral de PSNR de

30 para separar estas distribuciones. Para cada tipo de escala (lineal, logarítmica y raíz cuadrada), se generaron dos conjuntos de datos: uno con todas las muestras y otro denominado *Clean 30*, que incluye solo las muestras con PSNR superior a 30. La versión *Clean 30* excluye el 17,39 % de los datos más ruidosos, conservando el 82,61 % de las muestras con mejor relación señal-ruido.

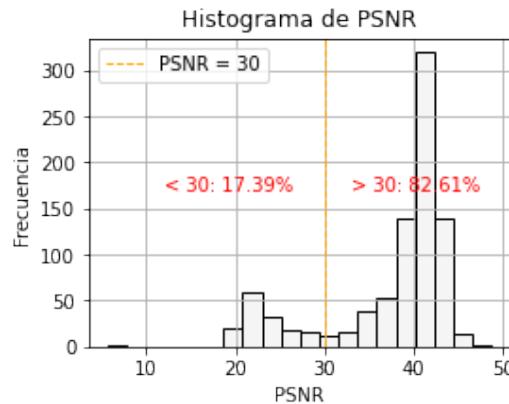


Figura 5.3: Histograma de frecuencias de los valores PSNR de las muestras, mostrando la división en el umbral de PSNR = 30.

5. **Aumento de Datos (*data augmentation*)**: Para incrementar la diversidad del conjunto de datos y mejorar la robustez del modelo, se aplicó un *flip* aleatorio en los ejes x, y, o xy a las imágenes. Esta técnica ayuda a prevenir el sobreajuste y permite al modelo generalizar mejor. En el contexto de imágenes astronómicas, es fundamental mantener la integridad de la información física. Por lo tanto, se evitaron técnicas de aumento de datos comunes en otros campos, como alteraciones de brillo, contraste o distorsiones geométricas. Estas modificaciones podrían introducir artefactos o alterar características críticas como la fotometría o la morfología de los objetos celestes, comprometiendo la validez científica de los datos. Los *flips*, en cambio, preservan la información cuantitativa mientras aumentan la variabilidad del conjunto de entrenamiento.

Esto resultó en seis variantes distintas del conjunto de datos original, cada una diseñada para capturar diferentes aspectos de las estructuras astronómicas:

- Versión completa en escala lineal
- Versión *Clean 30* en escala lineal
- Versión completa en escala logarítmica

- Versión *Clean 30* en escala logarítmica
- Versión completa en escala de raíz cuadrada
- Versión *Clean 30* en escala de raíz cuadrada

Las diferentes escalas proporcionan distintas perspectivas de los datos astronómicos, destacando características específicas de los objetos celestes. Las Figuras 5.4, 5.5, 5.6, 5.7, 5.8 y 5.9 muestran ejemplos visuales de estas escalas aplicadas a imágenes de los conjuntos WIDE y DUD (Deep+UltraDeep). Estas figuras ilustran cómo cada transformación modifica la representación de las estructuras galácticas.

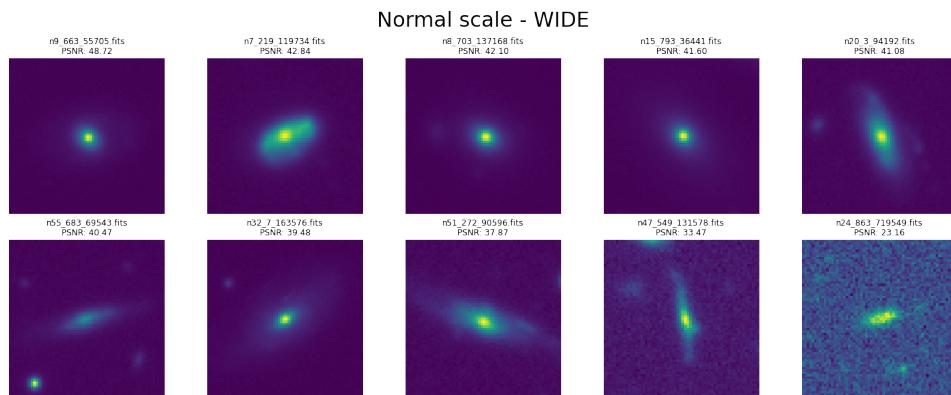


Figura 5.4: Muestra de datos en escala lineal - WIDE

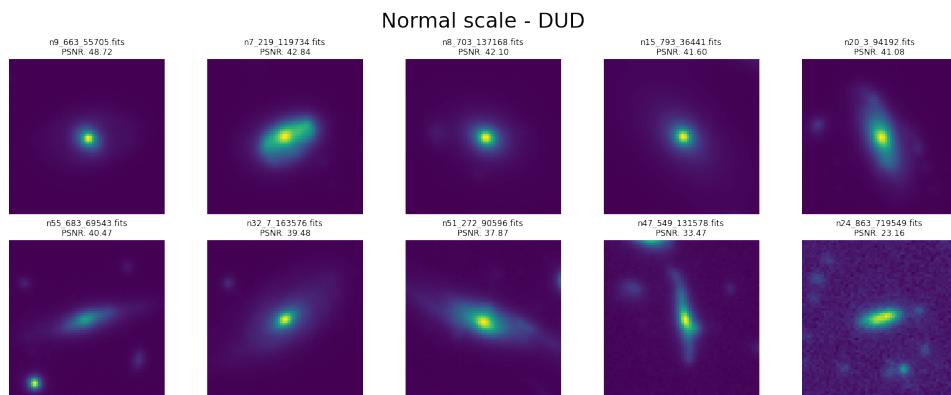


Figura 5.5: Muestra de datos en escala lineal - DUD

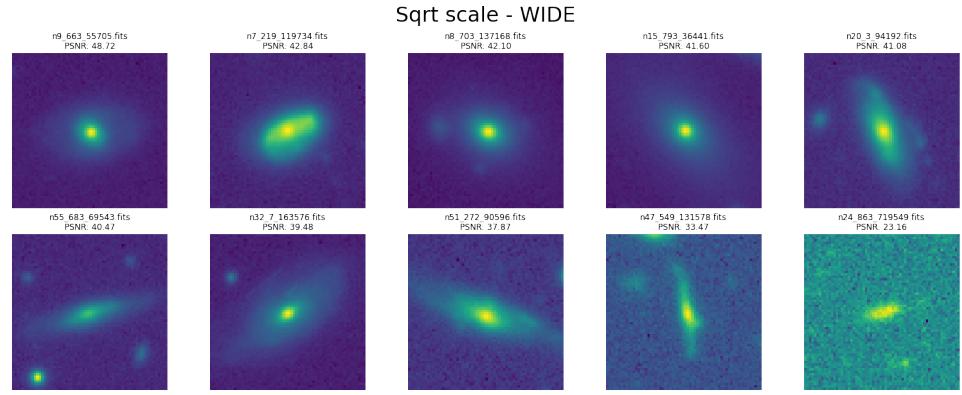


Figura 5.6: Muestra de datos en escala raíz cuadrada - WIDE

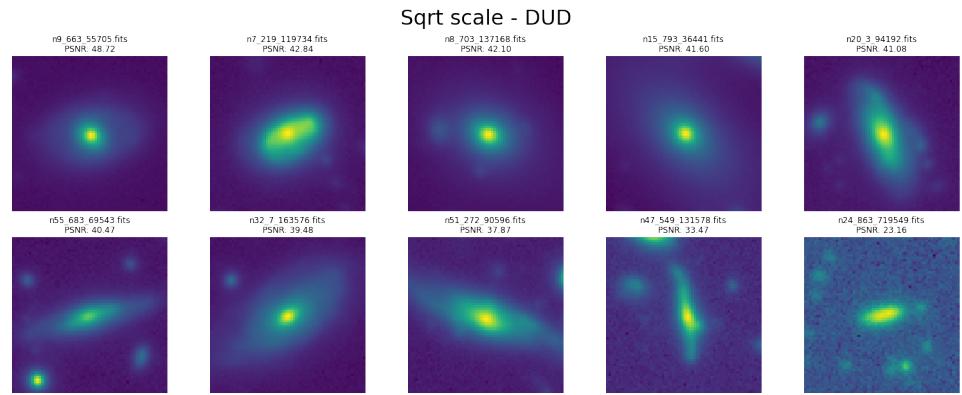


Figura 5.7: Muestra de datos en escala raíz cuadrada - DUD

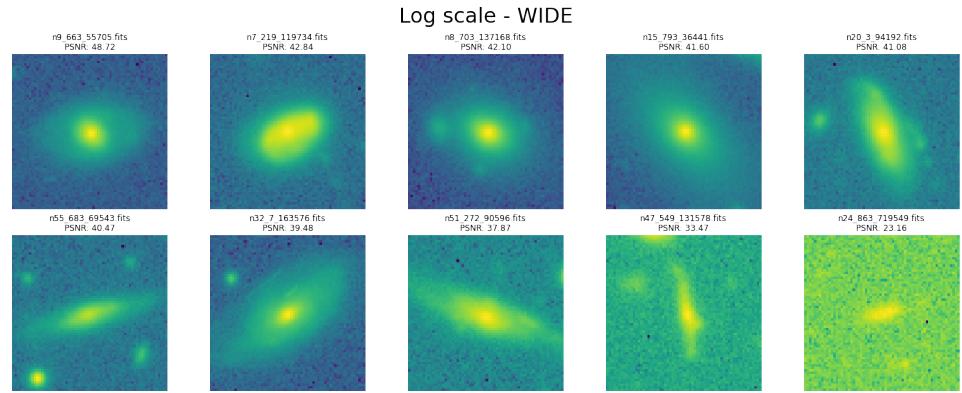


Figura 5.8: Muestra de datos en escala logarítmica - WIDE

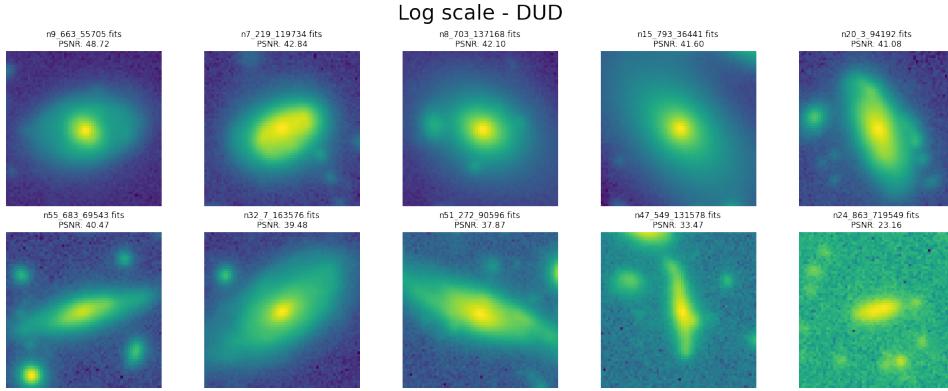


Figura 5.9: Muestra de datos en escala logarítmica - DUD

5.3. Exploración de métricas

Las métricas tradicionales de comparación de imágenes presentan limitaciones al evaluar imágenes generadas por modelos de difusión, particularmente en contextos con diferentes niveles de ruido. Estos modelos son capaces de modelar la distribución de probabilidad de los datos a nivel de píxel, lo que permite capturar la variabilidad inherente en los datos astronómicos. Sin embargo, las métricas comúnmente utilizadas no evalúan adecuadamente esta característica, lo que puede llevar a evaluaciones imprecisas de la calidad de las imágenes generadas. Para abordar esta discrepancia, se han explorado métricas alternativas. Se ha diseñado un conjunto de experimentos utilizando elementos de prueba sintéticos, permitiendo un control preciso sobre las características de la imagen y la variabilidad de los datos. Este enfoque facilita un análisis sistemático de diversas métricas, tanto comunes como novedosas, con el objetivo de identificar las más adecuadas para evaluar imágenes generadas por modelos de difusión en contextos astronómicos.

5.3.1. Elementos de prueba

El estudio utiliza diversos elementos de prueba con distintos niveles de ruido para evaluar el comportamiento de las métricas. El conjunto incluye:

- **Ruido puro:** Una imagen sin elementos estructurales (Fig. 5.10).
- **Formas geométricas con ruido:**
 - Cuadrado y triángulo con ruido de fondo (Fig. 5.11, 5.13).
 - Cuadrado y triángulo con ruido en toda la imagen (Fig. 5.12, 5.14).
- **Simulaciones simplificadas de galaxias:**

- Simulación de una galaxia elíptica (Fig. 5.15).
- Simulación de una galaxia circular (Fig. 5.16).

Estos elementos, mostrados en las Figuras 5.10 a 5.16, permiten analizar cómo las métricas responden al ruido en ausencia de características definidas, cómo distinguen entre ruido de fondo y ruido uniforme, y cómo manejan estructuras más complejas en presencia de ruido. Las simulaciones de galaxias proporcionan casos de prueba más cercanos a escenarios astronómicos reales.

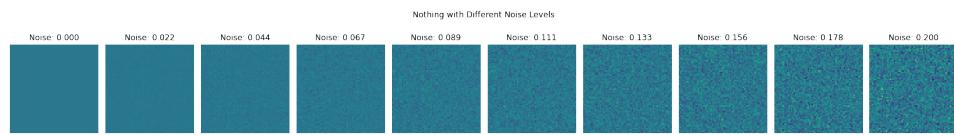


Figura 5.10: Muestras para el caso de ruido puro con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2

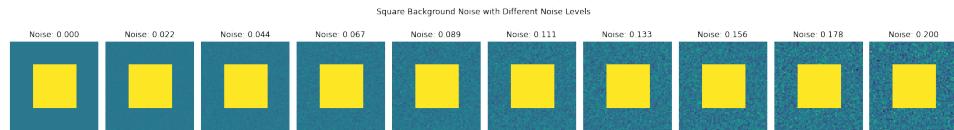


Figura 5.11: Muestras para el caso cuadrado con ruido de fondo con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2

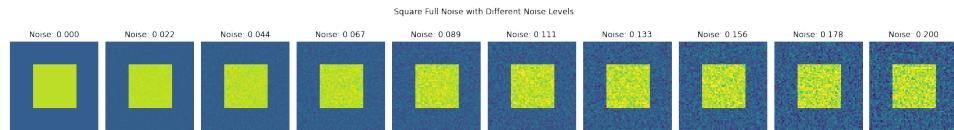


Figura 5.12: Muestras para el caso cuadrado con ruido en toda la imagen con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2

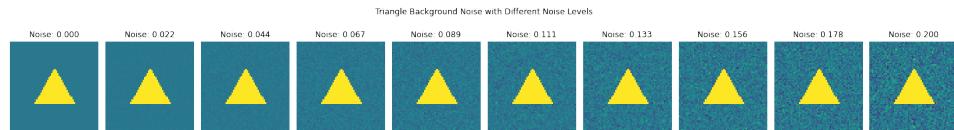


Figura 5.13: Muestras para el caso triangulo con ruido de fondo con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2

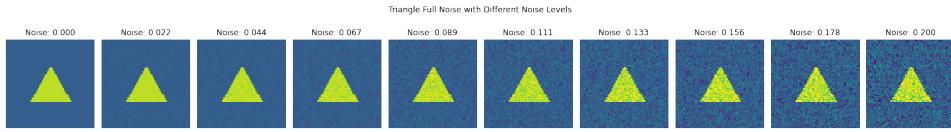


Figura 5.14: Muestras para el caso triangulo con ruido en toda la imagen con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2

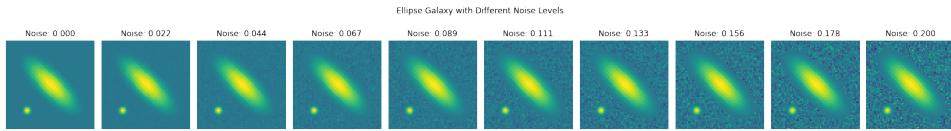


Figura 5.15: Muestras para el caso galaxia elíptica con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2

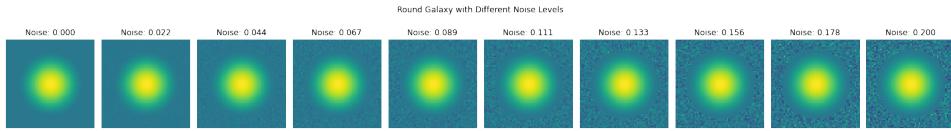


Figura 5.16: Muestras para el caso galaxia circular con distintos valores de ruido gausiano con una desviación que va de 0 a 0.2

5.3.2. Niveles de ruido

El estudio examina un rango de niveles de ruido gaussiano para cada elemento de prueba. Se aplica ruido con media 0, variando la desviación estándar desde 0 (sin ruido) hasta 0.2 (ruido significativo), con 20 niveles intermedios equidistantes. El ruido gaussiano, caracterizado por su distribución normal, afecta la claridad y detalle de las imágenes a medida que aumenta la desviación estándar. Esta gama de niveles permite evaluar la sensibilidad y robustez de las diferentes métricas en condiciones que van desde imágenes claras hasta aquellas con perturbaciones significativas, observando cómo responden a incrementos graduales en la intensidad del ruido.

5.3.3. Métricas evaluadas

Se han utilizado diversas métricas que abarcan medidas globales de error, estructura local e información de frecuencia. Se han incluido el Índice de Similaridad Estructural (*Structural Similarity Index*, SSIM), la Relación Señal a Ruido Pico (*Peak Signal-to-Noise Ratio*, PSNR), el Error Cuadrático Medio (*Mean Squared Error*, MSE) y el Error Absoluto Medio (*Mean Absolute Error*, MAE), con sus variantes centradas. Se han incorporado métricas basadas en la divergencia de Kullback-Leibler (KL) aplicadas al histograma de la imagen, filas y columnas. Se han considerado también la Relación Señal

a Ruido (*Signal-to-Noise Ratio*, SNR), una métrica de contorno y el MSE de la Transformada de Fourier. Esta selección permite cuantificar diferentes aspectos de la similitud entre imágenes en presencia de ruido.

5.3.4. Procedimiento experimental

Se ha seguido un procedimiento sistemático para cada tipo de elemento de prueba y cada métrica. Se ha generado una serie de imágenes con niveles de ruido crecientes. Posteriormente, se ha aplicado cada métrica para comparar todos los pares posibles de imágenes dentro de esta serie. Los resultados de estas comparaciones se han organizado en una matriz de similitud, donde cada celda representa la comparación entre dos niveles específicos de ruido.

Este método permite observar cómo cada métrica responde a los cambios incrementales en el nivel de ruido para los diferentes tipos de imágenes. Se proporciona una base para evaluar la sensibilidad y robustez de las métricas en diversas condiciones, mostrando su comportamiento en presencia de ruido.

En las secciones siguientes, se presentarán y analizarán los resultados de estos experimentos. Este análisis mostrará el comportamiento de cada métrica en relación con los diferentes elementos de prueba y niveles de ruido, permitiendo una evaluación de su eficacia en el contexto de imágenes con ruido.

5.4. Configuración Experimental

Esta sección describe la configuración experimental utilizada para evaluar y comparar aspectos de los modelos de reconstrucción y generación de imágenes astronómicas. El diseño experimental se ha estructurado para analizar el rendimiento de los modelos bajo diversas condiciones y parámetros.

La configuración experimental se divide en varias subsecciones:

Se presentan los modelos base utilizados en el estudio: la arquitectura *U-Net* y los modelos de difusión probabilística de eliminación de ruido (*Denoising Diffusion Probabilistic Models*, DDPMs). Estos modelos base sirven como referencia para las comparaciones.

Se exploran los siguientes aspectos que influyen en el rendimiento de los modelos:

- El impacto del número de **pasos de difusión** en los DDPMs, evaluando configuraciones de 10, 20, 50, 100 y 250 pasos.
- El efecto del **número de parámetros** de la red en la calidad de las reconstrucciones, evaluando tamaños de 665K, 2M, 10M y 30M de parámetros.
- La influencia de la **cantidad de datos de entrenamiento**, utilizando diferentes proporciones del conjunto de datos (10 %, 25 %, 50 %, 75 % y 100 %).

Generando un total de 120 modelos distintos (72 de difusión y 48 *Residual Attention Unets*). Cada aspecto se ha analizado de manera aislada, modificando solo los parámetros a evaluar mientras se mantienen constantes los demás elementos de la configuración base. Este enfoque permite evaluar el impacto de cada factor en el rendimiento del modelo.

En las siguientes subsecciones, se describen los diferentes componentes de la configuración experimental, comenzando con los modelos base utilizados en este estudio.

5.4.0.1. UNet

La arquitectura UNet utilizada en este estudio procesa imágenes monocanales de 64x64 píxeles, con un canal de entrada y uno de salida. La red contiene aproximadamente 2 millones de parámetros, distribuidos en varias capas y bloques:

Un bloque inicial residual conecta los canales de entrada con los primeros canales de la red. Siguen bloques de contracción que reducen la dimensionalidad de la imagen mediante convoluciones 3x3, activaciones ReLU y max-pooling 2x2.

En la parte central se encuentran bloques residuales que operan en la dimensionalidad intermedia del espacio latente. Posteriormente, bloques de expansión restauran la dimensionalidad original de la imagen usando convoluciones y técnicas de up-sampling.

Se incorporan bloques de auto-atención en las etapas de expansión. Un bloque residual final convierte las características procesadas en la imagen de salida.

En toda la arquitectura se utiliza Group Normalization con un valor de 32 grupos, lo que ayuda a estabilizar el entrenamiento y mejorar la generalización del modelo.

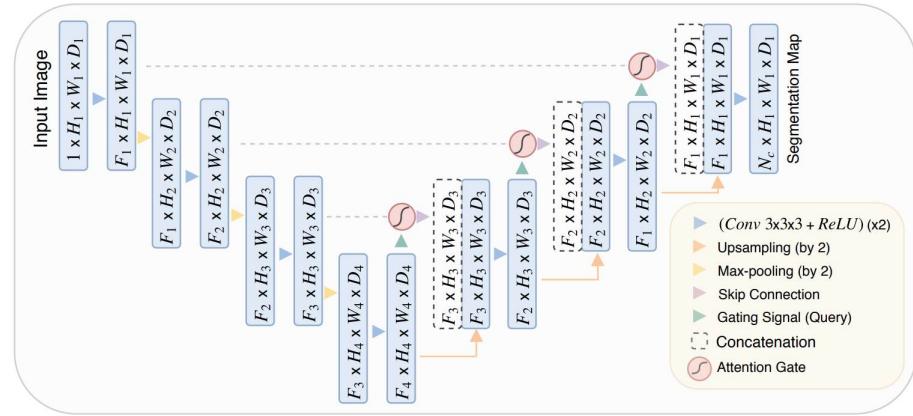


Figura 5.17: Diagrama de la arquitectura *Residual Attention UNet* utilizado como UNet base

5.4.0.2. Denoising Diffusion Probabilistic Models

La reconstrucción de imágenes mediante modelos de difusión probabilística de eliminación de ruido (DDPMs) utiliza la misma arquitectura U-Net de otros experimentos, con algunas modificaciones. El modelo DDPM recibe dos canales de entrada: uno para la imagen de ruido y otro para la imagen de referencia del proceso de guiado. La salida se mantiene como una imagen monocanal.

La configuración incluye 50 pasos de difusión y el *Cosine Scheduler* para controlar el ruido añadido en cada paso. Los canales en la fase de contracción son 64, 128, 256 y 512, mientras que en la fase intermedia se utilizan 512 canales. Esta estructura resulta en un total de 2 millones de parámetros.

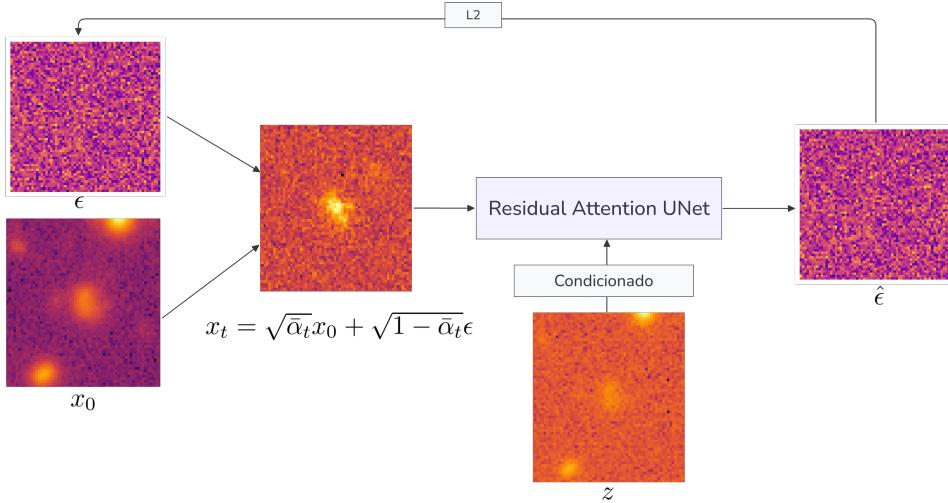


Figura 5.18: Representación esquemática de un paso en el proceso de entrenamiento de un modelo de difusión guiado. x_0 es la imagen esperada (objetivo), z es la imagen ruidosa utilizada para el guiado. Para el paso de tiempo t , ϵ representa el ruido de entrada y x_t es la imagen calculada para el paso t generada según la ecuación mostrada. La *Residual Attention UNet*, condicionada con z , procesa x_t para estimar el ruido $\hat{\epsilon}$. El modelo se entrena minimizando el *loss* entre ϵ y $\hat{\epsilon}$ en cada paso. Este proceso se repite para cada uno de los pasos de difusión definidos.

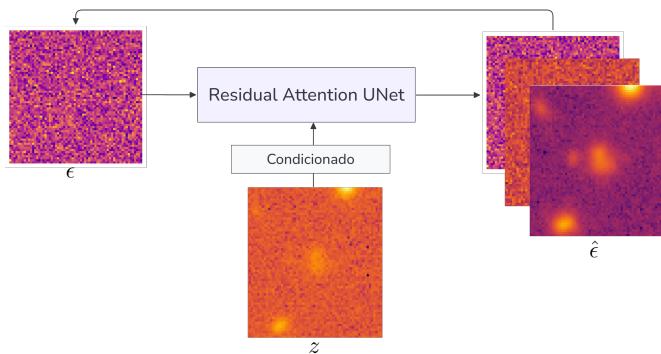


Figura 5.19: Proceso de inferencia del modelo de difusión guiado. Se inicia con ruido aleatorio ϵ como imagen de entrada. En cada paso, la Residual Attention UNet estima el ruido presente $\hat{\epsilon}$ en la imagen, condicionada por la imagen de referencia z . La imagen resultante de cada paso se utiliza como entrada para el siguiente, concatenándola con z . Este proceso se repite durante el número predefinido de pasos de difusión, reduciendo gradualmente el ruido hasta obtener la imagen final reconstruida.

5.4.0.3. Configuración de entrenamientos

Los modelos se entrenaron bajo una configuración estandarizada para permitir comparaciones consistentes. El protocolo de entrenamiento estableció un límite de 60,000 épocas, implementando un mecanismo de *early stopping* con una paciencia de 1,200 épocas para prevenir el sobreajuste y optimizar la eficiencia computacional.

La optimización se realizó mediante el algoritmo *Adam*, con una tasa de aprendizaje de $1e - 4$. Se implementó un sistema de *model checkpoints* para preservar el modelo con el menor error de validación. Los *batches* de entrenamiento se configuraron con un tamaño de 32 muestras. En los modelos de difusión, el positional encoding se configuró con una dimensión de 64.

El cálculo del error difiere entre los modelos DDPM y UNet. En DDPM, el error se cuantifica como la divergencia KL del ruido de las muestras del *batch* con pasos aleatorios de difusión. Esta métrica presenta mayor variabilidad y menor comparabilidad directa con el error de UNet. Una evaluación más precisa del error en DDPM requeriría el cálculo de todos los pasos de difusión en cada evaluación, lo cual excede las capacidades computacionales disponibles para este estudio. Esta limitación se ha considerado en el análisis e interpretación de los resultados.

5.4.1. Impacto del Número de Diffusion Steps

El número de pasos de difusión en los modelos de difusión probabilística determina la granularidad del proceso de eliminación y adición de ruido. Para evaluar el efecto de este parámetro en el rendimiento del modelo, se diseñó un experimento comparativo con cinco configuraciones: 10, 20, 50, 100 y 250 pasos de difusión. Estas configuraciones cubren un espectro desde un proceso de difusión con pocos pasos hasta uno con muchos pasos. Cada configuración se probó manteniendo constantes los demás parámetros del modelo, aislando así el efecto del número de pasos de difusión. Se analizó cómo cada configuración afectaba la precisión de la reconstrucción, las características visuales de las imágenes resultantes y el tiempo de procesamiento. Este experimento busca examinar la relación entre la calidad de la reconstrucción y la eficiencia computacional en la reconstrucción de imágenes astronómicas.

5.4.2. Impacto de la cantidad de datos

Para comprender cómo la cantidad de datos de entrenamiento afecta el rendimiento de los modelos de reconstrucción de imágenes astronómicas, se diseñó un conjunto de experimentos que varían el tamaño del conjunto de datos utilizado. El conjunto de datos completo se dividió inicialmente en un 80 % para entrenamiento y un 20 % para pruebas. A partir del conjunto de entrenamiento, se crearon subconjuntos que representaban el 10 %,

25 %, 50 %, 75 % y 100 % de los datos disponibles. Para cada subconjunto, se entrenó un modelo completo, manteniendo constantes todos los demás parámetros y la arquitectura. Posteriormente, se evaluó el rendimiento de cada modelo en el conjunto de prueba, que se mantuvo constante para todas las configuraciones. Este enfoque permite analizar cómo la cantidad de datos de entrenamiento influye en la capacidad del modelo para generalizar y producir reconstrucciones precisas.

5.4.3. Impacto del número de parámetros de la red

El estudio evaluó el efecto del número de parámetros en el rendimiento de la red mediante modificaciones de la arquitectura compartida de UNet. Se examinaron cuatro configuraciones con diferentes niveles de complejidad. La configuración reducida utiliza hasta la capa de 256 canales, con 665K parámetros. La configuración base emplea hasta la capa de 512 canales, con 2M parámetros. La configuración ampliada extiende la arquitectura con una capa adicional de 1024 canales, alcanzando 10M parámetros. La configuración extendida incorpora una capa de 2048 canales, llegando a 30M parámetros.

La evaluación de cada configuración se basó en la precisión de la reconstrucción, el tiempo de entrenamiento y la eficiencia computacional. Este enfoque permitió examinar la relación entre la complejidad del modelo y su rendimiento en la reconstrucción de imágenes astronómicas.

Cada configuración fue evaluada en términos de precisión en la reconstrucción, tiempo de entrenamiento y eficiencia computacional. Este enfoque permite una comprensión completa de los *trade-offs* entre la complejidad del modelo y su rendimiento, proporcionando información valiosa para optimizar la arquitectura de la red en futuras aplicaciones de reconstrucción de imágenes astronómicas.

5.4.4. Impacto de la Agregación

Los modelos de difusión generan variaciones en sus predicciones entre distintas iteraciones debido a la naturaleza estocástica del proceso de difusión. Para analizar esta variabilidad, se implementó una técnica de agregación de imágenes que consiste en generar y promediar múltiples imágenes a partir de la misma entrada.

Se realizaron experimentos con diferentes cantidades de imágenes agregadas: 1, 2, 3, 5, 6, 7, 8, 9, 10 y 25. Para cada configuración, se analizó el impacto en métricas de calidad como PSNR, SSIM, FFT MSE, KL Histogram, MAE, MSE, Central MAE y Central MSE. Se evaluó la relación entre la mejora en la calidad de la imagen y el aumento en el tiempo de computación requerido.

La agregación de múltiples predicciones permite estimar la varianza de la reconstrucción. Al aplicar un umbral de brillo específico (entre -1 y 1) para

distinguir entre regiones de galaxia y fondo, la variabilidad entre predicciones en cada píxel proporciona una medida de la certeza de la clasificación. Este método es particularmente útil para identificar galaxias contiguas más pequeñas o estructuras débiles que podrían no ser evidentes en una sola predicción o en los datos de entrada originales. Este enfoque de agregación ofrece una herramienta para evaluar la estabilidad de las predicciones y la varianza de cada píxel predicho.

Capítulo 6

Resultados

6.1. Exploración de Métricas

Para evaluar el rendimiento de las métricas propuestas se generaron matrices de similitud para cada métrica analizada, utilizando imágenes que incluían una galaxia elíptica simulada con niveles graduales de ruido gaussiano. Estas visualizaciones permiten comparar el rendimiento de las métricas en la cuantificación de similitud entre imágenes afectadas por distintos grados de ruido.

Las matrices de similitud se construyeron como cuadrículas donde filas y columnas representan las mismas imágenes, ordenadas por nivel de ruido. Cada celda contiene el valor de similitud calculado entre la imagen de la fila y la de la columna correspondientes.

Las métricas tradicionales como SSIM, PSNR, MAE y MSE, junto con sus variantes centradas, mostraron un patrón en forma de cuarto de circunferencia en sus matrices. Este patrón indica que estas métricas tienden a asignar mayor similitud a imágenes con menor nivel de ruido, incluso si el nivel de ruido difiere del original.

La divergencia de Kullback-Leibler (KL) aplicada a distribuciones de entropía e intensidad de histogramas mostró una diagonal más pronunciada en sus matrices, pero presentó limitaciones en consistencia y captura de información espacial directa para los distintos elementos.

El MSE de la Transformada Rápida de Fourier (FFT) mostró resultados prometedores, con una diagonal bien definida en su matriz de similitud. Esta métrica opera en el dominio de la frecuencia, permitiendo comparar componentes de frecuencia sensibles a estructura y ruido.

El MSE de la FFT mostró sensibilidad a patrones y estructuras en diferentes escalas espaciales, lo cual es relevante para imágenes astronómicas con características a diversas escalas.

La Figura 6.1 muestra las matrices de similitud para diversas métricas aplicadas a la simulación de una galaxia elíptica. Matrices de similitud adi-

cionales para otros tipos de imágenes se presentan en el Apéndice 7.5.

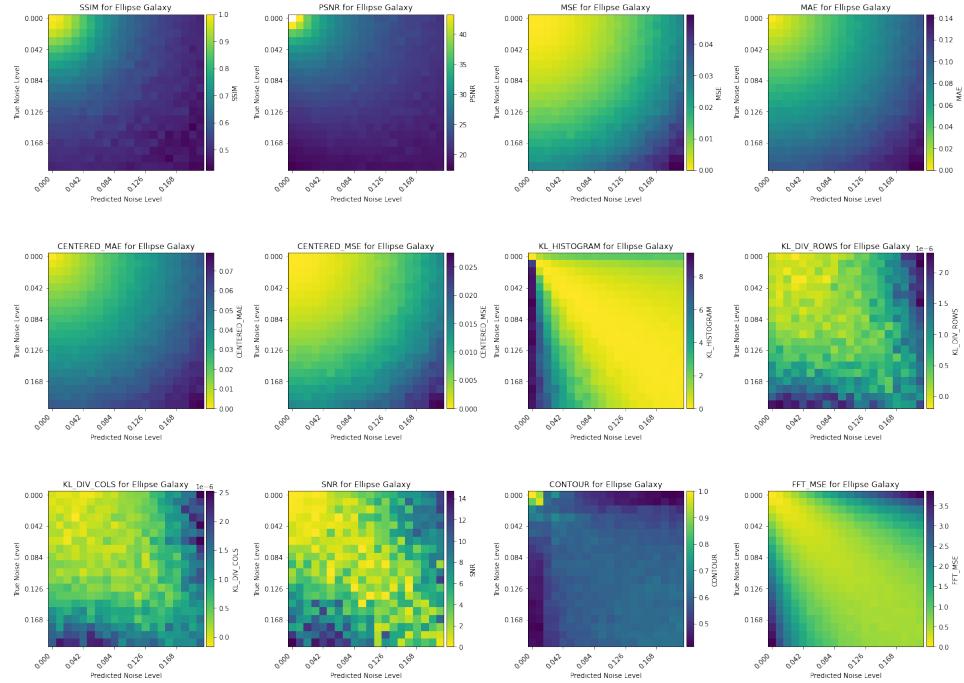


Figura 6.1: Matrices de similitud para diversas métricas aplicadas a la simulación de una galaxia elíptica

6.2. Experimentación de Modelos

Esta sección presenta los resultados de las diversas configuraciones experimentales para los modelos evaluados. Los datos se muestran en tablas, donde cada columna de métrica incluye una flecha indicativa: una flecha hacia abajo (\downarrow) señala que valores menores son preferibles, mientras que una flecha hacia arriba (\uparrow) indica que valores mayores son mejores. En las tablas, se han resaltado en negrita los mejores valores para cada métrica, y se han subrayado los segundos mejores. Las tablas de agregación no marcan los mejores resultados, como si se muestran en el resto de tablas, ya que su propósito es evaluar tendencias generales de cada métrica más que identificar resultados óptimos específicos.

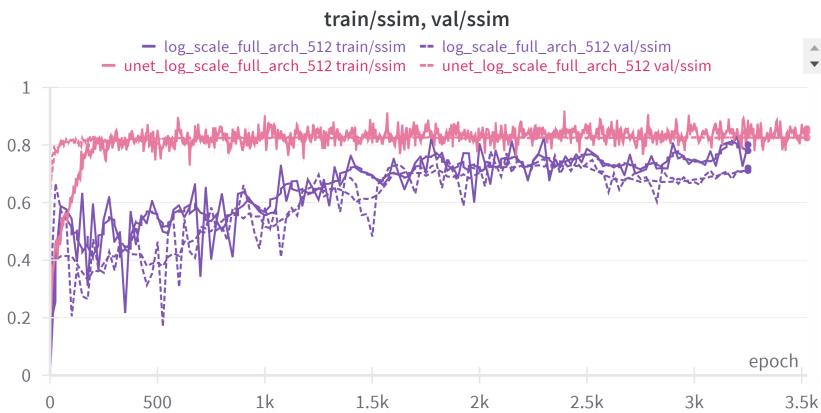


Figura 6.2: Evolución del *SSIM* durante el entrenamiento para la escala de datos logarítmica con el conjunto de datos completo. Se muestran las curvas de entrenamiento y validación para los modelos *UNet* y *DDPM*, ambos con una arquitectura de 2M de parámetros. La línea rosa continua representa el *SSIM* del conjunto de entrenamiento y la discontinua del mismo color el de validación. De manera similar, la línea morada continua representa el modelo *DDPM* en el subconjunto de entrenamiento y la discontinua los resultados del subconjunto de validación.

La Figura 6.2 ilustra la evolución de la métrica *SSIM* durante el entrenamiento. Se presenta la progresión del *SSIM* para la escala de datos logarítmica, utilizando el conjunto de datos completo. Las curvas muestran el comportamiento de los modelos *UNet* y *DDPM*, ambos con una arquitectura de 2M de parámetros, para los conjuntos de entrenamiento y validación.

6.2.1. Impacto del Número de Pasos de Difusión

El análisis del impacto del número de pasos de difusión reveló patrones según la escala de los datos y según el número de pasos de difusión.

En la escala logarítmica, tanto para las versiones completa como “*Clean 30*” de las imágenes, se observó una tendencia de mejora en el rendimiento al aumentar el número de pasos de difusión. Como se muestra en las Tablas 6.1 y 6.2, los modelos DDPM superaron consistentemente a la UNet base en métricas como el MSE de la FFT y la divergencia KL del histograma de intensidades. Esta superioridad fue notable en la capacidad de los modelos DDPM para preservar las características estructurales y la varianza de intensidades de las imágenes originales.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>Base - UNet</i>	0.6254 ± 0.7687	0.8772 ± 0.0855	32.6200 ± 3.4457	0.5666 ± 0.6532	0.0373 ± 0.0393	0.0029 ± 0.0079	0.0185 ± 0.0104	0.0006 ± 0.0006
<i>Steps 10 - DDPM</i>	0.3067 ± 0.4402	0.8619 ± 0.0895	31.5489 ± 3.5265	0.2183 ± 0.3310	0.0432 ± 0.0453	0.0039 ± 0.0101	0.0226 ± 0.0142	0.0009 ± 0.0011
<i>Steps 20 - DDPM</i>	0.3177 ± 0.4456	0.8512 ± 0.1047	31.0604 ± 3.7314	0.4633 ± 0.7373	0.0461 ± 0.0464	0.0043 ± 0.0108	0.0288 ± 0.0167	0.0013 ± 0.0015
<i>Steps 50 - DDPM</i>	0.2783 ± 0.4047	0.8523 ± 0.0986	31.2983 ± 3.8517	0.1812 ± 0.2096	0.0451 ± 0.0456	0.0041 ± 0.0102	0.0260 ± 0.0181	0.0012 ± 0.0016
<i>Steps 100 - DDPM</i>	0.2331 ± 0.3616	0.8495 ± 0.1134	31.2359 ± 3.9067	0.1378 ± 0.1817	0.0451 ± 0.0500	0.0045 ± 0.0126	0.0226 ± 0.0151	0.0009 ± 0.0013
<i>Steps 250 - DDPM</i>	0.2195 ± 0.3494	0.8310 ± 0.1238	30.4727 ± 4.0197	0.1679 ± 0.3106	0.0484 ± 0.0531	0.0052 ± 0.0138	0.0254 ± 0.0182	0.0012 ± 0.0023

Tabla 6.1: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Log Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>Base - UNet</i>	0.8589 ± 1.0662	0.8163 ± 0.1831	31.9258 ± 4.2065	1.4917 ± 2.2396	0.0414 ± 0.0475	0.0040 ± 0.0174	0.0237 ± 0.0195	0.0016 ± 0.0026
<i>Steps 10 - DDPM</i>	0.4637 ± 0.6446	0.7717 ± 0.2331	29.8775 ± 5.4277	1.1644 ± 3.3304	0.0652 ± 0.0771	0.0102 ± 0.0266	0.0479 ± 0.0635	0.0072 ± 0.0175
<i>Steps 20 - DDPM</i>	0.4018 ± 0.5650	0.7963 ± 0.1960	30.6069 ± 4.9617	0.9605 ± 3.4392	0.0532 ± 0.0599	0.0064 ± 0.0191	0.0319 ± 0.0372	0.0031 ± 0.0068
<i>Steps 50 - DDPM</i>	0.3256 ± 0.4755	0.7235 ± 0.2337	27.4745 ± 5.6341	2.1895 ± 5.3007	0.0809 ± 0.1235	0.0233 ± 0.0909	0.0576 ± 0.0982	0.0141 ± 0.0686
<i>Steps 100 - DDPM</i>	0.3035 ± 0.4520	0.7706 ± 0.2082	29.7876 ± 4.3293	0.7112 ± 2.6588	0.0552 ± 0.0579	0.0064 ± 0.0210	0.0360 ± 0.0282	0.0029 ± 0.0053
<i>Steps 250 - DDPM</i>	0.2617 ± 0.4265	0.7375 ± 0.2223	28.3513 ± 4.9719	0.6019 ± 2.4428	0.0693 ± 0.0782	0.0109 ± 0.0296	0.0428 ± 0.0496	0.0056 ± 0.0134

Tabla 6.2: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Log Scale. Conjunto de datos: Full.

Los datos en escala de raíz cuadrada, representada en las Tablas 6.3 y 6.4, mostrarán resultados similares a los de escala logarítmica en términos del MSE de la FFT, con los modelos DDPM de mayor número de pasos manteniendo su ventaja. Sin embargo, se observó una inversión en la tendencia de la divergencia KL del histograma, donde los modelos DDPM con menor número de pasos parecían tener un mejor desempeño. Este fenómeno sugiere que la escala de raíz cuadrada puede estar resaltando aspectos de la distribución de intensidades que son mejor capturados por modelos con menos pasos de difusión o que la métrica no es suficiente robusta para analizar datos a esta escala.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>Base - UNet</i>	0.1273 ± 0.2223	0.9730 ± 0.0286	41.2363 ± 3.9788	0.2908 ± 0.5510	0.0154 ± 0.0142	0.0004 ± 0.0010	0.0172 ± 0.0092	0.0005 ± 0.0005
<i>Steps 10 - DDPM</i>	0.0992 ± 0.1760	0.9665 ± 0.0275	39.8000 ± 3.0892	0.3041 ± 0.5534	0.0175 ± 0.0150	0.0005 ± 0.0011	0.0197 ± 0.0106	0.0007 ± 0.0007
<i>Steps 20 - DDPM</i>	0.0960 ± 0.1785	0.9695 ± 0.0314	39.4595 ± 3.8285	0.2508 ± 0.3434	0.0192 ± 0.0168	0.0007 ± 0.0013	0.0223 ± 0.0138	0.0009 ± 0.0010
<i>Steps 50 - DDPM</i>	0.0915 ± 0.1468	0.9547 ± 0.0390	38.3239 ± 3.7775	0.2772 ± 0.4760	0.0216 ± 0.0186	0.0008 ± 0.0016	0.0250 ± 0.0135	0.0010 ± 0.0010
<i>Steps 100 - DDPM</i>	0.0751 ± 0.1343	0.9630 ± 0.0393	37.5774 ± 4.2024	0.6194 ± 0.9674	0.0251 ± 0.0206	0.0011 ± 0.0019	0.0247 ± 0.0158	0.0010 ± 0.0011
<i>Steps 250 - DDPM</i>	0.0669 ± 0.1249	0.9600 ± 0.0452	37.3285 ± 3.5599	0.6808 ± 1.2286	0.0247 ± 0.0199	0.0010 ± 0.0014	0.0238 ± 0.0156	0.0010 ± 0.0013

Tabla 6.3: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
Base - UNet	0.4139 ± 0.8783	0.8859 ± 0.1947	38.9404 ± 6.6994	1.1096 ± 2.0748	0.0253 ± 0.0368	0.0020 ± 0.0085	0.0244 ± 0.0218	0.0016 ± 0.0028
Steps 10 - DDPM	0.2783 ± 0.4936	0.8436 ± 0.196	34.5439 ± 5.7466	0.6186 ± 0.9963	0.0391 ± 0.0471	0.0037 ± 0.0121	0.0406 ± 0.0311	0.0036 ± 0.0056
Steps 20 - DDPM	1.2302 ± 1.1633	0.4952 ± 0.1254	24.8917 ± 2.2136	0.5694 ± 0.5526	0.0958 ± 0.0749	0.0148 ± 0.0239	0.0945 ± 0.0240	0.0144 ± 0.0074
Steps 50 - DDPM	0.1690 ± 0.3675	0.8682 ± 0.2192	37.1572 ± 7.2302	0.2868 ± 0.4063	0.0328 ± 0.0477	0.0034 ± 0.0127	0.0362 ± 0.0372	0.0037 ± 0.0067
Steps 100 - DDPM	0.1456 ± 0.3196	0.8585 ± 0.2423	37.4494 ± 7.6605	0.3491 ± 1.1050	0.0346 ± 0.0572	0.0045 ± 0.0176	0.0340 ± 0.0410	0.0040 ± 0.0099
Steps 250 - DDPM	0.1322 ± 0.3146	0.8497 ± 0.2486	36.9372 ± 7.7831	0.3233 ± 1.1389	0.0364 ± 0.0596	0.0049 ± 0.0185	0.0374 ± 0.0444	0.0047 ± 0.0124

Tabla 6.4: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Sqrt Scale. Conjunto de datos: Full.

En la escala lineal, los resultados para la versión completa de las imágenes (Tabla 6.6) mostraron tendencias similares a las observadas en la escala logarítmica, aunque con diferencias menos pronunciadas entre los modelos. Esto indica que la escala lineal puede estar suavizando algunas de las diferencias sutiles que son más evidentes en la escala logarítmica. Para la versión limpia en escala lineal (Tabla 6.5), las diferencias de rendimiento entre las configuraciones fueron tan mínimas que no se pudo establecer una superioridad clara de un modelo sobre otro en ninguna de las métricas evaluadas al tener una desviación estándar mayor a sus diferencias.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
Base - UNet	0.0148 ± 0.0670	0.9941 ± 0.0061	46.3564 ± 3.4079	0.0776 ± 0.0465	0.0076 ± 0.0095	0.0001 ± 0.0009	0.0137 ± 0.0081	0.0005 ± 0.0006
Steps 10 - DDPM	0.0473 ± 0.0897	0.9877 ± 0.0107	44.6906 ± 3.7476	0.0788 ± 0.0550	0.0094 ± 0.0099	0.0002 ± 0.0009	0.0151 ± 0.0077	0.0005 ± 0.0006
Steps 20 - DDPM	0.0109 ± 0.0270	0.9939 ± 0.0074	46.7614 ± 4.5823	0.0630 ± 0.0319	0.0068 ± 0.0100	0.0001 ± 0.0011	0.0145 ± 0.0102	0.0005 ± 0.0008
Steps 50 - DDPM	0.0285 ± 0.0626	0.9906 ± 0.0078	41.4484 ± 5.4121	0.7439 ± 1.3756	0.0169 ± 0.0164	0.0006 ± 0.0021	0.0238 ± 0.0141	0.0011 ± 0.0011
Steps 100 - DDPM	0.0113 ± 0.0269	0.9941 ± 0.0058	46.8284 ± 4.2583	0.0591 ± 0.0291	0.0060 ± 0.0099	0.0001 ± 0.0009	0.0151 ± 0.0095	0.0006 ± 0.0007
Steps 250 - DDPM	0.0118 ± 0.0296	0.9933 ± 0.0080	44.8687 ± 4.4817	0.1025 ± 0.1132	0.0090 ± 0.0117	0.0002 ± 0.0016	0.0173 ± 0.0107	0.0007 ± 0.0011

Tabla 6.5: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
Base - UNet	0.1799 ± 0.5292	0.9405 ± 0.1266	44.2514 ± 7.7717	1.0933 ± 2.5707	0.0148 ± 0.0271	0.0010 ± 0.0077	0.0196 ± 0.0207	0.0014 ± 0.0026
Steps 10 - DDPM	0.1623 ± 0.4370	0.9299 ± 0.1300	39.8007 ± 7.4943	1.2583 ± 3.4206	0.0232 ± 0.0358	0.0018 ± 0.0097	0.0332 ± 0.0319	0.0031 ± 0.0063
Steps 20 - DDPM	0.1142 ± 0.3167	0.9312 ± 0.1366	41.5805 ± 7.7352	0.4911 ± 0.8602	0.0193 ± 0.0315	0.0014 ± 0.0090	0.0264 ± 0.0252	0.0021 ± 0.0039
Steps 50 - DDPM	0.1881 ± 0.3090	0.8937 ± 0.1523	32.9681 ± 6.3549	2.8793 ± 4.4457	0.0490 ± 0.0439	0.0043 ± 0.0114	0.0622 ± 0.0329	0.0063 ± 0.0061
Steps 100 - DDPM	0.0724 ± 0.2325	0.9219 ± 0.1596	41.3297 ± 7.7342	0.1518 ± 0.2425	0.0183 ± 0.0359	0.0016 ± 0.0103	0.0293 ± 0.0285	0.0029 ± 0.0052
Steps 250 - DDPM	0.0725 ± 0.2229	0.9184 ± 0.1665	40.8577 ± 8.1110	0.2484 ± 0.4773	0.0223 ± 0.0376	0.0019 ± 0.0098	0.0301 ± 0.0283	0.0026 ± 0.0045

Tabla 6.6: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Linear Scale. Conjunto de datos: Full.

Los resultados muestran variaciones en el rendimiento de los modelos según las métricas utilizadas. Las métricas capaces de captar la varianza de los píxeles (generalmente las zonas de menos intensidad) tienden a favorecer a los modelos DDPM con mayor número de pasos de difusión, como se observa en los valores de FFT MSE y *KL histogram* en todas las tablas. Por otro lado, métricas como SSIM y PSNR generalmente muestran mejores resultados para la arquitectura UNet base. Esta variación en los resultados según las diferentes métricas es debido a como estas últimas favorecen a imágenes borrosas frente a imágenes que mantienen las estructuras finas.

6.2.2. Impacto del Porcentaje de Datos

Para este análisis se evaluó el rendimiento como el porcentaje de datos utilizados para el entrenamiento afectan a su capacidad de generalizar y su rendimiento.

En la escala logarítmica, para el conjunto de datos “*Clean 30*”, los modelos DDPM mostraron un rendimiento superior en las métricas FFT MSE y divergencia KL del histograma de intensidades. El rendimiento de DDPM mejoró con el aumento de datos hasta alcanzar el 50 % del conjunto, donde las mejoras en las métricas se estabilizaron. Para las demás métricas, tanto UNet como DDPM mostraron mejoras graduales al incrementar el volumen de datos. DDPM presentó un rendimiento inferior en escenarios de datos limitados, pero en configuraciones con mayor cantidad de datos, ambos modelos alcanzaron un rendimiento similar, con diferencias dentro del margen de la desviación típica. Los resultados en escala logarítmica para el conjunto de datos “*Full*” mostraron tendencias parecidas a las de “*Clean 30*”. Se observó una mejora en el rendimiento al aumentar el volumen de datos, con las métricas relacionadas con el ruido favoreciendo a DDPM y las restantes a UNet. DDPM requirió un volumen mayor de datos para igualar el rendimiento de UNet en este escenario. También se puede observar la incapacidad de UNet a predecir detalles finos al fijarnos en la constancia de sus resultados en la métrica FFT MSE.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - <i>DDPM</i>	0.3015 ± 0.4366	0.6668 ± 0.2035	24.5174 ± 4.5456	2.3269 ± 3.0329	0.1160 ± 0.1013	0.0237 ± 0.0403	0.0620 ± 0.0484	0.0072 ± 0.0124
10 % - <i>UNET</i>	0.6016 ± 0.7380	0.8685 ± 0.0938	31.5711 ± 3.5256	0.5313 ± 0.9092	0.0422 ± 0.0442	0.0037 ± 0.0095	0.0206 ± 0.0137	0.0008 ± 0.0013
25 % - <i>DDPM</i>	0.2592 ± 0.3945	0.6241 ± 0.2083	22.1641 ± 5.0059	1.6104 ± 2.3736	0.1683 ± 0.1282	0.0447 ± 0.0673	0.1220 ± 0.0929	0.0246 ± 0.0390
25 % - <i>UNET</i>	0.5993 ± 0.7501	0.8712 ± 0.0922	32.1371 ± 3.5138	0.7473 ± 1.2750	0.0399 ± 0.0416	0.0033 ± 0.0067	0.0210 ± 0.0122	0.0008 ± 0.0010
50 % - <i>DDPM</i>	0.2344 ± 0.3639	0.8883 ± 0.1095	30.2845 ± 4.0958	0.1826 ± 0.2107	0.0522 ± 0.0532	0.0055 ± 0.0133	0.0273 ± 0.0157	0.0012 ± 0.0012
50 % - <i>UNET</i>	0.6191 ± 0.7572	0.8753 ± 0.0876	32.7118 ± 3.7524	0.5789 ± 0.8188	0.0372 ± 0.0393	0.0029 ± 0.0078	0.0188 ± 0.0115	0.0006 ± 0.0008
75 % - <i>DDPM</i>	0.2571 ± 0.3906	0.8493 ± 0.0999	30.8458 ± 3.8842	0.2009 ± 0.2494	0.0476 ± 0.0477	0.0045 ± 0.0108	0.0247 ± 0.0151	0.0011 ± 0.0012
75 % - <i>UNET</i>	0.6174 ± 0.7627	0.8782 ± 0.0886	32.8057 ± 3.9592	0.6669 ± 1.0444	0.0371 ± 0.0400	0.0030 ± 0.0080	0.0181 ± 0.0111	0.0006 ± 0.0008
100 % - <i>DDPM</i>	0.2710 ± 0.4015	0.8531 ± 0.1001	31.2053 ± 3.8923	0.2433 ± 0.3454	0.0457 ± 0.0464	0.0042 ± 0.0104	0.0258 ± 0.0194	0.0013 ± 0.0020
100 % - <i>UNET</i>	0.6254 ± 0.7687	0.8772 ± 0.0855	32.6200 ± 3.4457	0.5666 ± 0.6532	0.0373 ± 0.0393	0.0029 ± 0.0079	0.0185 ± 0.0104	0.0006 ± 0.0006

Tabla 6.7: Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Log Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - <i>DDPM</i>	0.3603 ± 0.5222	0.4495 ± 0.3060	20.3304 ± 5.7528	5.9981 ± 8.0509	0.2222 ± 0.1864	0.0841 ± 0.1318	0.1683 ± 0.1351	0.0496 ± 0.0792
10 % - <i>UNET</i>	0.8200 ± 1.0260	0.8002 ± 0.1848	30.9341 ± 4.0271	1.5428 ± 3.1048	0.0475 ± 0.0526	0.0050 ± 0.0190	0.0294 ± 0.0265	0.0023 ± 0.0051
25 % - <i>DDPM</i>	0.3033 ± 0.4600	0.5455 ± 0.2816	22.4598 ± 5.7813	3.8650 ± 6.2061	0.1683 ± 0.1521	0.0515 ± 0.0918	0.1133 ± 0.0964	0.0244 ± 0.0388
25 % - <i>UNET</i>	0.8391 ± 1.0507	0.8043 ± 0.1897	31.1371 ± 4.2380	1.8275 ± 3.5410	0.0466 ± 0.0533	0.0050 ± 0.0199	0.0285 ± 0.0278	0.0024 ± 0.0051
50 % - <i>DDPM</i>	0.3108 ± 0.4684	0.4465 ± 0.3209	20.4348 ± 6.0565	4.1281 ± 6.1526	0.2203 ± 0.1696	0.0773 ± 0.1078	0.1686 ± 0.1286	0.0482 ± 0.0633
50 % - <i>UNET</i>	0.8453 ± 1.0611	0.8056 ± 0.1860	31.2168 ± 3.8920	1.2931 ± 2.8971	0.0463 ± 0.0499	0.0046 ± 0.0169	0.0278 ± 0.0259	0.0021 ± 0.0046
75 % - <i>DDPM</i>	0.3496 ± 0.5081	0.4084 ± 0.3132	19.3961 ± 5.7616	8.4047 ± 8.6645	0.2417 ± 0.2082	0.1017 ± 0.1730	0.1392 ± 0.1123	0.0359 ± 0.0682
75 % - <i>UNET</i>	0.8584 ± 1.0677	0.8102 ± 0.1912	31.7545 ± 4.1998	1.6973 ± 3.1909	0.0431 ± 0.0495	0.0043 ± 0.0177	0.0260 ± 0.0236	0.0019 ± 0.0035
100 % - <i>DDPM</i>	0.2707 ± 0.4282	0.7398 ± 0.2252	27.9644 ± 4.9054	1.0170 ± 3.5706	0.0761 ± 0.0798	0.0122 ± 0.0289	0.0513 ± 0.0560	0.0070 ± 0.0145
100 % - <i>UNET</i>	0.8589 ± 1.0662	0.8163 ± 0.1831	31.9258 ± 4.2065	1.4917 ± 2.2396	0.0414 ± 0.0475	0.0040 ± 0.0174	0.0237 ± 0.0195	0.0016 ± 0.0026

Tabla 6.8: Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Log Scale. Conjunto de datos: Full.

En la escala de raíz cuadrada para el conjunto “Clean 30”, los patrones fueron similares a los de la escala logarítmica. Debido a la disminución del *SNR* en esta escala, las métricas FFT MSE y KL Histogram mostraron resultados más equiparables entre DDPM y UNet. DDPM siguió requiriendo más datos para alcanzar un rendimiento comparable al de UNet en otras métricas y UNet no muestra un aumento en FFT MSE entre más datos se usen para entrenar.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - <i>DDPM</i>	0.5068 ± 0.8641	0.6455 ± 0.2790	20.6010 ± 7.4515	12.5360 ± 7.9282	0.2407 ± 0.1671	0.0859 ± 0.1080	0.2066 ± 0.1217	0.0632 ± 0.0646
10 % - <i>UNET</i>	0.1275 ± 0.2151	0.9678 ± 0.0305	39.6252 ± 3.3630	0.2521 ± 0.3094	0.0177 ± 0.0163	0.0006 ± 0.0015	0.0241 ± 0.0126	0.0009 ± 0.0009
25 % - <i>DDPM</i>	0.1464 ± 0.2718	0.9176 ± 0.0834	29.7513 ± 6.7805	5.5713 ± 7.1653	0.0814 ± 0.0732	0.0120 ± 0.0211	0.0633 ± 0.0534	0.0074 ± 0.0123
25 % - <i>UNET</i>	0.1281 ± 0.2209	0.9723 ± 0.0288	40.9778 ± 3.6467	0.3231 ± 0.5544	0.0154 ± 0.0145	0.0004 ± 0.0010	0.0178 ± 0.0091	0.0005 ± 0.0006
50 % - <i>DDPM</i>	0.1506 ± 0.2466	0.9298 ± 0.0514	30.9022 ± 5.0242	3.4306 ± 4.4335	0.0623 ± 0.0463	0.0061 ± 0.0083	0.0508 ± 0.0365	0.0043 ± 0.0060
50 % - <i>UNET</i>	0.1276 ± 0.2207	0.9721 ± 0.0293	40.9860 ± 4.0137	0.4565 ± 0.8113	0.0159 ± 0.0153	0.0005 ± 0.0012	0.0187 ± 0.0109	0.0006 ± 0.0007
75 % - <i>DDPM</i>	0.4401 ± 0.6244	0.7843 ± 0.1569	23.4793 ± 6.7852	12.5433 ± 7.6626	0.1610 ± 0.1099	0.0380 ± 0.0469	0.1092 ± 0.0746	0.0201 ± 0.0251
75 % - <i>UNET</i>	0.1377 ± 0.2349	0.9730 ± 0.0291	41.0437 ± 3.8646	0.4061 ± 0.6829	0.0156 ± 0.0144	0.0005 ± 0.0011	0.0181 ± 0.0098	0.0005 ± 0.0006
100 % - <i>DDPM</i>	0.0915 ± 0.1468	0.9547 ± 0.0390	38.3239 ± 3.7778	0.2772 ± 0.4760	0.0216 ± 0.0186	0.0008 ± 0.0016	0.0250 ± 0.0135	0.0010 ± 0.0010
100 % - <i>UNET</i>	0.1273 ± 0.2223	0.9730 ± 0.0286	41.2363 ± 3.9788	0.2908 ± 0.5510	0.0154 ± 0.0142	0.0004 ± 0.0010	0.0172 ± 0.0092	0.0005 ± 0.0005

Tabla 6.9: Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - <i>DDPM</i>	0.2337 ± 0.4153	0.7388 ± 0.3028	24.2048 ± 7.6804	10.1420 ± 8.8887	0.1629 ± 0.1357	0.0449 ± 0.0660	0.1337 ± 0.1052	0.0323 ± 0.0428
10 % - <i>UNET</i>	0.3805 ± 0.8273	0.8760 ± 0.2128	37.6693 ± 7.0696	1.6065 ± 3.9461	0.0313 ± 0.0505	0.0036 ± 0.0146	0.0304 ± 0.0380	0.0032 ± 0.0083
25 % - <i>DDPM</i>	0.1504 ± 0.3267	0.8652 ± 0.2311	37.1167 ± 6.7552	0.4885 ± 1.1875	0.0318 ± 0.0466	0.0032 ± 0.0130	0.0314 ± 0.0309	0.0029 ± 0.0055
25 % - <i>UNET</i>	0.4023 ± 0.8625	0.8824 ± 0.1991	38.4193 ± 6.9544	1.1100 ± 2.0057	0.0268 ± 0.0406	0.0024 ± 0.0104	0.0272 ± 0.0274	0.0023 ± 0.0045
50 % - <i>DDPM</i>	0.1667 ± 0.3622	0.8694 ± 0.2259	37.1724 ± 7.1511	0.5495 ± 1.2239	0.0330 ± 0.0495	0.0035 ± 0.0160	0.0325 ± 0.0429	0.0041 ± 0.0155
50 % - <i>UNET</i>	0.4074 ± 0.8660	0.8830 ± 0.2003	38.9713 ± 7.3424	1.3836 ± 2.5577	0.0271 ± 0.0418	0.0025 ± 0.0101	0.0267 ± 0.0283	0.0022 ± 0.0043
75 % - <i>DDPM</i>	0.1531 ± 0.3316	0.8682 ± 0.2261	37.1598 ± 6.7757	0.4622 ± 1.1229	0.0316 ± 0.0448	0.0030 ± 0.0116	0.0290 ± 0.0287	0.0025 ± 0.0047
75 % - <i>UNET</i>	0.3883 ± 0.8333	0.8805 ± 0.1997	38.4214 ± 6.9857	1.2968 ± 3.0177	0.0276 ± 0.0426	0.0026 ± 0.0103	0.0277 ± 0.0272	0.0022 ± 0.0042
100 % - <i>DDPM</i>	0.3256 ± 0.4755	0.7235 ± 0.2337	27.4745 ± 5.6341	2.1895 ± 5.3007	0.0899 ± 0.1235	0.0233 ± 0.0099	0.0576 ± 0.0982	0.0141 ± 0.0686
100 % - <i>UNET</i>	0.4139 ± 0.8783	0.8859 ± 0.1947	38.9404 ± 6.6994	1.1096 ± 2.0748	0.0253 ± 0.0368	0.0020 ± 0.0085	0.0244 ± 0.0218	0.0016 ± 0.0028

Tabla 6.10: Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Sqrt Scale. Conjunto de datos: Full.

Para la escala lineal, tanto en los conjuntos “Clean 30” como “Full”, el impacto del aumento de datos fue menos pronunciado. Se observaron mejoras en el rendimiento con más datos, pero estos incrementos fueron más ligeros que en el resto de escalas, indicando una menor sensibilidad de esta escala a las variaciones en el volumen de datos de entrenamiento. Esto se debe posiblemente a la baja presencia de detalles finos y su alto nivel de PSR.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - <i>DDPM</i>	0.3847 ± 0.7524	0.8874 ± 0.1688	33.4711 ± 9.2080	4.4361 ± 6.7048	0.0692 ± 0.0839	0.0118 ± 0.0267	0.0742 ± 0.0764	0.0125 ± 0.0229
10 % - <i>UNET</i>	0.0625 ± 0.2273	0.9793 ± 0.0077	41.6436 ± 2.3223	0.1200 ± 0.0431	0.0156 ± 0.0150	0.0005 ± 0.0023	0.0211 ± 0.0079	0.0009 ± 0.0007
25 % - <i>DDPM</i>	0.1871 ± 0.3398	0.9507 ± 0.0596	35.1081 ± 7.3113	3.8969 ± 5.5604	0.0443 ± 0.0388	0.0035 ± 0.0063	0.0436 ± 0.0321	0.0039 ± 0.0050
25 % - <i>UNET</i>	0.0122 ± 0.0353	0.9944 ± 0.0065	46.7535 ± 4.0824	0.0653 ± 0.0523	0.0065 ± 0.0098	0.0001 ± 0.0010	0.0143 ± 0.0095	0.0005 ± 0.0008
50 % - <i>DDPM</i>	0.0161 ± 0.0337	0.9929 ± 0.0062	43.3260 ± 4.4515	0.1719 ± 0.3742	0.0115 ± 0.0127	0.0003 ± 0.0014	0.0203 ± 0.0115	0.0008 ± 0.0009
50 % - <i>UNET</i>	0.0123 ± 0.0361	0.9947 ± 0.0059	47.0599 ± 4.0804	0.0781 ± 0.1170	0.0063 ± 0.0093	0.0001 ± 0.0011	0.0133 ± 0.0078	0.0004 ± 0.0006
75 % - <i>DDPM</i>	0.0242 ± 0.0442	0.9917 ± 0.0070	44.1269 ± 3.7962	0.1182 ± 0.1558	0.0097 ± 0.0114	0.0002 ± 0.0017	0.0175 ± 0.0093	0.0007 ± 0.0010
75 % - <i>UNET</i>	0.0119 ± 0.0357	0.9955 ± 0.0053	48.3788 ± 4.5083	0.0605 ± 0.0381	0.0051 ± 0.0087	0.0001 ± 0.0009	0.0121 ± 0.0082	0.0004 ± 0.0006
100 % - <i>DDPM</i>	0.0285 ± 0.0626	0.9906 ± 0.0078	41.4484 ± 5.4121	0.7439 ± 1.3756	0.0169 ± 0.0164	0.0006 ± 0.0021	0.0238 ± 0.0141	0.0011 ± 0.0011
100 % - <i>UNET</i>	0.0148 ± 0.0670	0.9941 ± 0.0061	46.3564 ± 3.4079	0.0776 ± 0.0465	0.0076 ± 0.0095	0.0001 ± 0.0009	0.0137 ± 0.0081	0.0005 ± 0.0006

Tabla 6.11: Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - <i>DDPM</i>	0.0775 ± 0.2484	0.9260 ± 0.1522	41.3579 ± 7.5033	0.3150 ± 0.6589	0.0194 ± 0.0344	0.0016 ± 0.0097	0.0291 ± 0.0288	0.0025 ± 0.0051
10 % - <i>UNET</i>	0.1755 ± 0.5098	0.9378 ± 0.1305	42.9030 ± 7.8664	1.5959 ± 4.2075	0.0175 ± 0.0335	0.0014 ± 0.0097	0.0242 ± 0.0292	0.0023 ± 0.0057
25 % - <i>DDPM</i>	0.1335 ± 0.2972	0.8934 ± 0.1756	33.1630 ± 8.7321	8.5411 ± 11.0359	0.0637 ± 0.0740	0.0095 ± 0.0213	0.0718 ± 0.0595	0.0101 ± 0.0150
25 % - <i>UNET</i>	0.1751 ± 0.5127	0.9389 ± 0.1291	44.1885 ± 8.0847	0.7881 ± 1.8124	0.0147 ± 0.0304	0.0011 ± 0.0087	0.0215 ± 0.0269	0.0020 ± 0.0057
50 % - <i>DDPM</i>	0.0834 ± 0.2563	0.9291 ± 0.1470	42.6319 ± 7.4223	0.1801 ± 0.2660	0.0161 ± 0.0309	0.0012 ± 0.0095	0.0237 ± 0.0221	0.0018 ± 0.0032
50 % - <i>UNET</i>	0.1777 ± 0.5208	0.9390 ± 0.1272	43.9338 ± 7.7514	0.8689 ± 2.0925	0.0147 ± 0.0286	0.0010 ± 0.0085	0.0207 ± 0.0221	0.0015 ± 0.0031
75 % - <i>DDPM</i>	0.0872 ± 0.2762	0.9298 ± 0.1442	42.6756 ± 7.8664	0.1663 ± 0.2836	0.0164 ± 0.0330	0.0014 ± 0.0108	0.0256 ± 0.0262	0.0024 ± 0.0057
75 % - <i>UNET</i>	0.1770 ± 0.5227	0.9405 ± 0.1277	43.4565 ± 7.3184	0.8833 ± 1.9769	0.0164 ± 0.0273	0.0010 ± 0.0084	0.0202 ± 0.0205	0.0014 ± 0.0027
100 % - <i>DDPM</i>	0.1881 ± 0.3090	0.8937 ± 0.1523	32.9681 ± 6.3549	2.8793 ± 4.4457	0.0490 ± 0.0439	0.0043 ± 0.0114	0.0622 ± 0.0329	0.0063 ± 0.0061
100 % - <i>UNET</i>	0.1799 ± 0.5292	0.9405 ± 0.1266	44.2514 ± 7.7717	1.0933 ± 2.5707	0.0148 ± 0.0271	0.0010 ± 0.0077	0.0196 ± 0.0207	0.0014 ± 0.0026

Tabla 6.12: Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Linear Scale. Conjunto de datos: Full.

6.2.3. Impacto del Número de Parámetros de la Red

Este experimento evaluó cómo el número de parámetros en la arquitectura de la red afecta el rendimiento de los modelos en diferentes escalas y conjuntos de datos.

Para la escala logarítmica, tanto en el conjunto de datos “*Full*” como en el “*Clean 30*”, los resultados mostraron patrones similares, como se puede ver en las Tablas 6.14 y 6.13. El aumento en el número de parámetros no se tradujo en mejoras en el rendimiento del modelo a partir de los 2M o 10M de parámetros. Las diferencias observadas entre las distintas configuraciones de parámetros fueron generalmente menores que la desviación típica de cada métrica lo que indica que para este conjunto de datos, aumentar el tamaño de la red a partir de los 10M de parámetros no se translada en una mejora del rendimiento.

Este patrón se repitió a través de las diferentes escalas de datos analizadas (Tablas 6.16, 6.15, 6.18 y 6.17), incluyendo la escala de raíz cuadrada y la escala lineal. En todos los casos, no se observó una tendencia clara de mejora en el rendimiento al aumentar el número de parámetros más allá de los 10M de parámetros.

Notablemente, los modelos con 2M y 10M de parámetros tendieron a obtener los mejores resultados en la mayoría de las métricas evaluadas. Este comportamiento se observó de manera consistente en todas las escalas y conjuntos de datos analizados.

La falta de mejora significativa con el aumento de parámetros se observó de manera uniforme en todas las métricas evaluadas, incluyendo aquellas que miden la calidad general de la reconstrucción y las que se enfocan en aspectos específicos como la preservación de la varianza o la estructura de la imagen.

Experiment	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.2425 ± 0.3734	0.7806 ± 0.1340	27.9136 ± 4.8536	0.2919 ± 0.2896	0.0795 ± 0.0677	0.0109 ± 0.0194	0.0570 ± 0.0355	0.0048 ± 0.0055	
<i>665K - UNET</i>	0.6017 ± 0.7514	0.8752 ± 0.0874	32.6673 ± 7.7739	0.6280 ± 0.9717	0.0375 ± 0.0402	0.0390 ± 0.0082	0.0189 ± 0.0112	0.0007 ± 0.0008	
<i>2M - DDPM</i>	0.2710 ± 0.4015	0.8531 ± 0.1001	31.2053 ± 3.8929	0.2433 ± 0.3454	0.0457 ± 0.0464	0.0042 ± 0.0104	0.0258 ± 0.0194	0.0013 ± 0.0020	
<i>2M - UNET</i>	0.6254 ± 0.7687	0.8772 ± 0.0855	32.6200 ± 3.4457	0.5666 ± 0.6532	0.0373 ± 0.0393	0.0029 ± 0.0079	0.0185 ± 0.0104	0.0006 ± 0.0006	
<i>10M - DDPM</i>	0.2298 ± 0.3552	0.8161 ± 0.1147	28.6364 ± 3.4383	0.6243 ± 0.9667	0.0618 ± 0.0587	0.0073 ± 0.0153	0.0273 ± 0.0214	0.0015 ± 0.0030	
<i>10M - UNET</i>	0.6167 ± 0.7605	0.8750 ± 0.0892	32.5641 ± 3.4864	0.5008 ± 0.6643	0.0375 ± 0.0396	0.0030 ± 0.0081	0.0199 ± 0.0117	0.0007 ± 0.0007	
<i>30M - DDPM</i>	0.2731 ± 0.4004	0.8342 ± 0.1134	29.4540 ± 3.7745	0.7585 ± 1.3461	0.0571 ± 0.0550	0.0063 ± 0.0137	0.0270 ± 0.0217	0.0015 ± 0.0025	
<i>30M - UNET</i>	0.6262 ± 0.7724	0.8757 ± 0.0893	32.5903 ± 3.5676	0.4996 ± 0.7116	0.0379 ± 0.0402	0.0030 ± 0.0082	0.0185 ± 0.0113	0.0006 ± 0.0007	

Tabla 6.13: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Clean 30.

Experiment	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.5919 ± 0.7340	0.5515 ± 0.1710	23.8730 ± 3.5300	1.1955 ± 3.7025	0.1128 ± 0.1017	0.0231 ± 0.0455	0.0755 ± 0.0519	0.0117 ± 0.0207	
<i>665K - UNET</i>	0.8754 ± 1.0749	0.8114 ± 0.1850	31.7784 ± 4.1824	1.7807 ± 3.4117	0.0428 ± 0.0476	0.0041 ± 0.0171	0.0257 ± 0.0234	0.0018 ± 0.0035	
<i>2M - DDPM</i>	0.2707 ± 0.4282	0.7398 ± 0.2252	27.9644 ± 4.9054	1.0170 ± 3.5706	0.0761 ± 0.0798	0.0122 ± 0.0289	0.0513 ± 0.0560	0.0070 ± 0.0145	
<i>2M - UNET</i>	0.8589 ± 1.0662	0.8163 ± 0.1831	31.9258 ± 4.2065	1.4917 ± 2.2306	0.0414 ± 0.0475	0.0040 ± 0.0174	0.0237 ± 0.0195	0.0016 ± 0.0026	
<i>10M - DDPM</i>	0.4356 ± 0.5702	0.1486 ± 0.3613	15.6133 ± 6.0380	14.3965 ± 9.2546	0.3865 ± 0.2801	0.2273 ± 0.2873	0.2438 ± 0.1841	0.0993 ± 0.1510	
<i>10M - UNET</i>	0.8633 ± 0.7112	0.8122 ± 0.1897	31.7242 ± 4.2979	1.5385 ± 3.0214	0.0428 ± 0.0492	0.0043 ± 0.0176	0.0241 ± 0.0221	0.0017 ± 0.0031	
<i>30M - DDPM</i>	0.3948 ± 0.5368	0.6271 ± 0.2170	23.6025 ± 5.1353	4.9305 ± 6.8739	0.1369 ± 0.1389	0.0380 ± 0.0848	0.0727 ± 0.0974	0.0163 ± 0.0622	
<i>30M - UNET</i>	0.8279 ± 1.0241	0.8123 ± 0.1894	31.5650 ± 4.0361	1.2869 ± 2.7785	0.0428 ± 0.0492	0.0043 ± 0.0179	0.0243 ± 0.0219	0.0017 ± 0.0030	

Tabla 6.14: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Full.

Experiment	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.4892 ± 0.6347	0.7705 ± 0.1251	21.8246 ± 3.5846	13.0968 ± 6.3126	0.1679 ± 0.0808	0.0347 ± 0.0308	0.1201 ± 0.0585	0.0199 ± 0.0170	
<i>665K - UNET</i>	0.1385 ± 0.2343	0.9728 ± 0.0286	41.3118 ± 3.7368	0.3557 ± 0.5967	0.0148 ± 0.0141	0.0004 ± 0.0010	0.0179 ± 0.0101	0.0005 ± 0.0006	
<i>2M - DDPM</i>	0.0915 ± 0.1462	0.9547 ± 0.0390	38.3239 ± 3.7778	0.2772 ± 0.4760	0.0216 ± 0.0186	0.0008 ± 0.0016	0.0250 ± 0.0135	0.0010 ± 0.0010	
<i>2M - UNET</i>	0.1273 ± 0.2223	0.9730 ± 0.0286	41.2363 ± 3.9788	0.2908 ± 0.5510	0.0154 ± 0.0142	0.0004 ± 0.0010	0.0172 ± 0.0092	0.0005 ± 0.0005	
<i>10M - DDPM</i>	0.0765 ± 0.1330	0.9581 ± 0.0399	36.8769 ± 4.1554	0.5123 ± 0.9352	0.0273 ± 0.0220	0.0012 ± 0.0024	0.0298 ± 0.0185	0.0015 ± 0.0016	
<i>10M - UNET</i>	0.1340 ± 0.2313	0.9724 ± 0.0292	41.2595 ± 3.7842	0.3462 ± 0.5909	0.0149 ± 0.0143	0.0004 ± 0.0010	0.0185 ± 0.0114	0.0006 ± 0.0007	
<i>30M - DDPM</i>	0.1746 ± 0.2579	0.8952 ± 0.0658	25.8578 ± 4.9001	9.8082 ± 6.3819	0.1116 ± 0.0638	0.0165 ± 0.0173	0.0827 ± 0.0502	0.0101 ± 0.0112	
<i>30M - UNET</i>	0.1281 ± 0.2216	0.9720 ± 0.0298	41.3719 ± 3.8839	0.2121 ± 0.2343	0.0147 ± 0.0146	0.0004 ± 0.0011	0.0173 ± 0.0108	0.0006 ± 0.0008	

Tabla 6.15: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.

Experiment	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.5661 ± 0.7152	0.6030 ± 0.2434	20.4070 ± 4.8482	10.6361 ± 8.9235	0.2086 ± 0.1316	0.0608 ± 0.0728	0.1764 ± 0.0862	0.0430 ± 0.0406	
<i>665K - UNET</i>	0.4287 ± 0.8926	0.8856 ± 0.1968	39.1778 ± 6.9571	1.5730 ± 3.0309	0.0251 ± 0.0380	0.0021 ± 0.0088	0.0247 ± 0.0238	0.0018 ± 0.0032	
<i>2M - DDPM</i>	0.3256 ± 0.4755	0.7235 ± 0.2337	27.4745 ± 5.6341	2.1895 ± 5.3007	0.0899 ± 0.1235	0.0233 ± 0.0909	0.0576 ± 0.0982	0.0141 ± 0.0686	
<i>2M - UNET</i>	0.4139 ± 0.8783	0.8850 ± 0.1947	38.9404 ± 6.6994	1.1096 ± 2.0748	0.0253 ± 0.0368	0.0020 ± 0.0085	0.0244 ± 0.0218	0.0016 ± 0.0028	
<i>10M - DDPM</i>	0.1405 ± 0.3119	0.8541 ± 0.2413	34.4553 ± 6.9251	1.4663 ± 3.2507	0.0439 ± 0.0518	0.0046 ± 0.0144	0.0408 ± 0.0351	0.0040 ± 0.0066	
<i>10M - UNET</i>	0.4102 ± 0.8706	0.8852 ± 0.1961	39.0324 ± 7.0208	1.3017 ± 2.3188	0.0257 ± 0.0389	0.0022 ± 0.0094	0.0249 ± 0.0238	0.0018 ± 0.0032	
<i>30M - DDPM</i>	0.2120 ± 0.3612	0.5287 ± 0.3478	17.1145 ± 7.3121	18.9187 ± 9.9177	0.3502 ± 0.2359	0.1783 ± 0.2045	0.2644 ± 0.1742	0.1079 ± 0.1234	
<i>30M - UNET</i>	0.3940 ± 0.8466	0.8839 ± 0.1965	38.5393 ± 6.7142	1.6054 ± 2.9853	0.0264 ± 0.0390	0.0022 ± 0.0094	0.0261 ± 0.0245	0.0019 ± 0.0035	

Tabla 6.16: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Full.

Experiment	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.8925 ± 0.1059	0.6336 ± 0.2911	18.1847 ± 9.1404	25.9226 ± 7.5315	0.3470 ± 0.2413	0.1788 ± 0.2189	0.3107 ± 0.2070	0.1466 ± 0.1722	
<i>665K - UNET</i>	0.0116 ± 0.0232	0.9951 ± 0.0062	48.2020 ± 4.8651	0.0572 ± 0.2747	0.0052 ± 0.0096	0.0001 ± 0.0012	0.0129 ± 0.0091	0.0005 ± 0.0008	
<i>2M - DDPM</i>	0.0285 ± 0.0626	0.9906 ± 0.0708	41.4484 ± 5.4121	0.7430 ± 1.3756	0.0169 ± 0.0164	0.0006 ± 0.0021	0.0238 ± 0.0141	0.0011 ± 0.0011	
<i>2M - UNET</i>	0.0148 ± 0.0670	0.9941 ± 0.0661	46.3564 ± 3.4079	0.0776 ± 0.4645	0.0076 ± 0.0095	0.0001 ± 0.0009	0.0137 ± 0.0081	0.0005 ± 0.0006	
<i>10M - DDPM</i>	0.0464 ± 0.0931	0.9861 ± 0.0114	39.8029 ± 5.2187	0.8399 ± 1.3769	0.0101 ± 0.0190	0.0007 ± 0.0044	0.0272 ± 0.0137	0.0015 ± 0.0014	
<i>10M - UNET</i>	0.0104 ± 0.0299	0.9954 ± 0.0066	48.7918 ± 4.9886	0.0547 ± 0.0278	0.0049 ± 0.0094	0.0001 ± 0.0011	0.0124 ± 0.0097	0.0004 ± 0.0009	
<i>30M - DDPM</i>	0.0388 ± 0.0746	0.9893 ± 0.0075	42.6851 ± 4.2415	20.090 ± 0.2972	0.0124 ± 0.0131	0.0003 ± 0.0029	0.0201 ± 0.0095	0.0008 ± 0.0009	
<i>30M - UNET</i>	0.0113 ± 0.0339	0.9952 ± 0.0064	47.9733 ± 4.6110	0.0553 ± 0.0282	0.0054 ± 0.0096	0.0001 ± 0.0011	0.0129 ± 0.0093	0.0005 ± 0.0009	

Tabla 6.17: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.

Experiment	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.0957 ± 0.2566	0.9033 ± 0.1487	29.7433 ± 7.7533	12.6399 ± 12.0177	0.0846 ± 0.0845	0.0143 ± 0.0281	0.1053 ± 0.0732	0.0180 ± 0.0244	
<i>665K - UNET</i>	0.1861 ± 0.5431	0.9408 ± 0.1270	45.1199 ± 7.9687	0.9330 ± 2.2476	0.0130 ± 0.0264	0.0009 ± 0.0072	0.0180 ± 0.0194	0.0012 ± 0.0022	
<i>2M - DDPM</i>	0.1881 ± 0.3000	0.8937 ± 0.1523	32.9681 ± 6.3549	2.8793 ± 4.4457	0.0400 ± 0.0439	0.0043 ± 0.0114	0.0622 ± 0.0329	0.0063 ± 0.0061	
<i>2M - UNET</i>	0.1799 ± 0.5292	0.9405 ± 0.1266	44.2514 ± 7.7717	1.0932 ± 2.5707	0.0148 ± 0.0271	0.0010 ± 0.0077	0.0196 ± 0.0207	0.0014 ± 0.0026	
<i>10M - DDPM</i>	0.0776 ± 0.2365	0.9234 ± 0.1561	41.1243 ± 7.0375	0.1763 ± 0.2268	0.0189 ± 0.0326	0.0014 ± 0.0102	0.0278 ± 0.0240	0.0022 ± 0.0037	
<i>10M - UNET</i>	0.1786 ± 0.5270	0.9404 ± 0.1273	44.8452 ± 8.1136	1.1385 ± 2.8133	0.0140 ± 0.0273	0.0009 ± 0.0076	0.0194 ± 0.0209	0.0014 ± 0.0027	
<i>30M - DDPM</i>	0.1543 ± 0.3168	0.8919 ± 0.1840	32.8115						

6.2.4. Impacto de los Métodos de Agregación

Este apartado presenta los resultados obtenidos mediante la técnica de agregación, propuesta por Wang et al. (2023), de múltiples muestras generadas por los modelos de difusión. Los resultados completos están disponibles en el apartado 7.12. Se han generado gráficas que ilustran el comportamiento de diversas métricas en función del número de muestras utilizadas en la agregación.

En la escala lineal (Figura 6.3), se observó un cambio en casi todas las métricas al aumentar el número de muestras en la agregación. Los valores de las métricas *PSNR* y *SSIM* aumentaron, lo cual se atribuye al suavizado que se produce al calcular la media de las imágenes durante el proceso de agregación. Las métricas específicas del dominio astronómico también exhibieron cambios. Sin embargo, la métrica *FFT MSE* mostró una disminución en esta escala.

Para las escalas logarítmica (Figura 6.4) y de raíz cuadrada (Figura 6.5), los resultados mostraron patrones similares entre sí, pero diferentes a los de la escala lineal. En estas escalas, se observó una mejora en la mayoría de las métricas con el aumento de muestras agregadas. Sin embargo, la métrica *FFT MSE* mostró un comportamiento opuesto, empeorando a medida que se incrementaba el número de muestras en la agregación.

La divergencia en el comportamiento de la *FFT MSE* entre las diferentes escalas se relaciona con la preservación del ruido en cada escala. En las escalas logarítmica y de raíz cuadrada, donde hay una mayor varianza entre las intensidades de los píxeles, el proceso de agregación resulta en una pérdida de detalles finos. Esto se refleja en el empeoramiento de la métrica *FFT MSE*, como se puede observar en las Figuras 6.4 y 6.5.

En la escala lineal (Figura 6.3), donde el la varianza de intensidades es menor, el proceso de agregación tiende a mejorar la calidad de la imagen al reducir el ruido sin comprometer las estructuras de interés. Esto explica la mejora observada en la mayoría de las métricas, incluida la *FFT MSE*, en esta escala.

El impacto de la agregación varía en las métricas y en las escalas. Algunas métricas, como *PSNR* y *SSIM*, muestran mejoras con un mayor número de muestras agregadas en todas las escalas, como se evidencia en las tres figuras. Otras métricas, particularmente aquellas relacionadas con características específicas de las imágenes astronómicas, alcanzan un punto de saturación después de cierto número de muestras.

Estos resultados cuantifican el efecto de la agregación en la reconstrucción de imágenes astronómicas, demostrando sus efectos en diversas métricas y escalas de representación de la imagen. La técnica de agregación muestra efectos en la calidad de las reconstrucciones, pero su impacto varía según la escala de representación y la métrica considerada, como se puede observar

al comparar las Figuras 6.3, 6.4, y 6.5.

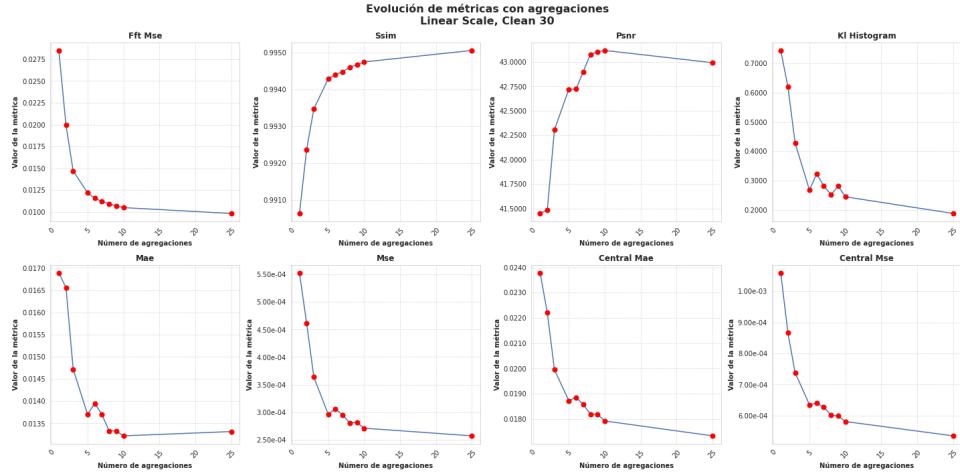


Figura 6.3: Evolución de las métricas en función del número de muestras agregadas en escala lineal. Se observa una mejora en la mayoría de las métricas, incluyendo *PSNR* y *SSIM*, a medida que aumenta el número de muestras. La métrica *FFT MSE* muestra una mejora en esta escala.

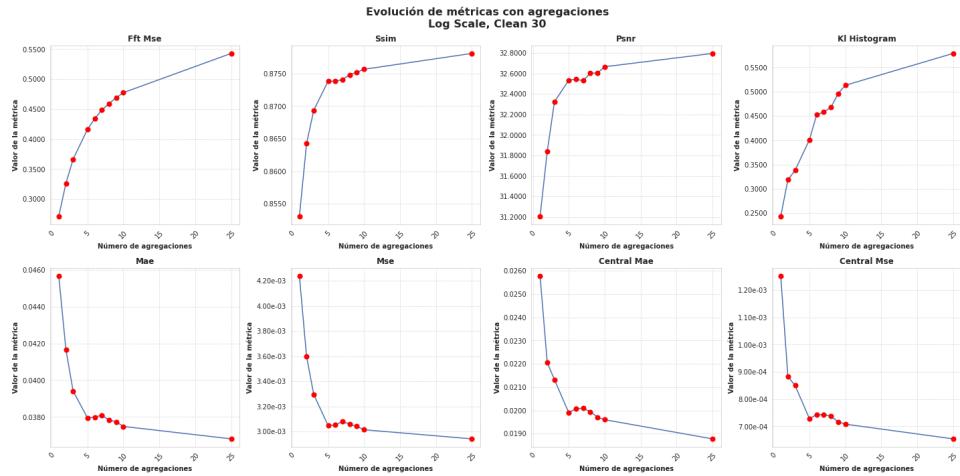


Figura 6.4: Evolución de las métricas en función del número de muestras agregadas en escala logarítmica. Se observa una mejora en la mayoría de las métricas con el aumento de muestras agregadas. La métrica *FFT MSE* muestra un empeoramiento.

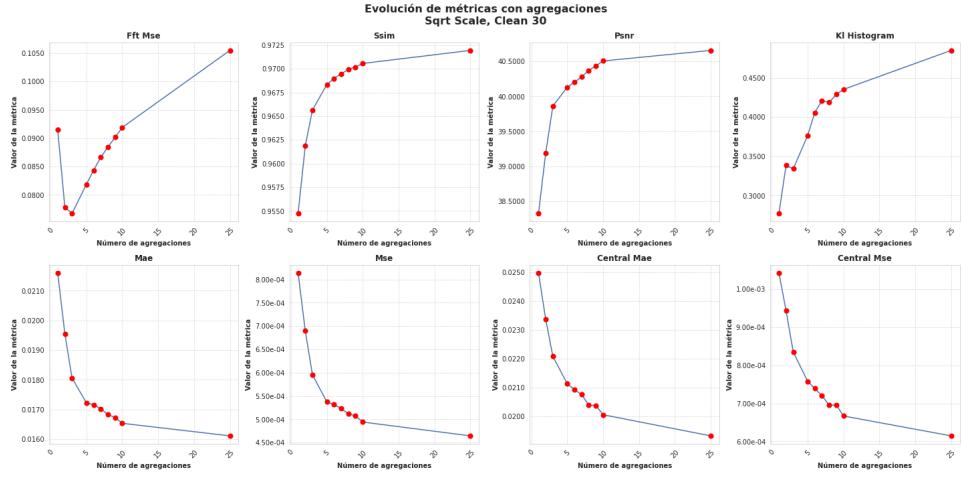
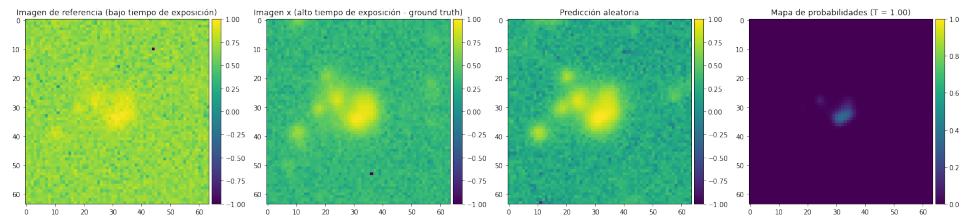


Figura 6.5: Evolución de las métricas en función del número de muestras agregadas en escala de raíz cuadrada. Se observan patrones similares a los de la escala logarítmica, con una mejora en la mayoría de las métricas, pero un empeoramiento en la *FFT MSE*.

6.2.5. Evaluación de la Incertidumbre

Las predicciones varían según el ruido inicial. Elementos relevantes de las muestras pueden ser pequeños o de baja intensidad en la imagen de referencia. Esta variabilidad permite estimar la certeza del modelo sobre si un píxel corresponde a una galaxia. El proceso implica realizar múltiples predicciones de la misma muestra y establecer un umbral (entre -1 y 1) para considerar un píxel como parte de una galaxia. Contabilizando en cuántas muestras se supera este umbral para cada píxel, se obtiene un mapa de probabilidades. Este método no es aplicable a los modelos de UNet, que producen resultados consistentes para la misma entrada de referencia.



La Figura 6.6 muestra un umbral de 1. Con este umbral alto, solo los píxeles con valores muy altos se consideran parte de una galaxia, resultando en una imagen de probabilidad con pocas áreas blancas. Esto indica una

alta especificidad del modelo, pero baja sensibilidad en la detección de estructuras galácticas.

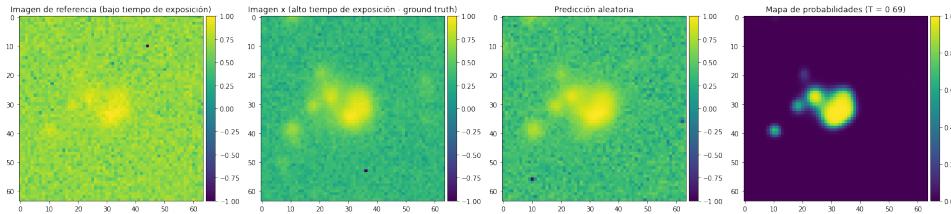


Figura 6.7: Representación del *Input*, el *True*, la predicción *DDPM* y las probabilidades con un umbral de 0.75

En la Figura 6.7, con un umbral de 0.75, se observa una detección más amplia de las estructuras galácticas. Las regiones centrales de las galaxias muestran probabilidades altas, mientras que las áreas periféricas comienzan a mostrar probabilidades más bajas pero detectables.

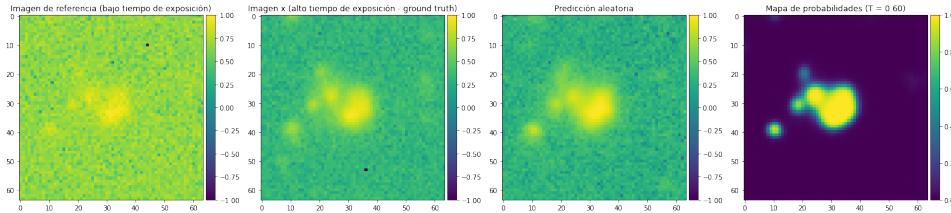


Figura 6.8: Representación del *Input*, el *True*, la predicción *DDPM* y las probabilidades con un umbral de 0.5

La Figura 6.8 utiliza un umbral de 0.5. En este caso, se observa un equilibrio entre la detección de las regiones centrales y periféricas de las galaxias. Las áreas con intensidad media también muestran probabilidades significativas, proporcionando un balance entre sensibilidad y especificidad.

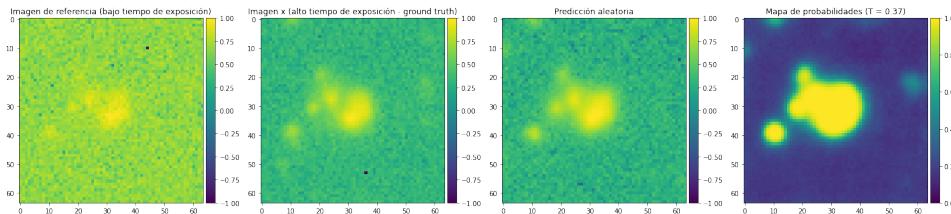


Figura 6.9: Representación del *Input*, el *True*, la predicción *DDPM* y las probabilidades con un umbral bajo de 0.1

En la Figura 6.9, con un umbral de 0.1, se observa una detección más amplia de estructuras. Este umbral bajo resulta en una mayor sensibilidad,

permitiendo la detección de estructuras más tenues y extendidas, pero potencialmente identificando más ruido como estructuras de galaxias.

6.2.6. Análisis cualitativo

Para el análisis cualitativo de las imágenes, se han generado múltiples muestras presentadas en un grid de 4 columnas y 2 filas. La primera fila muestra el *Input*, el *True*, la predicción del modelo *DDPM* y la predicción del modelo *UNet*, en ese orden. La segunda fila presenta las imágenes de los errores correspondientes a las predicciones de *DDPM* y *UNet*. Los errores se visualizan en rangos específicos para cada escala: logarítmica (-0.5 a 0.5), raíz cuadrada (-0.4 a 0.4) y lineal (-0.25 a 0.25).

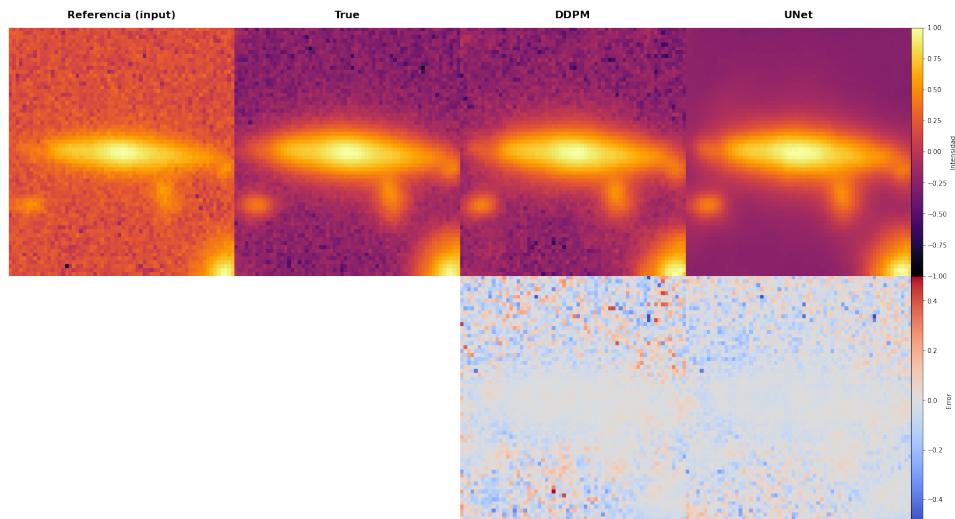


Figura 6.10: Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

En las muestras de escala logarítmica, como las Figuras 6.10 y 6.13, se observa una similitud visual entre las imágenes *True* y las generadas por *DDPM*. Esta similitud es menos evidente en las imágenes generadas por *UNet*. Sin embargo, el mapa de errores revela que *DDPM* presenta un error mayor en las zonas con más ruido en comparación con *UNet*. Esto se debe a que *UNet* realiza un suavizado que reduce el error en estas áreas, aunque a costa de perder fidelidad en los detalles finos.

En la escala de raíz cuadrada, se observa un fenómeno similar al de la escala logarítmica. Sin embargo, esta diferencia es menos perceptible en casos de alto SNR (Signal-to-Noise Ratio). La diferencia se hace más evidente en muestras con bajo SNR, como se puede observar en la Figura 6.17.

En cuanto a los datos en escala lineal, como se observa en las Figuras

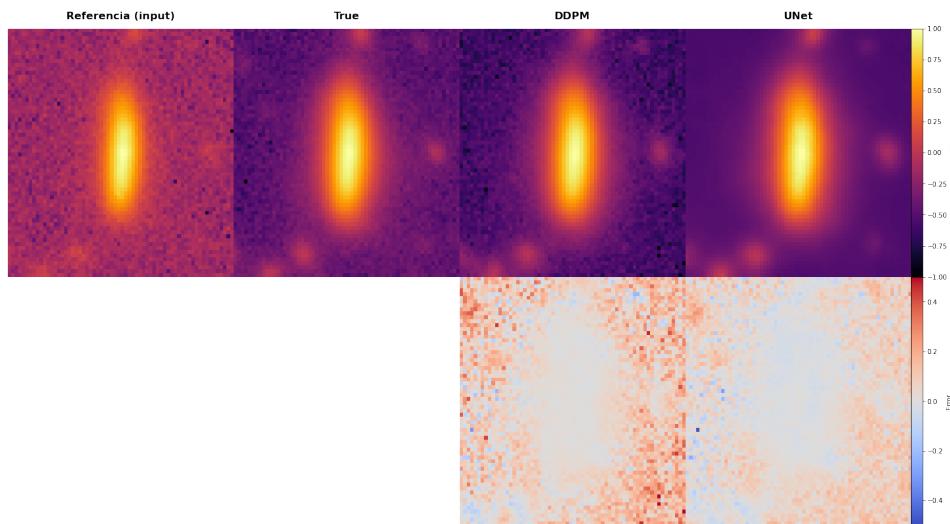


Figura 6.11: Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

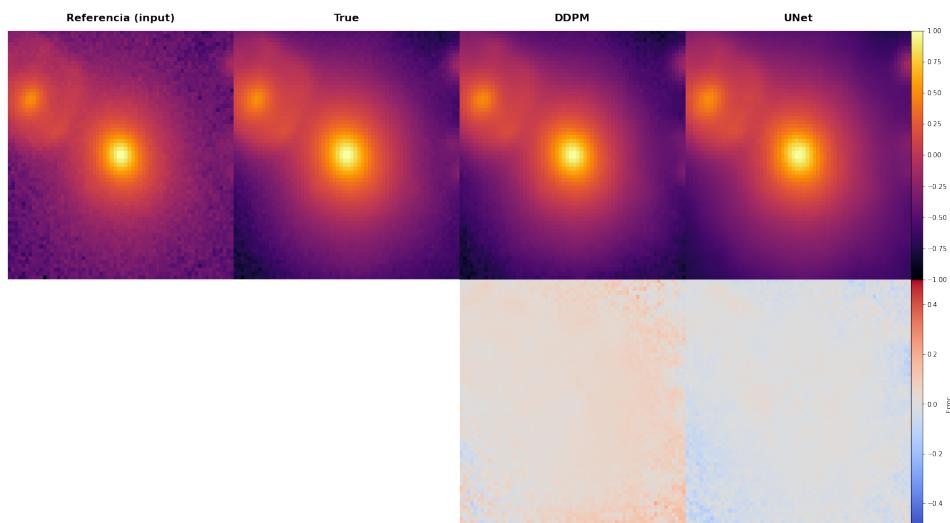


Figura 6.12: Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

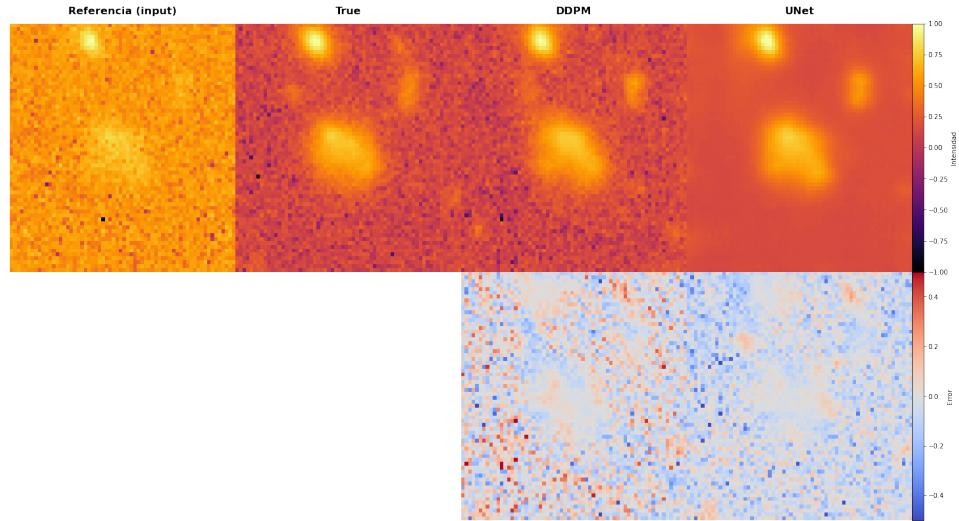


Figura 6.13: Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

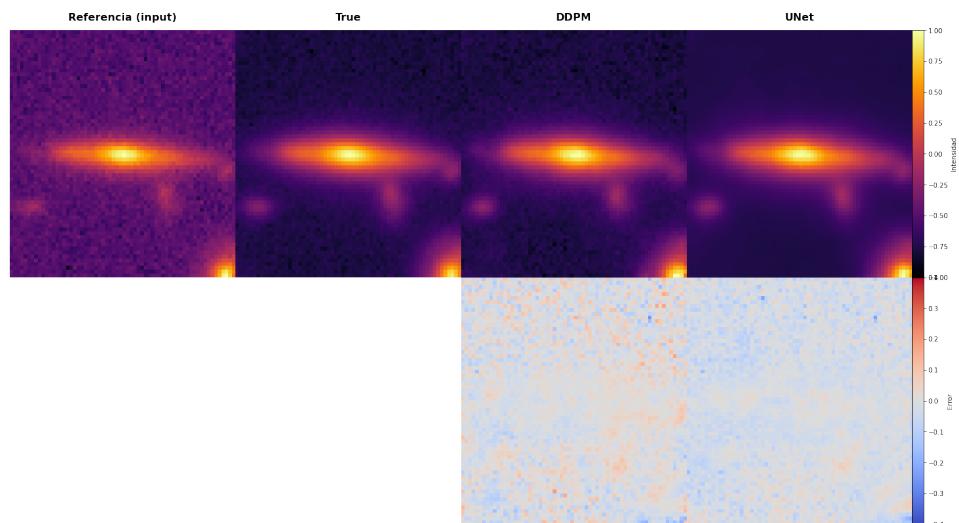


Figura 6.14: Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

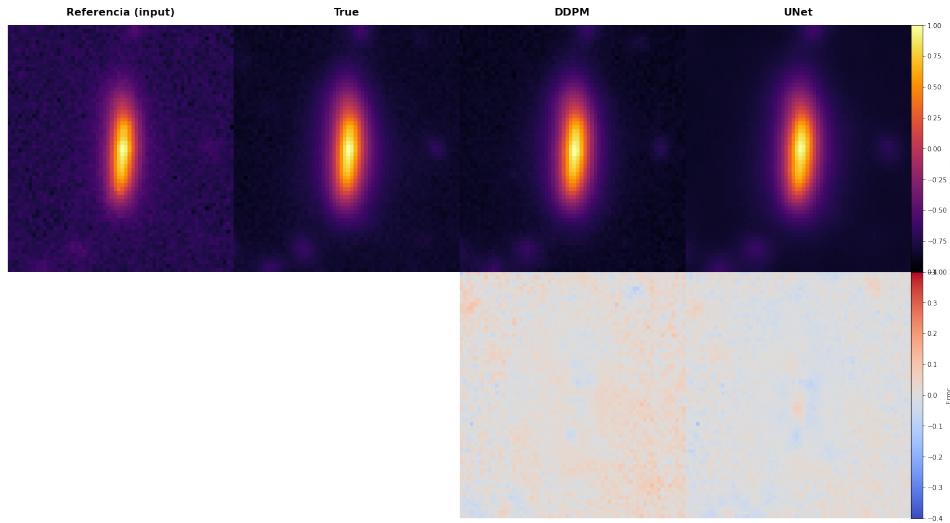


Figura 6.15: Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

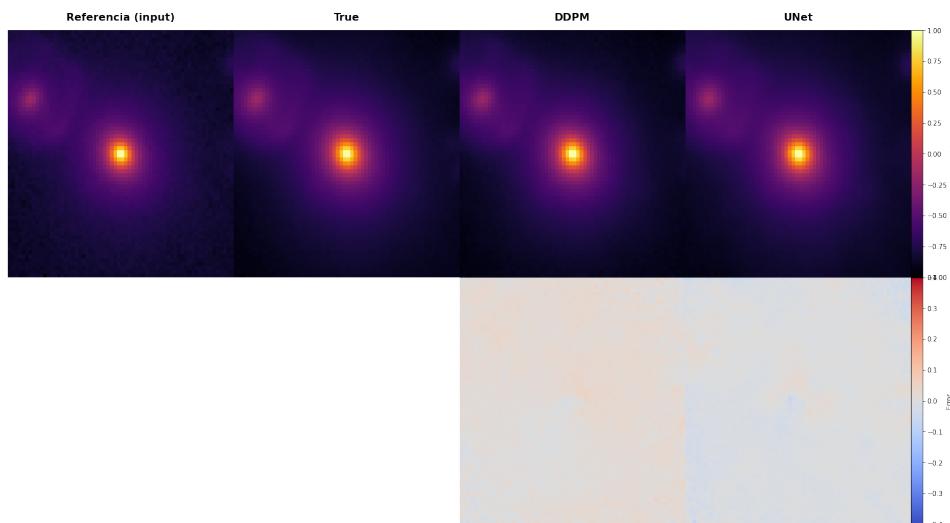


Figura 6.16: Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

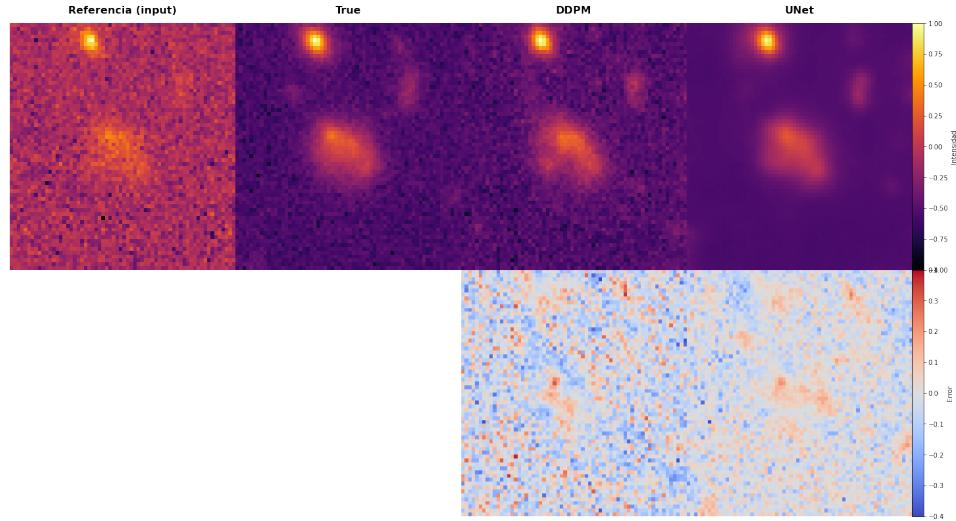


Figura 6.17: Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

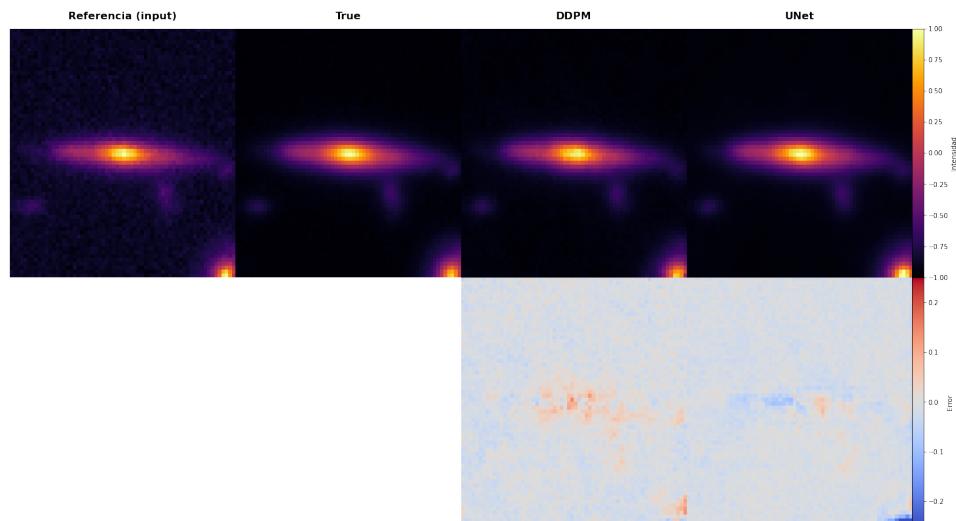


Figura 6.18: Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

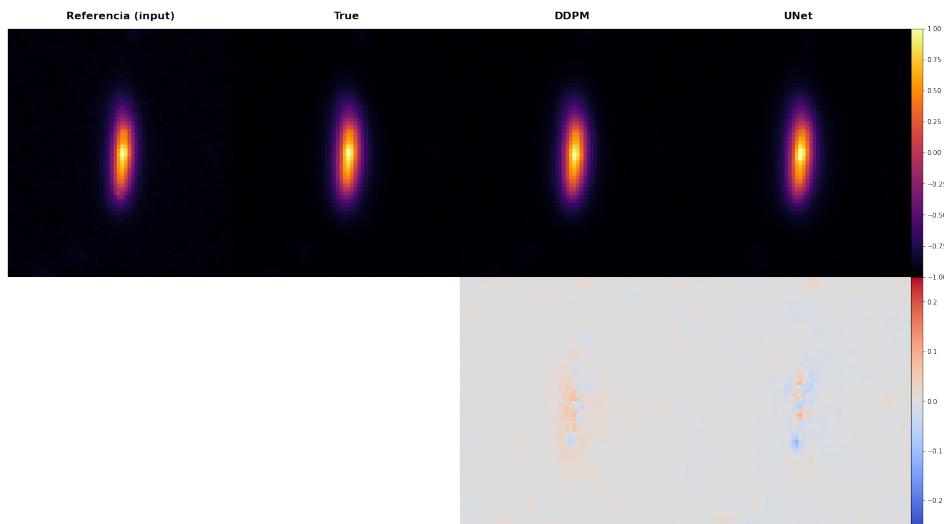


Figura 6.19: Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

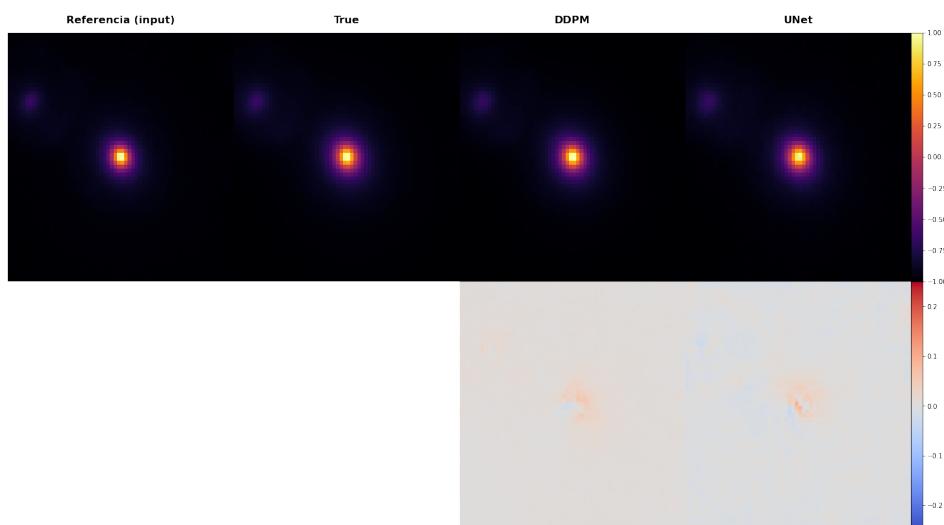


Figura 6.20: Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

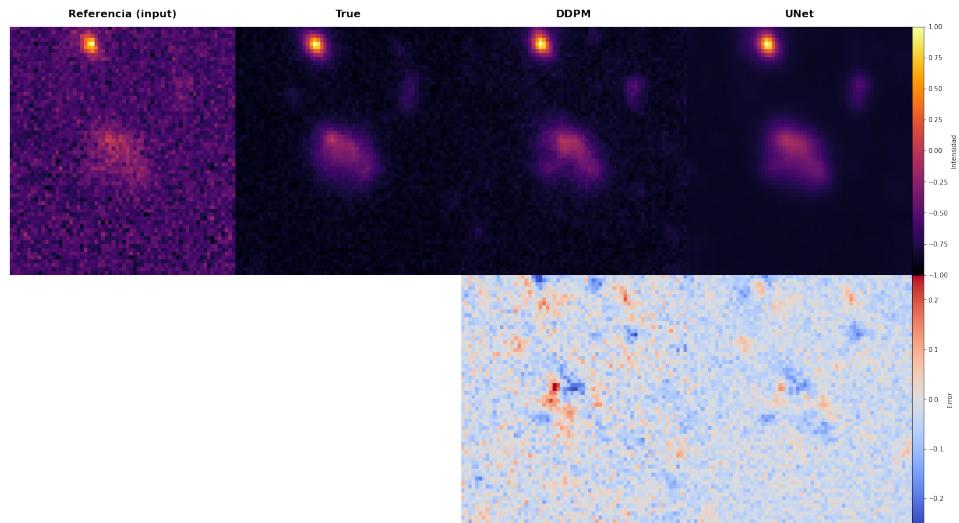


Figura 6.21: Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

6.18 y 6.19, solo se destacan las estructuras más brillantes, generalmente los centros de las galaxias. Esto limita la posibilidad de analizar cualitativamente la similitud entre las predicciones y la imagen real, ya que gran parte de la información de las estructuras menos brillantes no es visible en esta escala.

El modelo *DDPM* muestra una capacidad para caracterizar el ruido de fondo en las zonas sin galaxias. Esta característica es relevante en el contexto de imágenes astronómicas, donde el ruido de fondo puede contener información.

Las imágenes generadas por *DDPM* presentan una nitidez diferente en comparación con las producidas por *UNet*, que muestran un efecto de suavizado. Esta diferencia en nitidez se observa en los bordes y estructuras finas de las galaxias.

La diferencia visual entre los modelos *DDPM* y *UNet* no se refleja de la misma manera en las métricas clásicas de evaluación de imágenes. Como se observó en el análisis cuantitativo, métricas como *PSNR* o *SSIM* tienden a favorecer imágenes más suaves y con menos ruido, lo que puede resultar en una evaluación diferente para las imágenes generadas por *UNet* a pesar de su fidelidad visual a las imágenes originales.

La diferencia entre la evaluación cualitativa y ciertas métricas cuantitativas indica la importancia de utilizar múltiples enfoques en la evaluación de modelos de reconstrucción de imágenes astronómicas. Mientras que el análisis visual sugiere características distintas del modelo *DDPM* en términos de

preservación de detalles y características del ruido, las métricas tradicionales pueden no capturar estos aspectos del análisis astronómico de la misma manera.

Muestras adicionales están disponibles en las secciones 7.6, 7.7 y 7.8.

Capítulo 7

Conclusiones

7.1. Resumen de Resultados

Este estudio examina el uso de modelos de difusión probabilística (DDPM) en la reconstrucción de imágenes astronómicas de bajo SNR a alto SNR. Los resultados de la exploración de métricas indican que las métricas tradicionales como *SSIM*, *PSNR*, *MAE* y *MSE* no son adecuadas para evaluar la similitud entre imágenes con ruido en el contexto astronómico. Estas métricas tienden a asignar mayor similitud a imágenes con menor nivel de ruido, incluso si el nivel de ruido difiere del original.

La divergencia de Kullback-Leibler (KL) aplicada a distribuciones de entropía e intensidad de histogramas mostró una diagonal más pronunciada en sus matrices de similitud, pero presentó limitaciones en consistencia y captura de información espacial directa para los distintos elementos.

El *MSE* de la Transformada Rápida de Fourier (*FFT*) mostró resultados prometedores, con una diagonal bien definida en su matriz de similitud. Esta métrica opera en el dominio de la frecuencia, permitiendo comparar componentes de frecuencia sensibles a estructura y ruido. El *MSE* de la *FFT* mostró sensibilidad a patrones y estructuras en diferentes escalas espaciales, lo cual es relevante para imágenes astronómicas con características a diversas escalas.

El análisis del número de pasos de difusión reveló una relación entre el aumento de pasos y la mejora del rendimiento del modelo DDPM, especialmente en métricas como *FFT MSE* y *KL Histogram*. La UNet superó a DDPM en métricas tradicionales que no capturan específicamente las características de la varianza de los valores de menos intensidad.

Los modelos DDPM requieren un volumen mayor de datos de entrenamiento en comparación con las UNet para alcanzar un rendimiento comparable. Con suficientes datos, los DDPM mostraron un rendimiento superior, especialmente en términos cualitativos. El aumento en el número de parámetros de la red no produjo mejoras significativas en el rendimiento más

allá de cierto punto. Los modelos con 2M y 10M de parámetros obtuvieron resultados similares.

Las técnicas de agregación mediante promediado mejoraron las métricas clásicas como *SSIM* y *PSNR*, pero el análisis cualitativo reveló que estas imágenes agregadas eran más borrosas y menos fieles a las imágenes originales. Este efecto fue más pronunciado en escalas logarítmica y de raíz cuadrada. Estos resultados concuerdan con los obtenidos por Drozdova et al. (2024)

El análisis cualitativo mostró que los modelos DDPM logran una mayor fidelidad a las imágenes originales, especialmente en la preservación de la varianza de los valores, particularmente en zonas de baja intensidad como el fondo, y en la nitidez de las estructuras galácticas de menor intensidad. La variabilidad de los modelos DDPM permitió desarrollar un método para calcular la certeza de clasificación de píxeles como pertenecientes o no a una galaxia, proporcionando una medida de incertidumbre.

7.2. Limitaciones del Estudio

El estudio presenta limitaciones debido a restricciones en recursos computacionales, con un early stopping de 1200 épocas. La especificidad del *dataset* utilizado (“Full” y “Clean 30”) y la limitación a imágenes de 64x64 píxeles restringen la generalización de los resultados a otros datasets existentes. Las muestras utilizadas representan una región limitada del espacio para un telescopio en concreto, lo que puede no capturar toda la diversidad de morfologías galácticas existentes.

7.3. Posibles Ampliaciones y Trabajos Futuros

Las futuras investigaciones podrían explorar y desarrollar nuevas métricas para evaluar la similitud en imágenes astronómicas con ruido, considerando los resultados del *MSE* de la *FFT*. La prueba de estos modelos con otros conjuntos de datos astronómicos y la experimentación con diferentes arquitecturas de modelos de difusión son áreas de estudio. La evaluación del rendimiento de los modelos en imágenes de mayor resolución y la exploración de su capacidad para realizar transferencia entre escalas son direcciones de investigación. La combinación de estos modelos de difusión con otros modelos específicos del dominio astronómico y su aplicación en otros ámbitos de la astronomía más allá de la reconstrucción de imágenes galácticas presentan oportunidades para futuras investigaciones.

7.4. Conclusiones Finales

Este estudio examina el uso de modelos de difusión probabilística en la reconstrucción de imágenes astronómicas de alto SNR a partir de datos de bajo SNR. Los modelos DDPM mostraron capacidad para preservar detalles finos y características relevantes en el análisis astronómico. La evaluación cualitativa y las métricas cuantitativas tradicionales presentaron diferencias, indicando la necesidad de desarrollar métricas específicas para el dominio astronómico, con el *MSE* de la *FFT* presentando resultados a considerar. Los modelos DDPM requieren mayores recursos computacionales y tiempos de entrenamiento e inferencia más largos que las UNet. La capacidad de los modelos DDPM para proporcionar estimaciones de incertidumbre a nivel de píxel podría aplicarse en la identificación de estructuras débiles o en la delimitación de los bordes de las galaxias. Este trabajo presenta el uso de modelos de difusión en la reconstrucción de imágenes astronómicas e identifica áreas para futuras investigaciones y aplicaciones en el campo de la astrofísica observacional.

Bibliografía

- Aihara, H., AlSayyad, Y., Ando, M., Armstrong, R., Bosch, J., Egami, E., Furusawa, H., Furusawa, J., Harasawa, S., Harikane, Y., Hsieh, B.-C., Ikeda, H., Ito, K., Iwata, I., Kodama, T., Koike, M., Kokubo, M., Komiyama, Y., Li, X., Liang, Y., Lin, Y.-T., Lupton, R. H., Lust, N. B., MacArthur, L. A., Mawatari, K., Mineo, S., Miyatake, H., Miyazaki, S., More, S., Morishima, T., Murayama, H., Nakajima, K., Nakata, F., Nishizawa, A. J., Oguri, M., Okabe, N., Okura, Y., Ono, Y., Osato, K., Ouchi, M., Pan, Y.-C., Plazas Malagón, A. A., Price, P. A., Reed, S. L., Rykoff, E. S., Shibusawa, T., Simunovic, M., Strauss, M. A., Sugimori, K., Suto, Y., Suzuki, N., Takada, M., Takagi, Y., Takata, T., Takita, S., Tanaka, M., Tang, S., Taranu, D. S., Terai, T., Toba, Y., Turner, E. L., Uchiyama, H., Vijarnwannaluk, B., Waters, C. Z., Yamada, Y., Yamamoto, N., and Yamashita, T. (2022). Third data release of the hyper suprime-cam subaru strategic program. *Publications of the Astronomical Society of Japan*, 74(2):247272.
- Barratt, S. and Sharma, R. (2018). A note on the inception score.
- Boureau, Y.-L., Ponce, J., and Lecun, Y. (2010). A theoretical analysis of feature pooling in visual recognition. pages 111–118.
- Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on pattern analysis and machine intelligence*, (6):679–698.
- Choi, J., Kim, S., Jeong, Y., Gwon, Y., and Yoon, S. (2021). Ilvr: Conditioning method for denoising diffusion probabilistic models.
- Dhariwal, P. and Nichol, A. (2021). Diffusion models beat gans on image synthesis.
- Drozdova, M., Kinakh, V., Bait, O., Taran, O., Lastufka, E., Dessauges-Zavadsky, M., Holotyak, T., Schaerer, D., and Voloshynovskiy, S. (2023). Radio-astronomical image reconstruction with a conditional denoising diffusion model.
- Drozdova, M., Kinakh, V., Bait, O., Taran, O., Lastufka, E., Dessauges-Zavadsky, M., Holotyak, T., Schaerer, D., and Voloshynovskiy, S. (2024).

- Radio-astronomical image reconstruction with a conditional denoising diffusion model. *Astronomy and Astrophysics*, 683:A105.
- Dumoulin, V. and Visin, F. (2018). A guide to convolution arithmetic for deep learning.
- Gheller, C. and Vazza, F. (2021). Convolutional deep denoising autoencoders for radio astronomical images. *Monthly Notices of the Royal Astronomical Society*, 509(1):9901009.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press. <http://www.deeplearningbook.org>.
- Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B., and Hochreiter, S. (2018). Gans trained by a two time-scale update rule converge to a local nash equilibrium.
- Ho, J., Jain, A., and Abbeel, P. (2020). Denoising diffusion probabilistic models.
- Högbom, J. (1974). Aperture synthesis with a non-regular distribution of interferometer baselines. *Astronomy and Astrophysics Supplement, Vol. 15, p. 417*, 15:417.
- Huttenlocher, D., Klanderman, G., and Ruckridge, W. (1993). Comparing images using the hausdorff distance. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 15(9):850–863.
- Jaccard, P. (1912). The distribution of the flora in the alpine zone. *New Phytologist*, 11(2):37–50.
- Kanopoulos, N., Vasanthavada, N., and Baker, R. L. (1988). Design of an image edge detection filter using the sobel operator. *IEEE Journal of solid-state circuits*, 23(2):358–367.
- Kapur, J. N., Sahoo, P. K., and Wong, A. K. (1985). A new method for gray-level picture thresholding using the entropy of the histogram. *Computer vision, graphics, and image processing*, 29(3):273–285.
- Khader, F., Müller-Franzes, G., Tayebi Arasteh, S., Han, T., Haarburger, C., Schulze-Hagen, M., Schad, P., Engelhardt, S., Baeßler, B., Foersch, S., et al. (2023). Denoising diffusion probabilistic models for 3d medical image generation. *Scientific Reports*, 13(1):7303.
- Kullback, S. and Leibler, R. A. (1951). On information and sufficiency. *The annals of mathematical statistics*, 22(1):79–86.

- LeCun, Y., Boser, B., Denker, J., Henderson, D., Howard, R., Hubbard, W., and Jackel, L. (1989). Handwritten digit recognition with a back-propagation network. *Advances in neural information processing systems*, 2.
- Meng, C., He, Y., Song, Y., Song, J., Wu, J., Zhu, J.-Y., and Ermon, S. (2022). Sdedit: Guided image synthesis and editing with stochastic differential equations.
- Mohan, N. and Rafferty, D. (2015). Pybdsf: Python blob detection and source finder. *Astrophysics Source Code Library*, pages ascl–1502.
- Ni, Z.-L., Bian, G.-B., Zhou, X.-H., Hou, Z.-G., Xie, X.-L., Wang, C., Zhou, Y.-J., Li, R.-Q., and Li, Z. (2019). Raunet: Residual attention u-net for semantic segmentation of cataract surgical instruments.
- Nichol, A. Q. and Dhariwal, P. (2021). Improved denoising diffusion probabilistic models. In *International conference on machine learning*, pages 8162–8171. PMLR.
- Odena, A., Dumoulin, V., and Olah, C. (2016). Deconvolution and checkerboard artifacts. *Distill*.
- O’Shea, K. and Nash, R. (2015). An introduction to convolutional neural networks.
- Prince, S. J. (2023). *Understanding Deep Learning*. The MIT Press.
- Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation.
- Saharia, C., Chan, W., Chang, H., Lee, C. A., Ho, J., Salimans, T., Fleet, D. J., and Norouzi, M. (2022). Palette: Image-to-image diffusion models.
- Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., and Chen, X. (2016). Improved techniques for training gans.
- Scherer, D., Müller, A., and Behnke, S. (2010). Evaluation of pooling operations in convolutional architectures for object recognition. In Diamantaras, K., Duch, W., and Iliadis, L. S., editors, *Artificial Neural Networks – ICANN 2010*, pages 92–101, Berlin, Heidelberg. Springer Berlin Heidelberg.
- Shannon, C. E. (1948). A mathematical theory of communication. *The Bell system technical journal*, 27(3):379–423.
- Sohn, K., Lee, H., and Yan, X. (2015). Learning structured output representation using deep conditional generative models. *Advances in neural information processing systems*, 28.

- Song, J., Meng, C., and Ermon, S. (2022). Denoising diffusion implicit models.
- Sweere, S. F., Valtchanov, I., Lieu, M., Vojtekova, A., Verdugo, E., Santos-Lleo, M., Pacaud, F., Briassouli, A., and Cámpora-Pérez, D. (2022). Deep learning-based super-resolution and de-noising for xmm-newton images. *Monthly Notices of the Royal Astronomical Society*, 517(3):40544069.
- Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., and Wojna, Z. (2015). Rethinking the inception architecture for computer vision.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2023). Attention is all you need.
- Vojtekova, A., Lieu, M., Valtchanov, I., Altieri, B., Old, L., Chen, Q., and Hroch, F. (2020). Learning to denoise astronomical images with u-nets. *Monthly Notices of the Royal Astronomical Society*, 503(3):32043215.
- Wang, R., Chen, Z., Luo, Q., and Wang, F. (2023). A conditional denoising diffusion probabilistic model for radio interferometric image reconstruction. *Frontiers in Artificial Intelligence and Applications*, 372:2499–2506.
- Wang, Z., Bovik, A. C., Sheikh, H. R., and Simoncelli, E. P. (2004). Image quality assessment: from error visibility to structural similarity. *IEEE transactions on image processing*, 13(4):600–612.
- Wu, H. and Gu, X. (2015). Towards dropout training for convolutional neural networks. *Neural Networks*, 71:110.
- Wu, Y. and He, K. (2018). Group normalization. In *Proceedings of the European conference on computer vision (ECCV)*, pages 3–19.
- Xue, Z., Li, Y., Patel, Y., and Regier, J. (2023). Diffusion models for probabilistic deconvolution of galaxy images.
- Zamir, S. W., Arora, A., Khan, S., Hayat, M., Khan, F. S., and Yang, M.-H. (2022). Restormer: Efficient transformer for high-resolution image restoration.
- Zeiler, M. D., Taylor, G. W., and Fergus, R. (2011). Adaptive deconvolutional networks for mid and high level feature learning. In *2011 International Conference on Computer Vision*, pages 2018–2025.

Apéndice A: Disponibilidad de Datos y Código

El código fuente completo utilizado en este estudio, junto con los conjuntos de datos empleados, están disponibles públicamente para su revisión y reproducción. Todos estos recursos se pueden acceder a través del siguiente repositorio de GitHub:

<https://github.com/ander-db/DDPM-HSC>

Apéndice B: Figuras Suplementarias

7.5. Grid de comparación de similitud de métricas

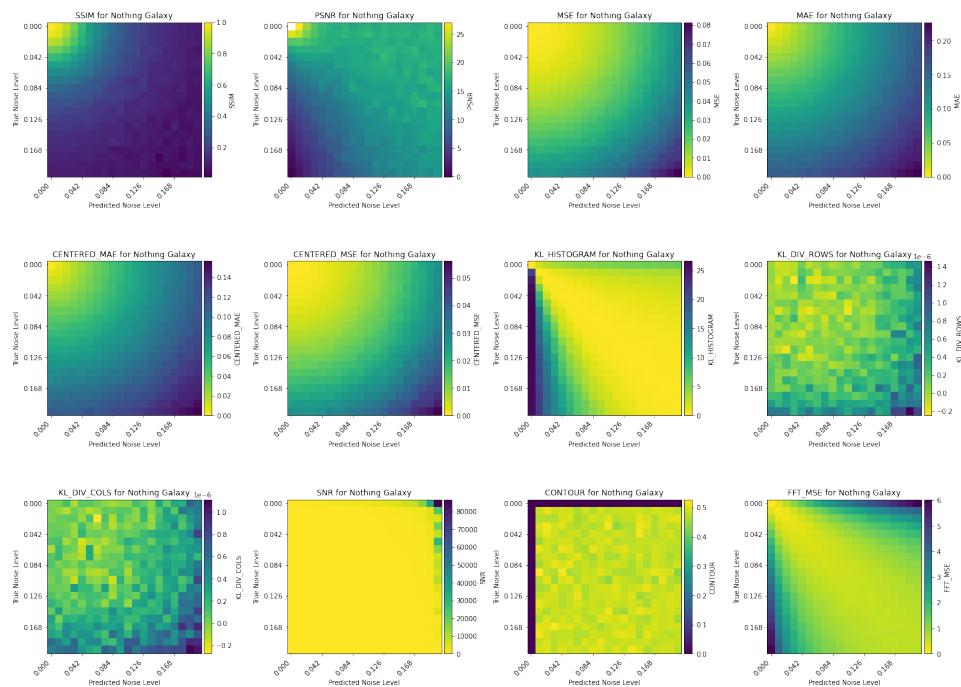


Figura 7.1: Visualizaciones de las matrices de similitud de varias métricas para ruido puro

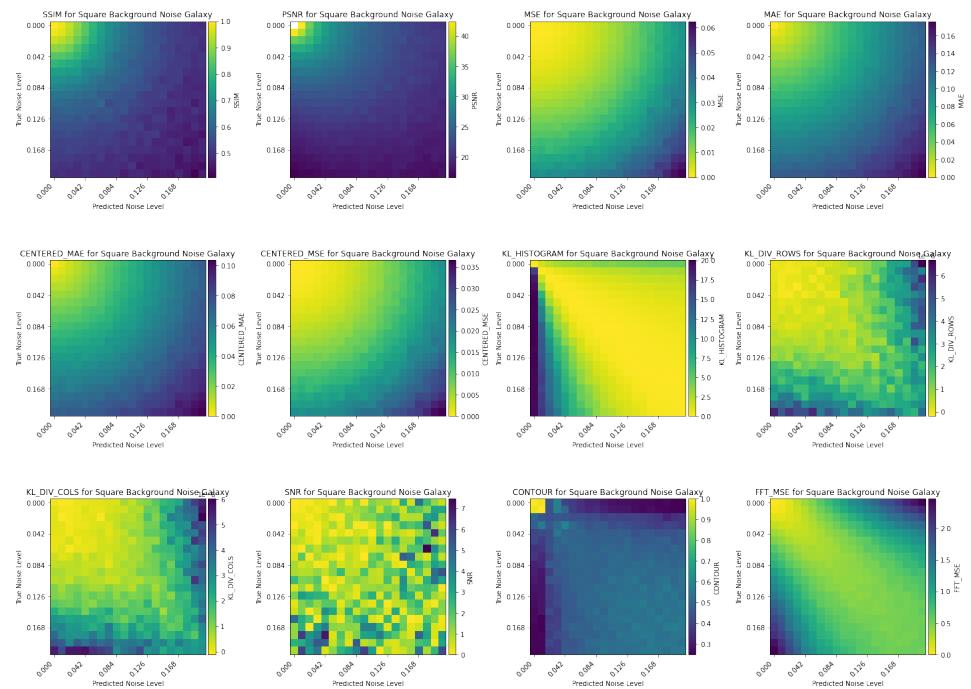


Figura 7.2: Visualizaciones de las matrices de similitud de varias métricas para cuadrado con ruido de fondo

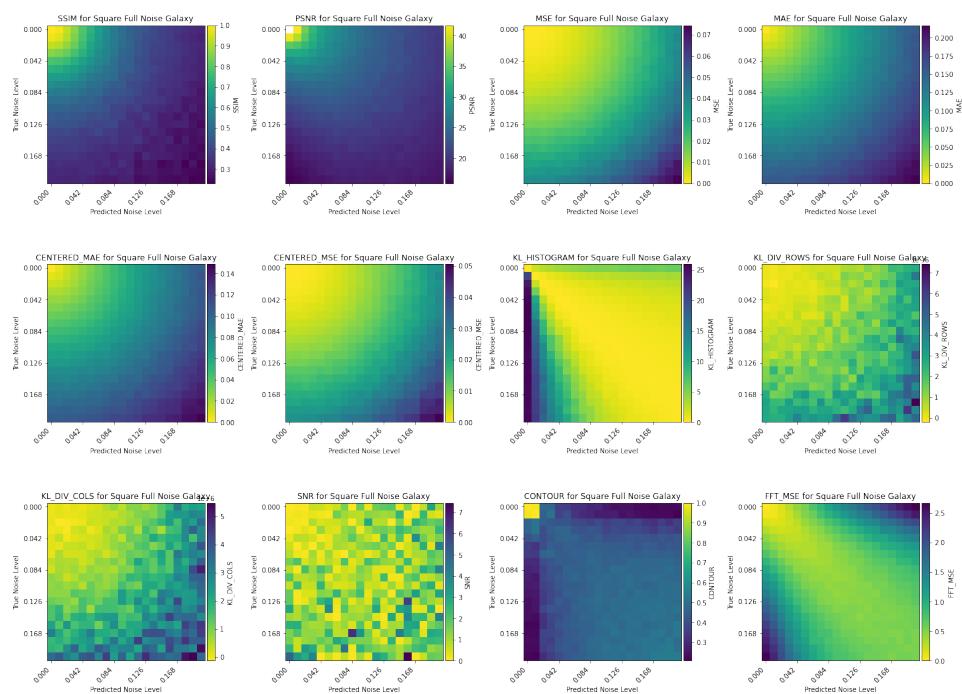


Figura 7.3: Visualizaciones de las matrices de similitud de varias métricas para cuadrado con ruido en toda la imagen

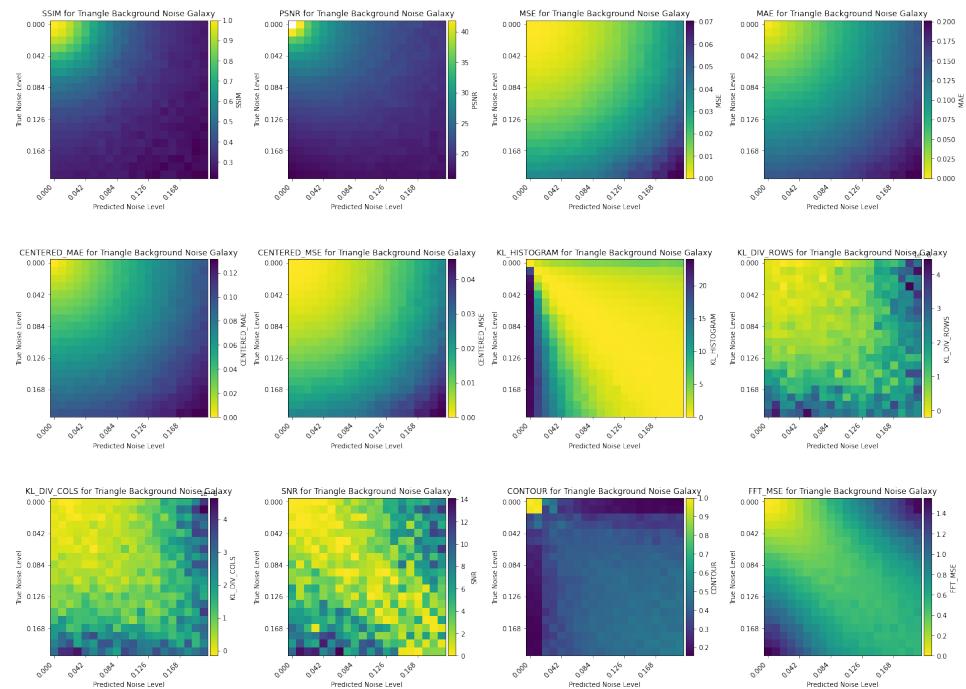


Figura 7.4: Visualizaciones de las matrices de similitud de varias métricas para triángulo con ruido de fondo

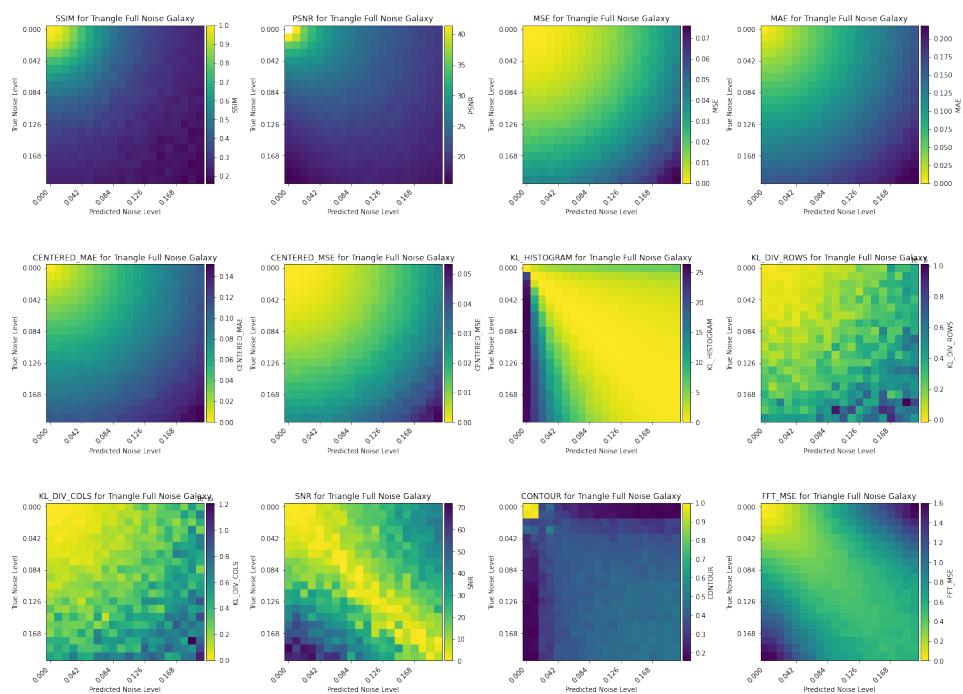


Figura 7.5: Visualizaciones de las matrices de similitud de varias métricas para triangulo con ruido en toda la imagen

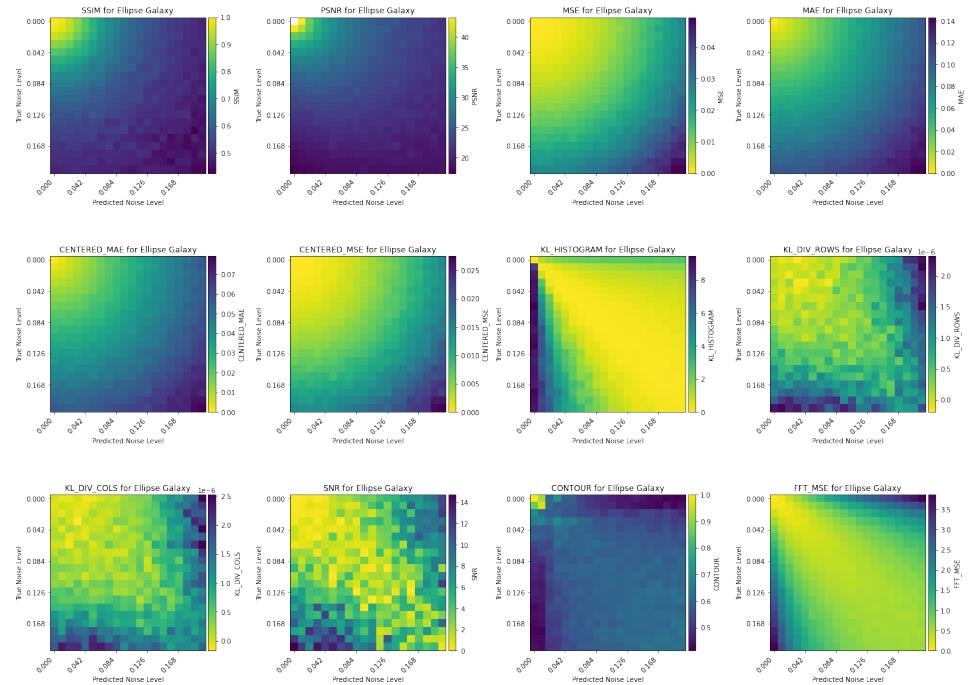


Figura 7.6: Visualizaciones de las matrices de similitud de varias métricas para simulación de una galaxia elíptica

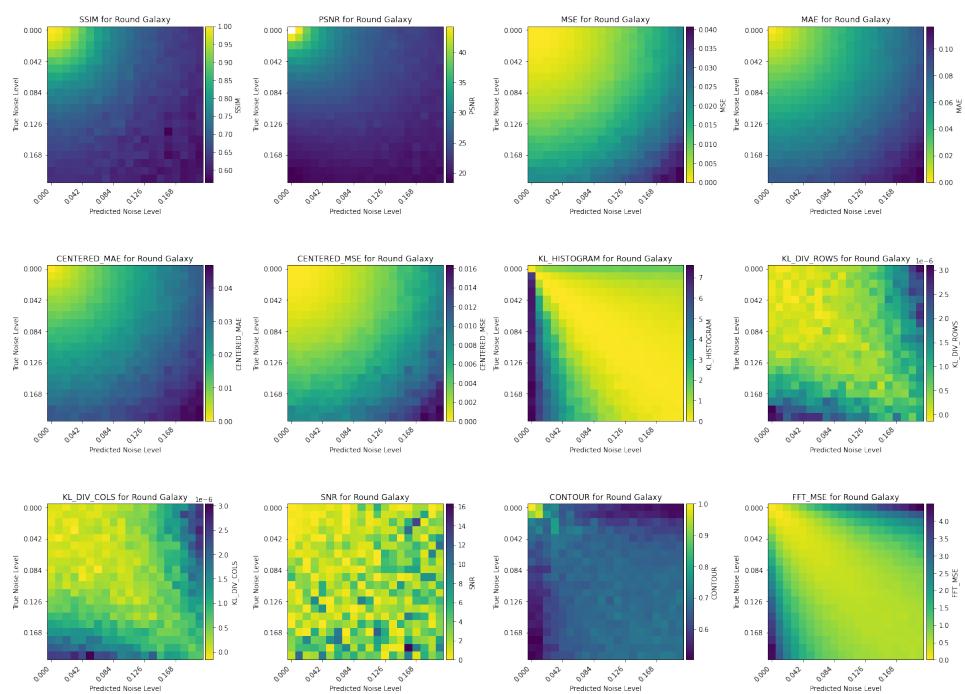


Figura 7.7: Visualizaciones de las matrices de similitud de varias métricas para simulación de una galaxia circular

7.6. Muestras en escala logarítmica

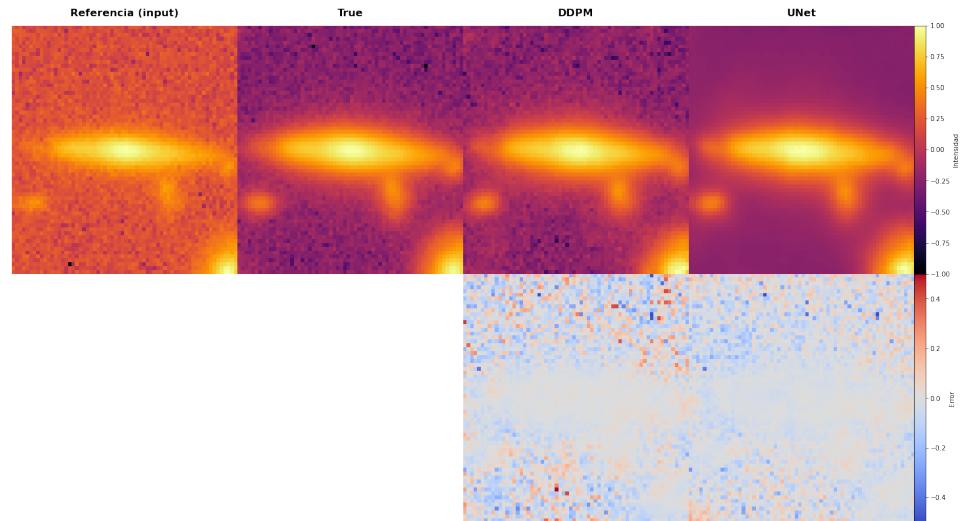


Figura 7.8: Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

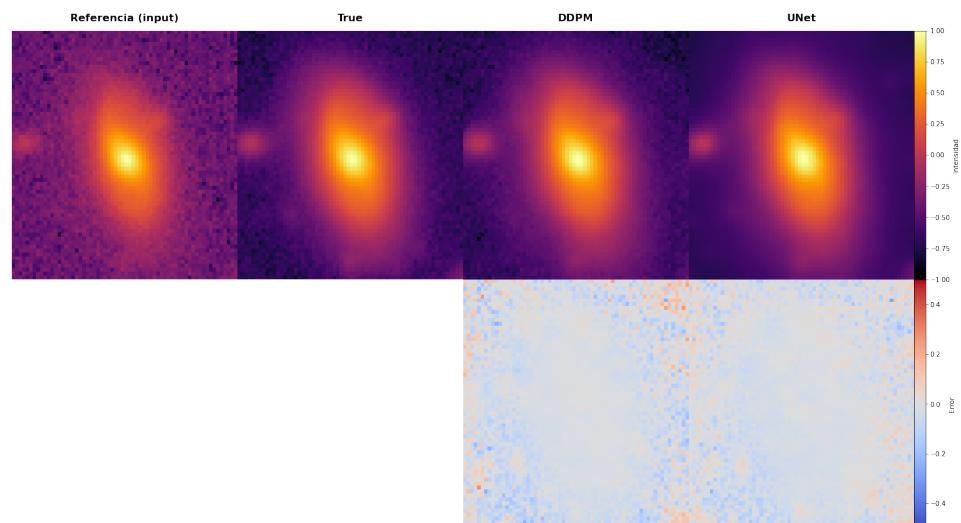


Figura 7.9: Muestra 2: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

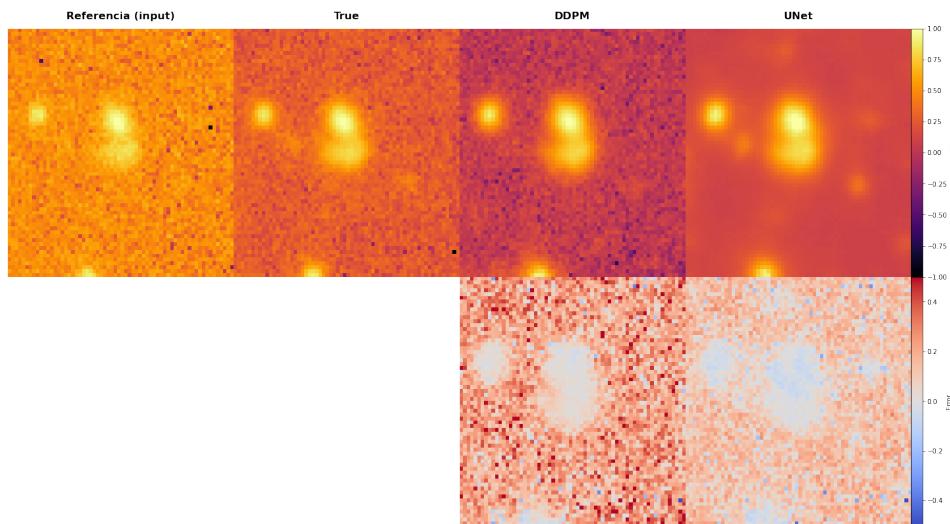


Figura 7.10: Muestra 3: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

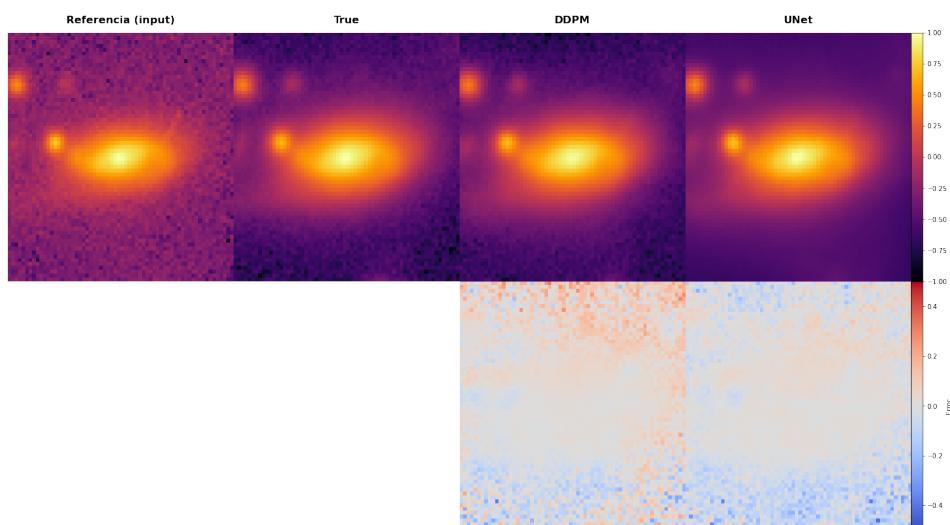


Figura 7.11: Muestra 4: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

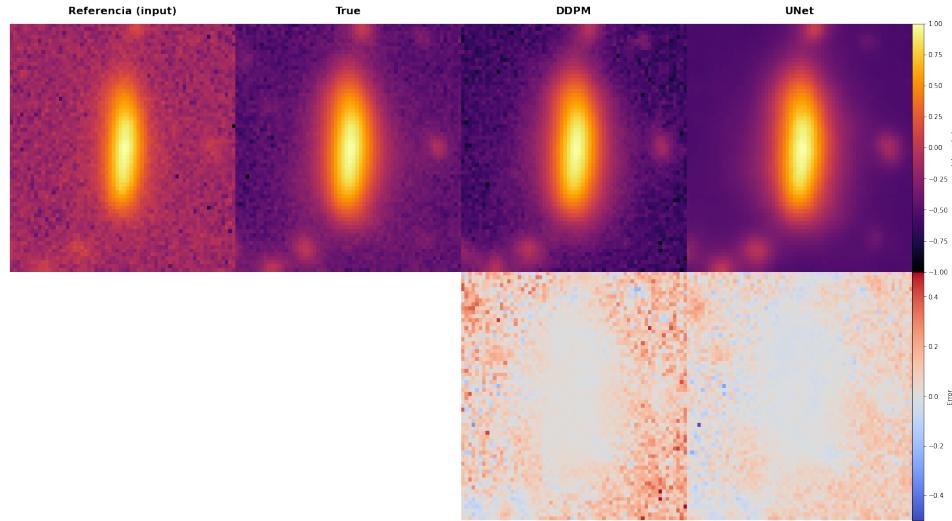


Figura 7.12: Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

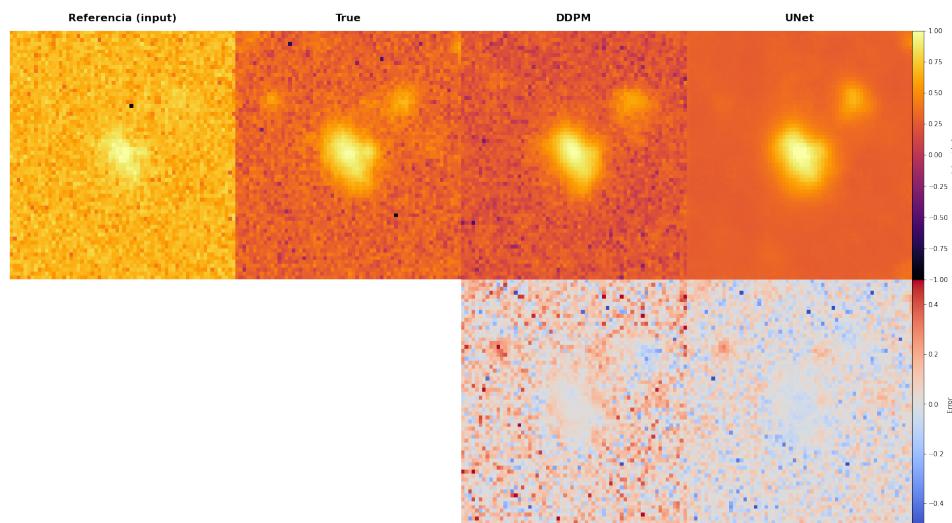


Figura 7.13: Muestra 6: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

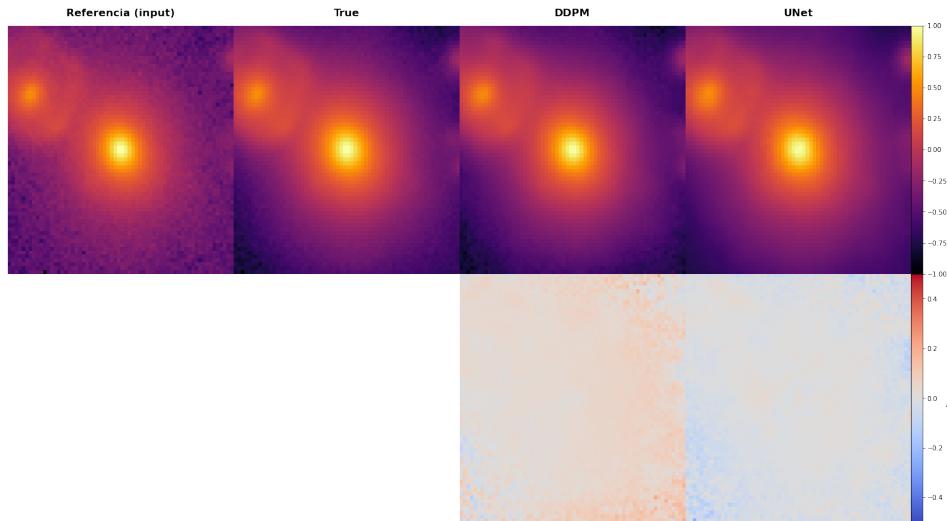


Figura 7.14: Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

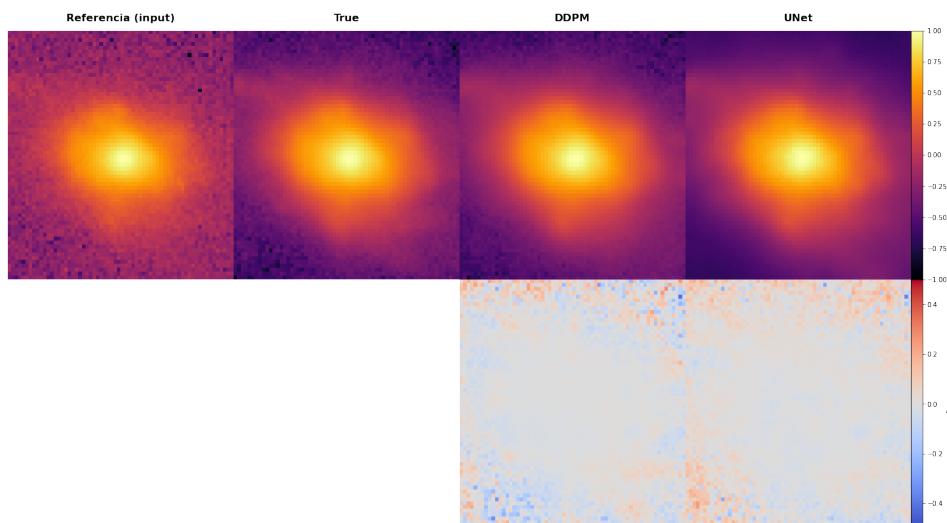


Figura 7.15: Muestra 8: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

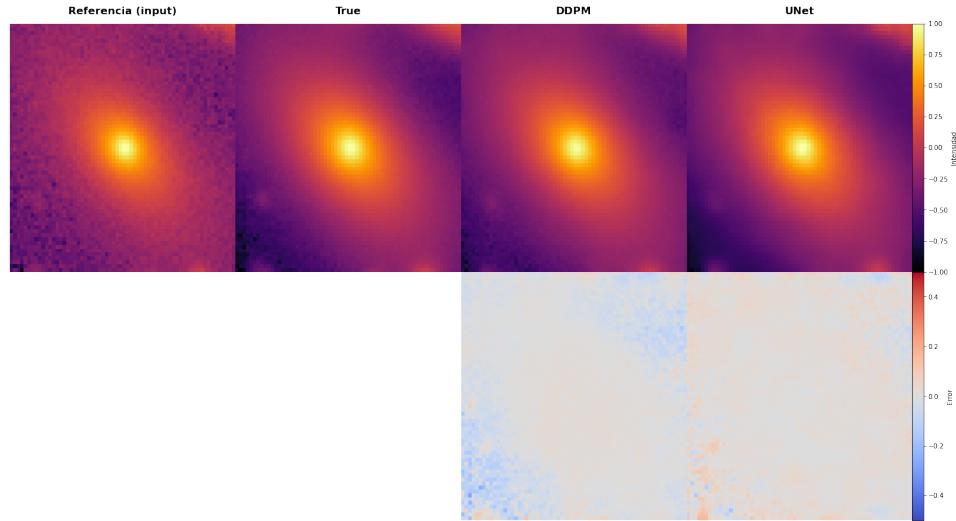


Figura 7.16: Muestra 9: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

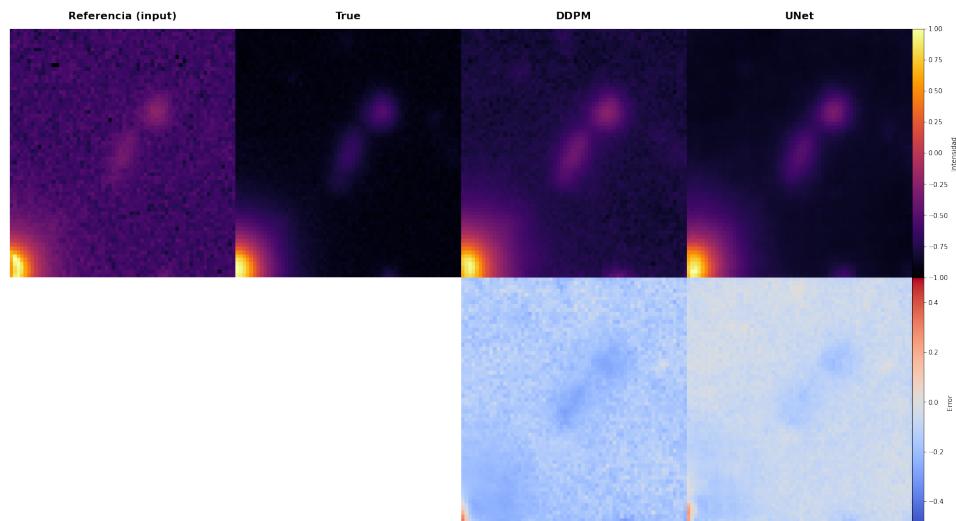


Figura 7.17: Muestra 10: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

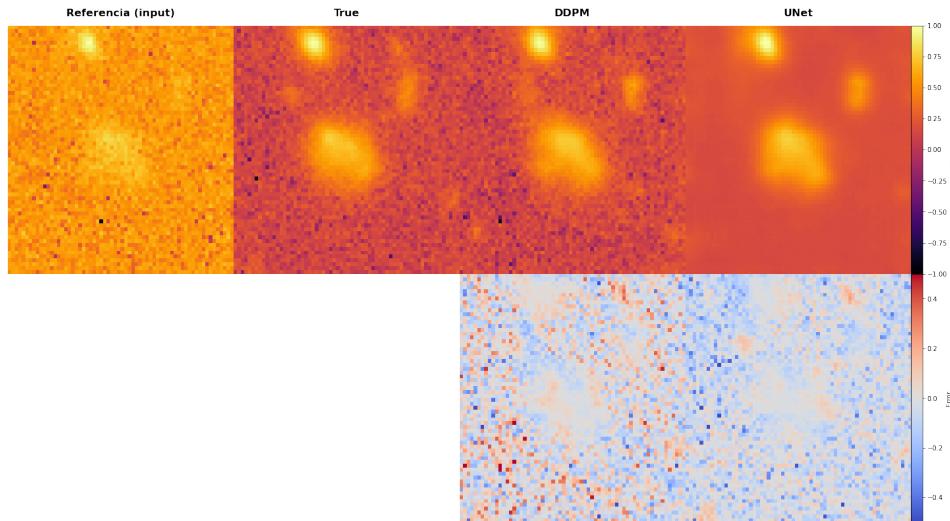


Figura 7.18: Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

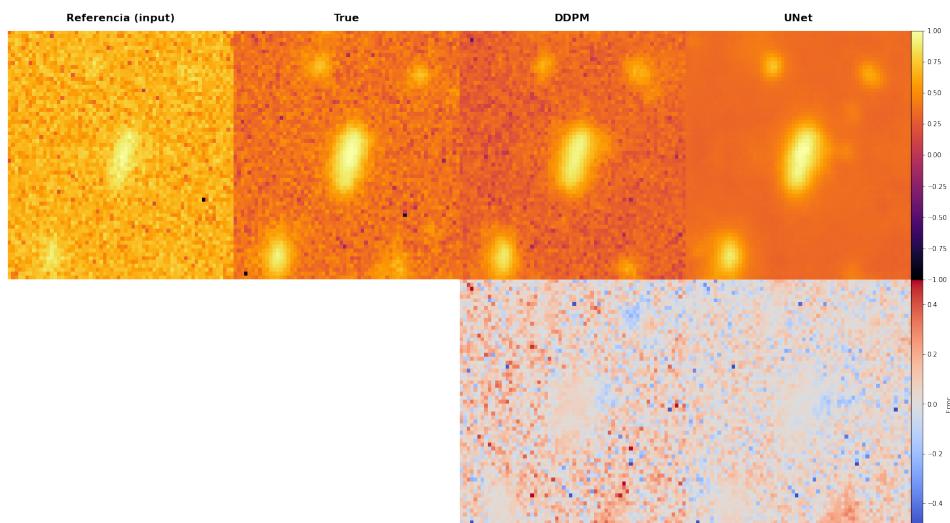


Figura 7.19: Muestra 12: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

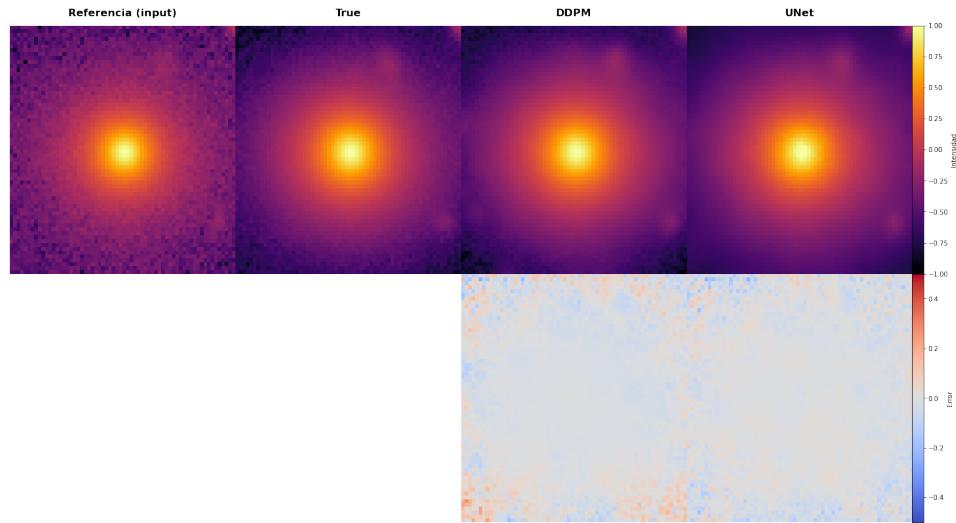


Figura 7.20: Muestra 13: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

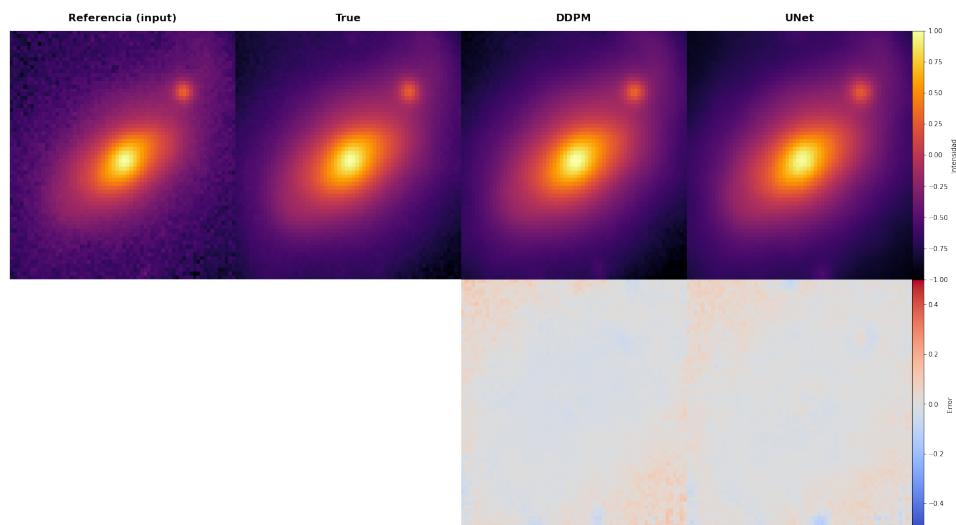


Figura 7.21: Muestra 14: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

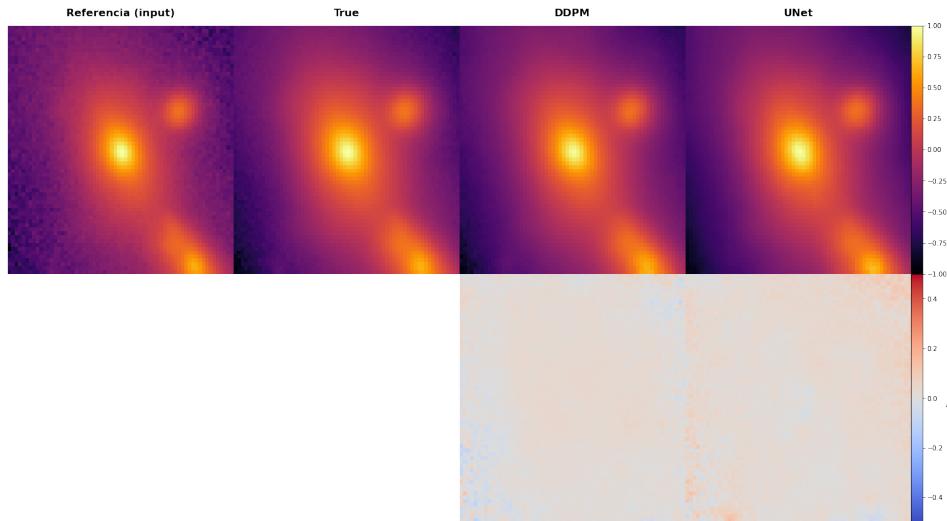


Figura 7.22: Muestra 15: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

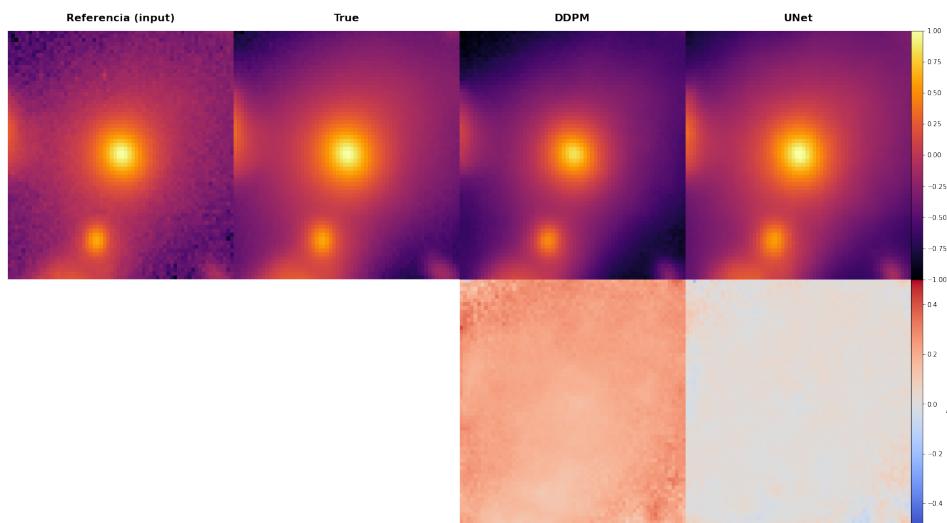


Figura 7.23: Muestra 16: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

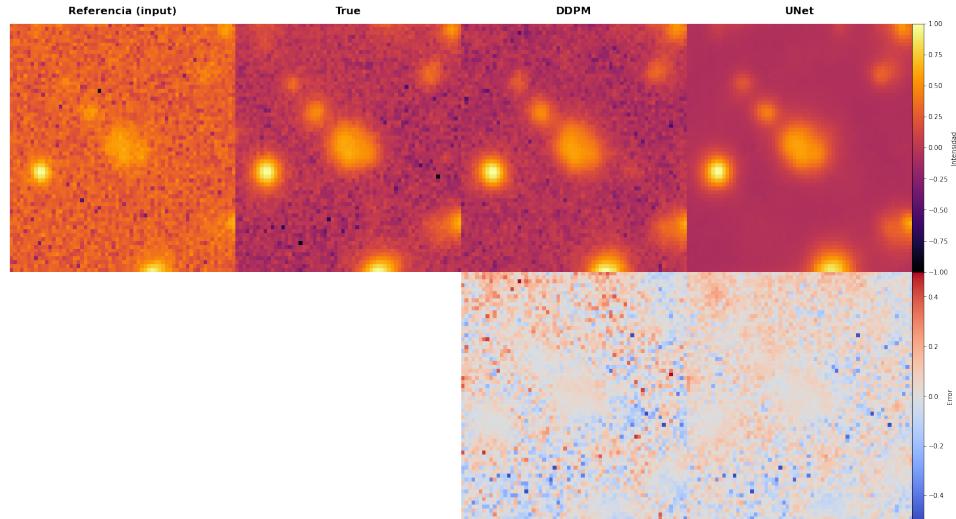


Figura 7.24: Muestra 17: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

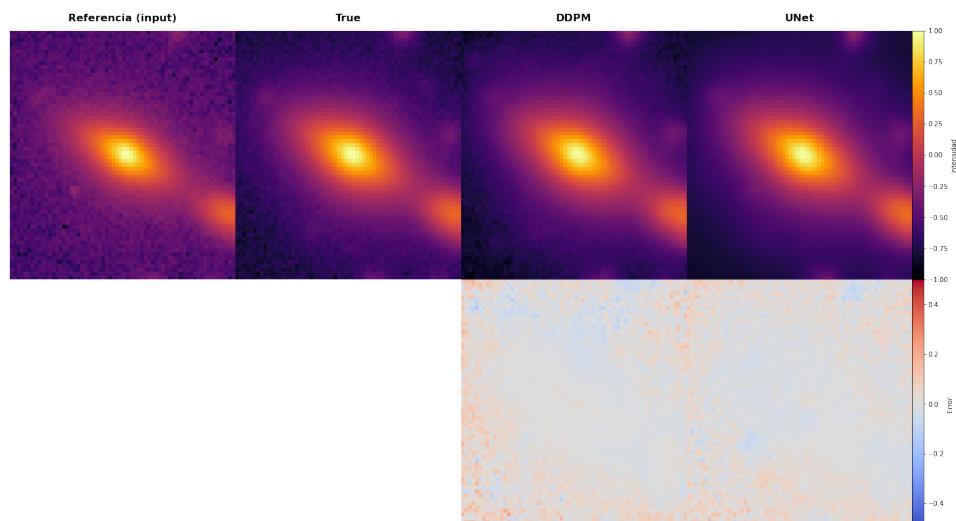


Figura 7.25: Muestra 18: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

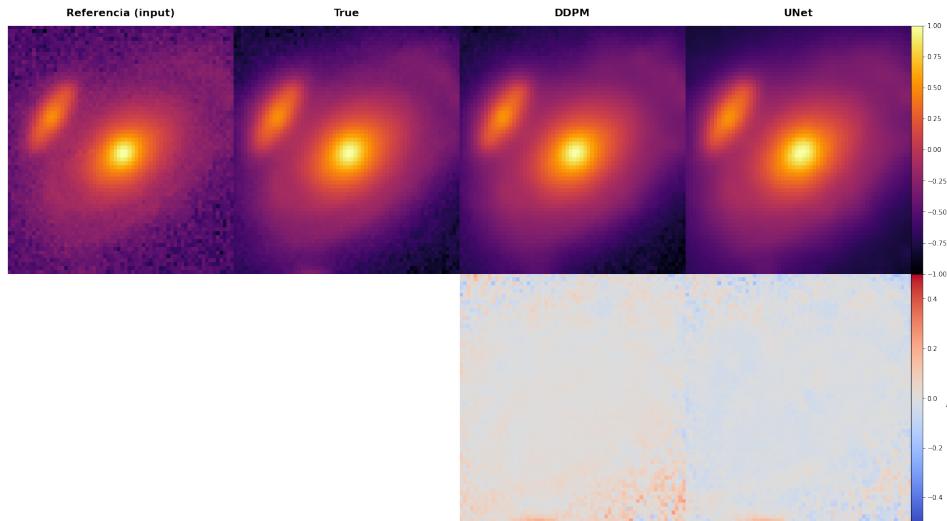


Figura 7.26: Muestra 19: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

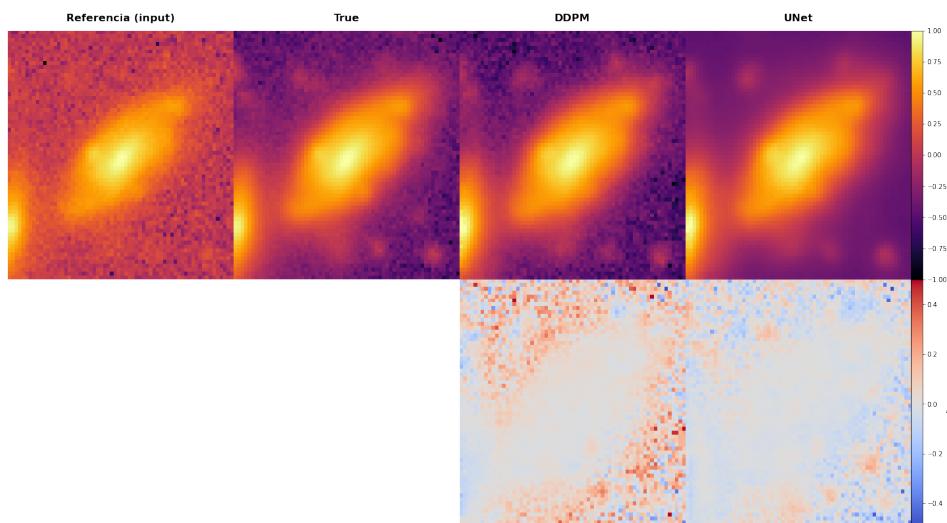


Figura 7.27: Muestra 20: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Log.

7.7. Muestras en escala raíz cuadrada

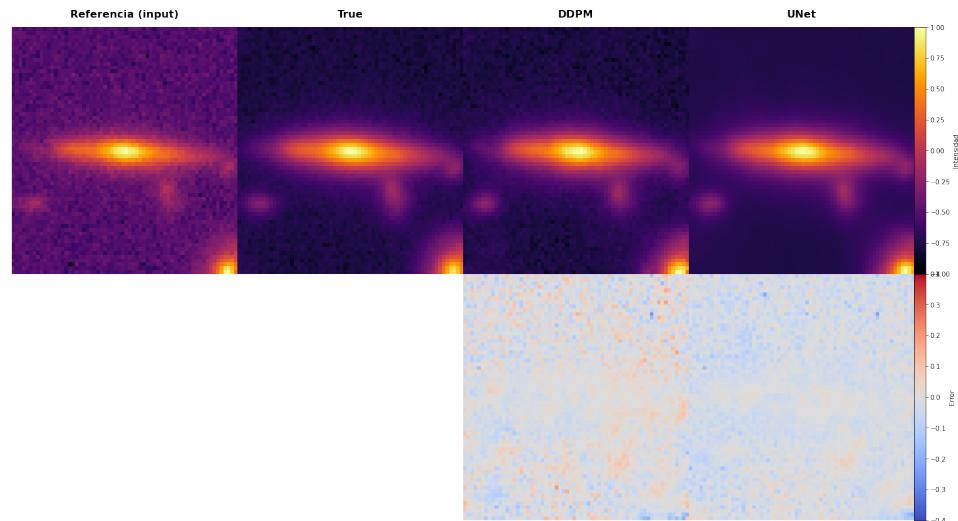


Figura 7.28: Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

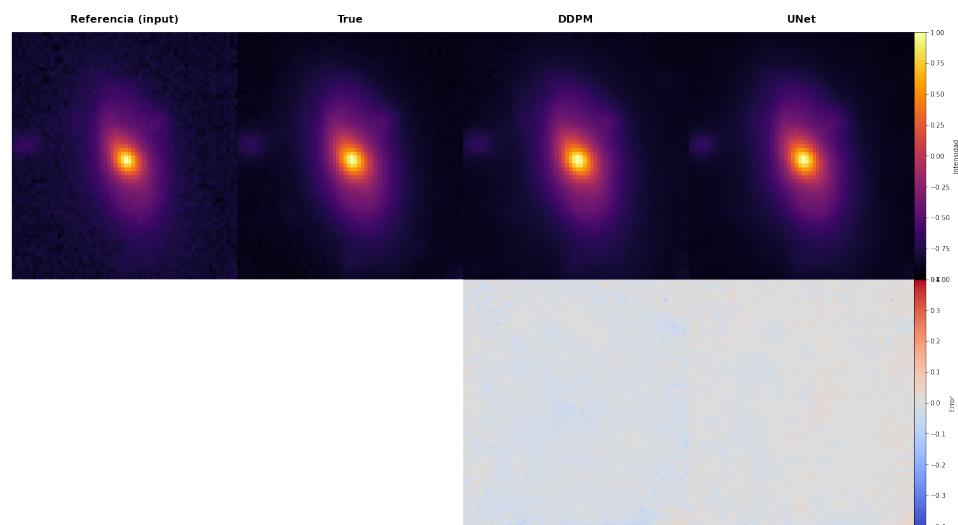


Figura 7.29: Muestra 2: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

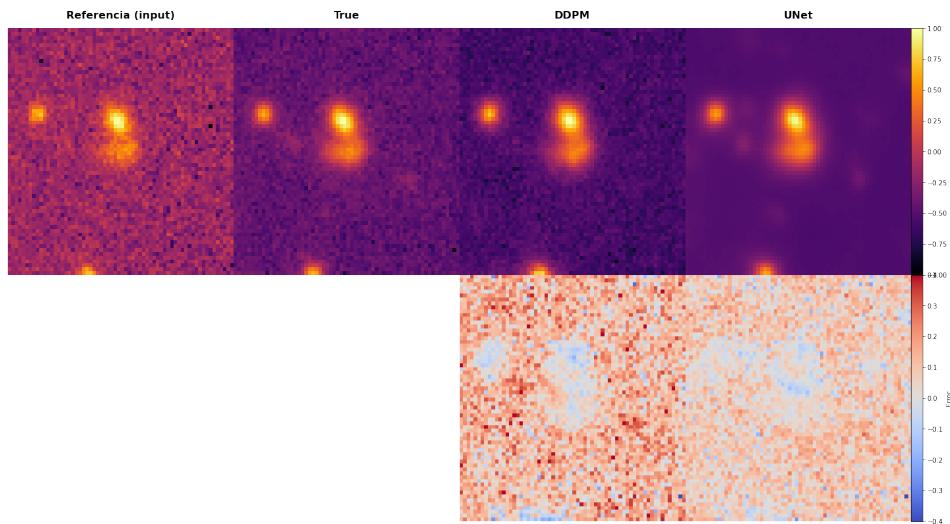


Figura 7.30: Muestra 3: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

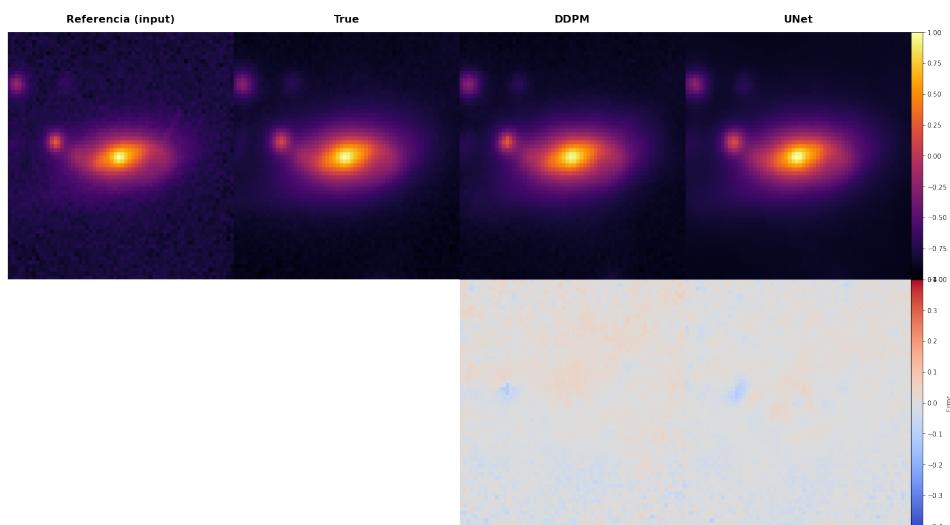


Figura 7.31: Muestra 4: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

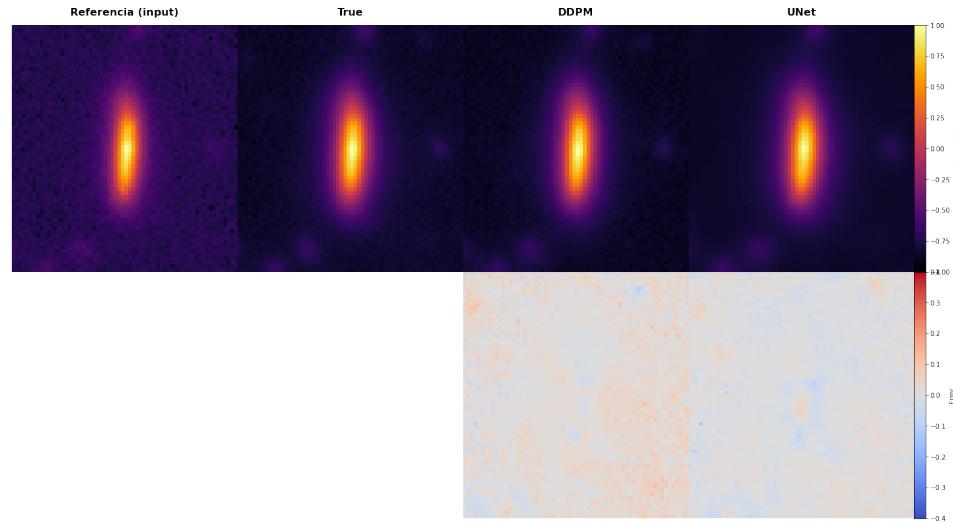


Figura 7.32: Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

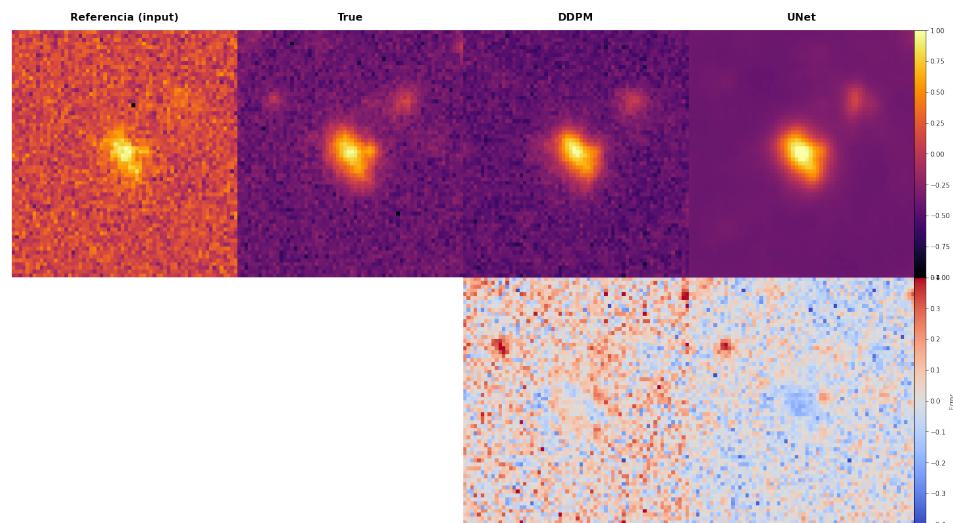


Figura 7.33: Muestra 6: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

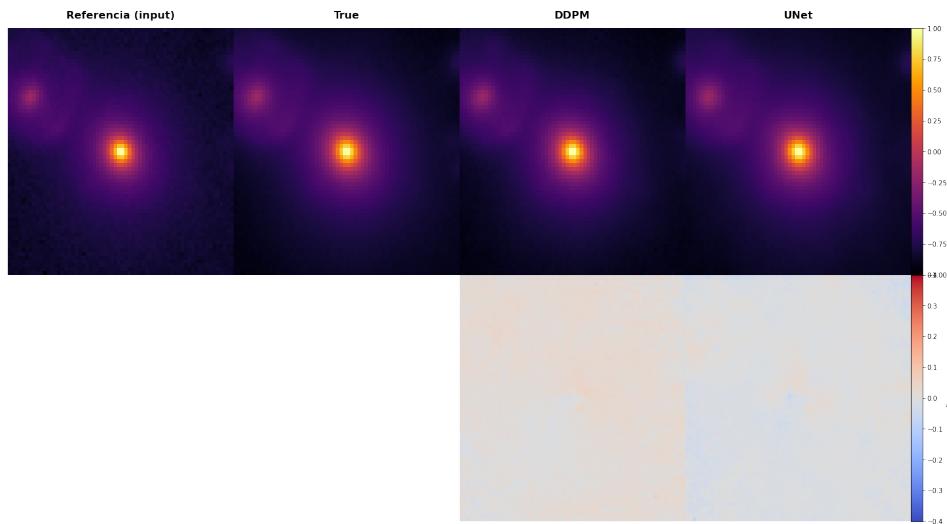


Figura 7.34: Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

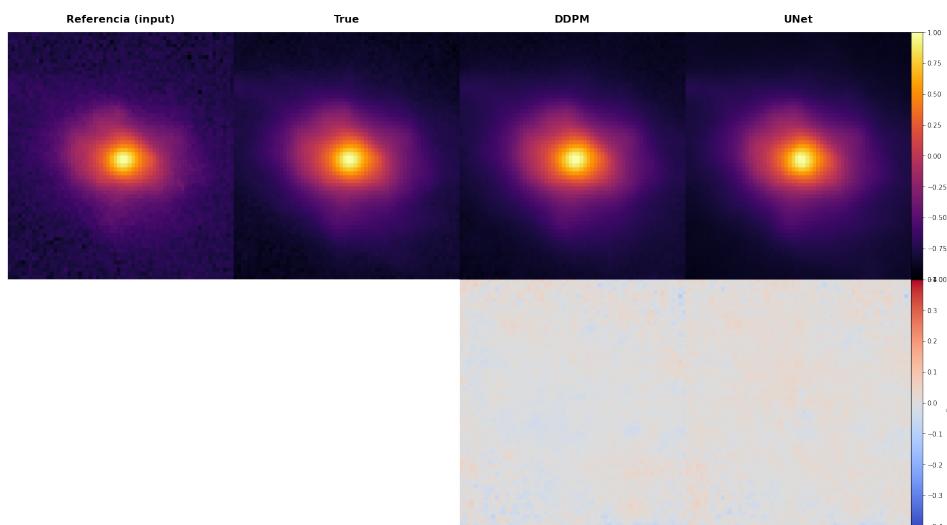


Figura 7.35: Muestra 8: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

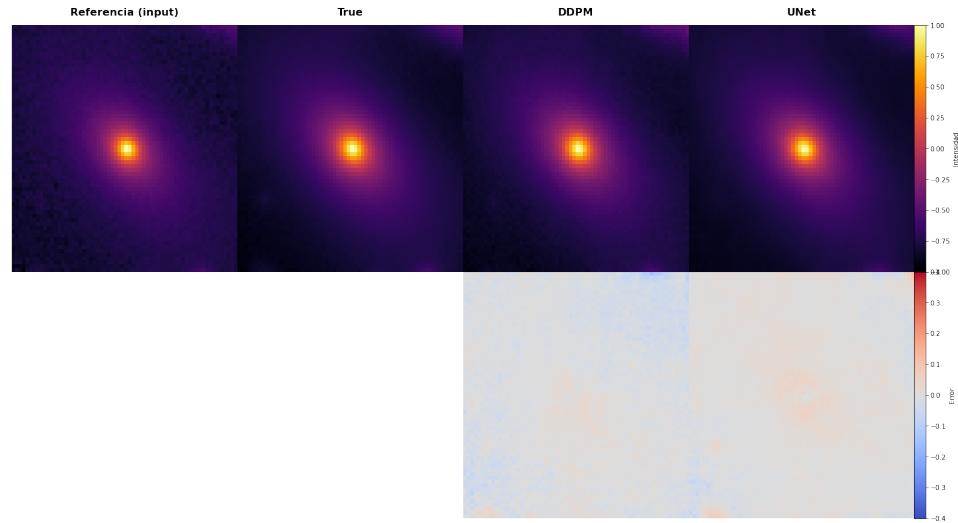


Figura 7.36: Muestra 9: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

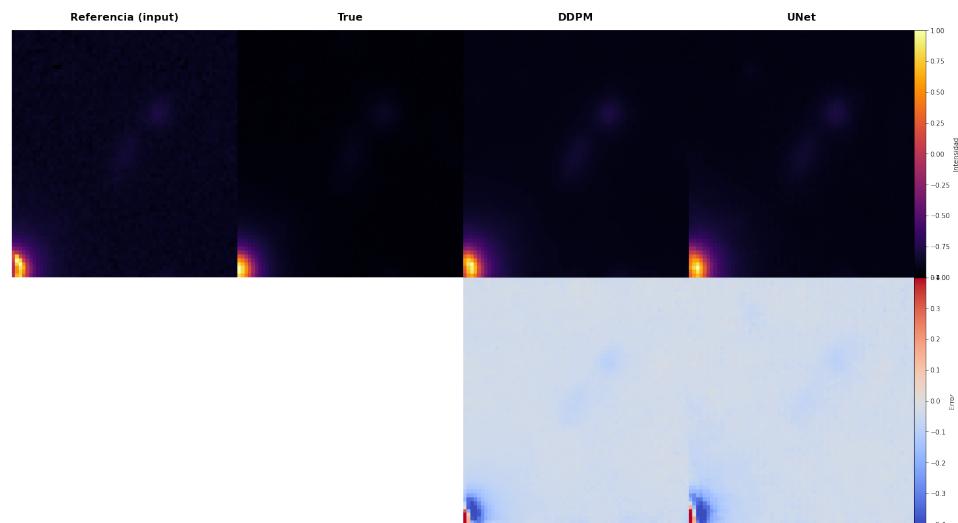


Figura 7.37: Muestra 10: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

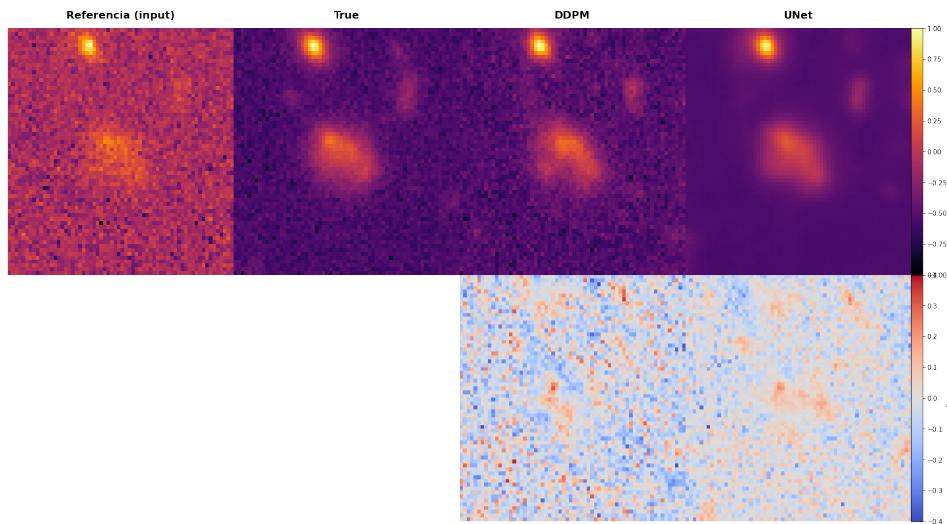


Figura 7.38: Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

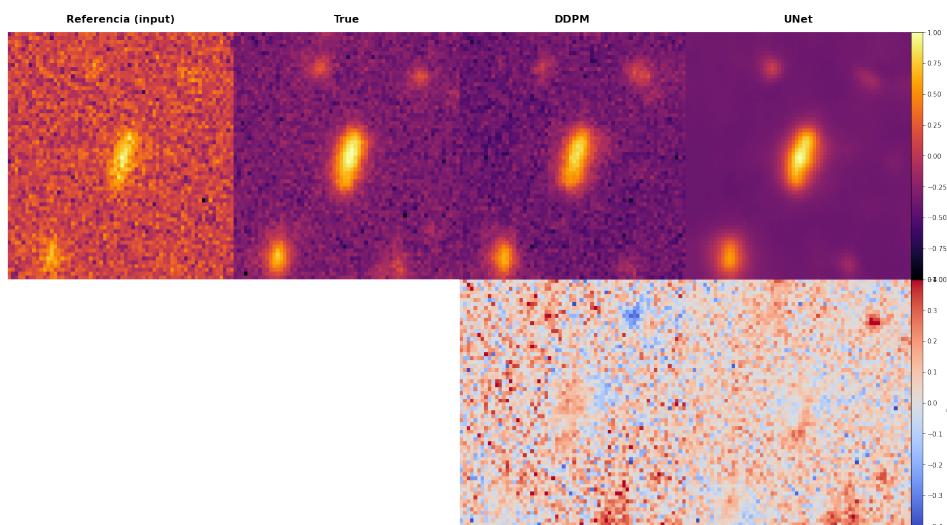


Figura 7.39: Muestra 12: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

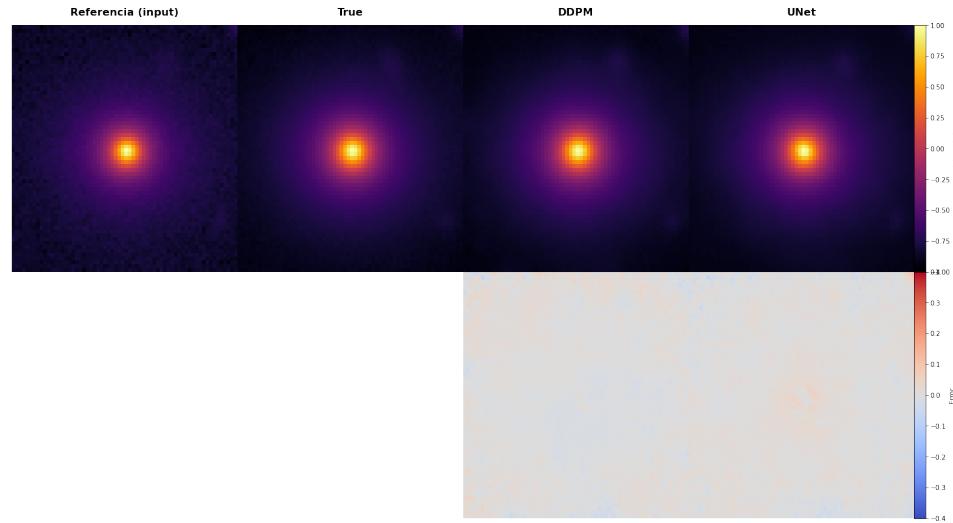


Figura 7.40: Muestra 13: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

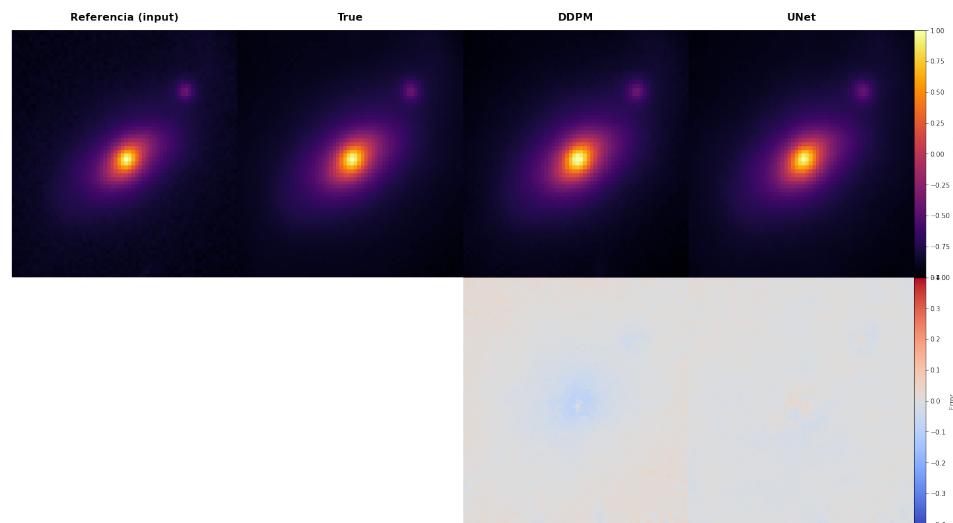


Figura 7.41: Muestra 14: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

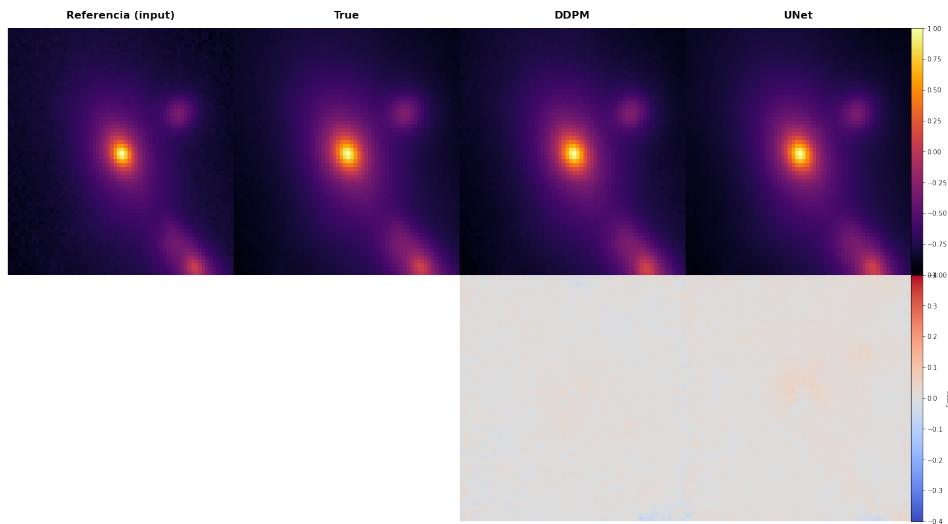


Figura 7.42: Muestra 15: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

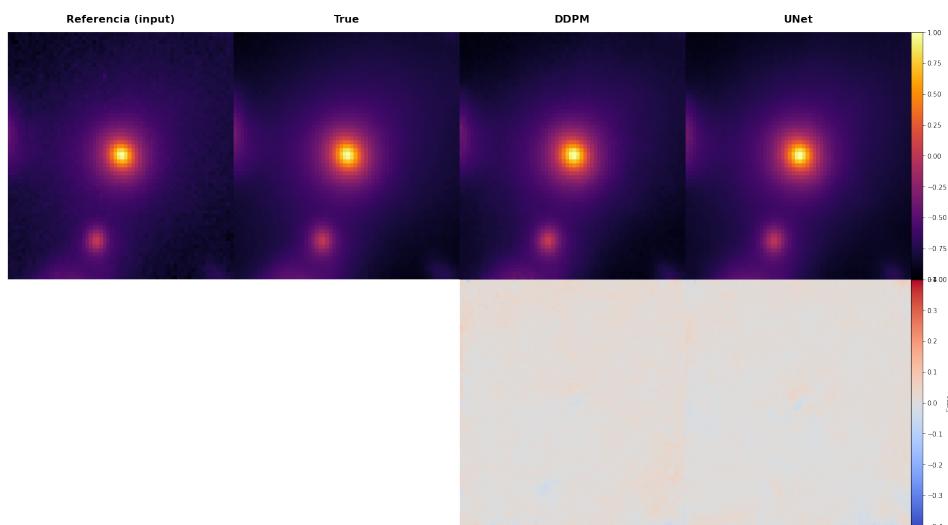


Figura 7.43: Muestra 16: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

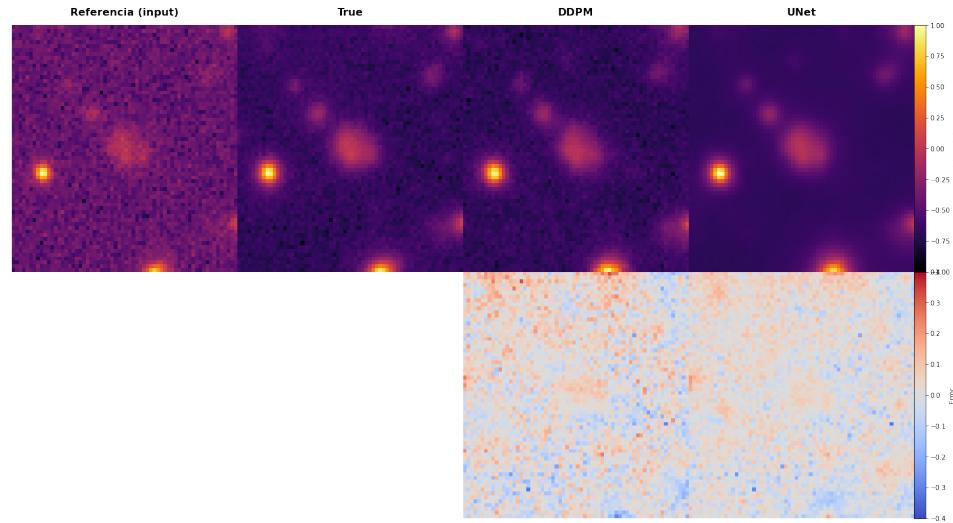


Figura 7.44: Muestra 17: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

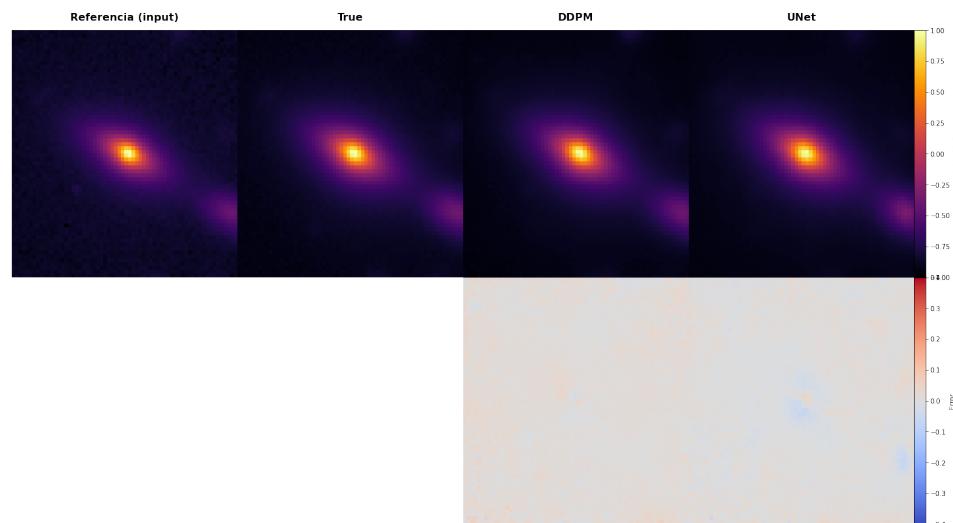


Figura 7.45: Muestra 18: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

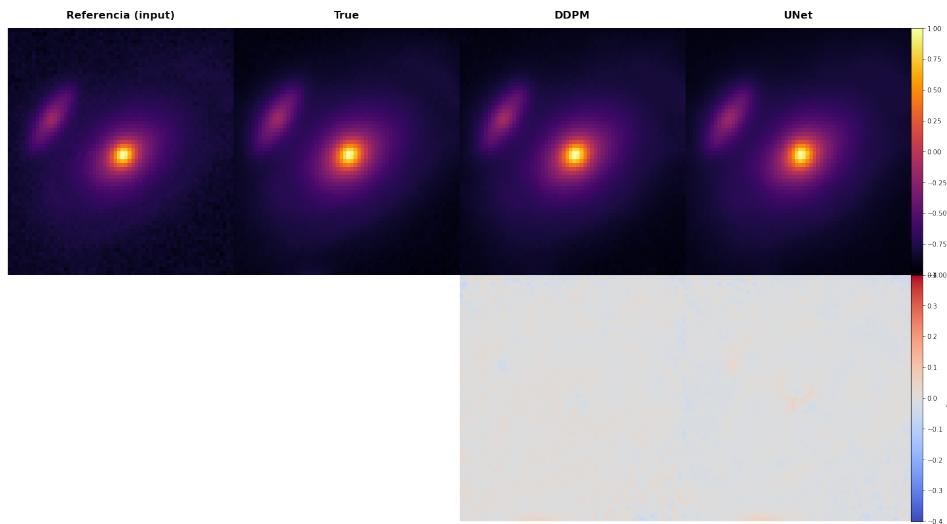


Figura 7.46: Muestra 19: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

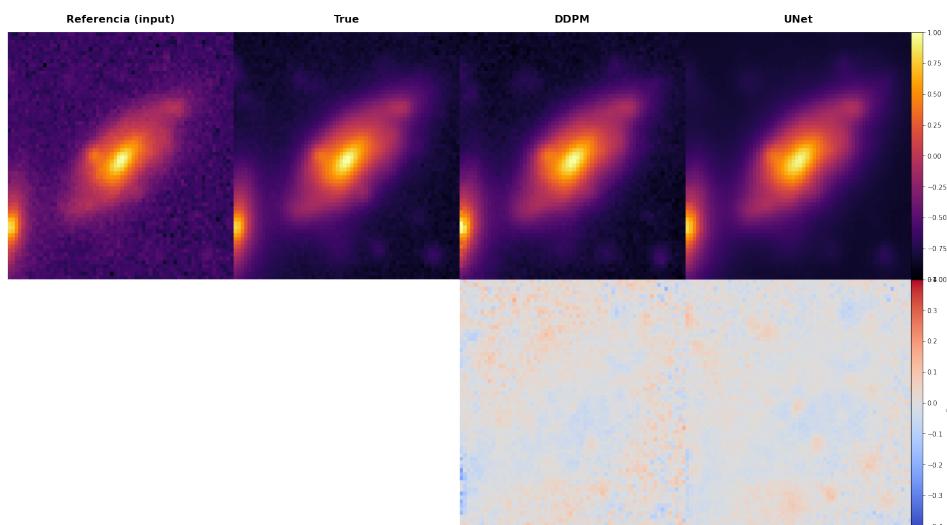


Figura 7.47: Muestra 20: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Sqrt.

7.8. Muestras en escala lineal

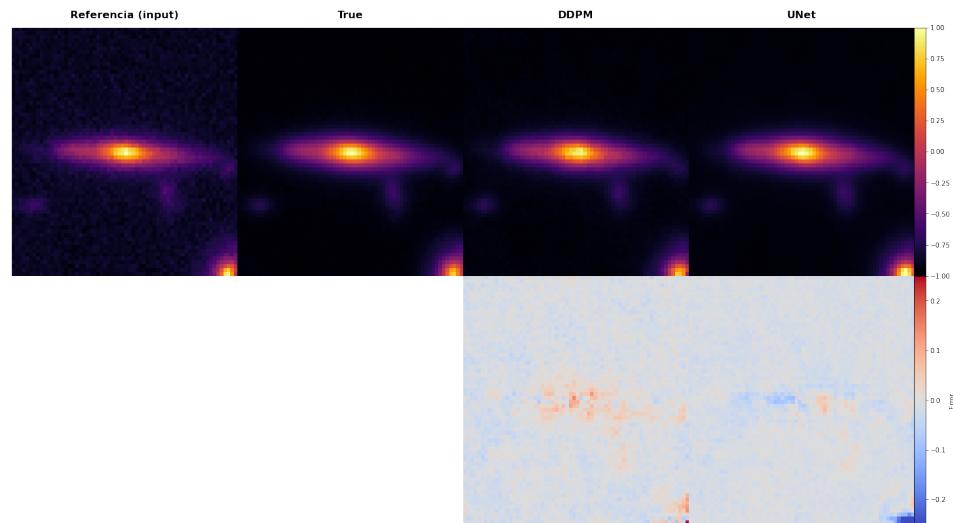


Figura 7.48: Muestra 1: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

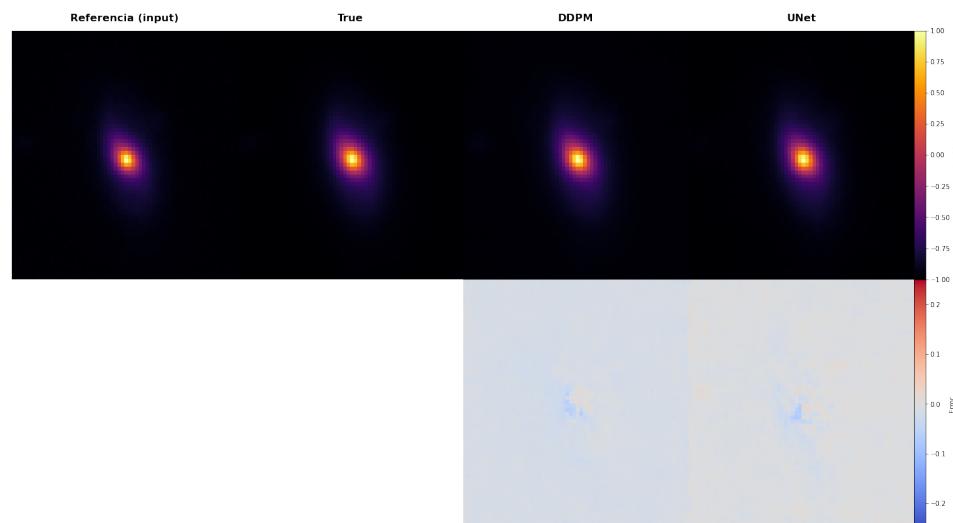


Figura 7.49: Muestra 2: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

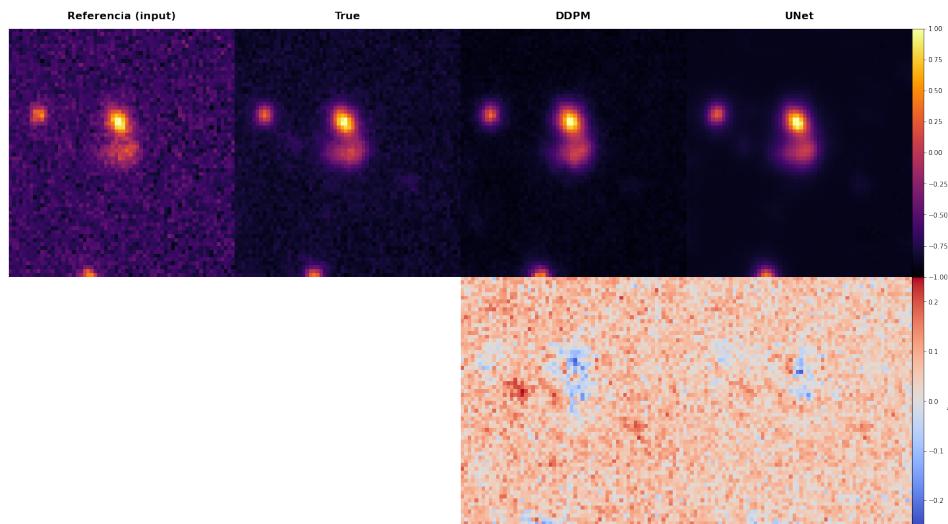


Figura 7.50: Muestra 3: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

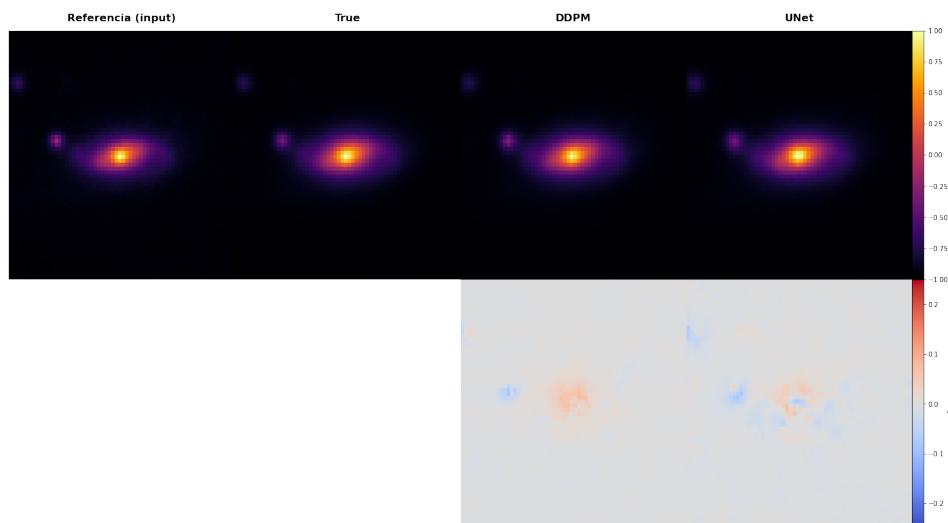


Figura 7.51: Muestra 4: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

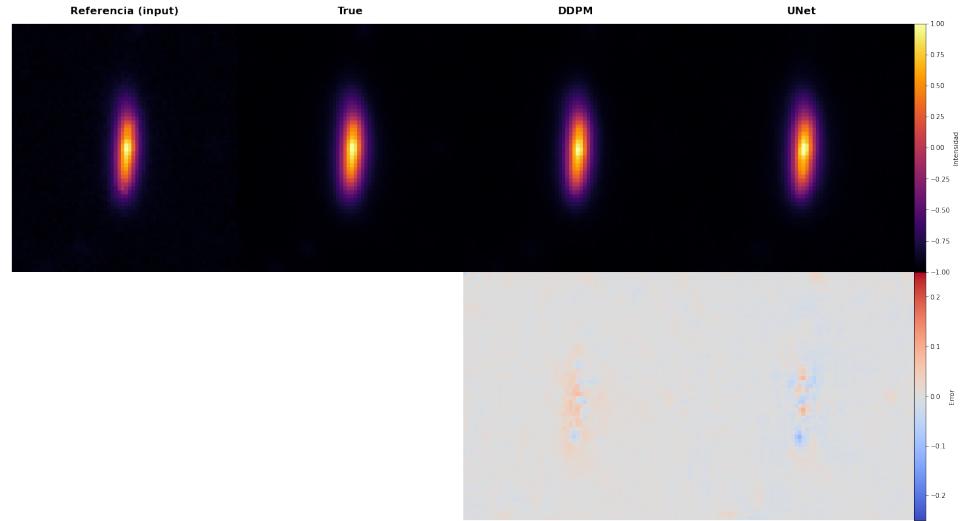


Figura 7.52: Muestra 5: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

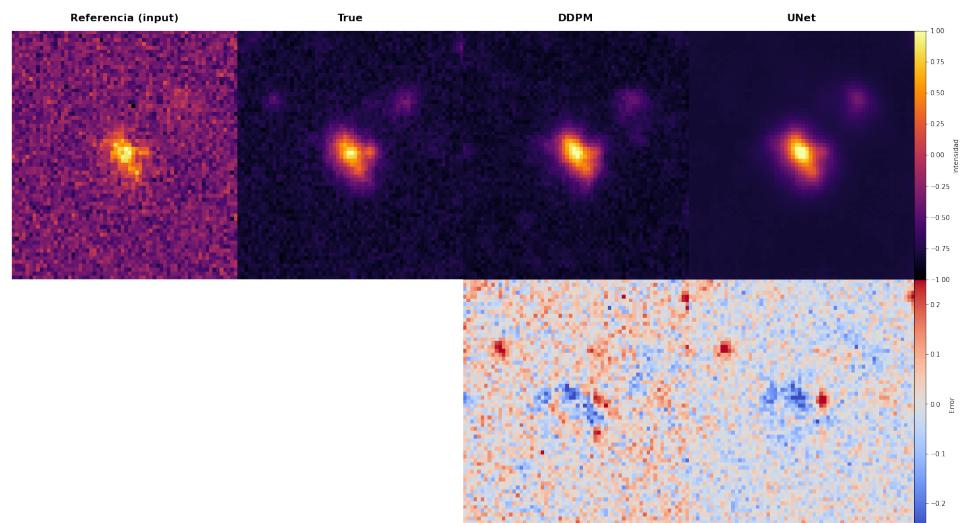


Figura 7.53: Muestra 6: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

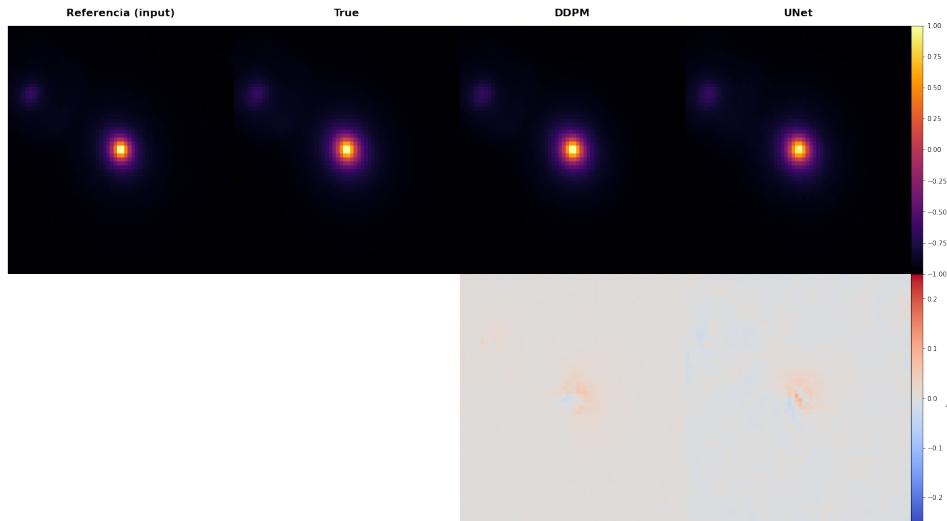


Figura 7.54: Muestra 7: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

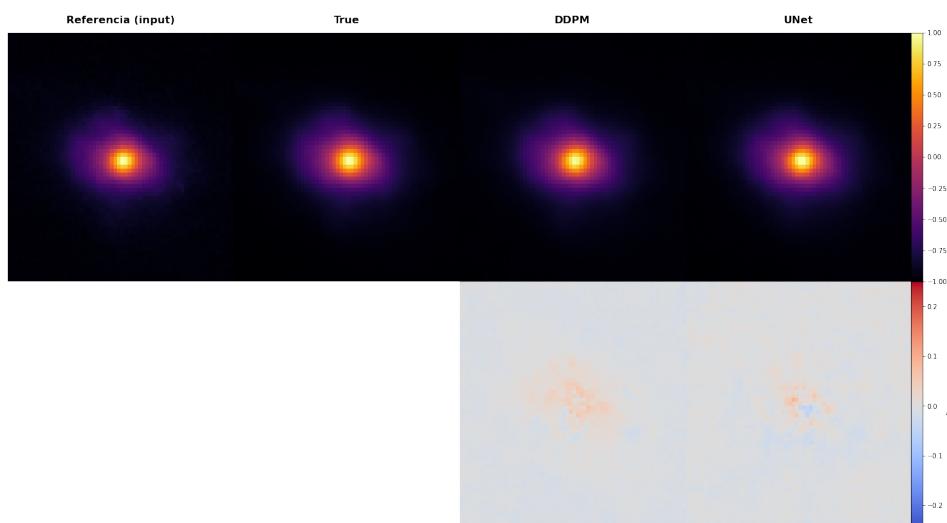


Figura 7.55: Muestra 8: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

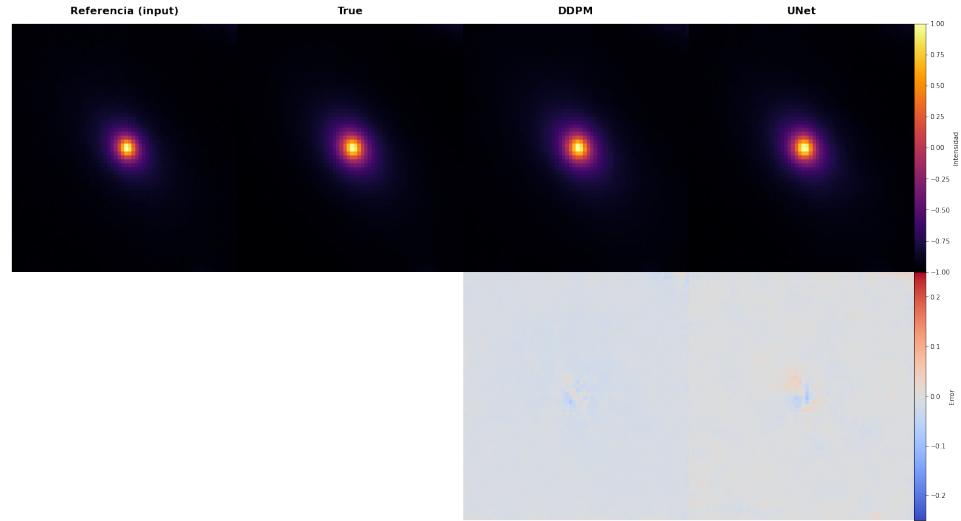


Figura 7.56: Muestra 9: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

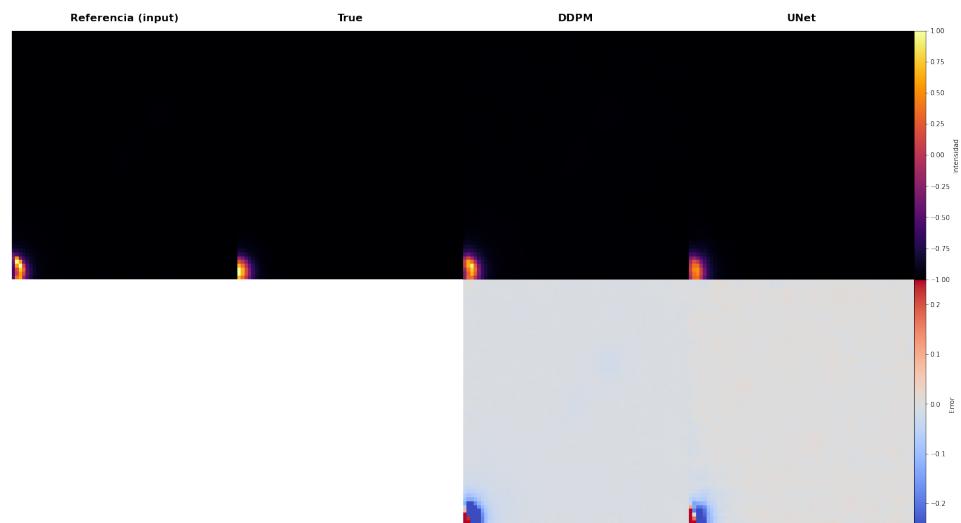


Figura 7.57: Muestra 10: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

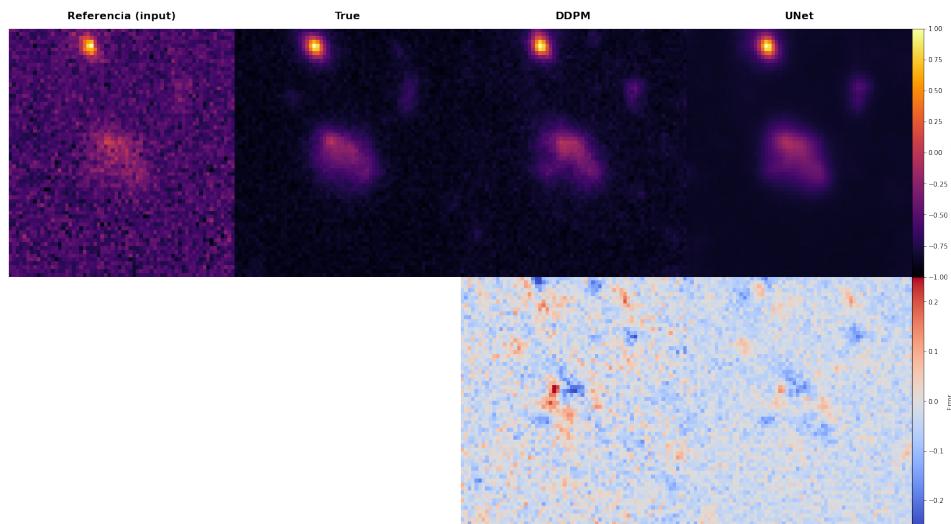


Figura 7.58: Muestra 11: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

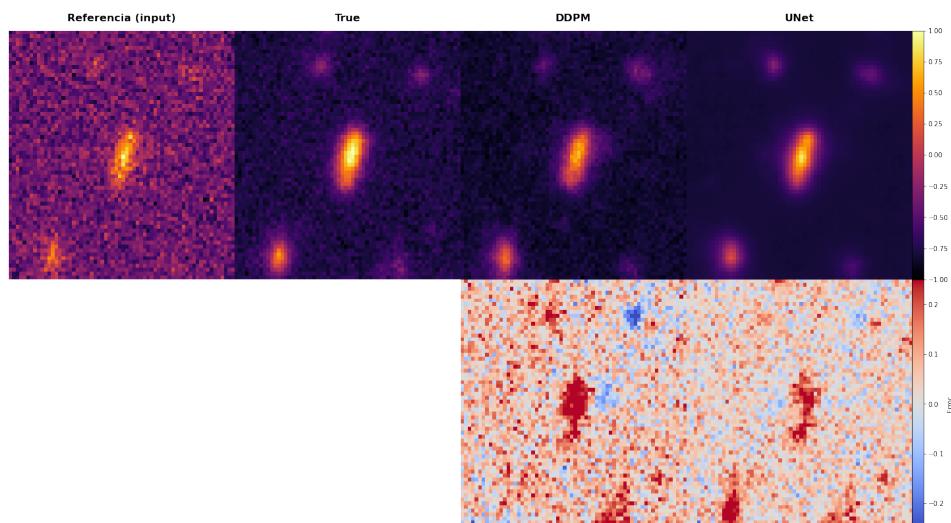


Figura 7.59: Muestra 12: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

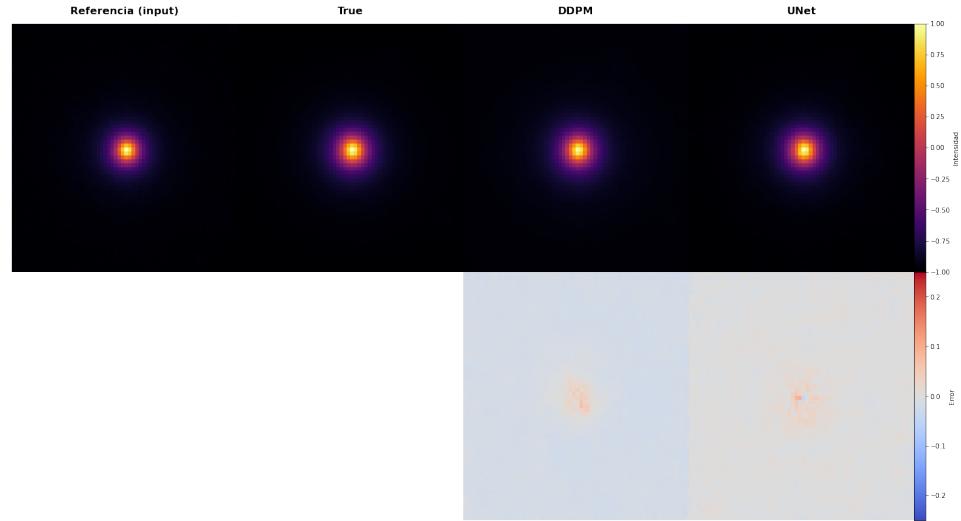


Figura 7.60: Muestra 13: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

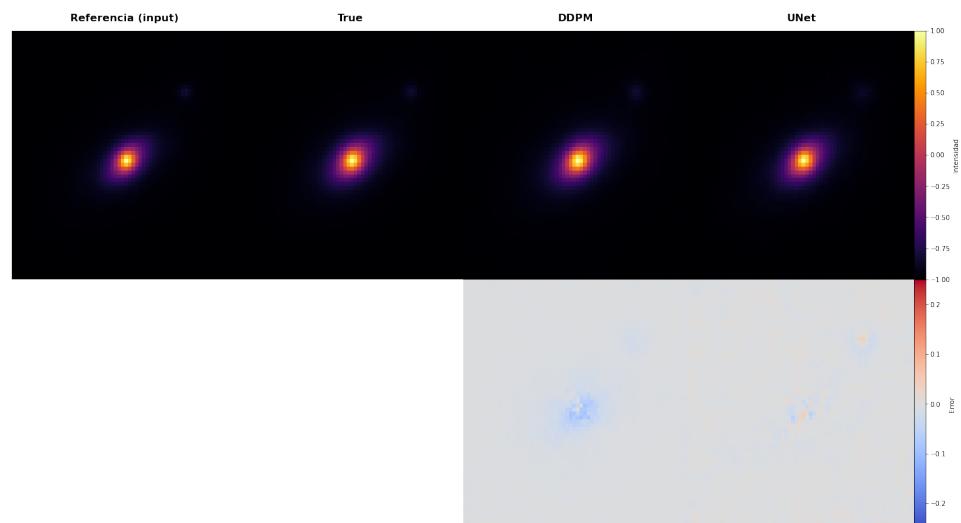


Figura 7.61: Muestra 14: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

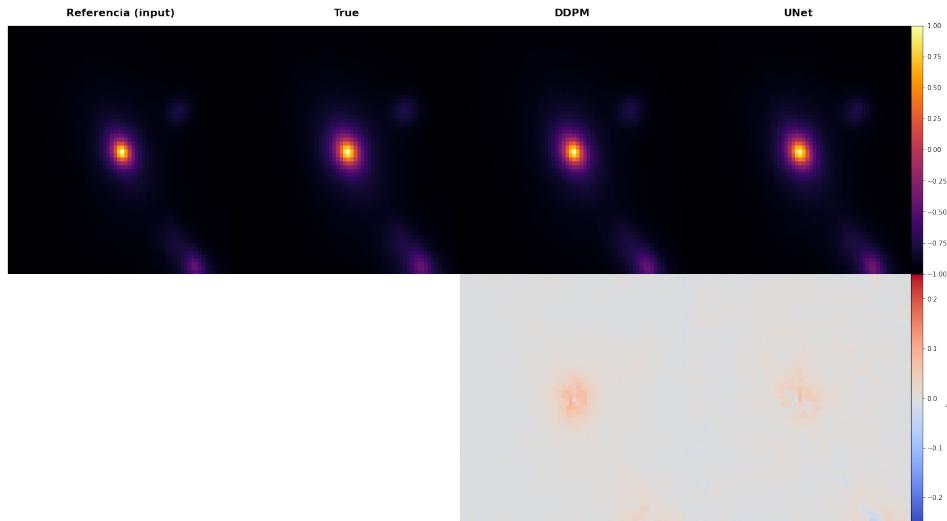


Figura 7.62: Muestra 15: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

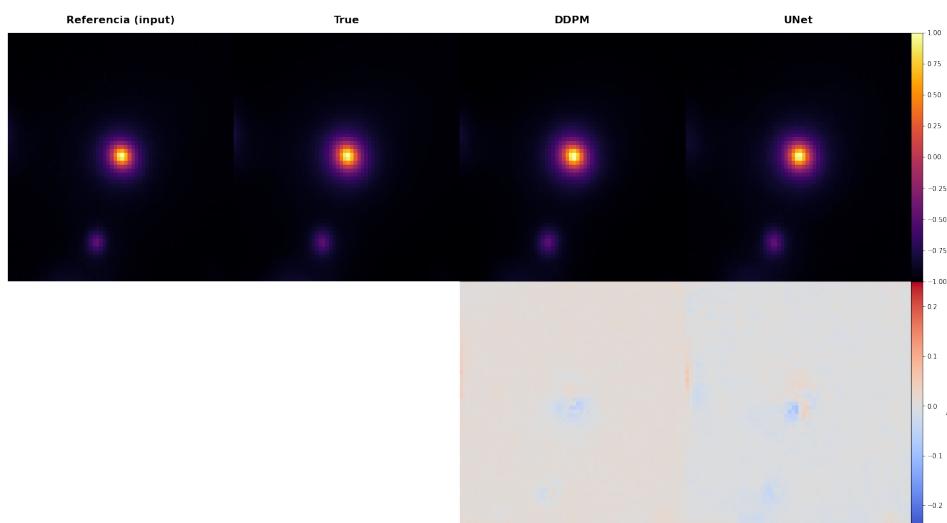


Figura 7.63: Muestra 16: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

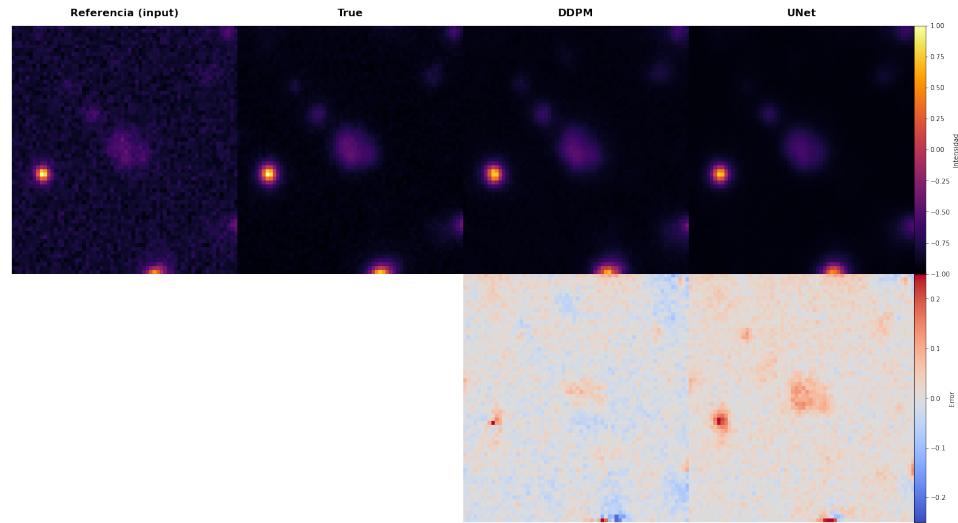


Figura 7.64: Muestra 17: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.



Figura 7.65: Muestra 18: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

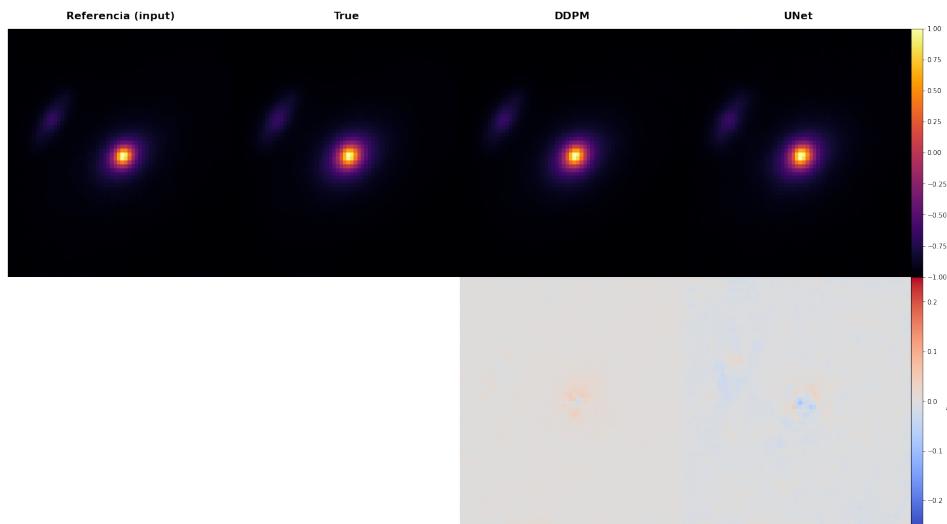


Figura 7.66: Muestra 19: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

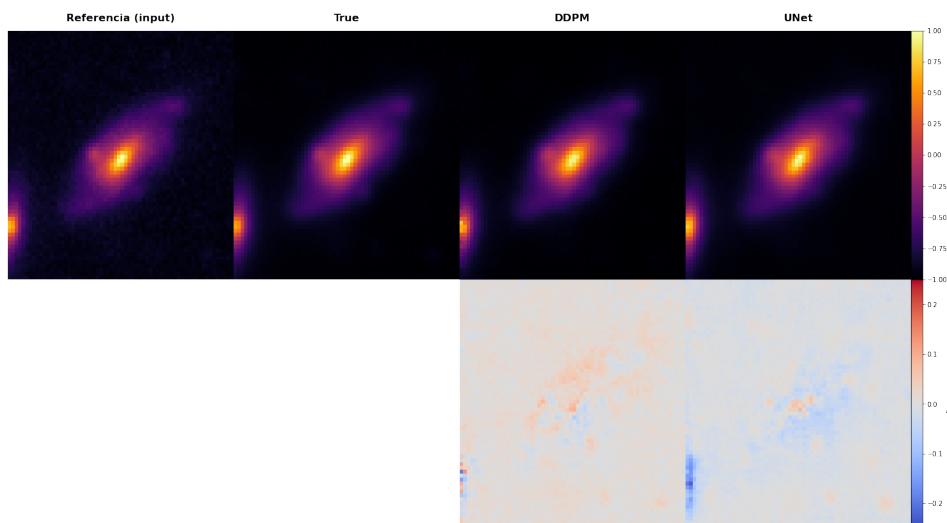


Figura 7.67: Muestra 20: Modelo DDPM con 2M de parámetros y 250 pasos de difusión y Residual Attention UNet con 2M de parámetros. Conjunto de datos Full y escala de datos Lineal.

Apéndice C: Tablas Suplementarias

7.9. Impacto del Número de Diffusion Steps

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
Base - UNet	0.0148 ± 0.0070	0.9941 ± 0.0061	46.3564 ± 3.4079	0.0776 ± 0.0465	0.0076 ± 0.0095	0.0001 ± 0.0009	0.0137 ± 0.0081	0.0005 ± 0.0006
Steps 10 - DDPM	0.0473 ± 0.0897	0.9877 ± 0.0107	44.6906 ± 3.7476	0.0788 ± 0.0550	0.0094 ± 0.0099	0.0002 ± 0.0009	0.0151 ± 0.0077	0.0005 ± 0.0006
Steps 20 - DDPM	0.0109 ± 0.0270	0.9939 ± 0.0074	46.7614 ± 4.5823	0.0630 ± 0.0319	0.0068 ± 0.0100	0.0001 ± 0.0011	0.0145 ± 0.0102	0.0005 ± 0.0008
Steps 50 - DDPM	0.0285 ± 0.0826	0.9906 ± 0.0078	41.4484 ± 5.4121	0.7439 ± 1.3756	0.0169 ± 0.0164	0.0006 ± 0.0021	0.0238 ± 0.0141	0.0011 ± 0.0011
Steps 100 - DDPM	0.0113 ± 0.0269	0.9941 ± 0.0058	46.8284 ± 4.2583	0.0591 ± 0.0291	0.0060 ± 0.0099	0.0001 ± 0.0009	0.0151 ± 0.0095	0.0006 ± 0.0007
Steps 250 - DDPM	0.0118 ± 0.0296	0.9933 ± 0.0080	44.8687 ± 4.4817	0.1025 ± 0.1132	0.0090 ± 0.0117	0.0002 ± 0.0016	0.0173 ± 0.0107	0.0007 ± 0.0011

Tabla 7.1: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
Base - UNet	0.1799 ± 0.5292	0.9405 ± 0.1266	44.2514 ± 7.7717	1.0933 ± 2.5707	0.0148 ± 0.0271	0.0010 ± 0.0077	0.0196 ± 0.0207	0.0014 ± 0.0026
Steps 10 - DDPM	0.1623 ± 0.4370	0.9299 ± 0.1300	39.8007 ± 7.4943	1.2583 ± 3.4206	0.0232 ± 0.0358	0.0018 ± 0.0097	0.0322 ± 0.0319	0.0031 ± 0.0063
Steps 20 - DDPM	0.1142 ± 0.3167	0.9312 ± 0.1366	41.5805 ± 7.7352	0.4011 ± 0.8602	0.0193 ± 0.0315	0.0014 ± 0.0090	0.0264 ± 0.0252	0.0021 ± 0.0039
Steps 50 - DDPM	0.1881 ± 0.3009	0.8937 ± 0.1523	32.9681 ± 6.3549	2.8793 ± 4.4457	0.0400 ± 0.0439	0.0043 ± 0.0114	0.0622 ± 0.0329	0.0063 ± 0.0061
Steps 100 - DDPM	0.0724 ± 0.2325	0.9219 ± 0.1596	41.3297 ± 7.7342	0.1518 ± 0.2425	0.0183 ± 0.0359	0.0016 ± 0.0103	0.0293 ± 0.0285	0.0029 ± 0.0052
Steps 250 - DDPM	0.0725 ± 0.2229	0.9184 ± 0.1665	40.8577 ± 8.1110	0.2484 ± 0.4773	0.0223 ± 0.0376	0.0019 ± 0.0098	0.0301 ± 0.0283	0.0026 ± 0.0045

Tabla 7.2: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Linear Scale. Conjunto de datos: Full.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
Base - UNet	0.1273 ± 0.2223	0.9730 ± 0.0286	41.2363 ± 3.9788	0.2908 ± 0.5510	0.0154 ± 0.0142	0.0004 ± 0.0010	0.0172 ± 0.0092	0.0005 ± 0.0005
Steps 10 - DDPM	0.0992 ± 0.1760	0.9665 ± 0.0275	39.8000 ± 3.0892	0.3041 ± 0.5534	0.0175 ± 0.0150	0.0005 ± 0.0011	0.0197 ± 0.0106	0.0007 ± 0.0007
Steps 20 - DDPM	0.0960 ± 0.1785	0.9695 ± 0.0314	39.4595 ± 3.8285	0.2508 ± 0.3434	0.0192 ± 0.0168	0.0007 ± 0.0013	0.0223 ± 0.0138	0.0009 ± 0.0010
Steps 50 - DDPM	0.0915 ± 0.1468	0.9547 ± 0.0390	38.3239 ± 3.7778	0.2772 ± 0.4760	0.0216 ± 0.0186	0.0008 ± 0.0016	0.0250 ± 0.0135	0.0010 ± 0.0010
Steps 100 - DDPM	0.0751 ± 0.1343	0.9630 ± 0.0392	37.5774 ± 4.2028	0.6194 ± 0.9674	0.0251 ± 0.0206	0.0011 ± 0.0019	0.0247 ± 0.0158	0.0010 ± 0.0011
Steps 250 - DDPM	0.0669 ± 0.1249	0.9600 ± 0.0452	37.3285 ± 3.5595	0.6808 ± 1.2286	0.0247 ± 0.0199	0.0010 ± 0.0018	0.0238 ± 0.0156	0.0010 ± 0.0013

Tabla 7.3: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
Base - UNet	0.4139 ± 0.8783	0.8859 ± 0.1947	38.9404 ± 6.6994	1.1096 ± 2.0748	0.0253 ± 0.0368	0.0020 ± 0.0085	0.0244 ± 0.0218	0.0016 ± 0.0028
Steps 10 - DDPM	0.2783 ± 0.4936	0.8436 ± 0.1969	34.5439 ± 5.7600	0.6186 ± 0.9963	0.0391 ± 0.0471	0.0037 ± 0.0121	0.0406 ± 0.0311	0.0036 ± 0.0056
Steps 20 - DDPM	1.2302 ± 1.1633	0.4952 ± 0.1254	24.8917 ± 2.2136	0.5694 ± 0.5526	0.0958 ± 0.0749	0.0148 ± 0.0239	0.0945 ± 0.0240	0.0144 ± 0.0074
Steps 50 - DDPM	0.1690 ± 0.3675	0.8682 ± 0.2192	37.1572 ± 7.2302	0.2868 ± 0.4063	0.0328 ± 0.0477	0.0034 ± 0.0127	0.0362 ± 0.0372	0.0037 ± 0.0067
Steps 100 - DDPM	0.1456 ± 0.3196	0.8585 ± 0.2423	37.4494 ± 7.6600	0.3491 ± 1.1050	0.0346 ± 0.0572	0.0045 ± 0.0176	0.0340 ± 0.0410	0.0040 ± 0.0099
Steps 250 - DDPM	0.1322 ± 0.3146	0.8497 ± 0.2486	36.9372 ± 7.7831	0.3233 ± 1.1389	0.0364 ± 0.0596	0.0049 ± 0.0185	0.0374 ± 0.0444	0.0047 ± 0.0124

Tabla 7.4: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Sqrt Scale. Conjunto de datos: Full.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
Base - UNet	0.6254 ± 0.7687	0.8772 ± 0.0855	32.6200 ± 3.4457	0.5666 ± 0.6532	0.0373 ± 0.0393	0.0029 ± 0.0077	0.0185 ± 0.0104	0.0006 ± 0.0006
Steps 10 - DDPM	0.3067 ± 0.4402	0.8619 ± 0.0893	31.5489 ± 3.5265	0.2183 ± 0.3310	0.0432 ± 0.0453	0.0039 ± 0.0101	0.0226 ± 0.0142	0.0009 ± 0.0011
Steps 20 - DDPM	0.3177 ± 0.4450	0.8512 ± 0.1047	31.0604 ± 3.7314	0.4633 ± 0.7373	0.0468 ± 0.0464	0.0043 ± 0.0108	0.0288 ± 0.0167	0.0013 ± 0.0015
Steps 50 - DDPM	0.2783 ± 0.4047	0.8523 ± 0.0986	31.2983 ± 3.8517	0.1812 ± 0.2096	0.0451 ± 0.0456	0.0041 ± 0.0102	0.0260 ± 0.0181	0.0012 ± 0.0016
Steps 100 - DDPM	0.2331 ± 0.3615	0.8495 ± 0.1134	31.2359 ± 3.9067	0.1378 ± 0.1817	0.0451 ± 0.0500	0.0045 ± 0.0126	0.0226 ± 0.0151	0.0009 ± 0.0013
Steps 250 - DDPM	0.2195 ± 0.3494	0.8310 ± 0.1238	30.4727 ± 4.0192	0.1679 ± 0.3106	0.0484 ± 0.0531	0.0052 ± 0.0138	0.0254 ± 0.0182	0.0012 ± 0.0023

Tabla 7.5: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Log Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
Base - UNet	0.8589 ± 0.1062	0.8163 ± 0.1831	31.9258 ± 4.2065	1.4917 ± 2.2306	0.0414 ± 0.0475	0.0040 ± 0.0174	0.0237 ± 0.0195	0.0016 ± 0.0026
Steps 10 - DDPM	0.4637 ± 0.6446	0.7717 ± 0.2331	29.8775 ± 5.4277	1.1644 ± 3.3304	0.0652 ± 0.0771	0.0102 ± 0.0266	0.0479 ± 0.0635	0.0072 ± 0.0175
Steps 20 - DDPM	0.4018 ± 0.5650	0.7963 ± 0.1960	30.6069 ± 4.9617	0.9605 ± 3.4392	0.0532 ± 0.0599	0.0064 ± 0.0191	0.0319 ± 0.0372	0.0031 ± 0.0068
Steps 50 - DDPM	0.3256 ± 0.4755	0.7235 ± 0.2337	27.4745 ± 5.6341	2.1895 ± 5.3007	0.0899 ± 0.1235	0.0233 ± 0.0909	0.0576 ± 0.0982	0.0141 ± 0.0686
Steps 100 - DDPM	0.3035 ± 0.4520	0.7706 ± 0.2082	29.7876 ± 4.3293	0.7112 ± 2.6588	0.0552 ± 0.0579	0.0064 ± 0.0210	0.0360 ± 0.0282	0.0029 ± 0.0053
Steps 250 - DDPM	0.2617 ± 0.4265	0.7375 ± 0.2223	28.3513 ± 4.9719	0.6019 ± 2.4428	0.0693 ± 0.0782	0.0109 ± 0.0296	0.0428 ± 0.0496	0.0056 ± 0.0134

Tabla 7.6: Comparación de métricas para diferentes pasos de difusión. Escala de datos: Log Scale. Conjunto de datos: Full.

7.10. Impacto del Porcentaje de Datos

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - DDPM	0.3015 ± 0.4366	0.6668 ± 0.2035	24.5174 ± 4.5456	2.3269 ± 3.0329	0.1160 ± 0.1013	0.0237 ± 0.0403	0.0620 ± 0.0484	0.0072 ± 0.0124
10 % - UNET	0.6016 ± 0.7380	0.8685 ± 0.0938	31.5711 ± 3.5256	0.5313 ± 0.9092	0.0422 ± 0.0442	0.0037 ± 0.0095	0.0206 ± 0.0137	0.0008 ± 0.0013
25 % - DDPM	0.2592 ± 0.3945	0.6241 ± 0.2093	22.1641 ± 5.0959	1.6104 ± 2.3736	0.1683 ± 0.1282	0.0447 ± 0.0673	0.1220 ± 0.0929	0.0246 ± 0.0390
25 % - UNET	0.5993 ± 0.7501	0.8712 ± 0.0922	32.1371 ± 3.5138	0.7473 ± 1.2750	0.0399 ± 0.0416	0.0033 ± 0.0086	0.0210 ± 0.0122	0.0008 ± 0.0010
50 % - DDPM	0.2344 ± 0.3639	0.8833 ± 0.1095	30.2845 ± 4.0955	0.1826 ± 0.2107	0.0522 ± 0.0532	0.0055 ± 0.0133	0.0273 ± 0.0157	0.0012 ± 0.0012
50 % - UNET	0.6191 ± 0.7572	0.8753 ± 0.0876	32.7118 ± 3.7524	0.5789 ± 0.8188	0.0372 ± 0.0395	0.0029 ± 0.0078	0.0188 ± 0.0115	0.0006 ± 0.0008
75 % - DDPM	0.2571 ± 0.3906	0.8493 ± 0.0999	30.8458 ± 3.8842	0.2009 ± 0.4094	0.0476 ± 0.0477	0.0045 ± 0.0108	0.0247 ± 0.0151	0.0011 ± 0.0012
75 % - UNET	0.6174 ± 0.7627	0.8782 ± 0.0888	32.8057 ± 3.9592	0.6669 ± 1.0444	0.0371 ± 0.0400	0.0030 ± 0.0080	0.0181 ± 0.0111	0.0006 ± 0.0008
100 % - DDPM	0.2710 ± 0.4015	0.8531 ± 0.1000	31.2053 ± 4.4505	0.2433 ± 0.3454	0.0457 ± 0.0464	0.0042 ± 0.0104	0.0258 ± 0.0194	0.0013 ± 0.0020
100 % - UNET	0.6254 ± 0.7687	0.8772 ± 0.0855	32.6200 ± 3.4457	0.5666 ± 0.6532	0.0373 ± 0.0393	0.0029 ± 0.0079	0.0185 ± 0.0100	0.0006 ± 0.0006

Tabla 7.7: Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Log Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - DDPM	0.3603 ± 0.5222	0.4495 ± 0.3060	20.3304 ± 5.7528	5.9981 ± 8.0509	0.2222 ± 0.1864	0.0841 ± 0.1318	0.1683 ± 0.1351	0.0496 ± 0.0792
10 % - UNET	0.8200 ± 1.0260	0.8002 ± 0.1848	30.9341 ± 4.0271	1.5428 ± 3.1048	0.0475 ± 0.0526	0.0050 ± 0.0190	0.0294 ± 0.0265	0.0023 ± 0.0051
25 % - DDPM	0.3033 ± 0.4600	0.5455 ± 0.2816	22.4598 ± 5.7813	3.8650 ± 6.2661	0.1683 ± 0.1521	0.0155 ± 0.0918	0.1133 ± 0.0964	0.0244 ± 0.0388
25 % - UNET	0.8391 ± 1.0507	0.8043 ± 0.1897	31.1371 ± 4.2380	1.8275 ± 3.5410	0.0466 ± 0.0533	0.0050 ± 0.0199	0.0285 ± 0.0278	0.0024 ± 0.0051
50 % - DDPM	0.3108 ± 0.4804	0.4465 ± 0.3209	20.4348 ± 6.0565	4.1281 ± 6.1526	0.2203 ± 0.1696	0.0773 ± 0.1078	0.1686 ± 0.1286	0.0482 ± 0.0633
50 % - UNET	0.8453 ± 1.0611	0.8056 ± 0.1860	31.2168 ± 3.8920	1.2931 ± 2.8971	0.0463 ± 0.0499	0.0046 ± 0.0169	0.0278 ± 0.0259	0.0021 ± 0.0046
75 % - DDPM	0.3496 ± 0.5081	0.4084 ± 0.3132	19.3961 ± 5.7616	8.4047 ± 8.6645	0.2417 ± 0.2082	0.1017 ± 0.1730	0.1392 ± 0.1123	0.0359 ± 0.0682
75 % - UNET	0.8584 ± 1.0677	0.8102 ± 0.1912	31.7545 ± 4.1998	1.6973 ± 3.1909	0.0431 ± 0.0495	0.0043 ± 0.0177	0.0260 ± 0.0238	0.0019 ± 0.0035
100 % - DDPM	0.2707 ± 0.4282	0.7398 ± 0.2252	27.9644 ± 4.9054	0.1070 ± 3.5706	0.0761 ± 0.0793	0.0122 ± 0.0289	0.0513 ± 0.0560	0.0070 ± 0.0145
100 % - UNET	0.8589 ± 1.0662	0.8168 ± 0.1833	31.9258 ± 4.2065	1.4917 ± 2.2396	0.0414 ± 0.0475	0.0040 ± 0.0174	0.0237 ± 0.0195	0.0016 ± 0.0026

Tabla 7.8: Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Log Scale. Conjunto de datos: Full.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - DDPM	0.5968 ± 0.8641	0.6455 ± 0.2790	20.6010 ± 4.7451	12.5360 ± 7.9282	0.2407 ± 0.1671	0.0859 ± 0.1080	0.2066 ± 0.1217	0.0632 ± 0.0646
10 % - UNET	0.1275 ± 0.2151	0.9678 ± 0.0305	39.6252 ± 3.3639	0.2521 ± 0.3694	0.0177 ± 0.0163	0.0006 ± 0.0015	0.0241 ± 0.0126	0.0009 ± 0.0009
25 % - DDPM	0.1464 ± 0.2718	0.9176 ± 0.0834	29.7513 ± 6.7805	5.5713 ± 7.1653	0.0814 ± 0.0732	0.0120 ± 0.0211	0.0633 ± 0.0534	0.0074 ± 0.0123
25 % - UNET	0.1281 ± 0.2209	0.9723 ± 0.0288	40.9778 ± 3.6467	0.3231 ± 0.5544	0.0154 ± 0.0145	0.0004 ± 0.0010	0.0178 ± 0.0091	0.0005 ± 0.0006
50 % - DDPM	0.1506 ± 0.2466	0.9298 ± 0.0519	30.9022 ± 5.0242	4.3306 ± 4.4335	0.0623 ± 0.0463	0.0060 ± 0.0082	0.0508 ± 0.0365	0.0043 ± 0.0060
50 % - UNET	0.1276 ± 0.2207	0.9721 ± 0.0293	40.9860 ± 4.0137	0.4565 ± 0.8113	0.0159 ± 0.0153	0.0005 ± 0.0012	0.0187 ± 0.0109	0.0006 ± 0.0007
75 % - DDPM	0.4401 ± 0.6244	0.7843 ± 0.1569	23.4793 ± 6.7852	12.5433 ± 7.6626	0.1610 ± 0.1099	0.0380 ± 0.0469	0.1092 ± 0.0746	0.0290 ± 0.0251
75 % - UNET	0.1377 ± 0.2349	0.9730 ± 0.0291	41.0437 ± 3.8646	0.4061 ± 0.6829	0.0156 ± 0.0144	0.0005 ± 0.0011	0.0181 ± 0.0098	0.0005 ± 0.0006
100 % - DDPM	0.0915 ± 0.1468	0.9547 ± 0.0390	38.3239 ± 3.7778	0.2772 ± 0.4760	0.0216 ± 0.0186	0.0008 ± 0.0016	0.0250 ± 0.0135	0.0010 ± 0.0010
100 % - UNET	0.1273 ± 0.2223	0.9730 ± 0.0286	41.2363 ± 3.9788	0.2900 ± 0.5510	0.0154 ± 0.0142	0.0004 ± 0.0010	0.0172 ± 0.0092	0.0005 ± 0.0005

Tabla 7.9: Comparación de métricas para diferentes porcentajes de datos. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - <i>DDPM</i>	0.2337 ± 0.4153	0.7388 ± 0.3028	24.2048 ± 7.6804	10.1420 ± 8.8887	0.1629 ± 0.1357	0.0449 ± 0.0660	0.1337 ± 0.1052	0.0325 ± 0.0428
10 % - <i>UNET</i>	0.3805 ± 0.8273	0.8760 ± 0.2128	37.6693 ± 7.0696	1.6065 ± 3.9461	0.0313 ± 0.0568	0.0036 ± 0.0146	0.0304 ± 0.0380	0.0032 ± 0.0083
25 % - <i>DDPM</i>	0.1504 ± 0.3267	0.8652 ± 0.2311	37.1167 ± 6.7552	0.4885 ± 1.1875	0.0318 ± 0.0468	0.0032 ± 0.0130	0.0314 ± 0.0309	0.0029 ± 0.0055
25 % - <i>UNET</i>	0.4023 ± 0.8625	0.8824 ± 0.1991	38.4193 ± 6.9544	1.1108 ± 2.0057	0.0268 ± 0.0406	0.0024 ± 0.0104	0.0272 ± 0.0274	0.0023 ± 0.0045
50 % - <i>DDPM</i>	0.1667 ± 0.3622	0.8694 ± 0.2259	37.1724 ± 7.1511	0.5495 ± 1.2239	0.0330 ± 0.0495	0.0035 ± 0.0160	0.0325 ± 0.0429	0.0041 ± 0.0155
50 % - <i>UNET</i>	0.4074 ± 0.8660	0.8830 ± 0.2003	38.9713 ± 7.3424	1.3836 ± 2.5577	0.0271 ± 0.0418	0.0025 ± 0.0101	0.0267 ± 0.0283	0.0022 ± 0.0043
75 % - <i>DDPM</i>	0.1531 ± 0.3316	0.8682 ± 0.2261	37.1598 ± 6.7757	0.4622 ± 1.1229	0.0316 ± 0.0448	0.0030 ± 0.0116	0.0290 ± 0.0287	0.0025 ± 0.0047
75 % - <i>UNET</i>	0.3885 ± 0.8333	0.8805 ± 0.1997	38.4214 ± 6.9857	1.2968 ± 3.0177	0.0276 ± 0.0426	0.0026 ± 0.0103	0.0277 ± 0.0272	0.0022 ± 0.0042
100 % - <i>DDPM</i>	0.3256 ± 0.4755	0.7235 ± 0.2337	27.4745 ± 5.6341	2.1809 ± 5.3007	0.0899 ± 0.1235	0.0233 ± 0.0099	0.0576 ± 0.0982	0.0141 ± 0.0686
100 % - <i>UNET</i>	0.4139 ± 0.8783	0.8859 ± 0.1947	38.9404 ± 6.6994	1.1096 ± 2.0748	0.0253 ± 0.0368	0.0020 ± 0.0085	0.0244 ± 0.0218	0.0016 ± 0.0028

Tabla 7.10: Comparación de métricas para diferentes porcentajes de datos.
Escala de datos: Sqrt Scale. Conjunto de datos: Full.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - <i>DDPM</i>	0.3847 ± 0.7524	0.8874 ± 0.1688	33.4711 ± 9.2080	4.4361 ± 6.7048	0.0692 ± 0.0839	0.0118 ± 0.0267	0.0742 ± 0.0764	0.0125 ± 0.0229
10 % - <i>UNET</i>	0.6025 ± 0.2273	0.9793 ± 0.0077	41.6436 ± 2.3223	0.1200 ± 0.0431	0.0156 ± 0.0150	0.0005 ± 0.0023	0.0211 ± 0.0079	0.0009 ± 0.0007
25 % - <i>DDPM</i>	0.1871 ± 0.3398	0.9507 ± 0.0596	35.1081 ± 7.3118	3.8969 ± 5.5604	0.0443 ± 0.0388	0.0035 ± 0.0063	0.0436 ± 0.0321	0.0035 ± 0.0050
25 % - <i>UNET</i>	0.0122 ± 0.0353	0.9944 ± 0.0066	46.7535 ± 4.0824	0.0655 ± 0.0523	0.0065 ± 0.0098	0.0001 ± 0.0010	0.0143 ± 0.0095	0.0005 ± 0.0008
50 % - <i>DDPM</i>	0.0161 ± 0.0337	0.9929 ± 0.0062	43.3260 ± 4.4515	0.1719 ± 0.3742	0.0115 ± 0.0127	0.0003 ± 0.0014	0.0203 ± 0.0115	0.0008 ± 0.0009
50 % - <i>UNET</i>	0.0123 ± 0.0361	0.9947 ± 0.0059	47.0599 ± 4.0804	0.0781 ± 0.1170	0.0063 ± 0.0093	0.0001 ± 0.0011	0.0133 ± 0.0078	0.0004 ± 0.0006
75 % - <i>DDPM</i>	0.0242 ± 0.0442	0.9917 ± 0.0070	44.1269 ± 3.7962	0.1182 ± 0.1558	0.0097 ± 0.0114	0.0002 ± 0.0017	0.0175 ± 0.0098	0.0007 ± 0.0010
75 % - <i>UNET</i>	0.0119 ± 0.0357	0.9955 ± 0.0053	48.3788 ± 4.5083	0.0065 ± 0.0381	0.0051 ± 0.0087	0.0001 ± 0.0009	0.0121 ± 0.0082	0.0004 ± 0.0006
100 % - <i>DDPM</i>	0.0285 ± 0.0626	0.9906 ± 0.0078	41.4484 ± 5.4121	0.7439 ± 1.3756	0.0169 ± 0.0164	0.0006 ± 0.0021	0.0238 ± 0.0141	0.0011 ± 0.0011
100 % - <i>UNET</i>	0.0148 ± 0.0670	0.9941 ± 0.0061	46.3564 ± 3.4079	0.0776 ± 0.0465	0.0076 ± 0.0095	0.0001 ± 0.0009	0.0137 ± 0.0081	0.0005 ± 0.0006

Tabla 7.11: Comparación de métricas para diferentes porcentajes de datos.
Escala de datos: Linear Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
10 % - <i>DDPM</i>	0.0775 ± 0.2484	0.9260 ± 0.1522	41.3579 ± 7.5031	0.3150 ± 0.6589	0.0194 ± 0.0344	0.0016 ± 0.0097	0.0291 ± 0.0288	0.0025 ± 0.0051
10 % - <i>UNET</i>	0.1755 ± 0.5098	0.9378 ± 0.1305	42.9030 ± 7.8664	1.5059 ± 4.2075	0.0175 ± 0.0335	0.0014 ± 0.0097	0.0242 ± 0.0292	0.0023 ± 0.0057
25 % - <i>DDPM</i>	0.1335 ± 0.2972	0.8934 ± 0.1756	33.1630 ± 8.7321	8.5411 ± 11.0359	0.0637 ± 0.0740	0.0095 ± 0.0213	0.0718 ± 0.0598	0.0101 ± 0.0150
25 % - <i>UNET</i>	0.1751 ± 0.5127	0.9389 ± 0.1291	44.1885 ± 8.0847	0.7881 ± 1.8124	0.0147 ± 0.0304	0.0011 ± 0.0087	0.0215 ± 0.0269	0.0020 ± 0.0057
50 % - <i>DDPM</i>	0.0834 ± 0.2563	0.9291 ± 0.1470	42.6319 ± 7.4228	0.1801 ± 0.2660	0.0161 ± 0.0309	0.0012 ± 0.0095	0.0237 ± 0.0221	0.0018 ± 0.0032
50 % - <i>UNET</i>	0.1777 ± 0.5208	0.9390 ± 0.1272	43.9338 ± 7.7514	0.8689 ± 2.0925	0.0147 ± 0.0286	0.0010 ± 0.0085	0.0207 ± 0.0221	0.0015 ± 0.0031
75 % - <i>DDPM</i>	0.0872 ± 0.2762	0.9298 ± 0.1442	42.6756 ± 7.8664	0.1663 ± 0.2836	0.0164 ± 0.0330	0.0014 ± 0.0108	0.0256 ± 0.0262	0.0024 ± 0.0057
75 % - <i>UNET</i>	0.1770 ± 0.5227	0.9405 ± 0.1277	43.4565 ± 7.3184	0.8833 ± 1.9769	0.0164 ± 0.0273	0.0010 ± 0.0084	0.0202 ± 0.0205	0.0014 ± 0.0027
100 % - <i>DDPM</i>	0.1881 ± 0.3090	0.8937 ± 0.1523	32.9681 ± 6.3549	2.8793 ± 4.4457	0.0490 ± 0.0439	0.0043 ± 0.0114	0.0622 ± 0.0329	0.0063 ± 0.0061
100 % - <i>UNET</i>	0.1799 ± 0.5292	0.9405 ± 0.1266	44.2514 ± 7.7717	1.0933 ± 2.5707	0.0148 ± 0.0271	0.0010 ± 0.0077	0.0196 ± 0.0207	0.0014 ± 0.0026

Tabla 7.12: Comparación de métricas para diferentes porcentajes de datos.
Escala de datos: Linear Scale. Conjunto de datos: Full.

7.11. Impacto del número de parámetros

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.2425 ± 0.3734	0.7806 ± 0.1340	27.9136 ± 4.8536	0.2919 ± 0.2896	0.0795 ± 0.0677	0.0109 ± 0.0194	0.0570 ± 0.0355	0.0048 ± 0.0055
<i>665K - UNET</i>	0.6017 ± 0.7514	0.8752 ± 0.0874	32.6673 ± 3.7739	0.6280 ± 0.9717	0.0375 ± 0.0402	0.0030 ± 0.0082	0.0189 ± 0.0112	0.0007 ± 0.0008
<i>2M - DDPM</i>	0.2710 ± 0.4015	0.8531 ± 0.1000	31.2053 ± 3.8923	0.2433 ± 0.3454	0.0457 ± 0.0464	0.0042 ± 0.0104	0.0258 ± 0.0191	0.0013 ± 0.0020
<i>2M - UNET</i>	0.6254 ± 0.7687	0.8772 ± 0.0855	32.6200 ± 3.4457	0.5666 ± 0.6532	0.0373 ± 0.0393	0.0029 ± 0.0079	0.0185 ± 0.0104	0.0006 ± 0.0006
<i>10M - DDPM</i>	0.2298 ± 0.3535	0.8161 ± 0.1147	28.6364 ± 3.4383	0.6243 ± 0.9667	0.0618 ± 0.0587	0.0073 ± 0.0153	0.0273 ± 0.0214	0.0015 ± 0.0030
<i>10M - UNET</i>	0.6167 ± 0.7605	0.8750 ± 0.0892	32.5641 ± 3.4864	0.5008 ± 0.6643	0.0375 ± 0.0398	0.0030 ± 0.0081	0.0199 ± 0.0117	0.0007 ± 0.0007
<i>30M - DDPM</i>	0.2731 ± 0.4004	0.8342 ± 0.1134	29.4540 ± 3.7745	0.7588 ± 1.3461	0.0571 ± 0.0550	0.0063 ± 0.0137	0.0270 ± 0.0217	0.0015 ± 0.0025
<i>30M - UNET</i>	0.6262 ± 0.7724	0.8757 ± 0.0893	32.5303 ± 3.5676	0.4996 ± 0.7116	0.0379 ± 0.0402	0.0030 ± 0.0082	0.0185 ± 0.0113	0.0006 ± 0.0007

Tabla 7.13: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.5019 ± 0.7340	0.5515 ± 0.1710	23.8730 ± 3.5309	1.1955 ± 3.7025	0.1128 ± 0.1017	0.0231 ± 0.0455	0.0755 ± 0.0519	0.0117 ± 0.0207
<i>665K - UNET</i>	0.8754 ± 1.0749	0.8114 ± 0.1856	31.7784 ± 4.1824	1.7807 ± 3.4117	0.0428 ± 0.0476	0.0041 ± 0.0171	0.0257 ± 0.0234	0.0018 ± 0.0035
<i>2M - DDPM</i>	0.2707 ± 0.4282	0.7398 ± 0.2252	27.9644 ± 4.9054	0.0170 ± 3.5706	0.0761 ± 0.0793	0.0122 ± 0.0289	0.0513 ± 0.0560	0.0070 ± 0.0145
<i>2M - UNET</i>	0.8589 ± 1.0662	0.8163 ± 0.1831	31.9258 ± 4.2065	1.4917 ± 2.2336	0.0414 ± 0.0475	0.0040 ± 0.0174	0.0237 ± 0.0191	0.0016 ± 0.0026
<i>10M - DDPM</i>	0.4356 ± 0.5702	0.1486 ± 0.3613	15.6133 ± 6.0380	14.3965 ± 9.2546	0.3865 ± 0.2801	0.2279 ± 0.2873	0.2438 ± 0.1841	0.0993 ± 0.1510
<i>10M - UNET</i>	0.8633 ± 1.0712	0.8122 ± 0.1875	31.7242 ± 4.2079	1.5385 ± 3.0214	0.0428 ± 0.0492	0.0043 ± 0.0176	0.0241 ± 0.0221	0.0017 ± 0.0031
<i>30M - DDPM</i>	0.3948 ± 0.5368	0.6271 ± 0.2170	23.6025 ± 5.1353	4.9305 ± 6.8739	0.1369 ± 0.3848	0.0380 ± 0.0848	0.0727 ± 0.0974	0.0163 ± 0.0622
<i>30M - UNET</i>	0.8279 ± 1.0241	0.8123 ± 0.1894	31.5650 ± 4.6361	1.2869 ± 2.7785	0.0428 ± 0.0492	0.0043 ± 0.0179	0.0243 ± 0.0219	0.0017 ± 0.0030

Tabla 7.14: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Full.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.4892 ± 0.6347	0.7706 ± 0.1251	21.8246 ± 3.5846	13.0968 ± 6.3126	0.1679 ± 0.0808	0.0347 ± 0.0308	0.1201 ± 0.0585	0.0199 ± 0.0170
<i>665K - UNET</i>	0.1385 ± 0.2343	0.9728 ± 0.0286	41.3118 ± 3.7368	0.3557 ± 0.5967	0.0148 ± 0.0141	0.0004 ± 0.0010	0.0179 ± 0.0101	0.0005 ± 0.0006
<i>2M - DDPM</i>	0.0915 ± 0.1468	0.9547 ± 0.0390	38.3239 ± 3.7778	0.2772 ± 0.4760	0.0216 ± 0.0186	0.0008 ± 0.0016	0.0250 ± 0.0135	0.0010 ± 0.0010
<i>2M - UNET</i>	0.1273 ± 0.2223	0.9730 ± 0.2028	41.2363 ± 3.9788	0.2908 ± 0.5510	0.0154 ± 0.0142	0.0004 ± 0.0010	0.0172 ± 0.0092	0.0005 ± 0.0005
<i>10M - DDPM</i>	0.0765 ± 0.1330	0.9581 ± 0.0399	36.8769 ± 4.1554	0.5212 ± 0.9352	0.0273 ± 0.0220	0.0012 ± 0.0024	0.0298 ± 0.0185	0.0015 ± 0.0016
<i>10M - UNET</i>	0.1340 ± 0.2313	0.9724 ± 0.0292	41.2595 ± 3.7842	0.3462 ± 0.5909	0.0149 ± 0.0143	0.0004 ± 0.0010	0.0185 ± 0.0114	0.0006 ± 0.0007
<i>30M - DDPM</i>	0.1746 ± 0.2579	0.8952 ± 0.0658	25.8578 ± 4.9001	9.5082 ± 6.3819	0.1116 ± 0.0638	0.0165 ± 0.0173	0.0827 ± 0.0502	0.0101 ± 0.0112
<i>30M - UNET</i>	0.1281 ± 0.2216	0.9720 ± 0.0298	41.3719 ± 3.8839	0.2121 ± 0.2343	0.0147 ± 0.0146	0.0004 ± 0.0011	0.0173 ± 0.0108	0.0006 ± 0.0008

Tabla 7.15: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.5661 ± 0.7152	0.6030 ± 0.2434	20.4070 ± 4.5482	10.6361 ± 8.9235	0.2086 ± 0.1316	0.0608 ± 0.0728	0.1764 ± 0.0862	0.0430 ± 0.0406
<i>665K - UNET</i>	0.4287 ± 0.8926	0.8856 ± 0.1968	39.1778 ± 6.9571	1.5730 ± 3.0309	0.0251 ± 0.0380	0.0021 ± 0.0088	0.0247 ± 0.0238	0.0018 ± 0.0032
<i>2M - DDPM</i>	0.3256 ± 0.4755	0.7235 ± 0.2337	27.4745 ± 5.6341	2.1895 ± 5.3007	0.0899 ± 0.1235	0.0233 ± 0.0909	0.0576 ± 0.0982	0.0141 ± 0.0868
<i>2M - UNET</i>	0.4120 ± 0.8783	0.8854 ± 0.1947	38.9404 ± 6.6994	1.1096 ± 2.0748	0.0253 ± 0.0368	0.0020 ± 0.0085	0.0244 ± 0.0218	0.0016 ± 0.0028
<i>10M - DDPM</i>	0.1405 ± 0.3119	0.8541 ± 0.2413	34.4553 ± 6.0251	1.4663 ± 3.2507	0.0439 ± 0.0518	0.0046 ± 0.0144	0.0408 ± 0.0351	0.0040 ± 0.0066
<i>10M - UNET</i>	0.4102 ± 0.8706	0.8852 ± 0.1661	39.0324 ± 7.0208	1.3017 ± 2.3188	0.0257 ± 0.0389	0.0022 ± 0.0064	0.0249 ± 0.0238	0.0018 ± 0.0032
<i>30M - DDPM</i>	0.2120 ± 0.3612	0.5287 ± 0.3478	17.1145 ± 7.3121	18.9187 ± 9.9177	0.3502 ± 0.2357	0.1783 ± 0.2045	0.2644 ± 0.1742	0.1079 ± 0.1234
<i>30M - UNET</i>	0.3940 ± 0.8466	0.8839 ± 0.1965	38.5393 ± 6.7142	1.6054 ± 2.9853	0.0264 ± 0.0390	0.0022 ± 0.0094	0.0261 ± 0.0245	0.0019 ± 0.0035

Tabla 7.16: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Full.

Experiment	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.8925 ± 1.0059	0.6336 ± 0.2911	18.1847 ± 9.1404	25.9226 ± 7.5315	0.3470 ± 0.2413	0.1786 ± 0.2189	0.3107 ± 0.2070	0.1466 ± 0.1722
<i>665K - UNET</i>	0.0116 ± 0.0323	0.9951 ± 0.0067	48.2020 ± 4.8561	0.0572 ± 0.0274	0.0052 ± 0.0096	0.0001 ± 0.0012	0.0129 ± 0.0099	0.0005 ± 0.0008
<i>2M - DDPM</i>	0.0285 ± 0.0626	0.9906 ± 0.0073	41.4484 ± 5.4121	0.7439 ± 1.3756	0.0169 ± 0.0164	0.0006 ± 0.0021	0.0238 ± 0.0144	0.0011 ± 0.0011
<i>2M - UNET</i>	0.0148 ± 0.0670	0.9941 ± 0.0061	46.3564 ± 3.4079	0.0775 ± 0.0465	0.0076 ± 0.0095	0.0001 ± 0.0009	0.0137 ± 0.0081	0.0005 ± 0.0006
<i>10M - DDPM</i>	0.0464 ± 0.0931	0.9861 ± 0.0114	39.8029 ± 5.2187	0.8399 ± 1.3769	0.0191 ± 0.0190	0.0007 ± 0.0044	0.0272 ± 0.0137	0.0015 ± 0.0014
<i>10M - UNET</i>	0.0104 ± 0.0299	0.9954 ± 0.0066	48.7918 ± 4.9886	0.0547 ± 0.0278	0.0049 ± 0.0094	0.0001 ± 0.0011	0.0124 ± 0.0097	0.0004 ± 0.0009
<i>30M - DDPM</i>	0.0388 ± 0.0746	0.9893 ± 0.0075	42.6851 ± 4.2415	0.2009 ± 0.2972	0.0124 ± 0.0131	0.0003 ± 0.0029	0.0201 ± 0.0095	0.0008 ± 0.0009
<i>30M - UNET</i>	0.0113 ± 0.0339	0.9952 ± 0.0064	47.9733 ± 4.6110	0.0553 ± 0.0282	0.0054 ± 0.0096	0.0001 ± 0.0011	0.0129 ± 0.0093	0.0005 ± 0.0009

Tabla 7.17: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.

Experiment	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>665K - DDPM</i>	0.0957 ± 0.2566	0.9033 ± 0.1487	29.7433 ± 7.7533	12.6399 ± 12.0177	0.0846 ± 0.0845	0.0143 ± 0.0281	0.1053 ± 0.0732	0.0180 ± 0.0244	
<i>665K - UNET</i>	0.1861 ± 0.5431	0.9408 ± 0.1270	45.1199 ± 7.9687	0.9330 ± 2.2476	0.0130 ± 0.0264	0.0009 ± 0.0072	0.0180 ± 0.0194	0.0012 ± 0.0022	
<i>2M - DDPM</i>	0.1881 ± 0.3090	0.8937 ± 0.1523	32.9681 ± 3.3549	2.8793 ± 4.4457	0.0490 ± 0.0439	0.0043 ± 0.0114	0.0622 ± 0.0329	0.0063 ± 0.0061	
<i>2M - UNET</i>	0.1799 ± 0.5292	0.9405 ± 0.1266	44.2514 ± 7.7717	1.0933 ± 2.5707	0.0148 ± 0.0271	0.0010 ± 0.0077	0.0196 ± 0.0207	0.0014 ± 0.0026	
<i>10M - DDPM</i>	0.0776 ± 0.2365	0.9234 ± 0.1561	41.1243 ± 7.0375	0.1763 ± 0.2268	0.0189 ± 0.0326	0.0014 ± 0.0102	0.0278 ± 0.0240	0.0022 ± 0.0037	
<i>10M - UNET</i>	0.1786 ± 0.5270	0.9404 ± 0.1273	44.8432 ± 8.1136	1.1385 ± 2.8133	0.0140 ± 0.0273	0.0009 ± 0.0076	0.0194 ± 0.0209	0.0014 ± 0.0027	
<i>30M - DDPM</i>	0.1543 ± 0.3168	0.8919 ± 0.1840	32.8115 ± 7.6152	5.1529 ± 6.5504	0.0592 ± 0.0611	0.0072 ± 0.0234	0.0557 ± 0.0480	0.0068 ± 0.0119	
<i>30M - UNET</i>	0.1738 ± 0.5146	0.9406 ± 0.1271	44.8373 ± 7.9973	0.9946 ± 2.3005	0.0137 ± 0.0274	0.0009 ± 0.0080	0.0196 ± 0.0213	0.0014 ± 0.0028	

Tabla 7.18: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Linear Scale. Conjunto de datos: Full.

7.12. Agregación

7.12.1. Impacto del número de pasos de difusión

Experiment	Aggregation	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>-Base - UNet</i>		1	0.0148 ± 0.0674	0.9941 ± 0.0061	46.3564 ± 3.4079	0.0776 ± 0.0465	0.0076 ± 0.0095	0.0001 ± 0.0009	0.0137 ± 0.0081	0.0005 ± 0.0006
<i>-Steps 10 - DDPM</i>		1	0.0173 ± 0.0897	0.9877 ± 0.0107	44.6994 ± 3.7476	0.0788 ± 0.0550	0.0089 ± 0.0099	0.0002 ± 0.0009	0.0151 ± 0.0077	0.0005 ± 0.0006
		2	0.0173 ± 0.0423	0.9918 ± 0.0063	44.2511 ± 3.9225	0.0789 ± 0.0550	0.0089 ± 0.0099	0.0002 ± 0.0009	0.0151 ± 0.0072	0.0005 ± 0.0005
		3	0.0255 ± 0.0423	0.9918 ± 0.0063	44.1987 ± 3.9101	0.0707 ± 0.0313	0.0086 ± 0.0088	0.0002 ± 0.0008	0.0142 ± 0.0071	0.0004 ± 0.0005
		5	0.0173 ± 0.0333	0.9934 ± 0.0063	45.8110 ± 3.3967	0.0652 ± 0.0290	0.0081 ± 0.0086	0.0001 ± 0.0008	0.0137 ± 0.0071	0.0004 ± 0.0005
		6	0.0169 ± 0.0316	0.9926 ± 0.0064	45.0036 ± 3.3232	0.0626 ± 0.0308	0.0089 ± 0.0086	0.0001 ± 0.0008	0.0137 ± 0.0073	0.0004 ± 0.0006
		7	0.0149 ± 0.0306	0.9929 ± 0.0064	3.3454	0.0631 ± 0.0319	0.0089 ± 0.0085	0.0001 ± 0.0008	0.0137 ± 0.0072	0.0004 ± 0.0006
		8	0.0140 ± 0.0299	0.9941 ± 0.0064	46.0488 ± 3.3720	0.0634 ± 0.0300	0.0079 ± 0.0085	0.0001 ± 0.0008	0.0136 ± 0.0073	0.0004 ± 0.0006
		9	0.0135 ± 0.0295	0.9941 ± 0.0064	46.0426 ± 3.4403	0.0646 ± 0.0308	0.0080 ± 0.0085	0.0001 ± 0.0008	0.0137 ± 0.0074	0.0004 ± 0.0006
		10	0.0131 ± 0.0293	0.9942 ± 0.0064	46.1043 ± 3.4857	0.0634 ± 0.0311	0.0079 ± 0.0085	0.0001 ± 0.0008	0.0137 ± 0.0074	0.0004 ± 0.0006
		25	0.0107 ± 0.0285	0.9948 ± 0.0066	46.2974 ± 3.5863	0.0604 ± 0.0262	0.0078 ± 0.0084	0.0001 ± 0.0008	0.0134 ± 0.0075	0.0004 ± 0.0006
<i>-Steps 20 - DDPM</i>		1	0.0109 ± 0.0276	0.9939 ± 0.0074	46.7614 ± 4.5823	0.0630 ± 0.0319	0.0068 ± 0.0100	0.0001 ± 0.0011	0.0145 ± 0.0109	0.0005 ± 0.0008
		2	0.0092 ± 0.0245	0.9947 ± 0.0066	47.4617 ± 4.6712	0.0591 ± 0.0236	0.0064 ± 0.0095	0.0001 ± 0.0010	0.0140 ± 0.0099	0.0005 ± 0.0007
		3	0.0087 ± 0.0244	0.9949 ± 0.0066	47.4725 ± 4.6711	0.0612 ± 0.0375	0.0062 ± 0.0094	0.0001 ± 0.0010	0.0135 ± 0.0092	0.0005 ± 0.0007
		5	0.0087 ± 0.0253	0.9951 ± 0.0059	47.4482 ± 4.5946	0.0630 ± 0.0382	0.0069 ± 0.0093	0.0001 ± 0.0009	0.0133 ± 0.0091	0.0005 ± 0.0007
		6	0.0087 ± 0.0254	0.9952 ± 0.0060	47.6010 ± 4.5467	0.0607 ± 0.0360	0.0068 ± 0.0092	0.0001 ± 0.0010	0.0130 ± 0.0091	0.0005 ± 0.0007
		7	0.0087 ± 0.0257	0.9952 ± 0.0059	47.6626 ± 4.6942	0.0611 ± 0.0386	0.0069 ± 0.0092	0.0001 ± 0.0010	0.0130 ± 0.0089	0.0004 ± 0.0007
		8	0.0087 ± 0.0256	0.9952 ± 0.0059	47.7151 ± 4.6705	0.0609 ± 0.0386	0.0068 ± 0.0091	0.0001 ± 0.0010	0.0128 ± 0.0087	0.0004 ± 0.0007
		9	0.0087 ± 0.0258	0.9952 ± 0.0058	47.7057 ± 4.5951	0.0692 ± 0.0409	0.0061 ± 0.0090	0.0001 ± 0.0010	0.0128 ± 0.0087	0.0004 ± 0.0007
		10	0.0087 ± 0.0259	0.9954 ± 0.0057	47.7159 ± 4.5934	0.0625 ± 0.0414	0.0061 ± 0.0090	0.0001 ± 0.0010	0.0128 ± 0.0087	0.0004 ± 0.0007
		25	0.0087 ± 0.0260	0.9956 ± 0.0054	47.8516 ± 4.5621	0.0615 ± 0.0418	0.0060 ± 0.0088	0.0001 ± 0.0009	0.0125 ± 0.0083	0.0004 ± 0.0006
<i>-Steps 50 - DDPM</i>		1	0.0147 ± 0.0263	0.9948 ± 0.0067	44.5121 ± 4.7356	0.0739 ± 0.0265	0.0078 ± 0.0084	0.0006 ± 0.0021	0.0238 ± 0.0114	0.0011 ± 0.0111
		2	0.0199 ± 0.0303	0.9924 ± 0.0065	44.4853 ± 4.5930	0.6204 ± 1.1815	0.0166 ± 0.0337	0.0005 ± 0.0013	0.0222 ± 0.0120	0.0009 ± 0.0101
		3	0.0147 ± 0.0303	0.9933 ± 0.0061	42.3055 ± 4.3994	0.4281 ± 0.8107	0.0147 ± 0.0121	0.0004 ± 0.0011	0.0199 ± 0.0109	0.0007 ± 0.0009
		5	0.0122 ± 0.0284	0.9943 ± 0.0057	42.7207 ± 3.8310	0.2676 ± 0.5094	0.0137 ± 0.0104	0.0003 ± 0.0009	0.0187 ± 0.0096	0.0006 ± 0.0007
		6	0.0116 ± 0.0284	0.9944 ± 0.0057	42.7216 ± 4.0396	0.2835 ± 0.7444	0.0139 ± 0.0106	0.0003 ± 0.0009	0.0189 ± 0.0098	0.0006 ± 0.0007
		7	0.0112 ± 0.0281	0.9945 ± 0.0057	42.8983 ± 4.1063	0.2815 ± 0.6213	0.0137 ± 0.0104	0.0003 ± 0.0009	0.0186 ± 0.0094	0.0006 ± 0.0007
		8	0.0109 ± 0.0278	0.9947 ± 0.0056	43.1037 ± 4.0726	0.2811 ± 0.6740	0.0133 ± 0.0102	0.0003 ± 0.0009	0.0182 ± 0.0090	0.0006 ± 0.0007
		10	0.0105 ± 0.0277	0.9947 ± 0.0057	43.1173 ± 3.8512	0.2447 ± 0.5784	0.0132 ± 0.0098	0.0003 ± 0.0009	0.0179 ± 0.0086	0.0006 ± 0.0007
		25	0.0098 ± 0.0274	0.9951 ± 0.0055	42.9917 ± 3.2358	0.1879 ± 0.2855	0.0138 ± 0.0089	0.0006 ± 0.0008	0.0173 ± 0.0077	0.0005 ± 0.0006
<i>-Steps 100 - DDPM</i>		1	0.0113 ± 0.0269	0.9941 ± 0.0055	46.8284 ± 4.2583	0.0911 ± 0.0291	0.0084 ± 0.0099	0.0001 ± 0.0009	0.0151 ± 0.0098	0.0006 ± 0.0007
		2	0.0109 ± 0.0267	0.9942 ± 0.0055	48.1024 ± 4.2583	0.0890 ± 0.0291	0.0082 ± 0.0092	0.0001 ± 0.0010	0.0149 ± 0.0097	0.0006 ± 0.0007
		3	0.0096 ± 0.0277	0.9952 ± 0.0054	47.3829 ± 4.6750	0.0546 ± 0.0281	0.0089 ± 0.0089	0.0001 ± 0.0008	0.0172 ± 0.0088	0.0004 ± 0.0007
		5	0.0094 ± 0.0271	0.9952 ± 0.0052	48.4431 ± 4.3969	0.0566 ± 0.0287	0.0049 ± 0.0085	0.5447e-05 ± 7.4747e-04	0.0123 ± 0.0078	0.0004 ± 0.0006
		6	0.0094 ± 0.0272	0.9952 ± 0.0053	48.3004 ± 4.2750	0.0583 ± 0.0277	0.0049 ± 0.0086	0.8253e-05 ± 7.7034e-04	0.0121 ± 0.0080	0.0004 ± 0.0006
		7	0.0094 ± 0.0271	0.9954 ± 0.0054	48.3991 ± 4.5510	0.0588 ± 0.0298	0.0049 ± 0.0087	0.8598e-05 ± 7.9695e-04	0.0123 ± 0.0083	0.0004 ± 0.0007
		8	0.0094 ± 0.0274	0.9955 ± 0.0055	48.4117 ± 4.5069	0.0565 ± 0.0305	0.0049 ± 0.0087	0.0001 ± 0.0008	0.0125 ± 0.0084	0.0004 ± 0.0007
		9	0.0094 ± 0.0275	0.9956 ± 0.0053	48.4636 ± 4.5287	0.0564 ± 0.0290	0.0049 ± 0.0087	0.8867e-05 ± 7.9326e-04	0.0124 ± 0.0083	0.0004 ± 0.0006
		10	0.0094 ± 0.0274	0.9956 ± 0.0053	48.4082 ± 4.4853	0.0550 ± 0.0292	0.0049 ± 0.0087	0.8974e-05 ± 8.1058e-04	0.0123 ± 0.0083	0.0004 ± 0.0007
		25	0.0094 ± 0.0278	0.9957 ± 0.0051	48.4968 ± 4.4053	0.0580 ± 0.0313	0.0048 ± 0.0085	0.9548e-05 ± 7.6542e-04	0.0124 ± 0.0081	0.0004 ± 0.0006
<i>-Steps 250 - DDPM</i>		1	0.0118 ± 0.0296	0.9933 ± 0.0080	44.8687 ± 4.8417	0.1025 ± 0.1132	0.0090 ± 0.0117	0.0006 ± 0.0016	0.0173 ± 0.0107	0.0007 ± 0.0111
		2	0.0104 ± 0.0274	0.9940 ± 0.0074	45.5538 ± 4.3232	0.0850 ± 0.0683	0.0080 ± 0.0108	0.0002 ± 0.0014	0.0161 ± 0.0109	0.0007 ± 0.0111
		3	0.0101 ± 0.0279	0.9945 ± 0.0069	45.8942 ± 4.1618	0.0802 ± 0.0674	0.0076 ± 0.0104	0.0002 ± 0.0014	0.0152 ± 0.0098	0.0006 ± 0.0101
		5	0.0099 ± 0.0282	0.9948 ± 0.0064	46.4955 ± 4.2486	0.0681 ± 0.0431	0.0070 ± 0.0098	0.0001 ± 0.0012	0.0142 ± 0.0086	0.0005 ± 0.0009
		6	0.0099 ± 0.0284	0.9949 ± 0.0066	46.5741 ± 4.2534	0.0682 ± 0.0430	0.0070 ± 0.0097	0.0001 ± 0.0012	0.0141 ± 0.0086	0.0005 ± 0.0009
		7	0.0099 ± 0.0284	0.9949 ± 0.0066	46.6103 ± 4.2125	0.0694 ± 0.0440	0.0069 ± 0.0096	0.0001 ± 0.0011	0.0140 ± 0.0086	0.0005 ± 0.0008
		8	0.0099 ± 0.0288	0.9950 ± 0.0062	46.6936 ± 4.2946	0.0726 ± 0.0529	0.0068 ± 0.0095	0.0001 ± 0.0011	0.0138 ± 0.0084	0.0005 ± 0.0008
		9	0.0100 ± 0.0291	0.9950 ± 0.0063	46.7165 ± 4.2540	0.0700 ± 0.0521	0.0068 ± 0.0096	0.0001 ± 0.0011	0.0137 ± 0.0085	0.0005 ± 0.0008
		10	0.0100 ± 0.0293	0.9950 ± 0.0063	46.7042 ± 4.1793	0.0673 ± 0.0463	0.0068 ± 0.0095	0.0001 ± 0.0011	0.0138 ± 0.0085	0.0005 ± 0.0009
		25	0.0101 ± 0.0292	0.9951 ± 0.0063	47.0952 ± 4.2408	0.0662 ± 0.0428	0.0064 ± 0.0094	0.0001 ± 0.0011	0.0133 ± 0.0086	0.0005 ± 0.0009

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>-Base - UNet</i>									
<i>-Steps 10 - DDPM</i>									
1	0.1799 ± 0.5292	0.9405 ± 0.1266	44.2514 ± 7.7717	1.0933 ± 2.5707	0.0148 ± 0.0271	0.0010 ± 0.0077	0.0196 ± 0.0207	0.0014 ± 0.026	
2	0.1623 ± 0.4370	0.9299 ± 0.1300	39.8007 ± 7.4943	1.2583 ± 3.4206	0.0232 ± 0.0358	0.0018 ± 0.0097	0.0332 ± 0.0319	0.0031 ± 0.0063	
3	0.1581 ± 0.4368	0.9333 ± 0.1273	40.3791 ± 7.3837	1.1284 ± 2.3987	0.0213 ± 0.0320	0.0015 ± 0.0088	0.0304 ± 0.0266	0.0024 ± 0.0040	
4	0.1586 ± 0.4517	0.9351 ± 0.1272	40.6791 ± 7.2590	0.8762 ± 1.5028	0.0201 ± 0.0301	0.0013 ± 0.0098	0.0289 ± 0.0226	0.0020 ± 0.0029	
5	0.1609 ± 0.4682	0.9365 ± 0.1272	40.8294 ± 6.7463	0.8518 ± 1.8742	0.0185 ± 0.0289	0.0012 ± 0.0088	0.0274 ± 0.0201	0.0018 ± 0.026	
6	0.1603 ± 0.4683	0.9372 ± 0.1270	41.1668 ± 6.6372	0.8234 ± 1.8614	0.0175 ± 0.0279	0.0011 ± 0.0084	0.0260 ± 0.0189	0.0017 ± 0.023	
7	0.1614 ± 0.4729	0.9376 ± 0.1268	41.2537 ± 6.6234	0.7366 ± 1.6524	0.0173 ± 0.0279	0.0011 ± 0.0085	0.0257 ± 0.0184	0.0016 ± 0.023	
8	0.1630 ± 0.4777	0.9377 ± 0.1268	41.2428 ± 6.5647	0.7746 ± 1.8444	0.0173 ± 0.0281	0.0011 ± 0.0085	0.0256 ± 0.0184	0.0016 ± 0.023	
9	0.1644 ± 0.4829	0.9379 ± 0.1266	41.3414 ± 6.5404	0.7669 ± 1.8453	0.0171 ± 0.0280	0.0011 ± 0.0085	0.0252 ± 0.0180	0.0016 ± 0.022	
10	0.1645 ± 0.4824	0.9381 ± 0.1267	41.3264 ± 6.7046	0.7363 ± 1.8153	0.0169 ± 0.0280	0.0011 ± 0.0084	0.0249 ± 0.0179	0.0015 ± 0.021	
11	0.1698 ± 0.4994	0.9384 ± 0.1270	41.8915 ± 6.9361	0.7666 ± 1.9069	0.0167 ± 0.0287	0.0011 ± 0.0085	0.0249 ± 0.0186	0.0016 ± 0.024	
12	0.1142 ± 0.3165	0.9312 ± 0.1366	41.5497 ± 7.7352	0.8674 ± 0.8692	0.0193 ± 0.0315	0.0014 ± 0.0094	0.0264 ± 0.0252	0.0005 ± 0.039	
13	0.2042 ± 0.3636	0.9339 ± 0.1224	41.8209 ± 7.7201	0.8674 ± 0.8696	0.0190 ± 0.0303	0.0013 ± 0.0085	0.0264 ± 0.0242	0.0009 ± 0.036	
14	0.1335 ± 0.3170	0.9345 ± 0.1304	42.0678 ± 7.6743	0.6439 ± 1.2825	0.0180 ± 0.0282	0.0013 ± 0.0082	0.0241 ± 0.0217	0.0017 ± 0.030	
15	0.1398 ± 0.4172	0.9374 ± 0.1290	42.5932 ± 7.4751	0.8531 ± 2.0054	0.0172 ± 0.0289	0.0011 ± 0.0084	0.0232 ± 0.0217	0.0016 ± 0.030	
16	0.1437 ± 0.4293	0.9384 ± 0.1286	42.8120 ± 7.4618	0.8824 ± 2.0097	0.0168 ± 0.0284	0.0011 ± 0.0082	0.0230 ± 0.0215	0.0015 ± 0.029	
17	0.1465 ± 0.4361	0.9386 ± 0.1283	42.8888 ± 7.4403	0.8983 ± 2.1205	0.0166 ± 0.0282	0.0011 ± 0.0082	0.0229 ± 0.0214	0.0015 ± 0.028	
18	0.1488 ± 0.4440	0.9390 ± 0.1279	43.0102 ± 7.4775	0.8751 ± 2.0018	0.0164 ± 0.0281	0.0011 ± 0.0081	0.0225 ± 0.0210	0.0015 ± 0.028	
19	0.1516 ± 0.4511	0.9391 ± 0.1277	43.9215 ± 7.3994	0.8273 ± 2.0230	0.0166 ± 0.0280	0.0011 ± 0.0084	0.0225 ± 0.0203	0.0015 ± 0.027	
20	0.1538 ± 0.4575	0.9392 ± 0.1277	42.6701 ± 7.4518	0.8729 ± 2.0623	0.0166 ± 0.0282	0.0011 ± 0.0082	0.0226 ± 0.0210	0.0015 ± 0.028	
21	0.1676 ± 0.4966	0.9400 ± 0.1268	43.1285 ± 7.4851	0.9621 ± 2.2774	0.0164 ± 0.0279	0.0010 ± 0.0080	0.0222 ± 0.0202	0.0014 ± 0.027	
22	1.0881 ± 0.3090	0.8937 ± 0.1523	32.9681 ± 6.3549	2.8703 ± 4.4457	0.0490 ± 0.0439	0.0043 ± 0.0114	0.0622 ± 0.0329	0.0063 ± 0.0061	
23	2.0514 ± 0.2792	0.9108 ± 0.1301	32.2393 ± 5.0271	3.9529 ± 5.1110	0.0504 ± 0.0376	0.0040 ± 0.0094	0.0637 ± 0.0258	0.0058 ± 0.0042	
24	3.0349 ± 0.2881	0.9186 ± 0.1347	32.2174 ± 3.9400	5.0175 ± 6.3329	0.0488 ± 0.0335	0.0035 ± 0.0087	0.0628 ± 0.0222	0.0054 ± 0.0037	
25	5.1294 ± 0.3211	0.9255 ± 0.1297	32.2563 ± 3.1407	5.8489 ± 6.6024	0.0470 ± 0.0292	0.0031 ± 0.0083	0.0610 ± 0.0187	0.0049 ± 0.0209	
26	6.0321 ± 0.3374	0.9271 ± 0.1282	32.1157 ± 2.8718	6.3596 ± 6.5295	0.0476 ± 0.0278	0.0030 ± 0.0081	0.0613 ± 0.0179	0.0048 ± 0.028	
27	7.0316 ± 0.3461	0.9284 ± 0.1277	32.2447 ± 2.9615	6.5469 ± 6.6804	0.0471 ± 0.0278	0.0030 ± 0.0081	0.0603 ± 0.0173	0.0047 ± 0.027	
28	8.0327 ± 0.3556	0.9290 ± 0.1271	32.2789 ± 2.9418	6.8895 ± 7.1771	0.0469 ± 0.0278	0.0030 ± 0.0081	0.0603 ± 0.0173	0.0047 ± 0.027	
29	9.1334 ± 0.3621	0.9295 ± 0.1265	32.2685 ± 2.9664	6.7696 ± 6.9251	0.0460 ± 0.0277	0.0030 ± 0.0080	0.0605 ± 0.0175	0.0047 ± 0.027	
30	10.1349 ± 0.3703	0.9302 ± 0.1261	32.2813 ± 2.8467	6.8225 ± 6.8681	0.0467 ± 0.0273	0.0029 ± 0.0079	0.0598 ± 0.0169	0.0046 ± 0.026	
31	10.4847 ± 0.4299	0.9331 ± 0.1261	32.2439 ± 2.6118	8.7809 ± 7.7001	0.0475 ± 0.0274	0.0029 ± 0.0077	0.0597 ± 0.0152	0.0045 ± 0.025	
32	1.0724 ± 0.2325	0.9210 ± 0.1596	41.3297 ± 7.7342	0.1518 ± 0.2425	0.0183 ± 0.0359	0.0016 ± 0.0103	0.0293 ± 0.0285	0.0029 ± 0.0052	
33	2.0804 ± 0.2621	0.9294 ± 0.1438	41.5673 ± 7.2984	0.2042 ± 0.3324	0.0168 ± 0.0315	0.0013 ± 0.0085	0.0270 ± 0.0233	0.0023 ± 0.0035	
34	3.0905 ± 0.2900	0.9317 ± 0.1379	41.3289 ± 6.9212	0.2800 ± 0.5317	0.0159 ± 0.0308	0.0012 ± 0.0084	0.0271 ± 0.0220	0.0022 ± 0.0032	
35	5.0107 ± 0.3287	0.9341 ± 0.1321	41.3739 ± 6.7657	0.3985 ± 0.8577	0.0154 ± 0.0297	0.0011 ± 0.0084	0.0267 ± 0.0212	0.0021 ± 0.031	
36	6.0193 ± 0.3416	0.9354 ± 0.1310	41.6551 ± 6.8204	0.4078 ± 0.8647	0.0159 ± 0.0291	0.0011 ± 0.0083	0.0258 ± 0.0209	0.0020 ± 0.029	
37	7.0131 ± 0.3510	0.9355 ± 0.1306	41.7072 ± 6.8793	0.4860 ± 1.1484	0.0153 ± 0.0297	0.0011 ± 0.0083	0.0259 ± 0.0216	0.0020 ± 0.031	
38	8.0164 ± 0.3597	0.9357 ± 0.1304	41.7990 ± 6.8146	0.5273 ± 1.1994	0.0151 ± 0.0292	0.0011 ± 0.0082	0.0253 ± 0.0212	0.0019 ± 0.030	
39	9.0191 ± 0.3665	0.9359 ± 0.1295	41.7925 ± 6.8284	0.5479 ± 1.2213	0.0151 ± 0.0293	0.0011 ± 0.0082	0.0254 ± 0.0213	0.0019 ± 0.031	
40	10.1223 ± 0.3749	0.9362 ± 0.1292	41.6582 ± 6.8480	0.5561 ± 1.2439	0.0150 ± 0.0292	0.0011 ± 0.0082	0.0253 ± 0.0214	0.0019 ± 0.030	
41	25.0444 ± 0.4303	0.9374 ± 0.1268	41.9592 ± 6.7932	0.7412 ± 1.6786	0.0148 ± 0.0288	0.0010 ± 0.0081	0.0247 ± 0.0206	0.0018 ± 0.029	
42	1.0725 ± 0.2228	0.9184 ± 0.1665	40.8577 ± 8.1110	0.2484 ± 0.4773	0.0223 ± 0.0376	0.0019 ± 0.0084	0.0301 ± 0.0283	0.0026 ± 0.0045	
43	2.0800 ± 0.2484	0.9248 ± 0.1502	41.7185 ± 8.7994	0.2143 ± 0.3491	0.0206 ± 0.0374	0.0018 ± 0.0111	0.0316 ± 0.0363	0.0037 ± 0.0088	
44	3.0842 ± 0.2716	0.9296 ± 0.1426	42.6109 ± 8.8359	0.2334 ± 0.3789	0.0179 ± 0.0335	0.0014 ± 0.0091	0.0278 ± 0.0297	0.0026 ± 0.0049	
45	5.0960 ± 0.3091	0.9337 ± 0.1364	43.2529 ± 8.5896	0.3120 ± 0.6533	0.0165 ± 0.0314	0.0013 ± 0.0085	0.0249 ± 0.0250	0.0020 ± 0.032	
46	6.1014 ± 0.3248	0.9347 ± 0.1348	43.3735 ± 8.5491	0.3608 ± 0.6949	0.0163 ± 0.0311	0.0012 ± 0.0084	0.0244 ± 0.0246	0.0019 ± 0.031	
47	7.1054 ± 0.3354	0.9354 ± 0.1338	43.3153 ± 8.3644	0.3650 ± 0.7333	0.0161 ± 0.0307	0.0012 ± 0.0083	0.0240 ± 0.0239	0.0018 ± 0.030	
48	8.1095 ± 0.3471	0.9356 ± 0.1329	43.5512 ± 8.3774	0.4063 ± 0.8355	0.0161 ± 0.0308	0.0012 ± 0.0083	0.0238 ± 0.0237	0.0018 ± 0.030	
49	9.0128 ± 0.3563	0.9363 ± 0.1325	43.5486 ± 8.3566	0.4111 ± 0.8747	0.0159 ± 0.0305	0.0012 ± 0.0083	0.0233 ± 0.0235	0.0017 ± 0.029	
50	10.1159 ± 0.3640	0.9365 ± 0.1321	43.5790 ± 8.4200	0.4244 ± 0.8702	0.0159 ± 0.0308	0.0012 ± 0.0085	0.0236 ± 0.0242	0.0018 ± 0.031	
51	25.0398 ± 0.4246	0.9384 ± 0.1287	43.9688 ± 8.3047	0.4790 ± 0.9734	0.0150 ± 0.0296	0.0011 ± 0.0082	0.0225 ± 0.0227	0.0016 ± 0.028	

Tabla 7.20: Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Linear Scale. Conjunto de datos: Full.

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
- <i>Base - UNet</i>		1.0273 ± 0.2223	0.9730 ± 0.0286	41.2363 ± 3.9788	0.2908 ± 0.5510	0.0154 ± 0.0142	0.0004 ± 0.0010	0.0172 ± 0.0092	0.0005 ± 0.0005
- <i>Steps 10 - DDPM</i>	1	0.0992 ± 0.1760	0.9665 ± 0.0275	39.8000 ± 3.0892	0.3041 ± 0.5534	0.0175 ± 0.0150	0.0005 ± 0.0011	0.0197 ± 0.0106	0.0007 ± 0.0007
	2	0.0938 ± 0.1783	0.9701 ± 0.0280	40.5057 ± 3.0961	0.2497 ± 0.3146	0.0159 ± 0.0142	0.0005 ± 0.0010	0.0185 ± 0.0099	0.0006 ± 0.0007
	3	0.0947 ± 0.1812	0.9714 ± 0.0286	40.8078 ± 3.2120	0.2183 ± 0.2505	0.0154 ± 0.0138	0.0004 ± 0.0010	0.0178 ± 0.0096	0.0005 ± 0.0006
	4	0.0975 ± 0.1851	0.9722 ± 0.0286	41.0729 ± 3.3362	0.2255 ± 0.2623	0.0150 ± 0.0137	0.0004 ± 0.0010	0.0173 ± 0.0096	0.0005 ± 0.0006
	5	0.0987 ± 0.1864	0.9723 ± 0.0287	41.1497 ± 3.4209	0.2232 ± 0.2573	0.0149 ± 0.0137	0.0004 ± 0.0010	0.0173 ± 0.0095	0.0005 ± 0.0006
	6	0.0996 ± 0.1876	0.9726 ± 0.0286	41.1980 ± 3.4029	0.2292 ± 0.2643	0.0148 ± 0.0137	0.0004 ± 0.0010	0.0169 ± 0.0095	0.0005 ± 0.0006
	7	0.1007 ± 0.1885	0.9728 ± 0.0287	41.2558 ± 3.4459	0.2244 ± 0.2639	0.0147 ± 0.0137	0.0004 ± 0.0010	0.0168 ± 0.0096	0.0005 ± 0.0006
	8	0.1017 ± 0.1895	0.9729 ± 0.0286	41.2696 ± 3.4501	0.2272 ± 0.2669	0.0147 ± 0.0137	0.0004 ± 0.0010	0.0168 ± 0.0095	0.0005 ± 0.0006
	9	0.1022 ± 0.1898	0.9729 ± 0.0287	41.2455 ± 3.4298	0.2316 ± 0.2708	0.0148 ± 0.0137	0.0004 ± 0.0010	0.0169 ± 0.0094	0.0005 ± 0.0006
	10	0.1068 ± 0.1936	0.9734 ± 0.0286	41.3711 ± 3.4118	0.2268 ± 0.2664	0.0145 ± 0.0136	0.0004 ± 0.0010	0.0165 ± 0.0092	0.0005 ± 0.0005
- <i>Steps 20 - DDPM</i>	1	0.0994 ± 0.1859	0.9710 ± 0.0296	39.5984 ± 3.8285	0.2508 ± 0.3343	0.0192 ± 0.0146	0.0005 ± 0.0013	0.0223 ± 0.0104	0.0009 ± 0.0010
	2	0.1032 ± 0.1913	0.9715 ± 0.0295	40.8374 ± 4.2654	0.2110 ± 0.2794	0.0192 ± 0.0146	0.0005 ± 0.0013	0.0186 ± 0.0120	0.0009 ± 0.0009
	3	0.1042 ± 0.1913	0.9715 ± 0.0295	40.8374 ± 4.3096	0.1956 ± 0.2707	0.0169 ± 0.0157	0.0005 ± 0.0012	0.0168 ± 0.0122	0.0007 ± 0.0008
	4	0.1084 ± 0.1965	0.9729 ± 0.0292	40.8760 ± 3.3220	0.1980 ± 0.2189	0.0161 ± 0.0152	0.0005 ± 0.0012	0.0162 ± 0.0121	0.0006 ± 0.0008
	5	0.1095 ± 0.1973	0.9721 ± 0.0294	40.9395 ± 4.1639	0.1980 ± 0.2226	0.0160 ± 0.0152	0.0005 ± 0.0012	0.0160 ± 0.0123	0.0006 ± 0.0008
	6	0.1102 ± 0.1983	0.9723 ± 0.0294	41.0284 ± 4.2251	0.1888 ± 0.2029	0.0159 ± 0.0155	0.0005 ± 0.0012	0.0188 ± 0.0124	0.0006 ± 0.0008
	7	0.1108 ± 0.1986	0.9724 ± 0.0292	40.9917 ± 4.2188	0.1824 ± 0.1917	0.0160 ± 0.0152	0.0005 ± 0.0012	0.0187 ± 0.0125	0.0006 ± 0.0008
	8	0.1115 ± 0.1995	0.9724 ± 0.0292	40.9912 ± 4.2040	0.1740 ± 0.1794	0.0160 ± 0.0152	0.0005 ± 0.0012	0.0187 ± 0.0123	0.0006 ± 0.0008
	9	0.1119 ± 0.1999	0.9724 ± 0.0294	40.9759 ± 4.1729	0.1776 ± 0.1780	0.0159 ± 0.0155	0.0005 ± 0.0012	0.0188 ± 0.0124	0.0006 ± 0.0008
	10	0.1151 ± 0.2037	0.9728 ± 0.0284	41.1090 ± 4.1631	0.1888 ± 0.2293	0.0156 ± 0.0147	0.0005 ± 0.0010	0.0183 ± 0.0118	0.0006 ± 0.0007
- <i>Steps 50 - DDPM</i>	1	0.0915 ± 0.1468	0.9547 ± 0.0300	38.3229 ± 3.7778	0.2772 ± 0.4760	0.0216 ± 0.0186	0.0008 ± 0.0016	0.0250 ± 0.0135	0.0010 ± 0.0010
	2	0.0778 ± 0.1352	0.9610 ± 0.0344	39.1855 ± 3.8337	0.3387 ± 0.6256	0.0196 ± 0.0175	0.0007 ± 0.0015	0.0234 ± 0.0141	0.0009 ± 0.0011
	3	0.0767 ± 0.1422	0.9656 ± 0.0328	39.8605 ± 3.8760	0.3341 ± 0.5658	0.0181 ± 0.0164	0.0006 ± 0.0013	0.0221 ± 0.0132	0.0008 ± 0.0009
	4	0.0819 ± 0.1543	0.9683 ± 0.0313	40.1307 ± 3.5370	0.3764 ± 0.6341	0.0172 ± 0.0155	0.0005 ± 0.0012	0.0211 ± 0.0125	0.0008 ± 0.0009
	5	0.0843 ± 0.1592	0.9690 ± 0.0304	40.2032 ± 3.6004	0.4058 ± 0.6579	0.0172 ± 0.0154	0.0005 ± 0.0012	0.0209 ± 0.0123	0.0007 ± 0.0008
	6	0.0866 ± 0.1630	0.9695 ± 0.0306	40.2785 ± 3.6194	0.4211 ± 0.6724	0.0170 ± 0.0153	0.0005 ± 0.0012	0.0207 ± 0.0119	0.0007 ± 0.0008
	7	0.0884 ± 0.1662	0.9699 ± 0.0303	40.3713 ± 3.6289	0.4188 ± 0.6716	0.0168 ± 0.0151	0.0005 ± 0.0011	0.0204 ± 0.0116	0.0007 ± 0.0008
	8	0.0902 ± 0.1691	0.9702 ± 0.0301	40.4388 ± 3.6900	0.4289 ± 0.6834	0.0167 ± 0.0151	0.0005 ± 0.0011	0.0204 ± 0.0117	0.0007 ± 0.0008
	9	0.0919 ± 0.1721	0.9706 ± 0.0295	40.5072 ± 3.6244	0.4353 ± 0.6749	0.0165 ± 0.0149	0.0005 ± 0.0011	0.0200 ± 0.0111	0.0007 ± 0.0007
	10	0.1055 ± 0.1914	0.9710 ± 0.0294	40.6579 ± 3.4127	0.4850 ± 0.6634	0.0161 ± 0.0143	0.0005 ± 0.0010	0.0193 ± 0.0106	0.0006 ± 0.0007
- <i>Steps 100 - DDPM</i>	1	0.0751 ± 0.1343	0.9630 ± 0.0302	37.5774 ± 4.2024	0.6194 ± 0.9674	0.0251 ± 0.0206	0.0011 ± 0.0019	0.0247 ± 0.0158	0.0010 ± 0.0011
	2	0.0812 ± 0.1472	0.9670 ± 0.0344	38.0248 ± 3.6363	0.5815 ± 0.7414	0.0233 ± 0.0185	0.0009 ± 0.0016	0.0229 ± 0.0139	0.0009 ± 0.0009
	3	0.0868 ± 0.1559	0.9686 ± 0.0325	38.4216 ± 3.5362	0.5997 ± 0.8556	0.0219 ± 0.0173	0.0008 ± 0.0014	0.0218 ± 0.0135	0.0008 ± 0.0009
	4	0.0949 ± 0.1690	0.9705 ± 0.0312	38.8904 ± 3.1075	0.6523 ± 0.8344	0.0205 ± 0.0160	0.0007 ± 0.0013	0.0200 ± 0.0119	0.0007 ± 0.0007
	5	0.0973 ± 0.1730	0.9705 ± 0.0312	38.9915 ± 3.2159	0.6814 ± 0.8117	0.0205 ± 0.0161	0.0007 ± 0.0013	0.0202 ± 0.0118	0.0007 ± 0.0007
	6	0.0997 ± 0.1763	0.9707 ± 0.0311	38.8501 ± 3.1602	0.7582 ± 1.1595	0.0204 ± 0.0161	0.0007 ± 0.0013	0.0201 ± 0.0116	0.0007 ± 0.0007
	7	0.1015 ± 0.1787	0.9708 ± 0.0306	38.9804 ± 3.2833	0.7380 ± 0.8418	0.0202 ± 0.0160	0.0007 ± 0.0013	0.0202 ± 0.0116	0.0007 ± 0.0007
	8	0.1033 ± 0.1811	0.9710 ± 0.0306	38.9475 ± 3.2303	0.9153 ± 1.2356	0.0202 ± 0.0160	0.0007 ± 0.0013	0.0202 ± 0.0116	0.0007 ± 0.0007
	9	0.1047 ± 0.1834	0.9710 ± 0.0304	38.9915 ± 3.2159	0.8072 ± 0.9962	0.0201 ± 0.0158	0.0007 ± 0.0013	0.0202 ± 0.0113	0.0007 ± 0.0007
	10	0.1145 ± 0.1986	0.9718 ± 0.0295	39.1236 ± 3.0839	0.9255 ± 1.3165	0.0196 ± 0.0154	0.0006 ± 0.0012	0.0196 ± 0.0111	0.0006 ± 0.0007
- <i>Steps 250 - DDPM</i>	1	0.0669 ± 0.1249	0.9600 ± 0.0452	37.3285 ± 3.5595	0.6808 ± 1.2286	0.0247 ± 0.0199	0.0010 ± 0.0018	0.0238 ± 0.0156	0.0010 ± 0.0013
	2	0.0732 ± 0.1363	0.9657 ± 0.0371	38.1753 ± 3.5060	0.7142 ± 1.1547	0.0221 ± 0.0177	0.0008 ± 0.0014	0.0217 ± 0.0129	0.0008 ± 0.0009
	3	0.0795 ± 0.1463	0.9681 ± 0.0344	38.4798 ± 3.1852	0.8456 ± 1.3817	0.0211 ± 0.0171	0.0007 ± 0.0013	0.0201 ± 0.0113	0.0007 ± 0.0008
	4	0.0884 ± 0.1589	0.9701 ± 0.0320	38.8651 ± 3.1222	0.8351 ± 1.2572	0.0200 ± 0.0160	0.0007 ± 0.0012	0.0187 ± 0.0099	0.0006 ± 0.0007
	5	0.0918 ± 0.1630	0.9705 ± 0.0344	38.9219 ± 3.1356	0.9085 ± 1.3250	0.0199 ± 0.0158	0.0006 ± 0.0012	0.0185 ± 0.0097	0.0006 ± 0.0007
	6	0.0944 ± 0.1679	0.9708 ± 0.0346	38.8890 ± 2.9733	0.9607 ± 1.2969	0.0199 ± 0.0160	0.0006 ± 0.0013	0.0183 ± 0.0098	0.0006 ± 0.0006
	7	0.0968 ± 0.1709	0.9710 ± 0.0305	38.8789 ± 2.8875	0.9345 ± 1.3034	0.0198 ± 0.0155	0.0006 ± 0.0013	0.0179 ± 0.0094	0.0006 ± 0.0006
	8	0.0988 ± 0.1740	0.9713 ± 0.0301	38.8458 ± 2.7342	0.9400 ± 1.3179	0.0198 ± 0.0153	0.0006 ± 0.0013	0.0179 ± 0.0094	0.0006 ± 0.0006
	9	0.1007 ± 0.1766	0.9716 ± 0.0302	38.8689 ± 2.7196	0.9729 ± 1.3236	0.0198 ± 0.0152	0.0006 ± 0.0013	0.0180 ± 0.0093	0.0006 ± 0.0006
	10	0.1133 ± 0.1948	0.9723 ± 0.0296	39.1382 ± 2.7910	1.0055 ± 1.3265	0.0191 ± 0.0151	0.0006 ± 0.0013	0.0173 ± 0.0098	0.0005 ± 0.0006

Tabla 7.21: Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>-Base - UNet</i>									
<i>-Steps 10 - DDPM</i>									
1	0.4139 ± 0.8783	0.8859 ± 0.1947	38.9404 ± 6.6994	1.1096 ± 2.0748	0.0253 ± 0.0368	0.0020 ± 0.0085	0.0244 ± 0.0218	0.0016 ± 0.0028	
2	0.2647 ± 0.5381	0.8598 ± 0.1939	35.6134 ± 6.0133	0.9623 ± 2.0313	0.0353 ± 0.0432	0.0031 ± 0.0104	0.0369 ± 0.0279	0.0029 ± 0.0045	
3	0.2691 ± 0.5795	0.8661 ± 0.1939	35.9831 ± 6.1518	1.0694 ± 1.9821	0.0346 ± 0.0428	0.0030 ± 0.0100	0.0364 ± 0.0275	0.0028 ± 0.0044	
5	0.2820 ± 0.6315	0.8734 ± 0.1938	36.8735 ± 6.2620	1.0678 ± 1.7500	0.0310 ± 0.0389	0.0025 ± 0.0089	0.0332 ± 0.0236	0.0023 ± 0.0033	
6	0.2894 ± 0.6494	0.8762 ± 0.1923	37.0734 ± 6.1348	1.0502 ± 1.7288	0.0299 ± 0.0377	0.0023 ± 0.0089	0.0318 ± 0.0218	0.0021 ± 0.0029	
7	0.2956 ± 0.6654	0.8768 ± 0.1931	37.0946 ± 6.1657	1.0378 ± 1.6994	0.0300 ± 0.0379	0.0023 ± 0.0087	0.0319 ± 0.0222	0.0021 ± 0.0030	
8	0.3014 ± 0.6789	0.8777 ± 0.1930	37.2585 ± 6.2172	1.0608 ± 1.7591	0.0296 ± 0.0382	0.0023 ± 0.0087	0.0315 ± 0.0219	0.0021 ± 0.0030	
9	0.3067 ± 0.6911	0.8783 ± 0.1930	37.2948 ± 6.2276	1.0684 ± 1.7351	0.0296 ± 0.0384	0.0023 ± 0.0088	0.0313 ± 0.0219	0.0021 ± 0.0030	
10	0.3103 ± 0.6986	0.8799 ± 0.1931	37.3866 ± 6.2786	1.1357 ± 1.8861	0.0293 ± 0.0384	0.0023 ± 0.0088	0.0309 ± 0.0218	0.0020 ± 0.0030	
15	0.3454 ± 0.7678	0.8810 ± 0.1940	37.2863 ± 6.3878	1.3197 ± 2.2427	0.0302 ± 0.0392	0.0025 ± 0.0091	0.0315 ± 0.0228	0.0021 ± 0.0032	
25	1.2302 ± 1.1634	0.4052 ± 0.1254	29.6852 ± 2.2134	0.5941 ± 0.5524	0.0958 ± 0.0749	0.0018 ± 0.0238	0.0945 ± 0.0240	0.0111 ± 0.0074	
2	0.4848 ± 0.8627	0.6055 ± 0.1380	26.0852 ± 2.0017	1.0404 ± 1.5682	0.0303 ± 0.0303	0.00120 ± 0.0172	0.0322 ± 0.0220	0.0111 ± 0.0055	
3	0.6650 ± 0.8868	0.7302 ± 0.1601	26.2474 ± 1.8868	1.3748 ± 2.0000	0.0824 ± 0.0359	0.0018 ± 0.0145	0.0801 ± 0.0200	0.0094 ± 0.0049	
5	0.4586 ± 0.5495	0.7321 ± 0.1614	26.7840 ± 1.8144	2.2578 ± 3.2489	0.0825 ± 0.0449	0.0092 ± 0.0120	0.0763 ± 0.0217	0.0082 ± 0.0044	
6	0.4414 ± 0.5136	0.7497 ± 0.1615	26.8984 ± 1.7569	2.7014 ± 4.0216	0.0819 ± 0.0470	0.0089 ± 0.0123	0.0755 ± 0.0218	0.0079 ± 0.0042	
7	0.4072 ± 0.4902	0.7639 ± 0.1678	26.9065 ± 1.7128	3.0753 ± 4.2020	0.0814 ± 0.0452	0.0087 ± 0.0113	0.0749 ± 0.0214	0.0076 ± 0.0041	
8	0.3813 ± 0.4756	0.7750 ± 0.1697	27.1064 ± 1.6384	3.3301 ± 4.4683	0.0806 ± 0.0437	0.0084 ± 0.0114	0.0738 ± 0.0206	0.0073 ± 0.0038	
9	0.3612 ± 0.4632	0.7832 ± 0.1712	27.1331 ± 1.6479	3.8509 ± 4.7226	0.0806 ± 0.0430	0.0083 ± 0.0113	0.0737 ± 0.0206	0.0073 ± 0.0038	
10	0.3463 ± 0.4584	0.7904 ± 0.1722	27.1992 ± 1.6377	3.9229 ± 4.7052	0.0803 ± 0.0432	0.0082 ± 0.0113	0.0734 ± 0.0209	0.0071 ± 0.0038	
25	0.2702 ± 0.4900	0.8320 ± 0.1811	27.4313 ± 1.6725	5.6002 ± 5.1020	0.0708 ± 0.0386	0.0079 ± 0.0106	0.0723 ± 0.0225	0.0067 ± 0.0042	
1	0.1690 ± 0.3675	0.8682 ± 0.2101	37.1172 ± 2.2302	0.2868 ± 4.0463	0.0328 ± 0.0447	0.0034 ± 0.0127	0.0362 ± 0.0372	0.0037 ± 0.0067	
2	0.2031 ± 0.4356	0.8761 ± 0.2113	38.1350 ± 3.7072	0.3710 ± 4.4708	0.0296 ± 0.0446	0.0029 ± 0.0108	0.0316 ± 0.0330	0.0029 ± 0.0057	
3	0.2260 ± 0.4778	0.8782 ± 0.2087	38.6037 ± 5.7501	0.4499 ± 6.0409	0.0291 ± 0.0447	0.0028 ± 0.0105	0.0308 ± 0.0336	0.0029 ± 0.0056	
5	0.2602 ± 0.5445	0.8800 ± 0.2047	38.7740 ± 7.5804	0.7238 ± 0.7359	0.0285 ± 0.0440	0.0027 ± 0.0105	0.0293 ± 0.0322	0.0026 ± 0.0053	
6	0.2726 ± 0.5704	0.8800 ± 0.2043	38.8594 ± 7.5103	0.6362 ± 0.8723	0.0286 ± 0.0443	0.0028 ± 0.0105	0.0302 ± 0.0331	0.0027 ± 0.0050	
7	0.2805 ± 0.5848	0.8812 ± 0.2025	38.3974 ± 7.3693	0.6031 ± 0.9298	0.0291 ± 0.0436	0.0028 ± 0.0113	0.0305 ± 0.0324	0.0027 ± 0.0055	
8	0.2879 ± 0.5984	0.8817 ± 0.2016	38.4123 ± 7.3896	0.6250 ± 0.9908	0.0289 ± 0.0433	0.0027 ± 0.0109	0.0302 ± 0.0313	0.0026 ± 0.0051	
9	0.2936 ± 0.6086	0.8819 ± 0.2007	38.4395 ± 7.3785	0.6429 ± 1.0174	0.0289 ± 0.0427	0.0027 ± 0.0098	0.0302 ± 0.0303	0.0025 ± 0.0047	
10	0.2998 ± 0.6222	0.8817 ± 0.2004	38.3877 ± 7.3750	0.6825 ± 1.0782	0.0286 ± 0.0429	0.0027 ± 0.0098	0.0305 ± 0.0308	0.0026 ± 0.0046	
25	0.3457 ± 0.7150	0.8820 ± 0.1996	38.5015 ± 7.2095	0.7991 ± 1.3361	0.0287 ± 0.0430	0.0027 ± 0.0099	0.0301 ± 0.0297	0.0025 ± 0.0046	
1	0.1456 ± 0.3199	0.8585 ± 0.2423	37.4494 ± 7.6605	0.3491 ± 1.1050	0.0346 ± 0.0572	0.0045 ± 0.0176	0.0340 ± 0.0410	0.0040 ± 0.0099	
2	0.1593 ± 0.3424	0.8718 ± 0.2206	38.4353 ± 7.2996	0.3685 ± 1.2737	0.0279 ± 0.0457	0.0029 ± 0.0118	0.0281 ± 0.0287	0.0024 ± 0.0048	
3	0.1772 ± 0.3781	0.8762 ± 0.2132	38.8830 ± 7.4732	0.3972 ± 1.1002	0.0279 ± 0.0445	0.0028 ± 0.0111	0.0267 ± 0.0271	0.0022 ± 0.0041	
5	0.2053 ± 0.4334	0.8800 ± 0.2060	39.2444 ± 7.6159	0.4963 ± 1.1560	0.0273 ± 0.0441	0.0027 ± 0.0108	0.0260 ± 0.0273	0.0021 ± 0.0043	
6	0.2151 ± 0.4543	0.8816 ± 0.2033	39.3591 ± 7.5455	0.4938 ± 1.1374	0.0265 ± 0.0423	0.0025 ± 0.0102	0.0252 ± 0.0260	0.0020 ± 0.0039	
7	0.2232 ± 0.4700	0.8810 ± 0.2024	39.2966 ± 7.4489	0.5275 ± 1.1552	0.0264 ± 0.0417	0.0024 ± 0.0099	0.0253 ± 0.0252	0.0019 ± 0.0037	
8	0.2313 ± 0.4850	0.8830 ± 0.2008	39.4955 ± 7.5265	0.5469 ± 1.1763	0.0265 ± 0.0409	0.0023 ± 0.0096	0.0244 ± 0.0246	0.0018 ± 0.0034	
9	0.2381 ± 0.4985	0.8831 ± 0.2002	39.5027 ± 7.5382	0.5789 ± 1.2280	0.0259 ± 0.0410	0.0024 ± 0.0096	0.0245 ± 0.0248	0.0018 ± 0.0034	
10	0.2446 ± 0.5111	0.8838 ± 0.1998	39.5743 ± 7.5785	0.6014 ± 1.2523	0.0259 ± 0.0414	0.0024 ± 0.0097	0.0243 ± 0.0250	0.0018 ± 0.0035	
25	0.2969 ± 0.6121	0.8861 ± 0.1962	39.7354 ± 7.5975	0.7339 ± 1.4199	0.0254 ± 0.0406	0.0023 ± 0.0094	0.0237 ± 0.0248	0.0018 ± 0.0034	
1	0.1322 ± 0.3149	0.8497 ± 0.2486	36.36372 ± 7.7834	0.3233 ± 1.1386	0.0364 ± 0.0596	0.0049 ± 0.0185	0.0374 ± 0.0444	0.0047 ± 0.0124	
2	0.1425 ± 0.3266	0.8623 ± 0.2321	37.8604 ± 7.7543	0.3813 ± 1.1325	0.0327 ± 0.0531	0.0039 ± 0.0152	0.0344 ± 0.0401	0.0039 ± 0.0100	
3	0.1580 ± 0.3606	0.8674 ± 0.2243	38.6552 ± 7.6088	0.4330 ± 1.1205	0.0311 ± 0.0489	0.0034 ± 0.0126	0.0329 ± 0.0352	0.0033 ± 0.0068	
5	0.1850 ± 0.4106	0.8729 ± 0.2181	38.4826 ± 7.5403	0.5399 ± 1.1953	0.0295 ± 0.0468	0.0031 ± 0.0114	0.0308 ± 0.0339	0.0030 ± 0.0060	
6	0.1963 ± 0.4336	0.8745 ± 0.2151	38.5955 ± 7.5887	0.5669 ± 1.2047	0.0292 ± 0.0463	0.0030 ± 0.0112	0.0305 ± 0.0332	0.0029 ± 0.0057	
7	0.2057 ± 0.4515	0.8751 ± 0.2140	38.7697 ± 7.6242	0.6191 ± 1.2447	0.0287 ± 0.0458	0.0029 ± 0.0113	0.0300 ± 0.0329	0.0028 ± 0.0057	
8	0.2152 ± 0.4694	0.8758 ± 0.2120	39.5924 ± 7.8148	0.6614 ± 1.2876	0.0284 ± 0.0469	0.0030 ± 0.0114	0.0299 ± 0.0346	0.0029 ± 0.0062	
9	0.2223 ± 0.4815	0.8767 ± 0.2129	39.6109 ± 7.8368	0.6822 ± 1.3165	0.0286 ± 0.0466	0.0030 ± 0.0113	0.0295 ± 0.0345	0.0029 ± 0.0062	
10	0.2296 ± 0.4961	0.8772 ± 0.2125	39.5025 ± 7.8096	0.6941 ± 1.3211	0.0286 ± 0.0466	0.0030 ± 0.0114	0.0295 ± 0.0348	0.0029 ± 0.0064	
25	0.2882 ± 0.6064	0.8800 ± 0.2095	39.3285 ± 7.6907	0.8767 ± 1.5400	0.0276 ± 0.0453	0.0028 ± 0.0109	0.0285 ± 0.0346	0.0028 ± 0.0063	

Tabla 7.22: Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Sqrt Scale. Conjunto de datos: Full.

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
- <i>Base - UNet</i>		0.6254 ± 0.7687	0.8772 ± 0.0855	32.6200 ± 3.4457	0.5666 ± 0.6532	0.0373 ± 0.0393	0.0029 ± 0.079	0.0185 ± 0.0104	0.0006 ± 0.0006
- <i>Steps 10 - DDPM</i>		1 0.3067 ± 0.4402 2 0.3552 ± 0.4983 3 0.3885 ± 0.5339 4 0.4404 ± 0.5820 5 0.4556 ± 0.5979 6 0.4669 ± 0.6078 7 0.4756 ± 0.6153 8 0.4842 ± 0.6238 9 0.4909 ± 0.6304 10 0.5000 ± 0.6304 25 0.5182 ± 0.6682	0.8619 ± 0.0895 0.8688 ± 0.0878 0.8721 ± 0.0892 0.8736 ± 0.0889 0.8742 ± 0.0884 0.8750 ± 0.0887 0.8753 ± 0.0887 0.8756 ± 0.0884 0.8756 ± 0.0884 0.8768 ± 0.0884	31.5489 ± 3.5263 31.9766 ± 3.2448 32.4597 ± 3.6507 32.4784 ± 3.5994 32.5049 ± 3.6352 32.5579 ± 3.6657 32.5488 ± 3.6584 32.5616 ± 3.6669 32.5439 ± 3.6605 32.7216 ± 3.7830	0.2183 ± 0.3310 0.2456 ± 0.2839 0.2742 ± 0.3576 0.3254 ± 0.4119 0.3345 ± 0.4261 0.3411 ± 0.4242 0.3483 ± 0.4238 0.3527 ± 0.4381 0.3579 ± 0.4426 0.4172 ± 0.5931	0.0432 ± 0.0453 0.0403 ± 0.0423 0.0396 ± 0.0413 0.0386 ± 0.0413 0.0386 ± 0.0409 0.0383 ± 0.0408 0.0383 ± 0.0408 0.0382 ± 0.0407 0.0383 ± 0.0407 0.0375 ± 0.0401	0.0039 ± 0.0101 0.0034 ± 0.0089 0.0032 ± 0.0085 0.0032 ± 0.0083 0.0032 ± 0.0083 0.0031 ± 0.0083 0.0031 ± 0.0082 0.0031 ± 0.0082 0.0031 ± 0.0082 0.0030 ± 0.0080	0.0226 ± 0.0142 0.0211 ± 0.0137 0.0206 ± 0.0138 0.0204 ± 0.0134 0.0201 ± 0.0134 0.0198 ± 0.0135 0.0199 ± 0.0139 0.0197 ± 0.0136 0.0197 ± 0.0138 0.0195 ± 0.0134	0.0009 ± 0.0011 0.0008 ± 0.0011 0.0008 ± 0.0010 0.0007 ± 0.0009
- <i>Steps 20 - DDPM</i>		1 0.3177 ± 0.4450 2 0.3780 ± 0.5144 3 0.4004 ± 0.5440 4 0.4662 ± 0.5870 5 0.4807 ± 0.5967 6 0.4930 ± 0.6119 8 0.5025 ± 0.6218 9 0.5111 ± 0.6297 10 0.5183 ± 0.6367 25 0.5751 ± 0.6974	0.8549 ± 0.0898 0.8604 ± 0.0898 0.8605 ± 0.0896 0.8609 ± 0.0898 0.8687 ± 0.0894 0.8691 ± 0.0942 0.8691 ± 0.0932 0.8699 ± 0.0932 0.8716 ± 0.0903 0.8716 ± 0.0903	31.0604 ± 3.7310 31.1199 ± 3.7194 32.0895 ± 3.5927 32.2394 ± 3.5269 32.2706 ± 3.5141 32.2910 ± 3.4772 32.2929 ± 3.4249 32.2929 ± 3.4249 32.4613 ± 3.4492 32.4613 ± 3.4492	0.4049 ± 0.4553 0.4049 ± 0.4553	0.0378 ± 0.0378 0.0378 ± 0.0378 0.0379 ± 0.0379 0.0379 ± 0.0379	0.0039 ± 0.0108 0.0039 ± 0.0108	0.0257 ± 0.0170 0.0254 ± 0.0170 0.0242 ± 0.0160 0.0242 ± 0.0160 0.0242 ± 0.0160 0.0242 ± 0.0160 0.0244 ± 0.0161 0.0244 ± 0.0161 0.0244 ± 0.0160 0.0245 ± 0.0158	0.0013 ± 0.0015 0.0011 ± 0.0016 0.0011 ± 0.0016 0.0010 ± 0.0013 0.0010 ± 0.0013 0.0010 ± 0.0013 0.0010 ± 0.0014 0.0010 ± 0.0014 0.0010 ± 0.0014 0.0010 ± 0.0014
- <i>Steps 50 - DDPM</i>		1 0.2783 ± 0.4047 2 0.3349 ± 0.4592 3 0.3749 ± 0.4970 5 0.4240 ± 0.5450 6 0.4415 ± 0.5624 7 0.4553 ± 0.5758 8 0.4657 ± 0.5856 9 0.4754 ± 0.5946 10 0.4839 ± 0.6036 25 0.5478 ± 0.6692	0.8523 ± 0.0898 0.8640 ± 0.0943 0.8693 ± 0.0964 0.8730 ± 0.0877 0.8740 ± 0.0878 0.8750 ± 0.0878 0.8754 ± 0.0879 0.8754 ± 0.0879 0.8764 ± 0.0879 0.8772 ± 0.0879	31.2983 ± 3.8517 31.9784 ± 3.7602 32.4127 ± 3.8945 32.6385 ± 3.7951 32.6800 ± 3.8332 32.6506 ± 3.8511 32.6764 ± 3.8649 32.6907 ± 3.8659 32.7247 ± 3.8545 32.7247 ± 3.8545	0.4182 ± 0.2094 0.4250 ± 0.2970 0.2953 ± 0.2953 0.3254 ± 0.4097 0.3379 ± 0.0398 0.3379 ± 0.0398 0.3379 ± 0.0398 0.3379 ± 0.0398 0.3379 ± 0.0398 0.3379 ± 0.0398	0.0451 ± 0.0456 0.0410 ± 0.0422 0.0394 ± 0.0411 0.0379 ± 0.0398 0.0378 ± 0.0395 0.0379 ± 0.0395 0.0379 ± 0.0395 0.0379 ± 0.0395 0.0379 ± 0.0395 0.0379 ± 0.0395	0.0041 ± 0.0102 0.0041 ± 0.0102 0.0032 ± 0.0083 0.0032 ± 0.0083 0.0030 ± 0.0080 0.0030 ± 0.0080 0.0030 ± 0.0080 0.0030 ± 0.0080 0.0030 ± 0.0080 0.0030 ± 0.0080	0.0260 ± 0.0181 0.0221 ± 0.0141 0.0218 ± 0.0155 0.0202 ± 0.0142 0.0205 ± 0.0138 0.0205 ± 0.0140 0.0205 ± 0.0139 0.0204 ± 0.0140 0.0204 ± 0.0140 0.0204 ± 0.0140	0.0012 ± 0.0016 0.0008 ± 0.0009 0.0009 ± 0.0012 0.0007 ± 0.0010 0.0007 ± 0.0009 0.0007 ± 0.0009 0.0008 ± 0.0010 0.0007 ± 0.0010 0.0007 ± 0.0010 0.0007 ± 0.0010
- <i>Steps 100 - DDPM</i>		1 0.2331 ± 0.3615 2 0.2770 ± 0.4098 3 0.3134 ± 0.4463 5 0.3652 ± 0.4956 6 0.3827 ± 0.5111 7 0.3986 ± 0.5264 8 0.4112 ± 0.5367 9 0.4235 ± 0.5483 10 0.4336 ± 0.5578 25 0.5120 ± 0.6319	0.8495 ± 0.1134 0.8629 ± 0.1048 0.8670 ± 0.1001 0.8733 ± 0.0959 0.8737 ± 0.0970 0.8737 ± 0.0970 0.8738 ± 0.0964 0.8741 ± 0.0959 0.8741 ± 0.0959 0.8741 ± 0.0959	31.2359 ± 3.9067 31.9807 ± 3.8626 32.1025 ± 3.7407 32.5315 ± 3.8817 32.6011 ± 0.3167 32.5553 ± 3.9274 32.6213 ± 3.9760 32.6919 ± 4.0204 32.7437 ± 3.8647 32.7472 ± 4.0194	0.4023 ± 0.1565 0.4023 ± 0.1565 0.2203 ± 0.2424 0.3276 ± 0.4047 0.3385 ± 0.4222 0.3386 ± 0.4222 0.3385 ± 0.4223 0.3385 ± 0.4223 0.3385 ± 0.4223 0.3385 ± 0.4223	0.0450 ± 0.0500 0.0450 ± 0.0500 0.0404 ± 0.0404 0.0394 ± 0.0411 0.0385 ± 0.0422 0.0386 ± 0.0422 0.0386 ± 0.0423 0.0386 ± 0.0423 0.0386 ± 0.0423 0.0386 ± 0.0423	0.0045 ± 0.0126 0.0045 ± 0.0126 0.0040 ± 0.0096 0.0039 ± 0.0096 0.0038 ± 0.0095 0.0038 ± 0.0095 0.0038 ± 0.0095 0.0038 ± 0.0095 0.0038 ± 0.0095 0.0038 ± 0.0095	0.0226 ± 0.0151 0.0200 ± 0.0122 0.0195 ± 0.0122 0.0179 ± 0.0110 0.0179 ± 0.0110 0.0181 ± 0.0116 0.0184 ± 0.0118 0.0187 ± 0.0121 0.0186 ± 0.0119 0.0187 ± 0.0120	0.0009 ± 0.0013 0.0007 ± 0.0008 0.0007 ± 0.0008 0.0006 ± 0.0007 0.0006 ± 0.0007 0.0006 ± 0.0007 0.0006 ± 0.0007 0.0006 ± 0.0007 0.0006 ± 0.0007 0.0006 ± 0.0007
- <i>Steps 250 - DDPM</i>		1 0.2195 ± 0.3494 2 0.2367 ± 0.3654 3 0.2627 ± 0.3943 5 0.3049 ± 0.4372 6 0.3231 ± 0.4554 7 0.3381 ± 0.4707 8 0.3509 ± 0.4848 9 0.3631 ± 0.4933 10 0.3740 ± 0.5038 25 0.4613 ± 0.5866	0.8310 ± 0.1238 0.8410 ± 0.1238 0.8510 ± 0.0990 0.8610 ± 0.0950 0.8697 ± 0.0926 0.8740 ± 0.0918 0.8790 ± 3.6037 0.8724 ± 0.0906 0.8724 ± 0.0906 0.8770 ± 0.0892	30.4727 ± 4.0194 32.6179 ± 3.8625 32.6796 ± 3.9733 32.6059 ± 3.9464 0.4409 ± 0.6381 0.3912 ± 0.3928 0.3912 ± 0.3928 0.3912 ± 0.3928 0.3912 ± 0.3928 0.3912 ± 0.3928	0.4018 ± 0.1693 0.4023 ± 0.4873 0.4023 ± 0.4873	0.0481 ± 0.0531 0.0481 ± 0.0531	0.0052 ± 0.0138 0.0052 ± 0.0138	0.0254 ± 0.0182 0.0237 ± 0.0167 0.0227 ± 0.0161 0.0212 ± 0.0146 0.0211 ± 0.0143 0.0211 ± 0.0143 0.0210 ± 0.0140 0.0208 ± 0.0138 0.0208 ± 0.0139 0.0208 ± 0.0137	0.0009 ± 0.0016 0.0009 ± 0.0016 0.0009 ± 0.0016 0.0008 ± 0.0014 0.0008 ± 0.0013 0.0008 ± 0.0013 0.0008 ± 0.0012 0.0008 ± 0.0011 0.0008 ± 0.0011 0.0008 ± 0.0011

Tabla 7.23: Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Log Scale. Conjunto de datos: Clean 30.

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>-Base - UNet</i>									
<i>-Steps 10 - DDPM</i>									
1	0.8589 ± 0.0662	0.8163 ± 0.1831	31.9258 ± 4.2065	1.4917 ± 2.2306	0.0414 ± 0.0475	0.0040 ± 0.0174	0.0237 ± 0.0195	0.0016 ± 0.026	
2	0.4637 ± 0.6446	0.7713 ± 0.2331	29.8775 ± 5.4277	1.1644 ± 3.3304	0.0652 ± 0.0771	0.0102 ± 0.0266	0.0479 ± 0.0635	0.0072 ± 0.0175	
3	0.5966 ± 0.7676	0.7877 ± 0.2119	30.5014 ± 5.4305	1.3249 ± 3.6707	0.0595 ± 0.0665	0.0080 ± 0.0204	0.0431 ± 0.0524	0.0054 ± 0.0124	
5	0.6547 ± 0.8240	0.7883 ± 0.2174	30.5945 ± 5.4418	1.3076 ± 3.2600	0.0592 ± 0.0664	0.0079 ± 0.0197	0.0431 ± 0.0522	0.0054 ± 0.0108	
6	0.6737 ± 0.8424	0.7832 ± 0.2245	30.4654 ± 5.6590	1.3271 ± 3.2905	0.0619 ± 0.0692	0.0086 ± 0.0206	0.0465 ± 0.0563	0.0062 ± 0.0122	
7	0.6877 ± 0.8572	0.7811 ± 0.2294	30.4504 ± 5.7669	1.3367 ± 3.3096	0.0629 ± 0.0713	0.0090 ± 0.0214	0.0477 ± 0.0589	0.0066 ± 0.0132	
8	0.6999 ± 0.8703	0.7797 ± 0.2320	30.5929 ± 5.7597	1.3580 ± 3.2844	0.0636 ± 0.0723	0.0093 ± 0.0219	0.0486 ± 0.0602	0.0069 ± 0.0138	
9	0.7100 ± 0.8817	0.7798 ± 0.2332	30.5866 ± 5.7720	1.3701 ± 3.2952	0.0639 ± 0.0728	0.0094 ± 0.0220	0.0488 ± 0.0610	0.0070 ± 0.0142	
10	0.7189 ± 0.8904	0.7788 ± 0.2331	30.5405 ± 5.7793	1.3686 ± 3.2905	0.0642 ± 0.0727	0.0094 ± 0.0220	0.0493 ± 0.0607	0.0070 ± 0.0139	
25	0.7816 ± 0.9592	0.7829 ± 0.2310	30.4944 ± 5.8144	1.3643 ± 3.2387	0.0633 ± 0.0729	0.0093 ± 0.0217	0.0484 ± 0.0611	0.0069 ± 0.0135	
25	0.0018 ± 0.3650	0.7963 ± 0.1960	30.6049 ± 4.9617	1.3659 ± 3.3002	0.0592 ± 0.0632	0.0080 ± 0.0194	0.0319 ± 0.0372	0.0031 ± 0.0068	
2	0.4554 ± 0.6456	0.7952 ± 0.1960	30.4322 ± 5.1715	1.3789 ± 3.4079	0.0553 ± 0.0632	0.0064 ± 0.0194	0.0332 ± 0.0372	0.0037 ± 0.0122	
3	0.5368 ± 0.7068	0.7953 ± 0.1994	30.5229 ± 4.9609	1.3199 ± 3.0013	0.0554 ± 0.0582	0.0061 ± 0.0182	0.0334 ± 0.0381	0.0038 ± 0.0079	
5	0.5977 ± 0.7327	0.8003 ± 0.1952	31.1797 ± 3.9274	1.2319 ± 2.9255	0.0496 ± 0.0551	0.0055 ± 0.0169	0.0294 ± 0.0336	0.0028 ± 0.0057	
6	0.6181 ± 0.7744	0.8080 ± 0.1961	31.3251 ± 4.0172	1.2156 ± 2.7956	0.0485 ± 0.0542	0.0053 ± 0.0166	0.0280 ± 0.0320	0.0025 ± 0.0051	
7	0.6343 ± 0.7907	0.8092 ± 0.1962	31.4384 ± 4.0509	1.2065 ± 2.7938	0.0486 ± 0.0542	0.0053 ± 0.0166	0.0287 ± 0.0333	0.0026 ± 0.0057	
8	0.6486 ± 0.8057	0.8104 ± 0.1957	31.4717 ± 4.0301	1.3017 ± 2.9516	0.0477 ± 0.0539	0.0052 ± 0.0166	0.0285 ± 0.0323	0.0025 ± 0.0051	
9	0.6619 ± 0.8197	0.8103 ± 0.1948	31.3746 ± 4.0547	1.4667 ± 3.1240	0.0487 ± 0.0544	0.0053 ± 0.0166	0.0296 ± 0.0320	0.0027 ± 0.0055	
10	0.6718 ± 0.8314	0.8105 ± 0.1940	31.2618 ± 4.0879	1.4655 ± 3.3372	0.0490 ± 0.0549	0.0054 ± 0.0165	0.0298 ± 0.0344	0.0027 ± 0.0050	
25	0.7518 ± 0.9179	0.8096 ± 0.1979	31.2016 ± 5.1010	1.6378 ± 3.5305	0.0506 ± 0.0578	0.0050 ± 0.0171	0.0315 ± 0.0394	0.0032 ± 0.0073	
1	0.3256 ± 0.4755	0.7235 ± 0.2337	27.5631 ± 5.6341	2.1789 ± 5.3007	0.0899 ± 0.1235	0.0233 ± 0.0909	0.0576 ± 0.0982	0.0141 ± 0.0686	
2	0.3928 ± 0.5454	0.7434 ± 0.1929	27.7530 ± 4.9294	2.1065 ± 4.6604	0.0810 ± 0.0945	0.0155 ± 0.0501	0.0509 ± 0.0720	0.0086 ± 0.0370	
3	0.4416 ± 0.5887	0.7447 ± 0.1991	27.7563 ± 4.7419	2.3121 ± 4.7343	0.0820 ± 0.1033	0.0174 ± 0.0617	0.0527 ± 0.0847	0.0108 ± 0.0491	
5	0.5105 ± 0.6581	0.7571 ± 0.1929	28.0033 ± 4.6011	2.5588 ± 4.9874	0.0797 ± 0.1054	0.0175 ± 0.0658	0.0517 ± 0.0890	0.0114 ± 0.0548	
6	0.5368 ± 0.6824	0.7518 ± 0.2014	27.7737 ± 4.7834	2.7485 ± 5.2904	0.0851 ± 0.1213	0.0220 ± 0.0886	0.0562 ± 0.1063	0.0154 ± 0.0781	
7	0.5565 ± 0.6994	0.7557 ± 0.1948	27.8821 ± 4.7534	2.7766 ± 5.2078	0.0852 ± 0.1151	0.0201 ± 0.0809	0.0544 ± 0.1012	0.0139 ± 0.0726	
8	0.5736 ± 0.7159	0.7575 ± 0.1997	28.0398 ± 4.8186	2.7709 ± 5.1519	0.0821 ± 0.1186	0.0208 ± 0.0870	0.0543 ± 0.1053	0.0148 ± 0.0780	
9	0.5891 ± 0.7305	0.7580 ± 0.1952	28.0027 ± 4.7152	2.8161 ± 5.1110	0.0813 ± 0.1139	0.0196 ± 0.0796	0.0535 ± 0.1001	0.0137 ± 0.0707	
10	0.6011 ± 0.7414	0.7617 ± 0.1915	28.0379 ± 4.5380	2.7860 ± 4.9919	0.0795 ± 0.1081	0.0180 ± 0.0719	0.0520 ± 0.0946	0.0124 ± 0.0664	
25	0.7067 ± 0.8495	0.7533 ± 0.2066	27.7055 ± 4.5025	3.2642 ± 5.1500	0.0847 ± 0.1266	0.0232 ± 0.1082	0.0561 ± 0.1155	0.0172 ± 0.1011	
1	0.3035 ± 0.4520	0.7706 ± 0.2082	29.7876 ± 4.3293	0.7112 ± 2.6584	0.0552 ± 0.0579	0.0064 ± 0.0210	0.0360 ± 0.0282	0.0029 ± 0.0053	
2	0.3741 ± 0.5269	0.7799 ± 0.2010	30.0941 ± 4.3175	1.0967 ± 3.2037	0.0538 ± 0.0568	0.0061 ± 0.0207	0.0360 ± 0.0303	0.0030 ± 0.0064	
3	0.4205 ± 0.5724	0.7855 ± 0.1944	30.2924 ± 4.1529	1.1999 ± 2.9756	0.0518 ± 0.0540	0.0056 ± 0.0207	0.0346 ± 0.0254	0.0026 ± 0.0044	
5	0.4865 ± 0.6333	0.7909 ± 0.1863	30.5047 ± 4.1088	1.3911 ± 2.9506	0.0503 ± 0.0527	0.0053 ± 0.0198	0.0340 ± 0.0254	0.0025 ± 0.0046	
6	0.5088 ± 0.6547	0.7911 ± 0.1863	30.5225 ± 4.1509	1.4525 ± 2.9925	0.0503 ± 0.0527	0.0053 ± 0.0198	0.0338 ± 0.0254	0.0025 ± 0.0045	
7	0.5265 ± 0.6712	0.7922 ± 0.1852	30.5327 ± 4.1625	1.5446 ± 3.0280	0.0502 ± 0.0528	0.0053 ± 0.0196	0.0338 ± 0.0261	0.0025 ± 0.0048	
8	0.5419 ± 0.6864	0.7938 ± 0.1841	30.5752 ± 4.1261	1.6040 ± 3.1660	0.0498 ± 0.0525	0.0052 ± 0.0195	0.0334 ± 0.0259	0.0025 ± 0.0047	
9	0.5556 ± 0.6994	0.7942 ± 0.1832	30.5743 ± 4.1294	1.6702 ± 3.1860	0.0499 ± 0.0526	0.0053 ± 0.0195	0.0336 ± 0.0262	0.0025 ± 0.0049	
10	0.5681 ± 0.7109	0.7943 ± 0.1838	30.5821 ± 4.1363	1.7327 ± 3.1933	0.0499 ± 0.0528	0.0053 ± 0.0198	0.0336 ± 0.0265	0.0025 ± 0.0050	
25	0.6589 ± 0.8003	0.7957 ± 0.1812	30.5989 ± 4.1670	2.0729 ± 3.4169	0.0499 ± 0.0523	0.0052 ± 0.0194	0.0335 ± 0.0253	0.0024 ± 0.0043	
1	0.2617 ± 0.4265	0.7375 ± 0.2223	28.3513 ± 4.9719	0.6019 ± 2.4428	0.0698 ± 0.0782	0.0109 ± 0.0296	0.0428 ± 0.0494	0.0056 ± 0.0134	
2	0.2643 ± 0.4216	0.7705 ± 0.2091	29.5608 ± 4.4982	0.6336 ± 2.5793	0.0586 ± 0.0653	0.0077 ± 0.0220	0.0354 ± 0.0381	0.0037 ± 0.0076	
3	0.2906 ± 0.4531	0.7801 ± 0.2080	30.0766 ± 4.6693	0.7437 ± 3.0566	0.0559 ± 0.0625	0.0070 ± 0.0198	0.0339 ± 0.0367	0.0034 ± 0.0071	
5	0.3407 ± 0.5057	0.7898 ± 0.2015	30.5867 ± 4.5769	0.7928 ± 3.0221	0.0532 ± 0.0594	0.0064 ± 0.0182	0.0338 ± 0.0358	0.0032 ± 0.0066	
6	0.3648 ± 0.5337	0.7937 ± 0.1984	30.2771 ± 4.5217	0.8276 ± 3.1113	0.0521 ± 0.0579	0.0061 ± 0.0177	0.0327 ± 0.0346	0.0031 ± 0.0064	
7	0.3837 ± 0.5525	0.7963 ± 0.1973	30.4844 ± 4.5586	0.8203 ± 3.0908	0.0517 ± 0.0585	0.0061 ± 0.0179	0.0322 ± 0.0366	0.0031 ± 0.0076	
8	0.4019 ± 0.5710	0.7966 ± 0.1992	30.8180 ± 4.7887	0.9310 ± 3.3861	0.0543 ± 0.0643	0.0061 ± 0.0209	0.0339 ± 0.0369	0.0036 ± 0.0136	
9	0.4174 ± 0.5863	0.7983 ± 0.1982	30.5509 ± 4.8178	0.8301 ± 3.3801	0.0527 ± 0.0628	0.0067 ± 0.0201	0.0335 ± 0.0430	0.0038 ± 0.0124	
10	0.4326 ± 0.6011	0.7993 ± 0.1976	30.9674 ± 4.7832	0.9574 ± 3.3592	0.0525 ± 0.0620	0.0066 ± 0.0195	0.0333 ± 0.0428	0.0037 ± 0.0114	
25	0.5584 ± 0.7249	0.8052 ± 0.1963	31.2005 ± 4.9077	1.2038 ± 3.3907	0.0513 ± 0.0589	0.0061 ± 0.0176	0.0327 ± 0.0393	0.0034 ± 0.0082	

Tabla 7.24: Comparación de métricas para diferentes pasos de difusión y agregaciones. Escala de datos: Log Scale. Conjunto de datos: Full.

7.12.2. Impacto del porcentaje de datos

Experiment	Aggregation	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
-*10% - DDPN										
1	0.3015 ± 0.3666	0.6668 ± 0.2036	24.5174 ± 4.5456	2.3269 ± 3.0329	0.1160 ± 0.1013	0.0237 ± 0.0403	0.0620 ± 0.0484	0.0072 ± 0.0124		
2	0.3143 ± 0.4467	0.7261 ± 0.1516	25.3749 ± 4.1506	2.4817 ± 2.8751	0.1007 ± 0.0858	0.0175 ± 0.0290	0.0500 ± 0.0373	0.0046 ± 0.0074		
3	0.3412 ± 0.4790	0.7539 ± 0.1306	25.7022 ± 3.7553	2.6943 ± 3.0011	0.0944 ± 0.0808	0.0153 ± 0.0251	0.0431 ± 0.0301	0.0034 ± 0.0052		
5	0.3850 ± 0.5254	0.7657 ± 0.1183	25.8904 ± 3.4066	2.7581 ± 3.0061	0.0907 ± 0.0748	0.0138 ± 0.0222	0.0412 ± 0.0266	0.0029 ± 0.0038		
6	0.4019 ± 0.5431	0.7721 ± 0.1183	25.9221 ± 3.3733	2.8810 ± 3.1261	0.0902 ± 0.0746	0.0137 ± 0.0222	0.0407 ± 0.0282	0.0030 ± 0.0043		
7	0.4170 ± 0.5574	0.7752 ± 0.1198	26.0246 ± 3.5600	2.9261 ± 3.1776	0.0897 ± 0.0754	0.0137 ± 0.0223	0.0407 ± 0.0279	0.0029 ± 0.0041		
8	0.4287 ± 0.5681	0.7769 ± 0.1170	26.0493 ± 3.5337	2.9874 ± 3.1567	0.0891 ± 0.0741	0.0134 ± 0.0218	0.0330 ± 0.0264	0.0028 ± 0.0037		
9	0.4389 ± 0.5770	0.7787 ± 0.1157	26.0678 ± 3.6112	3.1189 ± 3.3218	0.0891 ± 0.0742	0.0135 ± 0.0218	0.0333 ± 0.0258	0.0027 ± 0.0036		
10	0.4474 ± 0.5853	0.7812 ± 0.1129	26.1141 ± 3.5345	3.1594 ± 3.4038	0.0884 ± 0.0738	0.0132 ± 0.0216	0.0335 ± 0.0257	0.0027 ± 0.0038		
25	0.5229 ± 0.6518	0.7825 ± 0.1131	25.9571 ± 3.3930	3.3318 ± 3.3027	0.0897 ± 0.0733	0.0134 ± 0.0211	0.0301 ± 0.0253	0.0027 ± 0.0037		
-*10% - UNET										
1	0.6016 ± 0.7380	0.8685 ± 0.0934	31.5711 ± 3.5252	0.5331 ± 0.9092	0.0422 ± 0.0442	0.0037 ± 0.0095	0.0200 ± 0.0137	0.0008 ± 0.0013		
1	0.2502 ± 0.3045	0.6241 ± 0.2083	22.1641 ± 5.0059	1.6104 ± 2.3736	0.1683 ± 0.1282	0.0447 ± 0.0673	0.1220 ± 0.0929	0.0246 ± 0.0390		
2	0.2529 ± 0.3863	0.6733 ± 0.1953	24.0350 ± 5.3706	1.1259 ± 1.9196	0.1404 ± 0.1181	0.0337 ± 0.0585	0.1114 ± 0.0885	0.0209 ± 0.0380		
3	0.2732 ± 0.4103	0.6905 ± 0.1927	24.3259 ± 5.0434	1.1507 ± 1.8067	0.1332 ± 0.1104	0.0290 ± 0.0545	0.1080 ± 0.0835	0.0192 ± 0.0359		
5	0.3116 ± 0.4492	0.6884 ± 0.1909	24.4623 ± 5.2914	1.1615 ± 2.0672	0.1345 ± 0.1081	0.0298 ± 0.0512	0.1125 ± 0.0809	0.0197 ± 0.0337		
6	0.3303 ± 0.4674	0.6887 ± 0.1898	24.5905 ± 5.3377	1.3072 ± 2.5112	0.1329 ± 0.1063	0.0290 ± 0.0495	0.1124 ± 0.0798	0.0194 ± 0.0324		
7	0.3460 ± 0.4823	0.6891 ± 0.1902	24.4789 ± 5.1775	1.3352 ± 2.4991	0.1334 ± 0.1069	0.0292 ± 0.0505	0.1126 ± 0.0829	0.0200 ± 0.0344		
8	0.3582 ± 0.4930	0.6905 ± 0.1869	24.6285 ± 5.2185	1.2854 ± 2.4485	0.1316 ± 0.1050	0.0283 ± 0.0487	0.1120 ± 0.0800	0.0194 ± 0.0332		
9	0.3705 ± 0.5042	0.6906 ± 0.1855	24.6705 ± 5.2403	1.3565 ± 2.4738	0.1310 ± 0.1040	0.0280 ± 0.0482	0.1115 ± 0.0791	0.0191 ± 0.0325		
10	0.3797 ± 0.5117	0.6883 ± 0.1859	24.5115 ± 5.0740	1.3865 ± 2.5114	0.1322 ± 0.1042	0.0283 ± 0.0493	0.1134 ± 0.0811	0.0193 ± 0.0341		
25	0.4717 ± 0.5918	0.6965 ± 0.1809	24.8951 ± 4.9800	1.4027 ± 2.6395	0.1261 ± 0.0957	0.0251 ± 0.0411	0.1100 ± 0.0734	0.0178 ± 0.0270		
-*25% - UNET										
1	0.5993 ± 0.7501	0.8712 ± 0.0922	32.1371 ± 3.5150	0.7473 ± 1.2750	0.0399 ± 0.0416	0.0033 ± 0.0086	0.0210 ± 0.0122	0.0008 ± 0.0010		
1	0.2344 ± 0.3639	0.8383 ± 0.1098	30.2845 ± 4.0996	0.1826 ± 0.2107	0.0522 ± 0.0532	0.0055 ± 0.0133	0.0273 ± 0.0157	0.0012 ± 0.0012		
2	0.2759 ± 0.4080	0.8543 ± 0.1077	31.1754 ± 4.1739	0.1950 ± 0.2083	0.0470 ± 0.0490	0.0047 ± 0.0117	0.0237 ± 0.0145	0.0010 ± 0.0011		
3	0.3107 ± 0.4423	0.8611 ± 0.1049	31.7063 ± 4.3094	0.2095 ± 0.2223	0.0444 ± 0.0481	0.0043 ± 0.0109	0.0226 ± 0.0135	0.0009 ± 0.0010		
5	0.3580 ± 0.4867	0.8663 ± 0.1013	32.0003 ± 4.5148	0.2261 ± 0.2192	0.0431 ± 0.0461	0.0040 ± 0.0101	0.0212 ± 0.0124	0.0008 ± 0.0008		
6	0.3757 ± 0.5034	0.8667 ± 0.1012	32.0245 ± 4.4550	0.2377 ± 0.2280	0.0429 ± 0.0464	0.0040 ± 0.0100	0.0215 ± 0.0128	0.0008 ± 0.0009		
7	0.3909 ± 0.5187	0.8665 ± 0.1022	31.9726 ± 4.4524	0.2613 ± 0.2545	0.0433 ± 0.0470	0.0041 ± 0.0102	0.0217 ± 0.0127	0.0008 ± 0.0009		
8	0.4026 ± 0.5296	0.8670 ± 0.1015	31.9769 ± 4.4225	0.2600 ± 0.2488	0.0433 ± 0.0470	0.0041 ± 0.0102	0.0216 ± 0.0127	0.0008 ± 0.0009		
9	0.4134 ± 0.5395	0.8677 ± 0.1006	31.9869 ± 3.8749	0.2792 ± 0.2647	0.0431 ± 0.0460	0.0041 ± 0.0101	0.0214 ± 0.0125	0.0008 ± 0.0009		
10	0.4224 ± 0.5492	0.8678 ± 0.1020	32.0473 ± 4.4160	0.2845 ± 0.2862	0.0430 ± 0.0470	0.0041 ± 0.0102	0.0215 ± 0.0126	0.0008 ± 0.0009		
25	0.4941 ± 0.6165	0.8708 ± 0.0996	32.2550 ± 4.5064	0.3226 ± 0.3377	0.0421 ± 0.0466	0.0039 ± 0.0099	0.0206 ± 0.0121	0.0007 ± 0.0008		
-*50% - UNET										
1	0.6191 ± 0.7572	0.8753 ± 0.0876	32.7118 ± 3.7524	0.5789 ± 0.8188	0.0372 ± 0.0390	0.0029 ± 0.0078	0.1888 ± 0.0115	0.0006 ± 0.0008		
1	0.2571 ± 0.3096	0.8493 ± 0.0999	30.8458 ± 3.8842	0.2090 ± 0.2494	0.0476 ± 0.0477	0.0045 ± 0.0108	0.0247 ± 0.0151	0.0011 ± 0.0012		
2	0.3064 ± 0.4386	0.8634 ± 0.0997	31.6062 ± 3.7489	0.2465 ± 0.2886	0.0429 ± 0.0441	0.0038 ± 0.0094	0.0213 ± 0.0136	0.0006 ± 0.0010		
3	0.3461 ± 0.4772	0.8701 ± 0.0916	32.1416 ± 3.6959	0.2630 ± 0.3222	0.0401 ± 0.0424	0.0034 ± 0.0088	0.0203 ± 0.0126	0.0007 ± 0.0009		
5	0.3969 ± 0.5255	0.8747 ± 0.0878	32.3680 ± 3.6098	0.3072 ± 0.3752	0.0389 ± 0.0404	0.0032 ± 0.0083	0.0198 ± 0.0110	0.0006 ± 0.0007		
6	0.4152 ± 0.5423	0.8746 ± 0.0888	32.3954 ± 3.5984	0.3184 ± 0.3568	0.0387 ± 0.0407	0.0032 ± 0.0082	0.0192 ± 0.0112	0.0007 ± 0.0007		
7	0.4303 ± 0.5573	0.8752 ± 0.0894	32.3827 ± 3.6477	0.3637 ± 0.4269	0.0388 ± 0.0412	0.0032 ± 0.0084	0.0198 ± 0.0109	0.0006 ± 0.0007		
8	0.4421 ± 0.5685	0.8761 ± 0.0894	32.4644 ± 3.7239	0.3718 ± 0.4251	0.0386 ± 0.0413	0.0032 ± 0.0084	0.0188 ± 0.0108	0.0006 ± 0.0007		
9	0.4524 ± 0.5781	0.8765 ± 0.0888	32.4782 ± 3.6991	0.4010 ± 0.4838	0.0385 ± 0.0411	0.0032 ± 0.0084	0.0187 ± 0.0108	0.0006 ± 0.0007		
10	0.4613 ± 0.5874	0.8772 ± 0.0888	32.5480 ± 3.7347	0.3979 ± 0.4819	0.0382 ± 0.0411	0.0031 ± 0.0083	0.0185 ± 0.0107	0.0006 ± 0.0007		
25	0.5310 ± 0.6550	0.8794 ± 0.0869	32.6413 ± 3.6701	0.4571 ± 0.4894	0.0377 ± 0.0407	0.0031 ± 0.0082	0.0180 ± 0.0098	0.0006 ± 0.0006		
-*75% - UNET										
1	0.6174 ± 0.7627	0.8782 ± 0.0886	32.8057 ± 3.9502	0.6660 ± 1.0444	0.0371 ± 0.0400	0.0039 ± 0.0080	0.0181 ± 0.0111	0.0006 ± 0.0008		
1	0.2710 ± 0.4015	0.8531 ± 0.1001	31.2053 ± 3.8923	0.2433 ± 0.3454	0.0457 ± 0.0461	0.0042 ± 0.0104	0.0258 ± 0.0194	0.0013 ± 0.0020		
2	0.3261 ± 0.4538	0.8643 ± 0.0949	31.8832 ± 3.7366	0.3188 ± 0.4736	0.0417 ± 0.0431	0.0036 ± 0.0093	0.0220 ± 0.0150	0.0009 ± 0.0011		
3	0.3665 ± 0.4931	0.8694 ± 0.0930	32.3223 ± 3.8017	0.3379 ± 0.4456	0.0394 ± 0.0417	0.0033 ± 0.0088	0.0213 ± 0.0154	0.0009 ± 0.0012		
5	0.4163 ± 0.5398	0.8738 ± 0.0892	32.5348 ± 3.5943	0.4011 ± 0.6205	0.0380 ± 0.0401	0.0030 ± 0.0082	0.0199 ± 0.0137	0.0007 ± 0.0009		
6	0.4340 ± 0.5562	0.8738 ± 0.0901	32.5433 ± 3.6380	0.4522 ± 0.6732	0.0380 ± 0.0401	0.0031 ± 0.0082	0.0201 ± 0.0139	0.0007 ± 0.0010		
7	0.4484 ± 0.5702	0.8741 ± 0.0908	32.5291 ± 3.6709	0.4582 ± 0.6708	0.0381 ± 0.0404	0.0031 ± 0.0083	0.0201 ± 0.0138	0.0007 ± 0.0010		
8	0.4592 ± 0.5803	0.8748 ± 0.0908	32.6026 ± 3.7454	0.4677 ± 0.6685	0.0378 ± 0.0403	0.0031 ± 0.0083	0.0199 ± 0.0139	0.0007 ± 0.0010		
9	0.4690 ± 0.5887	0.8752 ± 0.0900	32.6047 ± 3.7355	0.4961 ± 0.6840	0.0377 ± 0.0402	0.0030 ± 0.0082	0.0197 ± 0.0135	0.0007 ± 0.0009		
10	0.4775 ± 0.5980	0.8756 ± 0.0905	32.6654 ± 3.7537	0.5130 ± 0.7268	0.0375 ± 0.0401	0.0030 ± 0.0081	0.0196 ± 0.0134	0.0007 ± 0.0009		
25	0.5429 ± 0.6634	0.8781 ± 0.0890	32.7051 ± 3.7475	0.5785 ± 0.7379	0.0368 ± 0.0398	0.0029 ± 0.0080	0.0188 ± 0.0127	0.0007 ± 0.0009		
-*100% - UNET										
1	0.6254 ± 0.7687	0.8772 ± 0.0855	32.6200 ± 3.4457	0.5669 ± 0.6532	0.0373 ± 0.0393	0.0029 ± 0.0079	0.0185 ± 0.0104	0.0006 ± 0.0006		

Tabla 7.25: Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Log Scale. Conjunto de datos: Clean 30.

Experiment	Aggregation	FFT	MSI ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
-*10% - DDPM										
1	0.3603 ± 0.5222	0.4495 ± 0.3060	20.3301 ± 5.7528	5.9981 ± 0.0509	0.2223 ± 0.1864	0.0841 ± 0.1318	0.1683 ± 0.1351	0.0496 ± 0.0792		
2	0.3760 ± 0.5307	0.4955 ± 0.2616	21.5453 ± 5.6238	5.5027 ± 0.3014	0.1896 ± 0.1502	0.0585 ± 0.0838	0.1484 ± 0.1064	0.0353 ± 0.0497		
3	0.4121 ± 0.5753	0.5003 ± 0.2486	21.5758 ± 5.1917	5.3039 ± 0.2846	0.1819 ± 0.1436	0.0537 ± 0.0800	0.1458 ± 0.1032	0.0337 ± 0.0519		
5	0.4652 ± 0.6286	0.5241 ± 0.2250	21.9592 ± 4.9887	5.3080 ± 0.1806	0.1755 ± 0.1383	0.0499 ± 0.0747	0.1422 ± 0.0860	0.0314 ± 0.0491		
6	0.4804 ± 0.6456	0.5141 ± 0.2276	21.8594 ± 5.2836	5.3862 ± 0.1412	0.1817 ± 0.1444	0.0539 ± 0.0835	0.1465 ± 0.1061	0.0344 ± 0.0609		
7	0.5004 ± 0.6592	0.5265 ± 0.2166	22.1085 ± 5.2604	5.4223 ± 0.1570	0.1756 ± 0.1396	0.0503 ± 0.0786	0.1418 ± 0.1018	0.0320 ± 0.0586		
8	0.5172 ± 0.6720	0.5245 ± 0.2150	22.0303 ± 5.1430	5.4643 ± 0.1701	0.1767 ± 0.1379	0.0502 ± 0.0779	0.1427 ± 0.1001	0.0320 ± 0.0588		
9	0.5334 ± 0.6886	0.5243 ± 0.2171	22.0292 ± 5.1980	5.4923 ± 0.1109	0.1770 ± 0.1365	0.0500 ± 0.0756	0.1434 ± 0.0681	0.0319 ± 0.0562		
10	0.5425 ± 0.6937	0.5283 ± 0.2107	22.0161 ± 5.1558	5.4873 ± 0.9610	0.1757 ± 0.1324	0.0483 ± 0.0716	0.1426 ± 0.0932	0.0307 ± 0.0533		
25	0.6355 ± 0.7084	0.5309 ± 0.1907	22.0290 ± 4.9494	5.7069 ± 0.6875	0.1736 ± 0.1275	0.0464 ± 0.0732	0.1424 ± 0.0955	0.0309 ± 0.0614		
-*10% - UNET										
-*25% - DDPM										
1	0.3033 ± 0.4600	0.5455 ± 0.2816	22.1598 ± 5.7813	3.8650 ± 0.2061	0.1683 ± 0.1521	0.0515 ± 0.0918	0.1133 ± 0.0664	0.0244 ± 0.0388		
2	0.3315 ± 0.4944	0.5924 ± 0.2215	23.3404 ± 4.9061	3.6832 ± 0.5324	0.1400 ± 0.1149	0.0328 ± 0.0579	0.0949 ± 0.0636	0.0147 ± 0.0187		
3	0.3687 ± 0.5301	0.6370 ± 0.2226	24.6103 ± 4.5612	3.3464 ± 4.7287	0.1181 ± 0.1007	0.0241 ± 0.0444	0.0776 ± 0.0507	0.0099 ± 0.0132		
5	0.4293 ± 0.5904	0.6849 ± 0.2003	25.7546 ± 4.6503	3.3486 ± 4.4470	0.1013 ± 0.0890	0.0182 ± 0.0331	0.0638 ± 0.0441	0.0072 ± 0.0100		
6	0.4517 ± 0.6099	0.6952 ± 0.2026	25.5270 ± 4.1873	3.5820 ± 0.8895	0.1015 ± 0.0876	0.0180 ± 0.0319	0.0617 ± 0.0472	0.0072 ± 0.0107		
7	0.4727 ± 0.6291	0.6960 ± 0.2032	25.7103 ± 4.4302	3.6372 ± 4.9051	0.1002 ± 0.0872	0.0176 ± 0.0320	0.0619 ± 0.0452	0.0069 ± 0.0098		
8	0.4913 ± 0.6461	0.7034 ± 0.2071	25.7906 ± 4.5381	3.7928 ± 4.8361	0.0993 ± 0.0866	0.0174 ± 0.0308	0.0595 ± 0.0465	0.0068 ± 0.0102		
9	0.5076 ± 0.6610	0.7015 ± 0.2078	25.7210 ± 4.4574	3.8784 ± 4.8743	0.0999 ± 0.0863	0.0173 ± 0.0303	0.0594 ± 0.0452	0.0067 ± 0.0097		
10	0.5183 ± 0.6696	0.7117 ± 0.2128	25.9340 ± 4.8897	3.7551 ± 4.6982	0.0965 ± 0.0838	0.0163 ± 0.0291	0.0562 ± 0.0448	0.0063 ± 0.0094		
25	0.6398 ± 0.7838	0.7333 ± 0.2006	4.0503 ± 4.1859	4.1859 ± 4.4683	0.0883 ± 0.0766	0.0137 ± 0.0253	0.0468 ± 0.0387	0.0046 ± 0.0080		
-*25% - UNET										
-*50% - DDPM										
1	0.8391 ± 1.0507	0.8043 ± 0.1897	31.3714 ± 4.2380	4.8275 ± 3.5410	0.4666 ± 0.0533	0.0500 ± 0.0199	0.0285 ± 0.0278	0.0024 ± 0.0051		
2	0.3108 ± 0.4684	0.4465 ± 0.3209	21.3436 ± 6.0565	4.1284 ± 6.1526	0.2203 ± 0.1696	0.0773 ± 0.1078	0.1686 ± 0.1286	0.0482 ± 0.0633		
3	0.3103 ± 0.4728	0.5153 ± 0.2836	21.8424 ± 5.5265	3.7474 ± 5.3514	0.1812 ± 0.1349	0.0510 ± 0.0703	0.1402 ± 0.1028	0.0324 ± 0.0454		
5	0.3379 ± 0.5019	0.5067 ± 0.2993	23.1269 ± 5.9630	3.4602 ± 5.0738	0.1596 ± 0.1276	0.0418 ± 0.0598	0.1230 ± 0.0961	0.0262 ± 0.0353		
6	0.3875 ± 0.5587	0.6003 ± 0.3017	23.7621 ± 5.8799	3.3270 ± 4.7582	0.1480 ± 0.1255	0.0377 ± 0.0592	0.1123 ± 0.1009	0.0245 ± 0.0389		
7	0.4062 ± 0.5738	0.5894 ± 0.3034	23.1963 ± 5.8500	3.7074 ± 5.1121	0.1588 ± 0.1303	0.0423 ± 0.0634	0.1219 ± 0.1072	0.0281 ± 0.0422		
8	0.4277 ± 0.5954	0.6062 ± 0.3019	23.4588 ± 5.7334	3.6602 ± 4.9305	0.1523 ± 0.1267	0.0392 ± 0.0602	0.1161 ± 0.1038	0.0259 ± 0.0402		
9	0.4597 ± 0.6326	0.6170 ± 0.3032	23.7271 ± 5.9535	3.6920 ± 4.7851	0.1496 ± 0.1282	0.0388 ± 0.0617	0.1137 ± 0.1057	0.0258 ± 0.0416		
10	0.4710 ± 0.6376	0.6196 ± 0.3024	23.6265 ± 5.6541	3.5661 ± 4.6835	0.1497 ± 0.1287	0.0390 ± 0.0642	0.1140 ± 0.1071	0.0261 ± 0.0442		
25	0.5940 ± 0.7516	0.6427 ± 0.2874	24.0134 ± 5.5123	3.9228 ± 5.5863	0.1397 ± 0.1154	0.0328 ± 0.0511	0.1047 ± 0.0960	0.0216 ± 0.0355		
-*50% - UNET										
-*75% - DDPM										
1	0.8453 ± 1.0611	0.8056 ± 0.1860	31.2168 ± 3.8920	1.2931 ± 2.8971	0.0463 ± 0.0499	0.0046 ± 0.0169	0.0278 ± 0.0250	0.0021 ± 0.0046		
2	0.3496 ± 0.5081	0.4084 ± 0.3132	19.3961 ± 5.7616	8.4047 ± 6.6645	0.2417 ± 0.2082	0.1017 ± 0.1730	0.1392 ± 0.1123	0.0359 ± 0.0682		
3	0.3683 ± 0.5377	0.4609 ± 0.3228	20.8505 ± 6.0019	8.0768 ± 8.0391	0.2055 ± 0.1756	0.0731 ± 0.1191	0.1154 ± 0.0888	0.0238 ± 0.0429		
3	0.4067 ± 0.5727	0.4711 ± 0.2544	20.7757 ± 5.3998	8.4574 ± 7.7372	0.1994 ± 0.1688	0.0683 ± 0.1151	0.1100 ± 0.0913	0.0226 ± 0.0511		
5	0.4635 ± 0.6344	0.4986 ± 0.2211	21.0508 ± 5.0835	8.4637 ± 4.7552	0.1889 ± 0.1574	0.0605 ± 0.1000	0.1025 ± 0.0887	0.0202 ± 0.0495		
6	0.4849 ± 0.6462	0.4937 ± 0.2076	20.8294 ± 4.9371	8.5852 ± 4.7366	0.1932 ± 0.1588	0.0626 ± 0.1029	0.1058 ± 0.0931	0.0216 ± 0.0533		
7	0.5074 ± 0.6676	0.5022 ± 0.2048	20.9976 ± 4.8988	8.6510 ± 4.7344	0.1890 ± 0.1564	0.0602 ± 0.0985	0.1018 ± 0.0894	0.0201 ± 0.0475		
8	0.5238 ± 0.6838	0.5011 ± 0.1907	20.8718 ± 4.7265	8.7488 ± 7.1645	0.1900 ± 0.1530	0.0595 ± 0.0951	0.1026 ± 0.0881	0.0200 ± 0.0475		
9	0.5409 ± 0.6978	0.4973 ± 0.1935	20.8818 ± 4.7916	8.7801 ± 7.1645	0.1904 ± 0.1532	0.0597 ± 0.0947	0.1024 ± 0.0867	0.0197 ± 0.0462		
10	0.5524 ± 0.7092	0.5041 ± 0.1832	20.9327 ± 4.6858	8.8070 ± 7.0151	0.1880 ± 0.1476	0.0571 ± 0.0869	0.1010 ± 0.0813	0.0185 ± 0.0396		
25	0.6761 ± 0.8221	0.5012 ± 0.1583	20.7147 ± 4.3701	9.6363 ± 6.8180	0.1895 ± 0.1422	0.0561 ± 0.0806	0.1005 ± 0.0806	0.0182 ± 0.0401		
1	0.8584 ± 1.0677	0.8109 ± 0.1912	31.7545 ± 4.1998	1.6973 ± 3.1909	0.0431 ± 0.0495	0.0043 ± 0.0177	0.0260 ± 0.0236	0.0019 ± 0.0035		
2	0.2707 ± 0.4282	0.7394 ± 0.2252	27.9364 ± 4.9054	1.0173 ± 3.5706	0.0761 ± 0.0799	0.0122 ± 0.0289	0.0513 ± 0.0560	0.0070 ± 0.0145		
3	0.3141 ± 0.4805	0.7571 ± 0.2108	29.0268 ± 4.5773	1.1185 ± 3.4951	0.0695 ± 0.0695	0.0097 ± 0.0227	0.0466 ± 0.0447	0.0052 ± 0.0100		
3	0.3562 ± 0.5232	0.7729 ± 0.2148	29.2705 ± 4.7941	1.1395 ± 3.4852	0.0655 ± 0.0695	0.0091 ± 0.0223	0.0434 ± 0.0463	0.0050 ± 0.0103		
5	0.4200 ± 0.5909	0.7810 ± 0.2137	29.4934 ± 4.8126	1.2624 ± 3.4979	0.0645 ± 0.0695	0.0090 ± 0.0220	0.0428 ± 0.0472	0.0050 ± 0.0102		
6	0.4445 ± 0.6154	0.7798 ± 0.2170	29.3962 ± 5.0791	1.4114 ± 3.6079	0.0674 ± 0.0734	0.0099 ± 0.0233	0.0456 ± 0.0523	0.0058 ± 0.0118		
7	0.4662 ± 0.6349	0.7801 ± 0.2161	29.4671 ± 5.0319	1.3916 ± 3.5263	0.0664 ± 0.0719	0.0098 ± 0.0226	0.0449 ± 0.0507	0.0056 ± 0.0113		
8	0.4841 ± 0.6533	0.7818 ± 0.2167	29.5699 ± 5.0655	1.3825 ± 3.5127	0.0658 ± 0.0718	0.0095 ± 0.0225	0.0447 ± 0.0505	0.0055 ± 0.0112		
9	0.5009 ± 0.6688	0.7832 ± 0.2161	29.6029 ± 5.0435	1.3818 ± 3.5026	0.0654 ± 0.0714	0.0094 ± 0.0223	0.0442 ± 0.0504	0.0055 ± 0.0109		
10	0.5149 ± 0.6815	0.7845 ± 0.2188	29.6919 ± 5.1347	1.3925 ± 3.4828	0.0652 ± 0.0723	0.0095 ± 0.0225	0.0440 ± 0.0516	0.0056 ± 0.0112		
25	0.6309 ± 0.7393	0.7912 ± 0.2184	29.9374 ± 5.3495	1.5683 ± 3.5613	0.0641 ± 0.0731	0.0095 ± 0.0222	0.0423 ± 0.0537	0.0056 ± 0.0117		
1	0.8589 ± 1.0662	0.8163 ± 0.1831	31.9258 ± 4.2065	1.4917 ± 2.2396	0.0414 ± 0.0475	0.0040 ± 0.0174	0.0237 ± 0.0195	0.0016 ± 0.0026		

Tabla 7.26: Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Log Scale. Conjunto de datos: Full.

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
-*10% - DDPM									
1	0.5968 ± 0.8641	0.6455 ± 0.2790	20.6010 ± 7.4515	12.5360 ± 7.9282	0.2407 ± 0.1671	0.0859 ± 0.1080	0.2066 ± 0.1217	0.0632 ± 0.0646	
2	0.3965 ± 0.7409	0.7049 ± 0.2016	20.4668 ± 6.2540	14.6848 ± 7.5567	0.2253 ± 0.1286	0.0673 ± 0.0686	0.1946 ± 0.0912	0.0500 ± 0.0410	
3	0.3006 ± 0.4100	0.7332 ± 0.1676	19.6332 ± 4.3058	15.8057 ± 6.8092	0.2286 ± 0.1096	0.0643 ± 0.0590	0.1978 ± 0.0738	0.0478 ± 0.0334	
5	0.2082 ± 0.2872	0.7710 ± 0.1351	19.6775 ± 3.7644	17.1603 ± 5.7614	0.2219 ± 0.0924	0.0578 ± 0.0471	0.1931 ± 0.0628	0.0439 ± 0.0275	
6	0.1857 ± 0.2542	0.7782 ± 0.1249	19.5128 ± 3.3831	17.5128 ± 5.8411	0.2233 ± 0.0873	0.0575 ± 0.0439	0.1941 ± 0.0508	0.0438 ± 0.0262	
7	0.1689 ± 0.2314	0.7846 ± 0.1183	19.5286 ± 3.5297	17.6420 ± 5.8844	0.2234 ± 0.0856	0.0572 ± 0.0419	0.1940 ± 0.0585	0.0435 ± 0.0251	
8	0.1553 ± 0.2181	0.7889 ± 0.1168	19.4611 ± 3.2260	17.8265 ± 5.7070	0.2233 ± 0.0826	0.0567 ± 0.0404	0.1937 ± 0.0550	0.0430 ± 0.0237	
9	0.1453 ± 0.2065	0.7908 ± 0.1175	19.4227 ± 3.1994	17.7201 ± 5.8176	0.2244 ± 0.0837	0.0573 ± 0.0416	0.1943 ± 0.0551	0.0432 ± 0.0241	
10	0.1373 ± 0.1982	0.7964 ± 0.1116	19.4168 ± 2.9766	18.0202 ± 5.6175	0.2230 ± 0.0796	0.0561 ± 0.0392	0.1930 ± 0.0525	0.0424 ± 0.0230	
25	0.0988 ± 0.1630	0.8116 ± 0.0553	19.0001 ± 2.0618	19.1630 ± 4.6348	0.2282 ± 0.0634	0.0561 ± 0.0306	0.1968 ± 0.0398	0.0425 ± 0.0169	
-*10% - UNET									
1	0.1275 ± 0.2151	0.9678 ± 0.0305	39.6252 ± 3.3639	0.2521 ± 0.3694	0.0177 ± 0.1613	0.0006 ± 0.0015	0.0241 ± 0.0126	0.0009 ± 0.0009	
1	0.1464 ± 0.2718	0.9176 ± 0.0834	29.7513 ± 6.7802	5.5713 ± 7.1653	0.0814 ± 0.0732	0.0120 ± 0.0211	0.0633 ± 0.0534	0.0074 ± 0.0123	
2	0.1064 ± 0.1778	0.9403 ± 0.0455	30.6759 ± 5.6127	5.8903 ± 6.7077	0.0662 ± 0.0499	0.0069 ± 0.0094	0.0493 ± 0.0332	0.0040 ± 0.0048	
3	0.0666 ± 0.1615	0.9505 ± 0.0391	32.1177 ± 5.6641	5.3072 ± 6.2535	0.0555 ± 0.0445	0.0051 ± 0.0075	0.0413 ± 0.0255	0.0027 ± 0.0031	
5	0.0558 ± 0.1640	0.9580 ± 0.0225	33.3191 ± 5.3479	4.8347 ± 6.0299	0.0475 ± 0.0392	0.0038 ± 0.0058	0.0349 ± 0.0223	0.0020 ± 0.0023	
6	0.0554 ± 0.1660	0.9590 ± 0.0318	33.0576 ± 5.1567	5.1511 ± 6.2679	0.0482 ± 0.0381	0.0038 ± 0.0055	0.0348 ± 0.0235	0.0020 ± 0.0026	
7	0.0559 ± 0.1675	0.9597 ± 0.0316	32.8606 ± 5.0527	5.3632 ± 6.4062	0.0491 ± 0.0372	0.0038 ± 0.0054	0.0348 ± 0.0236	0.0020 ± 0.0025	
8	0.0660 ± 0.1696	0.9613 ± 0.0310	33.0022 ± 4.7200	5.3010 ± 6.0880	0.0473 ± 0.0352	0.0035 ± 0.0048	0.0331 ± 0.0214	0.0018 ± 0.0021	
9	0.0660 ± 0.1716	0.9616 ± 0.0316	33.0840 ± 4.9738	5.5002 ± 6.1765	0.0473 ± 0.0357	0.0035 ± 0.0051	0.0329 ± 0.0209	0.0018 ± 0.0022	
10	0.0663 ± 0.1739	0.9624 ± 0.0318	33.0344 ± 4.4582	5.2443 ± 5.9635	0.0464 ± 0.0346	0.0033 ± 0.0049	0.0322 ± 0.0202	0.0017 ± 0.0022	
25	0.1037 ± 0.1868	0.9653 ± 0.0297	32.7511 ± 4.1771	5.6126 ± 5.8624	0.0468 ± 0.0300	0.0031 ± 0.0038	0.0306 ± 0.0176	0.0015 ± 0.0016	
-*25% - UNET									
1	0.1281 ± 0.2209	0.9723 ± 0.0286	40.9775 ± 3.6467	0.3231 ± 0.5544	0.0154 ± 0.0145	0.0004 ± 0.0010	0.0178 ± 0.0091	0.0005 ± 0.0006	
1	0.1506 ± 0.2466	0.9298 ± 0.0519	30.9022 ± 5.0242	3.4306 ± 4.4335	0.0623 ± 0.0463	0.0006 ± 0.0083	0.0508 ± 0.0365	0.0043 ± 0.0060	
2	0.1123 ± 0.1741	0.9456 ± 0.0362	31.7971 ± 5.1633	3.8741 ± 4.4021	0.0555 ± 0.0373	0.0045 ± 0.0053	0.0454 ± 0.0283	0.0032 ± 0.0035	
3	0.1006 ± 0.1607	0.9521 ± 0.0329	31.9189 ± 4.5957	3.9931 ± 4.2370	0.0535 ± 0.0343	0.0040 ± 0.0046	0.0430 ± 0.0258	0.0028 ± 0.0029	
5	0.0972 ± 0.1630	0.9577 ± 0.0306	32.1753 ± 4.0639	3.7873 ± 3.9484	0.0506 ± 0.0300	0.0030 ± 0.0039	0.0414 ± 0.0235	0.0025 ± 0.0024	
6	0.0965 ± 0.1656	0.9586 ± 0.0307	31.9605 ± 3.8941	4.0575 ± 4.2856	0.0515 ± 0.0294	0.0035 ± 0.0036	0.0423 ± 0.0235	0.0025 ± 0.0025	
7	0.0968 ± 0.1678	0.9595 ± 0.0307	32.0068 ± 3.9015	4.1022 ± 4.2466	0.0514 ± 0.0296	0.0035 ± 0.0036	0.0421 ± 0.0235	0.0025 ± 0.0024	
8	0.0969 ± 0.1701	0.9604 ± 0.0301	32.0515 ± 3.7765	4.0201 ± 4.1077	0.0508 ± 0.0285	0.0034 ± 0.0034	0.0414 ± 0.0223	0.0024 ± 0.0022	
9	0.0968 ± 0.1720	0.9607 ± 0.0306	32.0273 ± 3.7383	4.3302 ± 4.3104	0.0509 ± 0.0285	0.0034 ± 0.0035	0.0413 ± 0.0223	0.0024 ± 0.0022	
10	0.0975 ± 0.1746	0.9616 ± 0.0301	32.0244 ± 3.4943	4.1847 ± 4.1951	0.0503 ± 0.0273	0.0033 ± 0.0033	0.0407 ± 0.0219	0.0023 ± 0.0022	
25	0.1049 ± 0.1895	0.9635 ± 0.0298	31.6637 ± 2.8069	4.4494 ± 4.0214	0.0515 ± 0.0251	0.0033 ± 0.0029	0.0414 ± 0.0208	0.0023 ± 0.0020	
-*50% - UNET									
1	0.1276 ± 0.2207	0.9721 ± 0.0293	40.9860 ± 4.0137	0.4565 ± 0.8113	0.0159 ± 0.0153	0.0005 ± 0.0012	0.0187 ± 0.0109	0.0006 ± 0.0007	
1	0.4401 ± 0.2644	0.7843 ± 0.1569	23.4793 ± 6.7852	12.5433 ± 7.6626	0.1610 ± 0.1099	0.0380 ± 0.0469	0.1092 ± 0.0746	0.0200 ± 0.0251	
2	0.2854 ± 0.3862	0.8380 ± 0.0877	22.7756 ± 4.7138	14.7032 ± 6.7430	0.1574 ± 0.0818	0.0314 ± 0.0296	0.1059 ± 0.0555	0.0160 ± 0.0154	
3	0.2194 ± 0.2935	0.8602 ± 0.0634	22.0045 ± 2.9674	16.2403 ± 5.4333	0.1603 ± 0.0697	0.0306 ± 0.0248	0.1071 ± 0.0471	0.0153 ± 0.0127	
5	0.1606 ± 0.2214	0.8855 ± 0.0477	22.3272 ± 2.6491	16.7394 ± 5.1716	0.1562 ± 0.0620	0.0283 ± 0.0208	0.1045 ± 0.0426	0.0141 ± 0.0106	
6	0.1452 ± 0.2016	0.8899 ± 0.0442	22.1670 ± 2.6961	16.9864 ± 5.4590	0.1577 ± 0.0614	0.0286 ± 0.0203	0.1058 ± 0.0441	0.0145 ± 0.0113	
7	0.1339 ± 0.1908	0.8944 ± 0.0328	22.1934 ± 2.7385	17.2323 ± 5.4836	0.1574 ± 0.0614	0.0286 ± 0.0200	0.1054 ± 0.0438	0.0143 ± 0.0109	
8	0.1256 ± 0.1814	0.8979 ± 0.0410	22.1701 ± 2.5031	17.4042 ± 5.1097	0.1568 ± 0.0590	0.0281 ± 0.0192	0.1048 ± 0.0421	0.0140 ± 0.0105	
9	0.1192 ± 0.1751	0.8999 ± 0.0411	22.1192 ± 2.4078	17.4033 ± 5.1747	0.1574 ± 0.0585	0.0282 ± 0.0192	0.1050 ± 0.0413	0.0140 ± 0.0104	
10	0.1152 ± 0.1723	0.9026 ± 0.0384	22.1127 ± 2.2690	17.3983 ± 5.1925	0.1570 ± 0.0574	0.0279 ± 0.0187	0.1044 ± 0.0416	0.0139 ± 0.0105	
25	0.0957 ± 0.1646	0.9122 ± 0.0352	21.8483 ± 1.8342	18.3128 ± 4.4792	0.1604 ± 0.0527	0.0285 ± 0.0166	0.1066 ± 0.0400	0.0142 ± 0.0100	
-*75% - UNET									
1	0.1377 ± 0.2349	0.9730 ± 0.0291	41.4037 ± 3.8644	0.4061 ± 0.6829	0.0156 ± 0.0144	0.0005 ± 0.0011	0.0234 ± 0.0141	0.0009 ± 0.0011	
1	0.0915 ± 0.1468	0.9547 ± 0.0309	38.3239 ± 3.7778	0.2772 ± 0.4760	0.0216 ± 0.0184	0.0006 ± 0.0016	0.0226 ± 0.0135	0.0010 ± 0.0010	
2	0.0778 ± 0.1352	0.9619 ± 0.0344	39.1855 ± 3.8337	0.3387 ± 0.6258	0.0196 ± 0.0175	0.0007 ± 0.0015	0.0234 ± 0.0141	0.0009 ± 0.0011	
3	0.0767 ± 0.1422	0.9656 ± 0.0328	39.8605 ± 3.8760	0.3341 ± 0.5658	0.0181 ± 0.0161	0.0006 ± 0.0013	0.0221 ± 0.0132	0.0006 ± 0.0009	
5	0.0819 ± 0.1543	0.9683 ± 0.0313	40.1307 ± 3.5370	0.3761 ± 0.6341	0.0172 ± 0.0155	0.0005 ± 0.0012	0.0211 ± 0.0125	0.0006 ± 0.0009	
6	0.0843 ± 0.1592	0.9690 ± 0.0309	40.2032 ± 3.6004	0.4055 ± 0.6579	0.0172 ± 0.0155	0.0005 ± 0.0012	0.0209 ± 0.0123	0.0007 ± 0.0008	
7	0.0866 ± 0.1630	0.9695 ± 0.0306	40.2785 ± 3.6198	0.4211 ± 0.6721	0.0170 ± 0.0155	0.0005 ± 0.0012	0.0207 ± 0.0119	0.0007 ± 0.0008	
8	0.0884 ± 0.1662	0.9699 ± 0.0303	40.3713 ± 3.6269	0.4188 ± 0.6716	0.0168 ± 0.0154	0.0005 ± 0.0011	0.0204 ± 0.0116	0.0007 ± 0.0008	
9	0.0902 ± 0.1691	0.9702 ± 0.0306	40.4388 ± 3.6900	0.4289 ± 0.6836	0.0167 ± 0.0154	0.0005 ± 0.0011	0.0204 ± 0.0117	0.0007 ± 0.0008	
10	0.0919 ± 0.1721	0.9706 ± 0.0299	40.5072 ± 3.6244	0.4353 ± 0.6749	0.0165 ± 0.0149	0.0005 ± 0.0011	0.0206 ± 0.0111	0.0007 ± 0.0007	
25	0.1055 ± 0.1914	0.9719 ± 0.0294	40.6579 ± 3.4127	0.4850 ± 0.6633	0.0161 ± 0.0144	0.0005 ± 0.0010	0.0198 ± 0.0106	0.0006 ± 0.0007	
-*100% - DDPM									
1	0.1273 ± 0.2223	0.9730 ± 0.0286	41.2363 ± 3.9788	0.2908 ± 0.5510	0.0154 ± 0.0142	0.0004 ± 0.0010	0.0172 ± 0.0092	0.0005 ± 0.0005	

Tabla 7.27: Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Sqrt Scale. Conjunto de datos: Clean 30.

Experiment	Aggregation	FFT	MSI ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
*10% - DDPM										
1	0.2337 ± 0.4153	0.7388 ± 0.3028	24.2048 ± 7.6804	10.1420 ± 8.8887	0.1629 ± 0.1357	0.0449 ± 0.0660	0.1337 ± 0.1052	0.0325 ± 0.0428		
2	0.2100 ± 0.4009	0.7673 ± 0.2891	24.7039 ± 7.4593	11.2617 ± 8.1610	0.1496 ± 0.1157	0.0358 ± 0.0496	0.1221 ± 0.0860	0.0252 ± 0.0288		
3	0.2143 ± 0.4286	0.7829 ± 0.2849	24.6307 ± 6.7631	11.9268 ± 8.6099	0.1442 ± 0.1082	0.0325 ± 0.0465	0.1171 ± 0.0828	0.0231 ± 0.0283		
5	0.2290 ± 0.4820	0.7994 ± 0.2791	24.4684 ± 5.7797	12.6313 ± 7.9400	0.1379 ± 0.0956	0.0282 ± 0.0412	0.1112 ± 0.0731	0.0200 ± 0.0249		
6	0.2395 ± 0.5051	0.8035 ± 0.2708	24.2346 ± 5.5193	13.0108 ± 7.7651	0.1393 ± 0.0916	0.0278 ± 0.0385	0.1126 ± 0.0712	0.0200 ± 0.0232		
7	0.2466 ± 0.5240	0.8042 ± 0.2710	24.2684 ± 5.3271	13.0238 ± 7.7613	0.1379 ± 0.0906	0.0272 ± 0.0384	0.1113 ± 0.0694	0.0194 ± 0.0229		
8	0.2514 ± 0.5364	0.8046 ± 0.2739	24.0507 ± 4.9600	13.1449 ± 7.5436	0.1380 ± 0.0881	0.0271 ± 0.0378	0.1119 ± 0.0672	0.0192 ± 0.0222		
9	0.2570 ± 0.5484	0.8041 ± 0.2753	23.9977 ± 4.9010	13.5379 ± 7.5086	0.1393 ± 0.0874	0.0270 ± 0.0375	0.1120 ± 0.0667	0.0192 ± 0.0218		
10	0.2626 ± 0.5616	0.8073 ± 0.2723	24.0175 ± 4.6475	13.4586 ± 7.1627	0.1371 ± 0.0841	0.0259 ± 0.0361	0.1100 ± 0.0635	0.0182 ± 0.0208		
25	0.3055 ± 0.6510	0.8094 ± 0.2711	23.4109 ± 3.5941	14.5712 ± 6.8126	0.1411 ± 0.0777	0.0269 ± 0.0346	0.1126 ± 0.0588	0.0182 ± 0.0200		
*10% - UNET										
*25% - DDPM										
1	0.1504 ± 0.3267	0.8652 ± 0.2311	37.1167 ± 6.7552	0.4884 ± 1.1875	0.0318 ± 0.0464	0.0032 ± 0.0130	0.0314 ± 0.0306	0.0029 ± 0.0055		
2	0.1667 ± 0.3552	0.8691 ± 0.2270	37.6342 ± 7.0291	0.5467 ± 1.1187	0.0308 ± 0.0472	0.0032 ± 0.0128	0.0298 ± 0.0325	0.0028 ± 0.0059		
3	0.1768 ± 0.3706	0.8717 ± 0.2244	38.1080 ± 7.3238	0.5383 ± 1.1143	0.0298 ± 0.0461	0.0031 ± 0.0126	0.0288 ± 0.0325	0.0027 ± 0.0058		
5	0.1904 ± 0.3955	0.8733 ± 0.2216	38.7558 ± 7.2569	0.5482 ± 1.1027	0.0291 ± 0.0462	0.0030 ± 0.0123	0.0280 ± 0.0321	0.0027 ± 0.0057		
6	0.1944 ± 0.4022	0.8743 ± 0.2201	38.8298 ± 7.2506	0.6265 ± 1.2349	0.0288 ± 0.0453	0.0029 ± 0.0120	0.0274 ± 0.0310	0.0025 ± 0.0053		
7	0.1973 ± 0.4076	0.8746 ± 0.2199	38.3504 ± 7.2726	0.5774 ± 1.1218	0.0289 ± 0.0455	0.0029 ± 0.0120	0.0274 ± 0.0312	0.0025 ± 0.0053		
8	0.1999 ± 0.4121	0.8748 ± 0.2195	38.3751 ± 7.2484	0.5685 ± 1.1022	0.0287 ± 0.0455	0.0029 ± 0.0120	0.0274 ± 0.0310	0.0025 ± 0.0053		
9	0.2017 ± 0.4152	0.8750 ± 0.2193	38.7593 ± 7.2529	0.5794 ± 1.1263	0.0287 ± 0.0454	0.0029 ± 0.0119	0.0273 ± 0.0310	0.0025 ± 0.0053		
10	0.2040 ± 0.4198	0.8753 ± 0.2186	38.3984 ± 7.2129	0.5793 ± 1.1293	0.0286 ± 0.0451	0.0028 ± 0.0118	0.0271 ± 0.0307	0.0025 ± 0.0052		
25	0.2165 ± 0.4540	0.8760 ± 0.2174	38.1769 ± 7.2230	0.6652 ± 1.2105	0.0283 ± 0.0458	0.0028 ± 0.0115	0.0270 ± 0.0307	0.0025 ± 0.0051		
1	0.4023 ± 0.8625	0.8892 ± 0.1991	38.1193 ± 6.9544	1.1160 ± 3.9461	0.0313 ± 0.0505	0.0036 ± 0.0146	0.0304 ± 0.0380	0.0032 ± 0.0083		
2	0.1667 ± 0.3622	0.8694 ± 0.2255	37.7124 ± 7.1511	0.5493 ± 1.2239	0.0300 ± 0.0455	0.0035 ± 0.0160	0.0325 ± 0.0429	0.0041 ± 0.0155		
3	0.1991 ± 0.4272	0.8765 ± 0.2153	37.5771 ± 7.0068	0.6862 ± 1.2062	0.0302 ± 0.0465	0.0031 ± 0.0147	0.0293 ± 0.0401	0.0035 ± 0.0141		
5	0.2181 ± 0.4611	0.8791 ± 0.2110	38.5065 ± 7.3539	0.6933 ± 1.1716	0.0284 ± 0.0441	0.0028 ± 0.0112	0.0273 ± 0.0331	0.0027 ± 0.0069		
6	0.2507 ± 0.5242	0.8809 ± 0.2082	38.7095 ± 7.3510	0.7328 ± 1.2089	0.0287 ± 0.0436	0.0027 ± 0.0109	0.0269 ± 0.0334	0.0026 ± 0.0068		
7	0.2625 ± 0.5480	0.8811 ± 0.2082	38.5390 ± 7.2793	0.8016 ± 0.9363	0.0285 ± 0.0455	0.0028 ± 0.0121	0.0278 ± 0.0363	0.0030 ± 0.0093		
7	0.2703 ± 0.5626	0.8822 ± 0.2058	38.5932 ± 7.2711	0.8678 ± 1.3387	0.0281 ± 0.0437	0.0027 ± 0.0111	0.0271 ± 0.0335	0.0026 ± 0.0072		
8	0.2771 ± 0.5767	0.8829 ± 0.2042	38.6687 ± 7.2564	0.8076 ± 1.0381	0.0277 ± 0.0430	0.0026 ± 0.0106	0.0265 ± 0.0317	0.0024 ± 0.0061		
9	0.2825 ± 0.5864	0.8832 ± 0.2029	38.7541 ± 7.2482	0.7932 ± 0.9756	0.0273 ± 0.0419	0.0025 ± 0.0102	0.0261 ± 0.0300	0.0023 ± 0.0053		
10	0.2890 ± 0.6002	0.8833 ± 0.2034	38.7736 ± 7.2853	0.8639 ± 1.0981	0.0274 ± 0.0424	0.0026 ± 0.0104	0.0263 ± 0.0313	0.0024 ± 0.0060		
25	0.3357 ± 0.6966	0.8840 ± 0.2030	38.8049 ± 7.3248	1.1399 ± 1.1747	0.0279 ± 0.0445	0.0028 ± 0.0116	0.0268 ± 0.0353	0.0027 ± 0.0086		
*50% - UNET										
*50% - DDPM										
1	0.4074 ± 0.8660	0.8840 ± 0.2033	38.9713 ± 7.3424	1.3836 ± 2.5577	0.0271 ± 0.0418	0.0025 ± 0.0101	0.0267 ± 0.0283	0.0022 ± 0.0043		
1	0.1531 ± 0.3316	0.8682 ± 0.2261	37.1598 ± 6.7757	0.4622 ± 1.1229	0.0316 ± 0.0448	0.0030 ± 0.0116	0.0290 ± 0.0287	0.0025 ± 0.0047		
2	0.1805 ± 0.3877	0.8761 ± 0.2143	37.5571 ± 6.7726	0.6493 ± 1.1524	0.0299 ± 0.0421	0.0027 ± 0.0103	0.0266 ± 0.0266	0.0021 ± 0.0040		
3	0.2015 ± 0.4283	0.8785 ± 0.2109	37.7610 ± 6.7507	0.7660 ± 1.2158	0.0294 ± 0.0423	0.0027 ± 0.0103	0.0260 ± 0.0263	0.0021 ± 0.0039		
5	0.2320 ± 0.4856	0.8818 ± 0.2053	37.9268 ± 6.5775	0.9192 ± 1.4057	0.0284 ± 0.0404	0.0025 ± 0.0098	0.0250 ± 0.0256	0.0019 ± 0.0036		
6	0.2435 ± 0.5100	0.8822 ± 0.2036	37.9241 ± 6.5159	1.0137 ± 1.5880	0.0282 ± 0.0399	0.0024 ± 0.0096	0.0247 ± 0.0248	0.0019 ± 0.0034		
7	0.2522 ± 0.5251	0.8832 ± 0.2030	38.0112 ± 6.6046	1.0292 ± 1.5803	0.0281 ± 0.0401	0.0024 ± 0.0096	0.0245 ± 0.0251	0.0019 ± 0.0034		
8	0.2604 ± 0.5430	0.8830 ± 0.2022	38.0613 ± 6.6132	1.0784 ± 1.6926	0.0280 ± 0.0404	0.0024 ± 0.0095	0.0244 ± 0.0249	0.0018 ± 0.0034		
9	0.2667 ± 0.5548	0.8830 ± 0.2015	38.0850 ± 6.5976	1.0783 ± 1.6952	0.0278 ± 0.0397	0.0024 ± 0.0095	0.0243 ± 0.0247	0.0018 ± 0.0033		
10	0.2730 ± 0.5684	0.8842 ± 0.2010	38.0891 ± 6.5898	1.1464 ± 1.8134	0.0278 ± 0.0395	0.0023 ± 0.0094	0.0242 ± 0.0247	0.0018 ± 0.0033		
25	0.3216 ± 0.6661	0.8852 ± 0.1993	38.0796 ± 6.5744	1.4210 ± 2.2858	0.0279 ± 0.0393	0.0023 ± 0.0094	0.0242 ± 0.0249	0.0018 ± 0.0034		
1	0.3883 ± 0.8333	0.8860 ± 0.1997	38.4214 ± 6.9857	1.2962 ± 3.0177	0.0276 ± 0.0424	0.0026 ± 0.0103	0.0277 ± 0.0272	0.0022 ± 0.0042		
2	0.3256 ± 0.4755	0.7233 ± 0.2337	27.4745 ± 5.6341	2.1895 ± 5.3007	0.0899 ± 0.1235	0.0233 ± 0.0909	0.0576 ± 0.0982	0.0141 ± 0.0686		
3	0.4416 ± 0.5887	0.7447 ± 0.1994	27.7563 ± 4.7419	2.3121 ± 4.7343	0.0820 ± 0.1033	0.0174 ± 0.0617	0.0527 ± 0.0847	0.0108 ± 0.0491		
5	0.5105 ± 0.6581	0.7571 ± 0.1929	28.0033 ± 4.6011	2.5585 ± 4.9874	0.0797 ± 0.1054	0.0175 ± 0.0658	0.0517 ± 0.0890	0.0114 ± 0.0548		
6	0.5368 ± 0.6829	0.7574 ± 0.2014	27.7737 ± 4.7834	2.7485 ± 5.2903	0.0851 ± 0.1213	0.0220 ± 0.0886	0.0562 ± 0.1068	0.0154 ± 0.0781		
7	0.5565 ± 0.6994	0.7575 ± 0.1948	27.8824 ± 4.7541	2.7765 ± 5.2078	0.0829 ± 0.1151	0.0201 ± 0.0809	0.0544 ± 0.1012	0.0139 ± 0.0726		
8	0.5736 ± 0.7159	0.7575 ± 0.1997	28.0398 ± 4.8186	2.7770 ± 5.1519	0.0821 ± 0.1186	0.0208 ± 0.0870	0.0543 ± 0.1053	0.0148 ± 0.0780		
9	0.5891 ± 0.7305	0.7580 ± 0.1952	28.0027 ± 4.7152	2.8164 ± 5.1110	0.0813 ± 0.1139	0.0186 ± 0.0796	0.0535 ± 0.1001	0.0137 ± 0.0707		
10	0.6011 ± 0.7414	0.7617 ± 0.1915	28.0370 ± 4.5380	2.7808 ± 4.9919	0.0795 ± 0.1081	0.0186 ± 0.0719	0.0520 ± 0.0946	0.0124 ± 0.0644		
25	0.7067 ± 0.8495	0.7533 ± 0.2066	27.7055 ± 4.5025	3.2642 ± 5.1509	0.0847 ± 0.1266	0.0232 ± 0.1082	0.0561 ± 0.1155	0.0172 ± 0.1011		
*100% - UNET										
1	0.4139 ± 0.8783	0.8859 ± 0.1947	38.9404 ± 6.6994	1.1096 ± 2.0748	0.0253 ± 0.0368	0.0020 ± 0.0085	0.0244 ± 0.0218	0.0016 ± 0.0028		

Tabla 7.28: Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Sqrt Scale. Conjunto de datos: Full.

Experiment	Aggregation	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
-*10% - DDPM										
1	0.3847 ± 0.7524	0.8874 ± 0.1688	33.4711 ± 9.2080	4.4361 ± 6.7048	0.0692 ± 0.0839	0.0118 ± 0.0267	0.0742 ± 0.0764	0.0125 ± 0.0229		
2	0.2804 ± 0.4819	0.9194 ± 0.0948	32.9273 ± 8.5136	6.7040 ± 8.9027	0.0651 ± 0.0622	0.0081 ± 0.0137	0.0700 ± 0.0566	0.0088 ± 0.0122		
3	0.2122 ± 0.3433	0.9404 ± 0.0571	32.3171 ± 7.5081	9.4520 ± 10.5392	0.0639 ± 0.0521	0.0068 ± 0.0094	0.0683 ± 0.0480	0.0075 ± 0.0087		
5	0.1496 ± 0.2436	0.9579 ± 0.0354	32.2947 ± 7.2403	13.0377 ± 11.6367	0.0630 ± 0.0481	0.0063 ± 0.0081	0.0673 ± 0.0453	0.0070 ± 0.0077		
6	0.1369 ± 0.2179	0.9604 ± 0.0323	32.0049 ± 7.1541	13.9362 ± 11.8729	0.0648 ± 0.0481	0.0065 ± 0.0081	0.0691 ± 0.0457	0.0072 ± 0.0079		
7	0.1219 ± 0.1985	0.9638 ± 0.0294	32.0006 ± 7.1617	14.3675 ± 11.7595	0.0651 ± 0.0481	0.0066 ± 0.0082	0.0692 ± 0.0461	0.0073 ± 0.0080		
8	0.1083 ± 0.1755	0.9674 ± 0.0251	32.0534 ± 6.9404	14.2886 ± 11.7878	0.0638 ± 0.0467	0.0063 ± 0.0076	0.0681 ± 0.0446	0.0069 ± 0.0074		
9	0.0992 ± 0.1580	0.9696 ± 0.0222	31.9451 ± 6.7894	14.3754 ± 11.7709	0.0638 ± 0.0454	0.0061 ± 0.0074	0.0680 ± 0.0435	0.0068 ± 0.0073		
10	0.0917 ± 0.1460	0.9714 ± 0.0209	31.9289 ± 6.7396	14.9646 ± 11.7265	0.0637 ± 0.0450	0.0061 ± 0.0072	0.0679 ± 0.0431	0.0068 ± 0.0072		
25	0.0507 ± 0.0796	0.9798 ± 0.0111	31.4873 ± 6.7787	17.0855 ± 11.7166	0.0669 ± 0.0440	0.0064 ± 0.0067	0.0709 ± 0.0425	0.0071 ± 0.0068		
-*10% - UNET										
1	0.1871 ± 0.3308	0.9507 ± 0.0504	35.1081 ± 7.3113	3.8096 ± 5.5604	0.0443 ± 0.0388	0.0035 ± 0.0063	0.0436 ± 0.0321	0.0035 ± 0.0050		
2	0.1289 ± 0.2333	0.9674 ± 0.0261	32.7923 ± 5.1934	5.7181 ± 7.2083	0.0453 ± 0.0283	0.0028 ± 0.0036	0.0436 ± 0.0236	0.0029 ± 0.0028		
3	0.0877 ± 0.1346	0.9769 ± 0.0150	33.6746 ± 3.8660	7.0041 ± 8.2886	0.0436 ± 0.0228	0.0024 ± 0.0026	0.0413 ± 0.0195	0.0024 ± 0.0021		
5	0.0567 ± 0.0862	0.9837 ± 0.0094	33.7954 ± 3.3448	8.9355 ± 9.0170	0.0422 ± 0.0186	0.0021 ± 0.0019	0.0399 ± 0.0170	0.0021 ± 0.0016		
6	0.0506 ± 0.0777	0.9846 ± 0.0088	33.5824 ± 3.1663	10.7758 ± 9.7630	0.0432 ± 0.0187	0.0022 ± 0.0020	0.0409 ± 0.0178	0.0022 ± 0.0018		
7	0.0444 ± 0.0690	0.9857 ± 0.0084	33.6879 ± 3.3072	10.2866 ± 9.2192	0.0429 ± 0.0184	0.0022 ± 0.0019	0.0406 ± 0.0177	0.0022 ± 0.0017		
8	0.0393 ± 0.0618	0.9867 ± 0.0088	33.7241 ± 3.0380	11.0762 ± 9.2231	0.0424 ± 0.0174	0.0021 ± 0.0018	0.0401 ± 0.0170	0.0021 ± 0.0016		
9	0.0362 ± 0.0577	0.9873 ± 0.0079	33.7318 ± 3.0434	12.7032 ± 10.0225	0.0424 ± 0.0175	0.0021 ± 0.0018	0.0400 ± 0.0171	0.0021 ± 0.0017		
10	0.0336 ± 0.0540	0.9870 ± 0.0077	33.6978 ± 2.8586	13.2328 ± 10.2338	0.0423 ± 0.0166	0.0021 ± 0.0017	0.0398 ± 0.0167	0.0021 ± 0.0016		
25	0.0197 ± 0.0403	0.9905 ± 0.0073	33.3891 ± 2.2487	16.9425 ± 0.0412	0.0432 ± 0.0138	0.0021 ± 0.0013	0.0402 ± 0.0147	0.0020 ± 0.0013		
-*25% - UNET										
1	0.1222 ± 0.3533	0.9944 ± 0.0066	46.7535 ± 4.0824	0.0653 ± 0.0523	0.0065 ± 0.0099	0.0001 ± 0.0010	0.0143 ± 0.0095	0.0005 ± 0.0008		
2	0.0912 ± 0.2927	0.9949 ± 0.0057	43.9260 ± 4.4515	1.7119 ± 0.3742	0.0115 ± 0.0127	0.0003 ± 0.0014	0.0203 ± 0.0115	0.0008 ± 0.0009		
3	0.0810 ± 0.2070	0.9943 ± 0.0058	43.9159 ± 4.2642	1.3275 ± 0.1973	0.0109 ± 0.0112	0.0002 ± 0.0011	0.0191 ± 0.0107	0.0007 ± 0.0008		
5	0.0610 ± 0.1642	0.9942 ± 0.0055	43.6879 ± 4.4715	4.7459 ± 0.0859	0.0058 ± 0.0058	0.0098 ± 0.0106	0.0022 ± 0.0020	0.0178 ± 0.0104	0.0006 ± 0.0008	
6	0.0598 ± 0.1623	0.9949 ± 0.0055	45.0838 ± 4.1210	0.0799 ± 0.0537	0.0092 ± 0.0099	0.0002 ± 0.0009	0.0169 ± 0.0096	0.0006 ± 0.0007		
7	0.0507 ± 0.1624	0.9949 ± 0.0055	45.2333 ± 4.0534	0.0781 ± 0.0607	0.0091 ± 0.0096	0.0006 ± 0.0002	0.0168 ± 0.0096	0.0006 ± 0.0007		
8	0.0496 ± 0.1624	0.9949 ± 0.0055	45.4926 ± 4.1048	0.0743 ± 0.0524	0.0088 ± 0.0094	0.0002 ± 0.0009	0.0163 ± 0.0088	0.0005 ± 0.0006		
9	0.0496 ± 0.1625	0.9950 ± 0.0054	45.4979 ± 4.1393	0.0771 ± 0.0545	0.0088 ± 0.0094	0.0002 ± 0.0008	0.0162 ± 0.0088	0.0005 ± 0.0006		
10	0.0495 ± 0.1626	0.9950 ± 0.0054	45.6204 ± 4.0815	0.0723 ± 0.0455	0.0086 ± 0.0092	0.0002 ± 0.0008	0.0159 ± 0.0084	0.0005 ± 0.0006		
25	0.0093 ± 0.0268	0.9953 ± 0.0055	45.8007 ± 3.7555	0.0712 ± 0.0571	0.0084 ± 0.0088	0.0001 ± 0.0008	0.0154 ± 0.0080	0.0005 ± 0.0006		
-*50% - UNET										
1	0.0123 ± 0.3661	0.9947 ± 0.0057	47.0599 ± 4.0809	0.0781 ± 0.1170	0.0063 ± 0.0013	0.0001 ± 0.0011	0.0133 ± 0.0078	0.0004 ± 0.0006		
1	0.0244 ± 0.4442	0.9917 ± 0.0070	44.1269 ± 3.7962	1.1882 ± 0.1558	0.0097 ± 0.0114	0.0002 ± 0.0017	0.0175 ± 0.0093	0.0007 ± 0.0010		
2	0.0168 ± 0.2037	0.9930 ± 0.0066	45.0634 ± 4.0170	1.0117 ± 0.1143	0.0086 ± 0.0105	0.0002 ± 0.0013	0.0157 ± 0.0094	0.0006 ± 0.0009		
3	0.0130 ± 0.2072	0.9937 ± 0.0064	45.5917 ± 4.0710	0.0975 ± 0.1075	0.0079 ± 0.0105	0.0002 ± 0.0013	0.0152 ± 0.0095	0.0006 ± 0.0010		
5	0.0109 ± 0.2060	0.9943 ± 0.0065	46.1642 ± 4.1528	0.0864 ± 0.1011	0.0074 ± 0.0100	0.0002 ± 0.0012	0.0143 ± 0.0094	0.0005 ± 0.0009		
6	0.0104 ± 0.2054	0.9943 ± 0.0065	46.1984 ± 4.2500	0.0898 ± 0.1068	0.0074 ± 0.0100	0.0002 ± 0.0011	0.0143 ± 0.0094	0.0005 ± 0.0009		
7	0.0101 ± 0.2053	0.9944 ± 0.0065	46.3137 ± 4.2923	0.0871 ± 0.1130	0.0073 ± 0.0109	0.0002 ± 0.0011	0.0142 ± 0.0095	0.0005 ± 0.0009		
8	0.0098 ± 0.2053	0.9945 ± 0.0065	46.4253 ± 4.3053	0.0878 ± 0.1131	0.0072 ± 0.0109	0.0001 ± 0.0011	0.0141 ± 0.0095	0.0005 ± 0.0009		
9	0.0097 ± 0.2055	0.9946 ± 0.0065	46.5623 ± 4.4313	0.0912 ± 0.1195	0.0071 ± 0.0099	0.0001 ± 0.0011	0.0140 ± 0.0094	0.0005 ± 0.0009		
10	0.0095 ± 0.2055	0.9946 ± 0.0065	46.6605 ± 4.4425	0.0887 ± 0.1164	0.0070 ± 0.0099	0.0001 ± 0.0011	0.0138 ± 0.0094	0.0005 ± 0.0009		
25	0.0090 ± 0.2060	0.9949 ± 0.0064	46.8800 ± 4.3622	0.0911 ± 0.1149	0.0068 ± 0.0096	0.0001 ± 0.0011	0.0133 ± 0.0092	0.0005 ± 0.0009		
-*75% - UNET										
1	0.0119 ± 0.3557	0.9955 ± 0.0054	48.3788 ± 4.5083	0.0605 ± 0.0381	0.0051 ± 0.0087	0.0001 ± 0.0009	0.0121 ± 0.0082	0.0004 ± 0.0006		
1	0.0285 ± 0.6266	0.9906 ± 0.0078	41.4484 ± 5.4121	4.7349 ± 1.3756	0.0169 ± 0.0164	0.0006 ± 0.0021	0.0226 ± 0.0141	0.0011 ± 0.0011		
2	0.0199 ± 0.3593	0.9924 ± 0.0065	41.4953 ± 4.5934	0.6201 ± 1.1815	0.0166 ± 0.0137	0.0005 ± 0.0013	0.0222 ± 0.0120	0.0009 ± 0.0010		
3	0.0147 ± 0.3003	0.9935 ± 0.0061	42.3055 ± 4.3994	0.4281 ± 0.8107	0.0147 ± 0.0121	0.0004 ± 0.0011	0.0199 ± 0.0108	0.0007 ± 0.0009		
5	0.0122 ± 0.2866	0.9943 ± 0.0057	42.7207 ± 3.8310	0.2676 ± 0.5094	0.0137 ± 0.0104	0.0003 ± 0.0009	0.0187 ± 0.0096	0.0006 ± 0.0007		
6	0.0116 ± 0.2820	0.9944 ± 0.0057	42.7216 ± 4.0394	0.3235 ± 0.7444	0.0139 ± 0.0106	0.0003 ± 0.0009	0.0189 ± 0.0098	0.0006 ± 0.0007		
7	0.0112 ± 0.2881	0.9945 ± 0.0057	42.8083 ± 4.1063	0.2815 ± 0.6213	0.0137 ± 0.0104	0.0003 ± 0.0009	0.0186 ± 0.0094	0.0006 ± 0.0007		
8	0.0109 ± 0.2879	0.9946 ± 0.0057	43.0765 ± 4.0510	0.2523 ± 0.5506	0.0133 ± 0.0101	0.0003 ± 0.0009	0.0182 ± 0.0089	0.0006 ± 0.0007		
9	0.0107 ± 0.2878	0.9947 ± 0.0057	43.1037 ± 4.0726	0.2811 ± 0.6740	0.0133 ± 0.0102	0.0003 ± 0.0009	0.0182 ± 0.0090	0.0006 ± 0.0007		
10	0.0105 ± 0.2877	0.9947 ± 0.0057	43.1173 ± 3.8512	0.2447 ± 0.5784	0.0132 ± 0.0099	0.0003 ± 0.0009	0.0179 ± 0.0086	0.0006 ± 0.0007		
25	0.0098 ± 0.2874	0.9951 ± 0.0065	42.9917 ± 3.2358	0.1879 ± 0.2855	0.0133 ± 0.0088	0.0003 ± 0.0008	0.0173 ± 0.0077	0.0005 ± 0.0006		
-*100% - UNET										
1	0.0148 ± 0.0670	0.9941 ± 0.0061	46.3564 ± 3.4079	0.0776 ± 0.0465	0.0076 ± 0.0095	0.0001 ± 0.0009	0.0137 ± 0.0081	0.0005 ± 0.0006		

Tabla 7.29: Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Linear Scale. Conjunto de datos: Clean 30.

Experiment	Aggregation	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>*10 % - DDPM</i>										
1	0.0775 ± 0.2484	0.0260 ± 0.1522	41.3579 ± 7.5031	0.3150 ± 0.6589	0.0194 ± 0.0344	0.0016 ± 0.0097	0.0201 ± 0.0288	0.0025 ± 0.0051		
2	0.0893 ± 0.2851	0.0306 ± 0.1431	41.6088 ± 7.7377	0.5303 ± 1.2320	0.0190 ± 0.0345	0.0016 ± 0.0093	0.0203 ± 0.0294	0.0025 ± 0.0052		
3	0.0991 ± 0.3130	0.0325 ± 0.1304	41.9917 ± 7.7815	0.7561 ± 1.9060	0.0183 ± 0.0340	0.0015 ± 0.0092	0.0285 ± 0.0292	0.0025 ± 0.0052		
5	0.1133 ± 0.3509	0.0341 ± 0.1357	42.2175 ± 7.6268	0.8160 ± 2.0314	0.0174 ± 0.0331	0.0014 ± 0.0091	0.0276 ± 0.0280	0.0023 ± 0.0049		
6	0.1183 ± 0.3640	0.0349 ± 0.1347	42.2363 ± 7.5509	0.8713 ± 2.3177	0.0173 ± 0.0326	0.0014 ± 0.0090	0.0274 ± 0.0273	0.0023 ± 0.0046		
7	0.1221 ± 0.3730	0.0353 ± 0.1312	42.3118 ± 7.5071	0.8525 ± 2.1070	0.0173 ± 0.0328	0.0014 ± 0.0091	0.0271 ± 0.0277	0.0023 ± 0.0048		
8	0.1253 ± 0.3809	0.0354 ± 0.1337	42.3218 ± 7.5791	0.8928 ± 2.1586	0.0173 ± 0.0328	0.0014 ± 0.0090	0.0270 ± 0.0277	0.0022 ± 0.0047		
9	0.1279 ± 0.3872	0.0357 ± 0.1333	42.2807 ± 7.5391	0.8836 ± 2.1474	0.0172 ± 0.0324	0.0014 ± 0.0090	0.0271 ± 0.0273	0.0022 ± 0.0046		
10	0.1307 ± 0.3951	0.0359 ± 0.1328	42.3349 ± 7.5600	0.8977 ± 2.1530	0.0171 ± 0.0324	0.0013 ± 0.0089	0.0269 ± 0.0271	0.0022 ± 0.0046		
25	0.1493 ± 0.4123	0.0367 ± 0.1314	42.7146 ± 7.6707	1.0479 ± 2.6367	0.1690 ± 0.0322	0.0013 ± 0.0089	0.0267 ± 0.0269	0.0022 ± 0.0045		
<i>*10 % - UNET</i>										
<i>*25 % - DDPM</i>										
1	0.1335 ± 0.2972	0.8934 ± 0.1756	33.1630 ± 8.7321	8.5411 ± 11.0359	0.0637 ± 0.0740	0.0095 ± 0.0213	0.0718 ± 0.0598	0.0101 ± 0.0150		
2	0.1138 ± 0.2551	0.0106 ± 0.1553	32.8906 ± 8.4350	10.5765 ± 11.1542	0.0622 ± 0.0634	0.0079 ± 0.0173	0.0688 ± 0.0505	0.0084 ± 0.0114		
3	0.1048 ± 0.2644	0.0181 ± 0.1404	32.6874 ± 7.3624	11.0990 ± 11.1067	0.0596 ± 0.0592	0.0071 ± 0.0164	0.0661 ± 0.0472	0.0076 ± 0.0110		
5	0.1076 ± 0.2960	0.0249 ± 0.1428	32.7316 ± 6.4813	11.4996 ± 10.8793	0.0561 ± 0.0547	0.0061 ± 0.0157	0.0626 ± 0.0438	0.0067 ± 0.0103		
6	0.1116 ± 0.3114	0.0263 ± 0.1401	32.5712 ± 6.4084	12.9372 ± 10.7957	0.0565 ± 0.0514	0.0058 ± 0.0144	0.0633 ± 0.0412	0.0066 ± 0.0093		
7	0.1138 ± 0.3206	0.0273 ± 0.1395	32.6012 ± 6.3782	12.5398 ± 10.8927	0.0565 ± 0.0516	0.0059 ± 0.0144	0.0627 ± 0.0415	0.0065 ± 0.0094		
8	0.1159 ± 0.3302	0.0282 ± 0.1385	32.4672 ± 6.0434	13.0579 ± 10.8694	0.0564 ± 0.0504	0.0057 ± 0.0142	0.0626 ± 0.0403	0.0064 ± 0.0090		
9	0.1181 ± 0.3377	0.0286 ± 0.1380	32.4664 ± 6.0179	12.7559 ± 11.0826	0.0565 ± 0.0504	0.0058 ± 0.0142	0.0625 ± 0.0405	0.0064 ± 0.0090		
10	0.1202 ± 0.3454	0.0294 ± 0.1370	32.4664 ± 5.7541	12.2732 ± 10.8858	0.0555 ± 0.0493	0.0055 ± 0.0140	0.0616 ± 0.0390	0.0061 ± 0.0087		
25	0.1380 ± 0.4033	0.0310 ± 0.1341	31.8054 ± 4.8597	15.2980 ± 10.2269	0.0574 ± 0.0464	0.0055 ± 0.0132	0.0627 ± 0.0366	0.0060 ± 0.0083		
<i>*25 % - UNET</i>										
<i>*50 % - DDPM</i>										
1	0.1751 ± 0.5127	0.0389 ± 0.1204	44.1885 ± 8.0847	0.7881 ± 1.8124	0.1437 ± 0.0304	0.0034 ± 0.0087	0.0215 ± 0.0293	0.0020 ± 0.0057		
2	0.0834 ± 0.2563	0.0291 ± 0.1470	42.6319 ± 7.4223	10.8793 ± 11.4996	0.0561 ± 0.0547	0.0061 ± 0.0157	0.0237 ± 0.0221	0.0018 ± 0.0032		
3	0.0948 ± 0.2995	0.0341 ± 0.1380	43.4696 ± 7.6262	0.3150 ± 0.5878	0.1485 ± 0.0298	0.0011 ± 0.0086	0.0219 ± 0.0203	0.0015 ± 0.0027		
3	0.1036 ± 0.3273	0.0361 ± 0.1349	37.7662 ± 7.7293	0.3899 ± 0.7684	0.1443 ± 0.0284	0.0010 ± 0.0086	0.0217 ± 0.0204	0.0015 ± 0.0028		
5	0.1185 ± 0.3683	0.0382 ± 0.1310	44.0767 ± 7.7698	0.4688 ± 0.9233	0.1385 ± 0.0277	0.0010 ± 0.0085	0.0209 ± 0.0193	0.0014 ± 0.0024		
6	0.1235 ± 0.3811	0.0387 ± 0.1302	44.2071 ± 7.8003	0.5613 ± 1.1609	0.1367 ± 0.0273	0.0009 ± 0.0084	0.0204 ± 0.0188	0.0013 ± 0.0023		
7	0.1276 ± 0.3910	0.0391 ± 0.1290	44.4142 ± 7.9367	0.5627 ± 1.1670	0.1336 ± 0.0274	0.0009 ± 0.0085	0.0202 ± 0.0192	0.0013 ± 0.0024		
8	0.1308 ± 0.3999	0.0394 ± 0.1295	44.4856 ± 7.9455	0.6255 ± 1.4310	0.1335 ± 0.0274	0.0009 ± 0.0084	0.0200 ± 0.0193	0.0013 ± 0.0024		
9	0.1332 ± 0.4058	0.0395 ± 0.1292	44.5581 ± 7.8707	0.6112 ± 1.2615	0.1335 ± 0.0272	0.0009 ± 0.0084	0.0201 ± 0.0192	0.0013 ± 0.0024		
10	0.1362 ± 0.4141	0.0396 ± 0.1284	44.5070 ± 7.8920	0.6495 ± 1.4480	0.1344 ± 0.0272	0.0009 ± 0.0084	0.0199 ± 0.0192	0.0013 ± 0.0024		
25	0.1576 ± 0.4707	0.0405 ± 0.1277	44.7708 ± 8.0579	0.7395 ± 1.7346	0.1334 ± 0.0274	0.0009 ± 0.0084	0.0197 ± 0.0195	0.0013 ± 0.0025		
<i>*50 % - UNET</i>										
<i>*75 % - DDPM</i>										
1	0.1777 ± 0.5205	0.0390 ± 0.1272	43.9338 ± 7.7514	0.8689 ± 2.0925	0.1447 ± 0.0298	0.0010 ± 0.0085	0.0207 ± 0.0221	0.0015 ± 0.0031		
2	0.0872 ± 0.2762	0.0298 ± 0.1442	42.6756 ± 7.8664	0.1663 ± 0.2836	0.1644 ± 0.0334	0.0014 ± 0.0108	0.0256 ± 0.0262	0.0024 ± 0.0057		
2	0.1000 ± 0.3174	0.0340 ± 0.1367	42.8507 ± 7.5872	0.2437 ± 0.4388	0.1514 ± 0.0312	0.0012 ± 0.0094	0.0247 ± 0.0235	0.0020 ± 0.0039		
3	0.1091 ± 0.3421	0.0355 ± 0.1339	43.0102 ± 7.5970	0.2995 ± 0.6213	0.1511 ± 0.0307	0.0012 ± 0.0093	0.0242 ± 0.0228	0.0019 ± 0.0036		
5	0.1227 ± 0.3780	0.0371 ± 0.1308	43.1691 ± 7.5262	0.3458 ± 0.6834	0.1446 ± 0.0297	0.0011 ± 0.0091	0.0233 ± 0.0214	0.0017 ± 0.0030		
6	0.1273 ± 0.3901	0.0376 ± 0.1299	43.2692 ± 7.5687	0.3841 ± 0.7598	0.1445 ± 0.0298	0.0011 ± 0.0090	0.0229 ± 0.0209	0.0017 ± 0.0029		
7	0.1312 ± 0.3992	0.0380 ± 0.1294	43.4476 ± 7.7083	0.4146 ± 0.8796	0.1444 ± 0.0298	0.0011 ± 0.0090	0.0226 ± 0.0209	0.0016 ± 0.0028		
8	0.1342 ± 0.4069	0.0381 ± 0.1290	43.4009 ± 7.6875	0.4234 ± 0.8902	0.1444 ± 0.0292	0.0011 ± 0.0089	0.0226 ± 0.0209	0.0016 ± 0.0028		
9	0.1363 ± 0.4117	0.0382 ± 0.1287	43.3663 ± 7.6432	0.4217 ± 0.8934	0.1443 ± 0.0290	0.0010 ± 0.0089	0.0227 ± 0.0207	0.0016 ± 0.0027		
10	0.1391 ± 0.4193	0.0384 ± 0.1285	43.4588 ± 7.7407	0.4187 ± 0.8686	0.1444 ± 0.0290	0.0011 ± 0.0089	0.0226 ± 0.0212	0.0017 ± 0.0029		
25	0.1576 ± 0.4686	0.0392 ± 0.1273	43.5015 ± 7.7671	0.4904 ± 1.1438	0.1446 ± 0.0295	0.0011 ± 0.0089	0.0226 ± 0.0211	0.0016 ± 0.0029		
<i>*75 % - UNET</i>										
<i>*100 % - DDPM</i>										
1	0.1770 ± 0.5227	0.0405 ± 0.1277	43.5663 ± 7.3184	0.8883 ± 1.9769	0.1644 ± 0.0273	0.0010 ± 0.0084	0.0202 ± 0.0205	0.0014 ± 0.0027		
1	0.1881 ± 0.3090	0.0397 ± 0.1523	32.9681 ± 6.3549	2.8793 ± 4.4457	0.4090 ± 0.0439	0.0043 ± 0.0114	0.0622 ± 0.0329	0.0063 ± 0.0061		
2	0.1514 ± 0.2792	0.0108 ± 0.1381	32.2393 ± 5.0271	3.9529 ± 5.1110	0.0504 ± 0.0376	0.0040 ± 0.0094	0.0637 ± 0.0258	0.0058 ± 0.0042		
3	0.1349 ± 0.2881	0.0186 ± 0.1347	32.1774 ± 3.9406	5.0175 ± 6.3329	0.0488 ± 0.0335	0.0035 ± 0.0087	0.0628 ± 0.0222	0.0054 ± 0.0037		
5	0.1294 ± 0.3211	0.0255 ± 0.1297	32.2563 ± 3.1407	5.8485 ± 6.6028	0.0470 ± 0.0292	0.0031 ± 0.0083	0.0610 ± 0.0187	0.0049 ± 0.0029		
6	0.1321 ± 0.3375	0.0271 ± 0.1282	32.1157 ± 2.8718	6.3595 ± 6.5265	0.0476 ± 0.0278	0.0030 ± 0.0081	0.0613 ± 0.0179	0.0048 ± 0.0028		
7	0.1316 ± 0.3461	0.0284 ± 0.1277	32.2447 ± 2.9615	6.5460 ± 6.6805	0.0471 ± 0.0278	0.0030 ± 0.0081	0.0603 ± 0.0173	0.0047 ± 0.0027		
8	0.1327 ± 0.3556	0.0290 ± 0.1271	32.2789 ± 2.9418	6.8895 ± 7.7171	0.0469 ± 0.0278	0.0030 ± 0.0080	0.0603 ± 0.0173	0.0047 ± 0.0027		
9	0.1334 ± 0.3621	0.0295 ± 0.1265	32.2685 ± 2.9664	6.7693 ± 6.9251	0.0469 ± 0.0277	0.0030 ± 0.0080	0.0605 ± 0.0175	0.0047 ± 0.0027		
10	0.1349 ± 0.3703	0.0300 ± 0.1266	32.2813 ± 2.8467	6.8225 ± 6.6861	0.0467 ± 0.0273	0.0029 ± 0.0079	0.0598 ± 0.0169	0.0046 ± 0.0026		
25	0.1487 ± 0.4299	0.0331 ± 0.1248	32.1439 ± 2.6118	8.7809 ± 7.7003	0.0475 ± 0.0266	0.0029 ± 0.0077	0.0597 ± 0.0152	0.0045 ± 0.0025		
<i>*100 % - UNET</i>										
1	0.1799 ± 0.5292	0.9405 ± 0.1266	44.2514 ± 7.7717	1.0933 ± 2.5707	0.0448 ± 0.0271	0.0010 ± 0.0077	0.0196 ± 0.0207	0.0014 ± 0.0026		

Tabla 7.30: Comparación de métricas para diferentes porcentajes de datos y agregaciones. Escala de datos: Linear Scale. Conjunto de datos: Full.

7.12.3. Impacto del número de parámetros de la red

Experiment	Aggregation	FFT	MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
-*665K - DDPM	1	0.2429 ± 0.3734	0.7806 ± 0.1340	27.9136 ± 4.8534	0.2910 ± 0.2881	0.0795 ± 0.0677	0.0109 ± 0.0194	0.0570 ± 0.0355	0.0048 ± 0.0055	
	2	0.2834 ± 0.4137	0.7961 ± 0.1273	28.5596 ± 4.6611	0.3037 ± 0.2969	0.0735 ± 0.0611	0.0091 ± 0.0166	0.0534 ± 0.0285	0.0039 ± 0.0038	
	3	0.3193 ± 0.4498	0.8000 ± 0.1228	28.6291 ± 4.4080	0.3076 ± 0.3022	0.0727 ± 0.0585	0.0087 ± 0.0156	0.0538 ± 0.0269	0.0038 ± 0.0037	
	5	0.3638 ± 0.4965	0.8024 ± 0.1223	28.6676 ± 4.4960	0.3293 ± 0.2991	0.0730 ± 0.0574	0.0086 ± 0.0144	0.0542 ± 0.0264	0.0039 ± 0.0034	
	6	0.3877 ± 0.5151	0.8032 ± 0.1203	28.7517 ± 4.4427	0.3309 ± 0.2911	0.0722 ± 0.0563	0.0084 ± 0.0140	0.0541 ± 0.0266	0.0038 ± 0.0035	
	7	0.4037 ± 0.5304	0.8023 ± 0.1210	28.6905 ± 4.4091	0.3415 ± 0.2962	0.0729 ± 0.0561	0.0085 ± 0.0142	0.0547 ± 0.0261	0.0039 ± 0.0035	
	8	0.4152 ± 0.5415	0.8018 ± 0.1201	28.6248 ± 4.3745	0.3495 ± 0.3047	0.0733 ± 0.0563	0.0085 ± 0.0142	0.0549 ± 0.0258	0.0039 ± 0.0035	
	9	0.4256 ± 0.5507	0.8028 ± 0.1187	28.6581 ± 4.3374	0.3509 ± 0.3022	0.0728 ± 0.0555	0.0084 ± 0.0139	0.0545 ± 0.0248	0.0038 ± 0.0032	
	10	0.4350 ± 0.5596	0.8015 ± 0.1202	28.6416 ± 4.3860	0.3582 ± 0.3142	0.0733 ± 0.0555	0.0085 ± 0.0141	0.0552 ± 0.0250	0.0039 ± 0.0033	
	25	0.5093 ± 0.6293	0.8034 ± 0.1180	28.7574 ± 4.4529	0.3739 ± 0.3224	0.0728 ± 0.0555	0.0084 ± 0.0139	0.0550 ± 0.0234	0.0038 ± 0.0030	
-*665K - UNET	1	0.6017 ± 0.7534	0.8752 ± 0.0874	32.6673 ± 3.7735	0.6290 ± 0.9717	0.0375 ± 0.0402	0.0030 ± 0.0082	0.0189 ± 0.0112	0.0007 ± 0.0008	
	1	0.2710 ± 0.4015	0.8531 ± 0.1001	31.2053 ± 3.8923	0.2433 ± 0.3454	0.0457 ± 0.0464	0.0042 ± 0.0104	0.0258 ± 0.0194	0.0013 ± 0.0020	
	2	0.3261 ± 0.4538	0.8643 ± 0.0949	31.8382 ± 3.7365	0.3188 ± 0.4736	0.0417 ± 0.0431	0.0036 ± 0.0093	0.0220 ± 0.0150	0.0009 ± 0.0011	
	3	0.3664 ± 0.4931	0.8694 ± 0.0930	32.3225 ± 3.8017	0.3379 ± 0.4456	0.0394 ± 0.0417	0.0033 ± 0.0088	0.0213 ± 0.0154	0.0009 ± 0.0012	
	5	0.4163 ± 0.5398	0.8738 ± 0.0892	32.5348 ± 3.5943	0.4011 ± 0.6262	0.0380 ± 0.0401	0.0034 ± 0.0082	0.0198 ± 0.0137	0.0007 ± 0.0009	
	6	0.4340 ± 0.5562	0.8738 ± 0.0902	32.5433 ± 3.6380	0.4529 ± 0.6732	0.0380 ± 0.0401	0.0034 ± 0.0082	0.0201 ± 0.0139	0.0007 ± 0.0010	
	7	0.4484 ± 0.5702	0.8741 ± 0.0904	32.5291 ± 3.6790	0.4582 ± 0.6704	0.0381 ± 0.0404	0.0031 ± 0.0083	0.0201 ± 0.0138	0.0007 ± 0.0010	
	8	0.4502 ± 0.5803	0.8748 ± 0.0904	32.6026 ± 3.7454	0.4677 ± 0.6685	0.0378 ± 0.0403	0.0031 ± 0.0083	0.0199 ± 0.0139	0.0007 ± 0.0010	
	9	0.4693 ± 0.5887	0.8752 ± 0.0900	32.6047 ± 3.7355	0.4961 ± 0.6840	0.0377 ± 0.0402	0.0034 ± 0.0082	0.0197 ± 0.0135	0.0007 ± 0.0009	
	10	0.4775 ± 0.5980	0.8756 ± 0.0905	32.6654 ± 3.7537	0.5130 ± 0.7264	0.0375 ± 0.0401	0.0034 ± 0.0081	0.0198 ± 0.0134	0.0007 ± 0.0009	
	25	0.5429 ± 0.6634	0.8781 ± 0.0898	32.7951 ± 3.7475	0.5785 ± 0.7379	0.0368 ± 0.0396	0.0029 ± 0.0080	0.0188 ± 0.0127	0.0007 ± 0.0009	
-*2M - UNET	1	0.6254 ± 0.7687	0.8772 ± 0.0855	32.6200 ± 3.4457	0.5666 ± 0.6532	0.0373 ± 0.0393	0.0029 ± 0.0079	0.0185 ± 0.0104	0.0006 ± 0.0006	
	1	0.2294 ± 0.3535	0.8161 ± 0.1147	28.6364 ± 3.4385	0.6243 ± 0.9667	0.0618 ± 0.0587	0.0036 ± 0.0153	0.0273 ± 0.0214	0.0015 ± 0.0030	
	2	0.2544 ± 0.3871	0.8083 ± 0.1020	28.9118 ± 3.2552	0.5845 ± 1.1974	0.0597 ± 0.0553	0.0064 ± 0.0136	0.0260 ± 0.0201	0.0014 ± 0.0025	
	3	0.2859 ± 0.4224	0.8402 ± 0.0964	29.2204 ± 3.1137	0.9092 ± 1.2961	0.0572 ± 0.0526	0.0061 ± 0.0126	0.0247 ± 0.0198	0.0013 ± 0.0026	
	5	0.3332 ± 0.4708	0.8463 ± 0.0920	29.4359 ± 2.8948	1.1581 ± 1.5084	0.0555 ± 0.0504	0.0056 ± 0.0119	0.0240 ± 0.0181	0.0011 ± 0.0021	
	6	0.3517 ± 0.4879	0.8471 ± 0.0924	29.4331 ± 2.9384	1.2683 ± 1.6182	0.0557 ± 0.0505	0.0056 ± 0.0119	0.0240 ± 0.0186	0.0012 ± 0.0023	
	7	0.3681 ± 0.5042	0.8487 ± 0.0920	29.4610 ± 2.9842	1.3616 ± 1.6841	0.0555 ± 0.0505	0.0056 ± 0.0118	0.0237 ± 0.0185	0.0011 ± 0.0023	
	8	0.3809 ± 0.5157	0.8503 ± 0.0913	29.5360 ± 2.9951	1.4174 ± 1.8374	0.0550 ± 0.0501	0.0055 ± 0.0117	0.0235 ± 0.0186	0.0011 ± 0.0023	
	9	0.3927 ± 0.5264	0.8506 ± 0.0917	29.5305 ± 2.9755	1.4282 ± 1.6894	0.0549 ± 0.0502	0.0055 ± 0.0117	0.0233 ± 0.0187	0.0011 ± 0.0023	
	10	0.4020 ± 0.5359	0.8518 ± 0.0902	29.5246 ± 2.8833	1.4885 ± 1.7439	0.0548 ± 0.0498	0.0055 ± 0.0115	0.0232 ± 0.0184	0.0011 ± 0.0022	
	25	0.4877 ± 0.6147	0.8542 ± 0.0873	29.5211 ± 2.7334	1.7448 ± 2.0164	0.0546 ± 0.0487	0.0054 ± 0.0110	0.0232 ± 0.0176	0.0011 ± 0.0020	
-*10M - UNET	1	0.6167 ± 0.7695	0.8750 ± 0.0892	32.5641 ± 3.4864	0.5008 ± 0.6643	0.0375 ± 0.0398	0.0030 ± 0.0081	0.0198 ± 0.0117	0.0007 ± 0.0007	
	1	0.2731 ± 0.4094	0.8342 ± 0.1134	29.4540 ± 3.7745	0.7585 ± 1.3446	0.0571 ± 0.0514	0.0063 ± 0.0137	0.0270 ± 0.0217	0.0015 ± 0.0025	
	2	0.3249 ± 0.4503	0.8441 ± 0.1014	29.6601 ± 3.4124	0.9527 ± 1.3542	0.0548 ± 0.0511	0.0056 ± 0.0120	0.0259 ± 0.0193	0.0012 ± 0.0019	
	3	0.3651 ± 0.4892	0.8505 ± 0.0974	29.9614 ± 3.2783	0.9820 ± 1.2538	0.0524 ± 0.0489	0.0051 ± 0.0113	0.0246 ± 0.0188	0.0012 ± 0.0019	
	5	0.4159 ± 0.5372	0.8507 ± 0.0942	30.1268 ± 3.0056	1.1021 ± 1.3575	0.0511 ± 0.0469	0.0048 ± 0.0107	0.0246 ± 0.0178	0.0011 ± 0.0018	
	6	0.4325 ± 0.5528	0.8545 ± 0.0934	30.0970 ± 3.0269	1.2117 ± 1.4682	0.0514 ± 0.0471	0.0049 ± 0.0107	0.0244 ± 0.0186	0.0011 ± 0.0020	
	7	0.4470 ± 0.5664	0.8556 ± 0.0933	30.1005 ± 3.0494	1.3062 ± 1.5086	0.0513 ± 0.0474	0.0049 ± 0.0107	0.0239 ± 0.0185	0.0011 ± 0.0020	
	8	0.4576 ± 0.5768	0.8571 ± 0.0926	30.2009 ± 3.0704	1.3133 ± 1.4948	0.0506 ± 0.0469	0.0048 ± 0.0105	0.0237 ± 0.0183	0.0011 ± 0.0019	
	9	0.4679 ± 0.5858	0.8572 ± 0.0934	30.1989 ± 3.0581	1.3740 ± 1.5798	0.0506 ± 0.0470	0.0048 ± 0.0106	0.0235 ± 0.0182	0.0011 ± 0.0019	
	10	0.4761 ± 0.5944	0.8587 ± 0.0918	30.1977 ± 2.9755	1.4043 ± 1.6573	0.0503 ± 0.0467	0.0047 ± 0.0104	0.0231 ± 0.0182	0.0010 ± 0.0019	
	25	0.5436 ± 0.6615	0.8600 ± 0.0897	30.1079 ± 2.7299	1.5743 ± 1.7004	0.0505 ± 0.0459	0.0047 ± 0.0101	0.0231 ± 0.0176	0.0010 ± 0.0018	
-*30M - UNET	1	0.6262 ± 0.7724	0.8757 ± 0.0893	32.5303 ± 3.5676	0.4996 ± 0.7116	0.0379 ± 0.0402	0.0030 ± 0.0082	0.0185 ± 0.0113	0.0006 ± 0.0007	

Tabla 7.31: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Clean 30.

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>-665K - DDPM</i>									
1	0.5919 ± 0.7340	0.5515 ± 0.1710	23.8730 ± 3.5309	1.1952 ± 3.7025	0.1128 ± 0.1017	0.0231 ± 0.0455	0.0755 ± 0.0519	0.0117 ± 0.0207	
2	0.3916 ± 0.5278	0.6168 ± 0.1679	24.8710 ± 3.4228	1.3082 ± 3.7764	0.1022 ± 0.0860	0.0178 ± 0.0320	0.0683 ± 0.0450	0.0089 ± 0.0156	
3	0.3277 ± 0.4617	0.6493 ± 0.1732	25.3670 ± 3.4432	1.5068 ± 3.8750	0.0981 ± 0.0820	0.0163 ± 0.0293	0.0664 ± 0.0450	0.0084 ± 0.0150	
5	0.2940 ± 0.4402	0.6827 ± 0.1742	25.8756 ± 3.6584	1.8311 ± 4.1383	0.0946 ± 0.0787	0.0152 ± 0.0273	0.0647 ± 0.0450	0.0079 ± 0.0145	
6	0.2921 ± 0.4466	0.6903 ± 0.1730	25.8917 ± 3.7624	2.0229 ± 4.3957	0.0957 ± 0.0798	0.0155 ± 0.0276	0.0651 ± 0.0476	0.0081 ± 0.0154	
7	0.2942 ± 0.4577	0.6983 ± 0.1747	26.6690 ± 3.8472	2.0630 ± 4.3751	0.0942 ± 0.0792	0.0152 ± 0.0274	0.0641 ± 0.0479	0.0079 ± 0.0158	
8	0.2973 ± 0.4650	0.7052 ± 0.1759	26.2594 ± 3.9154	2.0961 ± 4.4693	0.0925 ± 0.0780	0.0146 ± 0.0265	0.0635 ± 0.0472	0.0077 ± 0.0152	
9	0.3028 ± 0.4762	0.7092 ± 0.1746	26.3261 ± 3.9168	2.1281 ± 4.4486	0.0919 ± 0.0769	0.0143 ± 0.0259	0.0631 ± 0.0465	0.0075 ± 0.0149	
10	0.3095 ± 0.4899	0.7130 ± 0.1752	26.3930 ± 3.9334	2.1367 ± 4.3514	0.0914 ± 0.0767	0.0142 ± 0.0259	0.0629 ± 0.0465	0.0075 ± 0.0152	
25	0.3999 ± 0.6076	0.7286 ± 0.1747	26.5022 ± 3.9654	2.5745 ± 4.6172	0.0915 ± 0.0772	0.0143 ± 0.0269	0.0630 ± 0.0507	0.0078 ± 0.0176	
<i>-665K - UNET</i>									
1	0.8754 ± 1.0749	0.8114 ± 0.1850	31.7784 ± 4.1824	1.7807 ± 3.4117	0.0428 ± 0.0476	0.0041 ± 0.0171	0.0257 ± 0.0234	0.0018 ± 0.0035	
<i>-2M - DDPM</i>									
1	0.2707 ± 0.4282	0.7308 ± 0.4904	27.9644 ± 4.9054	1.0170 ± 3.5706	0.0761 ± 0.0799	0.0122 ± 0.0289	0.0513 ± 0.0560	0.0070 ± 0.0145	
2	0.3141 ± 0.4808	0.7573 ± 0.2104	28.6268 ± 4.5773	1.1189 ± 3.4951	0.0695 ± 0.0695	0.0097 ± 0.0227	0.0466 ± 0.0447	0.0052 ± 0.0100	
3	0.3562 ± 0.5232	0.7720 ± 0.2148	29.2705 ± 4.7941	1.1393 ± 3.4852	0.0655 ± 0.0695	0.0091 ± 0.0223	0.0434 ± 0.0463	0.0050 ± 0.0103	
5	0.4200 ± 0.5090	0.7810 ± 0.2137	29.4934 ± 4.8126	1.2624 ± 3.4397	0.0645 ± 0.0695	0.0090 ± 0.0220	0.0428 ± 0.0472	0.0050 ± 0.0102	
6	0.4445 ± 0.6154	0.7798 ± 0.2170	29.3962 ± 5.0793	1.4396 ± 3.6079	0.0674 ± 0.0734	0.0099 ± 0.0233	0.0456 ± 0.0523	0.0058 ± 0.0118	
7	0.4662 ± 0.6349	0.7801 ± 0.2104	29.4671 ± 5.0319	1.3916 ± 3.5263	0.0664 ± 0.0719	0.0098 ± 0.0226	0.0449 ± 0.0507	0.0056 ± 0.0113	
8	0.4841 ± 0.6533	0.7818 ± 0.2167	29.5699 ± 5.0655	1.3824 ± 3.5127	0.0568 ± 0.0718	0.0095 ± 0.0225	0.0447 ± 0.0505	0.0055 ± 0.0112	
9	0.5009 ± 0.6680	0.7832 ± 0.2104	29.6029 ± 0.0435	1.3818 ± 3.5026	0.0554 ± 0.0714	0.0094 ± 0.0223	0.0442 ± 0.0504	0.0055 ± 0.0109	
10	0.5149 ± 0.6815	0.7845 ± 0.2184	29.6919 ± 5.1347	1.3924 ± 3.4828	0.0562 ± 0.0723	0.0095 ± 0.0225	0.0440 ± 0.0516	0.0056 ± 0.0112	
25	0.6309 ± 0.7393	0.7912 ± 0.2184	29.9974 ± 3.5495	1.5689 ± 3.5613	0.0641 ± 0.0731	0.0095 ± 0.0222	0.0423 ± 0.0537	0.0056 ± 0.0117	
<i>-2M - UNET</i>									
<i>-10M - DDPM</i>									
1	0.8589 ± 1.0749	0.8163 ± 0.1850	31.9236 ± 4.1824	1.4917 ± 2.2396	0.0414 ± 0.0475	0.0040 ± 0.0174	0.0237 ± 0.0195	0.0016 ± 0.0026	
2	0.4356 ± 0.5702	0.8146 ± 0.3613	15.6133 ± 6.0386	14.3065 ± 9.2546	0.3865 ± 0.2801	0.2279 ± 0.2873	0.2438 ± 0.1841	0.0993 ± 0.1510	
3	0.4864 ± 0.6080	0.8213 ± 0.3175	15.9309 ± 4.4812	1.2624 ± 3.4397	0.0645 ± 0.0695	0.0090 ± 0.0220	0.0428 ± 0.0472	0.0050 ± 0.0102	
5	0.5372 ± 0.6447	0.8285 ± 0.2986	15.7458 ± 5.3592	15.1025 ± 7.9170	0.3630 ± 0.2397	0.1892 ± 0.2196	0.2252 ± 0.1647	0.0822 ± 0.1318	
6	0.5927 ± 0.6939	0.8283 ± 0.2167	15.8282 ± 5.0793	1.4527 ± 3.5127	0.0552 ± 0.0718	0.0095 ± 0.0225	0.0447 ± 0.0505	0.0055 ± 0.0112	
6	0.6138 ± 0.7074	0.8126 ± 0.2814	15.8638 ± 5.2863	15.3505 ± 7.3812	0.3563 ± 0.2301	0.1809 ± 0.2051	0.2208 ± 0.1630	0.0792 ± 0.1368	
7	0.6303 ± 0.7224	0.8120 ± 0.2764	16.0464 ± 5.3821	15.1503 ± 7.3999	0.3500 ± 0.2271	0.1741 ± 0.1976	0.2159 ± 0.1586	0.0755 ± 0.1300	
8	0.6475 ± 0.7361	0.8119 ± 0.2738	15.9639 ± 5.3071	15.3163 ± 7.2813	0.3516 ± 0.2260	0.1747 ± 0.1977	0.2167 ± 0.1584	0.0758 ± 0.1330	
9	0.6629 ± 0.7518	0.8184 ± 0.2178	15.9456 ± 5.2075	15.4633 ± 5.1841	0.3515 ± 0.2249	0.1742 ± 0.1941	0.2146 ± 0.1562	0.0749 ± 0.1262	
10	0.6720 ± 0.7602	0.8155 ± 0.2647	16.0185 ± 5.2485	15.4683 ± 6.9824	0.3475 ± 0.2182	0.1683 ± 0.1815	0.2128 ± 0.1491	0.0712 ± 0.1147	
25	0.7727 ± 0.8596	0.8196 ± 0.2403	15.8743 ± 5.1841	15.9230 ± 6.5485	0.3507 ± 0.2130	0.1683 ± 0.1782	0.2146 ± 0.1501	0.0722 ± 0.1273	
<i>-10M - UNET</i>									
<i>-30M - DDPM</i>									
1	0.8633 ± 1.0712	0.8122 ± 0.1875	31.7424 ± 4.2079	1.5385 ± 3.3014	0.0428 ± 0.0492	0.0043 ± 0.0176	0.0241 ± 0.0221	0.0017 ± 0.0031	
2	0.3948 ± 0.5702	0.8271 ± 0.2170	23.6025 ± 5.1353	4.9303 ± 6.8739	0.1369 ± 0.1389	0.0308 ± 0.0848	0.0727 ± 0.0974	0.0163 ± 0.0622	
3	0.4685 ± 0.6050	0.8622 ± 0.1750	23.5082 ± 4.4822	5.2458 ± 6.1198	0.1313 ± 0.1811	0.0312 ± 0.0618	0.0674 ± 0.0800	0.0122 ± 0.0444	
3	0.5188 ± 0.6469	0.8641 ± 0.1760	23.3289 ± 3.6396	5.5173 ± 5.8017	0.1315 ± 0.1812	0.0313 ± 0.0666	0.0678 ± 0.0860	0.0132 ± 0.0517	
5	0.5852 ± 0.7102	0.8611 ± 0.1527	23.4645 ± 3.5410	5.5483 ± 5.7116	0.1271 ± 0.1145	0.0309 ± 0.0631	0.0642 ± 0.0841	0.0123 ± 0.0482	
6	0.6097 ± 0.7335	0.8533 ± 0.1517	23.3413 ± 3.6572	6.0600 ± 5.7949	0.1308 ± 0.1218	0.0319 ± 0.0730	0.0666 ± 0.0933	0.0143 ± 0.0597	
7	0.6273 ± 0.7506	0.8621 ± 0.2648	23.4792 ± 3.6289	6.0860 ± 5.7754	0.1280 ± 0.1888	0.0315 ± 0.0704	0.0648 ± 0.0910	0.0136 ± 0.0584	
8	0.6429 ± 0.7655	0.8654 ± 0.1487	23.5073 ± 3.4967	6.1729 ± 5.6484	0.1269 ± 0.1744	0.0299 ± 0.0701	0.0642 ± 0.0907	0.0134 ± 0.0585	
9	0.6577 ± 0.7805	0.6636 ± 0.1495	23.4601 ± 3.4328	6.2263 ± 5.5893	0.1270 ± 0.1511	0.0294 ± 0.0668	0.0641 ± 0.0880	0.0129 ± 0.0550	
10	0.6687 ± 0.7910	0.6678 ± 0.1461	23.5186 ± 3.3110	6.2104 ± 5.4699	0.1250 ± 0.1109	0.0279 ± 0.0620	0.0624 ± 0.0837	0.0119 ± 0.0514	
25	0.7612 ± 0.8905	0.6615 ± 0.1487	23.3400 ± 3.2028	6.9098 ± 5.3750	0.1280 ± 0.1711	0.0301 ± 0.0740	0.0641 ± 0.0938	0.0139 ± 0.0649	
<i>-30M - UNET</i>									
1	0.8279 ± 1.0241	0.8123 ± 0.1894	31.5650 ± 4.0361	1.2869 ± 2.7785	0.0428 ± 0.0492	0.0043 ± 0.0179	0.0243 ± 0.0219	0.0017 ± 0.0030	

Tabla 7.32: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Log Scale. Conjunto de datos: Full.

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
<i>-665K - DDPM</i>									
1	0.4892 ± 0.6347	0.7706 ± 0.1251	21.8246 ± 3.5846	13.0968 ± 6.3126	0.1679 ± 0.0808	0.0347 ± 0.0308	0.1201 ± 0.0658	0.0199 ± 0.0170	
2	0.3193 ± 0.4085	0.8216 ± 0.0732	21.5153 ± 2.6210	15.4545 ± 5.7189	0.1686 ± 0.0642	0.0325 ± 0.0227	0.1201 ± 0.0462	0.0181 ± 0.0122	
3	0.2346 ± 0.3064	0.8481 ± 0.0566	21.4253 ± 1.8504	16.3310 ± 5.2867	0.1685 ± 0.0550	0.0314 ± 0.0191	0.1199 ± 0.0386	0.0172 ± 0.0102	
5	0.1670 ± 0.2279	0.8744 ± 0.0467	21.4059 ± 1.7238	17.0663 ± 4.9417	0.1671 ± 0.0513	0.0305 ± 0.0173	0.1191 ± 0.0379	0.0167 ± 0.0099	
6	0.1491 ± 0.2043	0.8759 ± 0.0455	21.4358 ± 1.7290	17.2691 ± 5.1156	0.1684 ± 0.0512	0.0310 ± 0.0174	0.1203 ± 0.0392	0.0171 ± 0.0104	
7	0.1359 ± 0.1900	0.8804 ± 0.0452	21.4697 ± 1.8028	17.2855 ± 5.0793	0.1680 ± 0.0515	0.0309 ± 0.0173	0.1198 ± 0.0392	0.0169 ± 0.0103	
8	0.1261 ± 0.1783	0.8842 ± 0.0447	21.4981 ± 1.7254	17.2501 ± 5.1307	0.1673 ± 0.0505	0.0305 ± 0.0169	0.1190 ± 0.0383	0.0167 ± 0.0100	
9	0.1184 ± 0.1698	0.8864 ± 0.0452	21.4919 ± 1.7232	17.3771 ± 5.0336	0.1675 ± 0.0503	0.0306 ± 0.0168	0.1192 ± 0.0375	0.0167 ± 0.0097	
10	0.1139 ± 0.1657	0.8888 ± 0.0433	21.4951 ± 1.6614	17.5233 ± 4.9136	0.1672 ± 0.0494	0.0304 ± 0.0164	0.1188 ± 0.0386	0.0165 ± 0.0097	
25	0.0899 ± 0.1517	0.8987 ± 0.0429	21.3389 ± 1.4959	17.9884 ± 4.7512	0.1690 ± 0.0473	0.0308 ± 0.0156	0.1202 ± 0.0376	0.0168 ± 0.0096	
<i>-665K - UNET</i>									
<i>-2M - DDPM</i>									
1	0.0915 ± 0.1468	0.9547 ± 0.0396	38.3239 ± 3.7778	0.327					

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
*665K - DDPM									
1	0.5661 ± 0.7152	0.6030 ± 0.2434	20.4070 ± 4.8482	10.6361 ± 8.9235	0.2086 ± 0.1316	0.0608 ± 0.0728	0.1764 ± 0.0862	0.0430 ± 0.0406	
2	0.3879 ± 0.5006	0.6605 ± 0.2229	19.9829 ± 3.6201	14.0006 ± 8.0052	0.2085 ± 0.1043	0.0543 ± 0.0532	0.1774 ± 0.0661	0.0391 ± 0.0283	
3	0.3168 ± 0.4363	0.6915 ± 0.2151	19.8544 ± 2.7983	16.0147 ± 6.8293	0.2067 ± 0.0912	0.0511 ± 0.0450	0.1770 ± 0.0571	0.0373 ± 0.0250	
5	0.2666 ± 0.4221	0.7254 ± 0.2064	19.9627 ± 2.3398	17.1294 ± 6.3086	0.2015 ± 0.0777	0.0466 ± 0.0350	0.1733 ± 0.0488	0.0347 ± 0.0197	
6	0.2612 ± 0.4345	0.7318 ± 0.1971	19.8347 ± 2.2594	17.6275 ± 6.2105	0.2041 ± 0.0767	0.0476 ± 0.0338	0.1751 ± 0.0494	0.0353 ± 0.0194	
7	0.2514 ± 0.4384	0.7390 ± 0.2012	19.9206 ± 2.2320	17.8518 ± 6.0482	0.2020 ± 0.0745	0.0461 ± 0.0325	0.1732 ± 0.0472	0.0344 ± 0.0183	
8	0.2467 ± 0.4490	0.7428 ± 0.2023	19.9233 ± 2.1286	18.1076 ± 5.7420	0.2014 ± 0.0719	0.0457 ± 0.0308	0.1730 ± 0.0454	0.0341 ± 0.0172	
9	0.2445 ± 0.4624	0.7448 ± 0.2039	19.8030 ± 2.0544	18.3214 ± 5.6057	0.2018 ± 0.0702	0.0457 ± 0.0298	0.1733 ± 0.0436	0.0340 ± 0.0164	
10	0.2442 ± 0.4749	0.7497 ± 0.2010	19.9482 ± 1.9948	18.4086 ± 5.6071	0.2002 ± 0.0684	0.0447 ± 0.0283	0.1715 ± 0.0422	0.0332 ± 0.0155	
25	0.2615 ± 0.5798	0.7618 ± 0.2006	19.7776 ± 1.7050	19.6634 ± 4.7752	0.2030 ± 0.0632	0.0452 ± 0.0255	0.1734 ± 0.0397	0.0335 ± 0.0150	
*665K - UNET									
1	0.4287 ± 0.8026	0.8856 ± 0.1963	39.1778 ± 6.5571	1.5730 ± 3.0386	0.0251 ± 0.0389	0.0024 ± 0.0088	0.0247 ± 0.0238	0.0018 ± 0.0032	
*2M - DDPM									
1	0.3295 ± 0.4755	0.7235 ± 0.2337	27.4745 ± 5.6341	2.1895 ± 5.3007	0.0899 ± 0.1238	0.0233 ± 0.0099	0.0576 ± 0.0982	0.0141 ± 0.0686	
2	0.3924 ± 0.5458	0.7434 ± 0.1929	27.7530 ± 4.9290	2.1065 ± 4.6604	0.0810 ± 0.0945	0.0155 ± 0.0501	0.050 ± 0.0720	0.0086 ± 0.0370	
3	0.4416 ± 0.5887	0.7447 ± 0.1991	27.7563 ± 4.7419	2.3212 ± 4.7343	0.0820 ± 0.1033	0.0174 ± 0.0617	0.0527 ± 0.0847	0.0104 ± 0.0491	
5	0.5105 ± 0.6581	0.7571 ± 0.1929	28.0033 ± 4.6011	2.5580 ± 4.9874	0.0797 ± 0.1054	0.0175 ± 0.0568	0.0517 ± 0.0890	0.0114 ± 0.0548	
6	0.5363 ± 0.6823	0.7518 ± 0.2014	27.7737 ± 4.7834	2.7485 ± 5.2903	0.0851 ± 0.1213	0.0229 ± 0.0866	0.0562 ± 0.1068	0.0154 ± 0.0781	
7	0.5565 ± 0.6994	0.7557 ± 0.1944	27.8821 ± 4.7511	2.7766 ± 5.2078	0.0829 ± 0.1151	0.0201 ± 0.0809	0.0544 ± 0.1012	0.0139 ± 0.0726	
8	0.5753 ± 0.7159	0.7578 ± 0.1997	28.0398 ± 4.8186	2.7709 ± 5.1519	0.0819 ± 0.1186	0.0206 ± 0.0870	0.0543 ± 0.1053	0.0148 ± 0.0780	
9	0.5891 ± 0.7305	0.7580 ± 0.1952	28.0027 ± 4.7152	2.8164 ± 5.1110	0.0813 ± 0.1130	0.0198 ± 0.0796	0.0535 ± 0.1001	0.0137 ± 0.0707	
10	0.6011 ± 0.7414	0.7617 ± 0.1915	28.0379 ± 4.5383	2.7869 ± 4.9919	0.0795 ± 0.1081	0.0179 ± 0.0719	0.0520 ± 0.0946	0.0124 ± 0.0644	
25	0.7067 ± 0.8495	0.7534 ± 0.2066	27.7055 ± 4.5025	3.2642 ± 5.1580	0.0847 ± 0.1266	0.0233 ± 0.0828	0.0561 ± 0.1155	0.0172 ± 0.1011	
*2M - UNET									
*10M - DDPM									
1	0.4138 ± 0.8783	0.8859 ± 0.1947	38.9404 ± 6.6994	1.1096 ± 2.0748	0.0253 ± 0.0368	0.0022 ± 0.0085	0.0244 ± 0.0218	0.0016 ± 0.0028	
2	0.1409 ± 0.3119	0.8541 ± 0.2413	34.4553 ± 6.9251	1.4663 ± 3.2507	0.0439 ± 0.0519	0.0048 ± 0.0144	0.0404 ± 0.0351	0.0040 ± 0.0066	
3	0.1572 ± 0.3442	0.8628 ± 0.2255	34.2546 ± 6.3515	1.7566 ± 2.4332	0.0433 ± 0.0475	0.0041 ± 0.0126	0.0401 ± 0.0304	0.0034 ± 0.0053	
4	0.1754 ± 0.3799	0.8675 ± 0.2109	34.3591 ± 5.9559	1.9468 ± 2.4454	0.0418 ± 0.0457	0.0038 ± 0.0121	0.0388 ± 0.0298	0.0032 ± 0.0052	
5	0.2047 ± 0.4376	0.8724 ± 0.2116	34.5540 ± 5.7589	2.2769 ± 2.3136	0.0401 ± 0.0433	0.0034 ± 0.0114	0.0375 ± 0.0281	0.0030 ± 0.0047	
6	0.2161 ± 0.4610	0.8736 ± 0.2094	34.4719 ± 5.6097	2.5128 ± 2.5569	0.0401 ± 0.0425	0.0034 ± 0.0111	0.0372 ± 0.0275	0.0029 ± 0.0045	
7	0.2251 ± 0.4762	0.8744 ± 0.2085	34.6065 ± 5.7185	2.7005 ± 3.4880	0.0397 ± 0.0426	0.0034 ± 0.0110	0.0367 ± 0.0280	0.0029 ± 0.0045	
8	0.2334 ± 0.4939	0.8750 ± 0.2075	34.6702 ± 5.8160	2.7069 ± 2.8378	0.0395 ± 0.0427	0.0034 ± 0.0110	0.0365 ± 0.0281	0.0029 ± 0.0045	
9	0.2393 ± 0.5053	0.8752 ± 0.2029	34.5397 ± 5.7435	2.7457 ± 2.8355	0.0396 ± 0.0428	0.0034 ± 0.0111	0.0362 ± 0.0276	0.0028 ± 0.0044	
10	0.2463 ± 0.5191	0.8759 ± 0.2058	34.6843 ± 5.7085	3.0248 ± 3.7456	0.0393 ± 0.0422	0.0034 ± 0.0108	0.0362 ± 0.0276	0.0028 ± 0.0044	
25	0.3002 ± 0.6248	0.8777 ± 0.2029	34.5377 ± 4.6057	3.2457 ± 4.2395	0.0396 ± 0.0416	0.0033 ± 0.0106	0.0361 ± 0.0276	0.0028 ± 0.0044	
*10M - UNET									
*30M - DDPM									
1	0.4102 ± 0.8706	0.8852 ± 0.1963	39.0324 ± 7.0028	1.3017 ± 2.3136	0.0257 ± 0.0389	0.0022 ± 0.0094	0.0249 ± 0.0238	0.0018 ± 0.0032	
2	0.2120 ± 0.3612	0.5287 ± 0.2347	17.3121 ± 9.9177	18.9187 ± 4.3748	0.3502 ± 0.2359	0.1783 ± 0.2045	0.2644 ± 0.1742	0.1079 ± 0.1234	
3	0.1829 ± 0.3544	0.5784 ± 0.2957	16.6116 ± 5.2827	20.8340 ± 7.7221	0.3345 ± 0.1907	0.1483 ± 0.1477	0.2504 ± 0.1390	0.0885 ± 0.0854	
4	0.1855 ± 0.3784	0.5885 ± 0.2693	16.1252 ± 4.1350	22.3748 ± 5.6955	0.3379 ± 0.1760	0.1452 ± 0.1396	0.2543 ± 0.1339	0.0884 ± 0.0891	
5	0.2041 ± 0.4238	0.6185 ± 0.2223	16.1810 ± 3.7853	22.9467 ± 5.3486	0.3289 ± 0.1541	0.1324 ± 0.1139	0.2468 ± 0.1178	0.0801 ± 0.0752	
6	0.2159 ± 0.4468	0.6166 ± 0.2223	16.1319 ± 3.8619	23.9972 ± 5.1109	0.3323 ± 0.1590	0.1357 ± 0.1174	0.2496 ± 0.1250	0.0832 ± 0.0831	
7	0.2239 ± 0.4640	0.6245 ± 0.2197	16.1308 ± 3.6453	23.1537 ± 5.0909	0.3292 ± 0.1511	0.1312 ± 0.1088	0.2466 ± 0.1183	0.0800 ± 0.0762	
8	0.2322 ± 0.4808	0.6255 ± 0.2167	16.0887 ± 3.5630	23.3580 ± 4.8060	0.3296 ± 0.1489	0.1308 ± 0.1073	0.2469 ± 0.1175	0.0799 ± 0.0770	
9	0.2388 ± 0.4946	0.6259 ± 0.2169	16.0340 ± 3.3961	23.3566 ± 4.5982	0.3297 ± 0.1456	0.1299 ± 0.1049	0.2467 ± 0.1145	0.0790 ± 0.0743	
10	0.2450 ± 0.5083	0.6351 ± 0.2096	16.0922 ± 3.2771	23.7378 ± 4.6187	0.3250 ± 0.1389	0.1259 ± 0.0958	0.2425 ± 0.1076	0.0753 ± 0.0662	
25	0.3013 ± 0.6118	0.6351 ± 0.1978	15.8411 ± 2.8910	24.1061 ± 4.1106	0.3306 ± 0.1304	0.1263 ± 0.0916	0.2465 ± 0.1050	0.0767 ± 0.0715	
*30M - UNET									
1	0.3940 ± 0.8466	0.8839 ± 0.1963	38.5393 ± 6.7142	1.6054 ± 2.9853	0.0264 ± 0.0390	0.0022 ± 0.0094	0.0261 ± 0.0245	0.0019 ± 0.0035	

Tabla 7.34: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Sqrt Scale. Conjunto de datos: Full.

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
*665K - DDPM									
1	0.8925 ± 1.0059	0.6336 ± 0.9911	18.1847 ± 9.1404	25.9226 ± 7.5315	0.3470 ± 0.2413	0.1786 ± 0.2189	0.3107 ± 0.2070	0.1466 ± 0.1722	
2	0.6239 ± 0.6696	0.7311 ± 0.1938	16.9185 ± 5.7332	27.7802 ± 4.9901	0.3337 ± 0.1730	0.1412 ± 0.1331	0.2978 ± 0.1491	0.1161 ± 0.1048	
3	0.4932 ± 0.5183	0.7453 ± 0.1558	15.9820 ± 3.7397	28.8847 ± 2.2404	0.3438 ± 0.1434	0.1396 ± 0.1142	0.3071 ± 0.1245	0.1146 ± 0.0888	
5	0.3415 ± 0.3683	0.7037 ± 0.1148	16.0325 ± 3.3160	29.0253 ± 2.1505	0.3358 ± 0.1246	0.1283 ± 0.0888	0.3005 ± 0.1068	0.1058 ± 0.0702	
6	0.3022 ± 0.3259	0.8045 ± 0.1000	15.9212 ± 3.1394	29.2100 ± 2.0596	0.3374 ± 0.1163	0.1274 ± 0.0813	0.3019 ± 0.1012	0.1054 ± 0.0655	
7	0.2718 ± 0.2958	0.8112 ± 0.0942	15.8481 ± 3.0762	29.1544 ± 2.0495	0.3396 ± 0.1145	0.1284 ± 0.0796	0.3032 ± 0.0998	0.1060 ± 0.0642	
8	0.2484 ± 0.2733	0.8178 ± 0.0862	15.7659 ± 2.8156	29.2240 ± 1.9621	0.3397 ± 0.1067	0.1268 ± 0.0736	0.3031 ± 0.0924	0.1045 ± 0.0590	
9	0.2291 ± 0.2539	0.8214 ± 0.0841	15.6927 ± 2.7032	29.2744 ± 1.9883	0.3415 ± 0.1043	0.1275 ± 0.0725	0.3044 ± 0.0897	0.1048 ± 0.0578	
10	0.2123 ± 0.2362	0.8273 ± 0.0790	15.6907 ± 2.5818	29.2715 ± 1.9743	0.3403 ± 0.1001	0.1258 ± 0.0696	0.3030 ± 0.0868	0.1034 ± 0.0558	
25	0.1121 ± 0.1326	0.8447 ± 0.0513	15.2746 ± 2.0025	29.4653 ± 1.8083	0.3514 ± 0.0817	0.1301 ± 0.0554	0.3128 ± 0.0729	0.1071 ± 0.0460	
*665K - UNET									
1	0.0116 ± 0.0323	0.9951 ± 0.0062	48.2020 ± 4.8651	0.0572 ± 0.0278	0.0049 ± 0.0099	0.0003 ± 0.0008	0.0173 ± 0.0077	0.0005 ± 0.0008	

Experiment	Aggregation	FFT MSE ↓	SSIM ↑	PSNR ↑	KL histogram ↓	MAE ↓	MSE ↓	Central MAE ↓	Central MSE ↓
*665K - DDPM									
1	0.0957 ± 0.2566	0.9033 ± 0.1487	29.7433 ± 7.7533	12.6399 ± 12.0177	0.0846 ± 0.0845	0.0143 ± 0.0281	0.1053 ± 0.0732	0.0180 ± 0.0244	
2	0.1036 ± 0.2980	0.9106 ± 0.1362	28.5634 ± 6.1737	15.8397 ± 11.4743	0.0863 ± 0.0661	0.0118 ± 0.0183	0.1077 ± 0.0554	0.0160 ± 0.0149	
3	0.1110 ± 0.3237	0.9138 ± 0.1334	28.2352 ± 5.1072	17.4200 ± 10.6337	0.0848 ± 0.0596	0.0108 ± 0.0167	0.1071 ± 0.0484	0.0151 ± 0.0137	
5	0.1241 ± 0.3645	0.9179 ± 0.1287	28.2034 ± 3.9777	18.7172 ± 5.7079	0.0802 ± 0.0488	0.0088 ± 0.0131	0.1084 ± 0.0375	0.0133 ± 0.0095	
6	0.1287 ± 0.3762	0.9186 ± 0.1271	28.0290 ± 3.7456	19.7201 ± 9.0772	0.0813 ± 0.0461	0.0087 ± 0.0123	0.1043 ± 0.0343	0.0132 ± 0.0084	
7	0.1325 ± 0.3858	0.9190 ± 0.1270	28.1133 ± 3.7586	19.9809 ± 9.9175	0.0807 ± 0.0462	0.0086 ± 0.0126	0.1033 ± 0.0342	0.0130 ± 0.0085	
8	0.1357 ± 0.3948	0.9193 ± 0.1269	28.1050 ± 3.5648	20.3319 ± 8.5984	0.0800 ± 0.0445	0.0084 ± 0.0122	0.1029 ± 0.0324	0.0128 ± 0.0075	
9	0.1382 ± 0.4009	0.9195 ± 0.1262	28.0912 ± 3.5168	20.2877 ± 8.2376	0.0801 ± 0.0441	0.0084 ± 0.0120	0.1029 ± 0.0324	0.0128 ± 0.0075	
10	0.1405 ± 0.4079	0.9201 ± 0.1257	28.1034 ± 3.2840	20.5497 ± 7.9681	0.0792 ± 0.0420	0.0080 ± 0.0115	0.1018 ± 0.0300	0.0124 ± 0.0070	
25	0.1601 ± 0.4596	0.9206 ± 0.1245	27.7113 ± 2.6073	22.0758 ± 6.0518	0.0815 ± 0.0381	0.0081 ± 0.0111	0.1084 ± 0.0251	0.0125 ± 0.0059	
1	0.1861 ± 0.5431	0.9408 ± 0.1270	45.1199 ± 7.9687	0.9330 ± 2.2476	0.0130 ± 0.0264	0.0009 ± 0.0072	0.0180 ± 0.0194	0.0012 ± 0.0022	
2	0.1881 ± 0.3909	0.8937 ± 0.1523	32.9961 ± 6.3549	2.8793 ± 4.4457	0.0490 ± 0.0439	0.0043 ± 0.0114	0.0622 ± 0.0329	0.0063 ± 0.0061	
3	0.1514 ± 0.2792	0.9108 ± 0.1393	32.2393 ± 5.0271	3.9529 ± 5.1110	0.0504 ± 0.0376	0.0044 ± 0.0094	0.0637 ± 0.0258	0.0058 ± 0.0042	
5	0.1349 ± 0.2881	0.9186 ± 0.1347	32.1774 ± 3.9406	5.0175 ± 6.3329	0.0488 ± 0.0355	0.0035 ± 0.0087	0.0628 ± 0.0222	0.0054 ± 0.0037	
6	0.1294 ± 0.3211	0.9255 ± 0.1297	32.2563 ± 3.1407	5.8489 ± 6.6028	0.0470 ± 0.0292	0.0031 ± 0.0083	0.0610 ± 0.0187	0.0049 ± 0.0029	
7	0.1321 ± 0.3378	0.9271 ± 0.1282	32.1157 ± 2.8718	6.3559 ± 6.5265	0.0476 ± 0.0278	0.0033 ± 0.0081	0.0613 ± 0.0179	0.0048 ± 0.0028	
7	0.1316 ± 0.3464	0.9284 ± 0.1277	32.2447 ± 2.9615	6.5469 ± 6.6805	0.0471 ± 0.0278	0.0030 ± 0.0081	0.0603 ± 0.0173	0.0047 ± 0.0027	
8	0.1327 ± 0.3556	0.9290 ± 0.1277	32.2789 ± 2.9418	6.8895 ± 7.1771	0.0469 ± 0.0278	0.0030 ± 0.0080	0.0604 ± 0.0173	0.0047 ± 0.0027	
9	0.1334 ± 0.3621	0.9295 ± 0.1265	32.2685 ± 2.9664	6.7695 ± 6.9251	0.0469 ± 0.0277	0.0030 ± 0.0080	0.0604 ± 0.0175	0.0047 ± 0.0027	
10	0.1349 ± 0.3703	0.9302 ± 0.1265	32.2813 ± 2.8467	6.8225 ± 6.8681	0.0467 ± 0.0273	0.0029 ± 0.0079	0.0550 ± 0.0169	0.0046 ± 0.0026	
25	0.1487 ± 0.4292	0.9331 ± 0.1248	32.1139 ± 2.6118	8.7809 ± 7.7003	0.0475 ± 0.0261	0.0029 ± 0.0077	0.0597 ± 0.0152	0.0045 ± 0.0025	
1	0.1799 ± 0.5292	0.9405 ± 0.1206	44.2514 ± 7.7717	1.0933 ± 2.5707	0.0148 ± 0.0271	0.0010 ± 0.0077	0.0196 ± 0.0207	0.0014 ± 0.0026	
1	0.0776 ± 0.2365	0.9234 ± 0.1560	41.1243 ± 7.0375	0.1769 ± 0.2268	0.0189 ± 0.0326	0.0014 ± 0.0102	0.0278 ± 0.0240	0.0022 ± 0.0037	
2	0.0843 ± 0.2676	0.9234 ± 0.1438	41.2403 ± 6.9827	0.3640 ± 0.7539	0.0184 ± 0.0306	0.0013 ± 0.0095	0.0275 ± 0.0218	0.0020 ± 0.0032	
3	0.0911 ± 0.2912	0.9331 ± 0.1389	41.5281 ± 6.9159	0.4577 ± 0.9551	0.0176 ± 0.0296	0.0012 ± 0.0093	0.0269 ± 0.0215	0.0019 ± 0.0031	
5	0.1048 ± 0.3293	0.9361 ± 0.1332	41.8514 ± 6.8525	0.5629 ± 1.1811	0.0169 ± 0.0283	0.0011 ± 0.0089	0.0257 ± 0.0198	0.0017 ± 0.0027	
6	0.1097 ± 0.3434	0.9367 ± 0.1320	41.9216 ± 6.8285	0.6315 ± 1.4980	0.0168 ± 0.0278	0.0011 ± 0.0087	0.0255 ± 0.0195	0.0016 ± 0.0026	
7	0.1135 ± 0.3527	0.9373 ± 0.1312	42.0760 ± 6.9290	0.7237 ± 1.7175	0.0167 ± 0.0279	0.0011 ± 0.0086	0.0252 ± 0.0198	0.0016 ± 0.0026	
8	0.1169 ± 0.3618	0.9376 ± 0.1306	42.1501 ± 6.9771	0.8135 ± 1.9668	0.0166 ± 0.0279	0.0011 ± 0.0084	0.0252 ± 0.0198	0.0016 ± 0.0026	
9	0.1191 ± 0.3675	0.9378 ± 0.1306	42.1124 ± 6.9511	0.8300 ± 1.9813	0.0166 ± 0.0277	0.0010 ± 0.0083	0.0253 ± 0.0198	0.0016 ± 0.0026	
10	0.1224 ± 0.3769	0.9381 ± 0.1295	42.1746 ± 6.9498	0.8353 ± 1.9795	0.0165 ± 0.0276	0.0010 ± 0.0082	0.0251 ± 0.0196	0.0016 ± 0.0026	
25	0.1456 ± 0.4367	0.9394 ± 0.1275	42.2867 ± 6.9853	1.0269 ± 2.4784	0.0166 ± 0.0274	0.0010 ± 0.0080	0.0248 ± 0.0196	0.0016 ± 0.0025	
1	0.1786 ± 0.5270	0.9404 ± 0.1273	44.8432 ± 8.1138	1.1385 ± 2.8133	0.0140 ± 0.0273	0.0009 ± 0.0076	0.0184 ± 0.0209	0.0014 ± 0.0027	
1	0.1543 ± 0.3168	0.8919 ± 0.1842	32.8115 ± 7.6152	5.1529 ± 6.5504	0.0592 ± 0.0611	0.0072 ± 0.0234	0.0557 ± 0.0480	0.0068 ± 0.0119	
2	0.1218 ± 0.2611	0.9079 ± 0.1660	31.7371 ± 6.4957	8.5875 ± 7.8935	0.0634 ± 0.0580	0.0074 ± 0.0170	0.0578 ± 0.0440	0.0063 ± 0.0098	
3	0.1070 ± 0.2549	0.9173 ± 0.1511	31.5919 ± 5.5064	9.6124 ± 8.1662	0.0616 ± 0.0513	0.0064 ± 0.0140	0.0564 ± 0.0398	0.0057 ± 0.0086	
5	0.1020 ± 0.2780	0.9264 ± 0.1426	31.5917 ± 4.7798	10.5558 ± 8.2246	0.0584 ± 0.0451	0.0054 ± 0.0123	0.0531 ± 0.0351	0.0049 ± 0.0074	
6	0.1049 ± 0.2935	0.9286 ± 0.1393	31.4747 ± 4.4445	10.8949 ± 7.8005	0.0579 ± 0.0419	0.0051 ± 0.0114	0.0524 ± 0.0323	0.0045 ± 0.0066	
7	0.1057 ± 0.3022	0.9298 ± 0.1385	31.5487 ± 4.5783	11.2569 ± 8.2368	0.0580 ± 0.0429	0.0052 ± 0.0116	0.0522 ± 0.0333	0.0046 ± 0.0069	
8	0.1074 ± 0.3117	0.9307 ± 0.1372	31.5782 ± 4.5362	11.7425 ± 8.5519	0.0577 ± 0.0429	0.0052 ± 0.0115	0.0526 ± 0.0333	0.0046 ± 0.0069	
9	0.1091 ± 0.3193	0.9313 ± 0.1364	31.5204 ± 4.5646	12.0273 ± 8.3913	0.0583 ± 0.0435	0.0053 ± 0.0117	0.0524 ± 0.0335	0.0046 ± 0.0069	
10	0.1113 ± 0.3281	0.9321 ± 0.1354	31.5385 ± 4.4362	11.9230 ± 8.1479	0.0577 ± 0.0425	0.0051 ± 0.0114	0.0517 ± 0.0327	0.0045 ± 0.0067	
25	0.1297 ± 0.3918	0.9352 ± 0.1321	31.1723 ± 4.1635	15.0620 ± 8.2933	0.0595 ± 0.0404	0.0052 ± 0.0107	0.0526 ± 0.0313	0.0044 ± 0.0062	
1	0.1738 ± 0.5146	0.9406 ± 0.1271	44.8373 ± 7.9973	0.9946 ± 2.3005	0.0137 ± 0.0274	0.0009 ± 0.0080	0.0196 ± 0.0213	0.0014 ± 0.0028	
*30M - UNET									
*30M - DDPM									

Tabla 7.36: Comparación de métricas para diferentes tamaños de arquitectura. Escala de datos: Linear Scale. Conjunto de datos: Full.